PROJET Cloud Healthcare Unit

Livrable 1

Référentiel de Données et Architecture

CESI
ÉCOLE D'INGÉNIEURS

FISA INFO A4 - 2026/2027

Lisa ACHOUR - Enzo CADIÈRE - Romain TOUZÉ- Thaïs VIANES

Sommaire

Sommaire **2**
Table des figures **2**
Remis en contexte **3**
Description technique **4**
a. explication couches Bronze/Silver/Gold 4
b. technologies retenues 5
c. justification des choix 6
d. Flux technologique 10
Plan de gouvernance des données **11**
a. Réglementaire 11
b. RGPD 11
c. HDS 12
d. OIDC 13
Spécifications fonctionnelles **15**
a. Sources 15
b. Nettoyage 16
c. Transformation 17
d. Gestion des erreurs 18
e. Planification des tâches 19
Plan conceptuel de données **20**
a. Tables de faits 21
b. Table de Dimensions 21
Conclusion **22**
Annexes **23**
Annexe 1 : Glossaire **23**

Table des figures

Figure 1 - Flux de données dans l'ETL **10**
Figure 2 - Architecture de la base Postgres **16**
Figure 3 - Plan conceptuel de Données **20**

Remis en contexte

Le groupe hospitalier CHU mène une transformation numérique de son système d'information. Il souhaite exploiter les grandes quantités de données produites par ses outils de gestion des soins pour mieux piloter son activité et améliorer la qualité des soins. Dans le cadre du projet *Cloud Healthcare Unit*, notre équipe doit concevoir un entrepôt de données décisionnel. Celui-ci rassemblera des données d'origines variées : l'activité médicale des patients, les informations sur les établissements, la satisfaction des usagers et les données nationales de mortalité. L'objectif est d'offrir une plateforme d'analyse unique aux praticiens comme à la direction des établissements.

Les analyses attendues portent principalement sur les taux de consultation et d'hospitalisation, que l'on pourra observer selon l'établissement, le diagnostic, le professionnel, le sexe, l'âge ou la période. La mortalité et la satisfaction par région viennent en complément.

Comme il s'agit de données de santé à caractère personnel, la solution doit respecter le Règlement Général sur la Protection des Données (RGPD), la certification Hébergeur de Données de Santé (HDS) et les recommandations de la Commission Nationale de l'Informatique et des libertés (CNIL), ce qui impose une gouvernance des données rigoureuse. Sur le plan technique, l'architecture suit le modèle Lakehouse en trois couches, avec une modélisation en étoile. Enfin, la solution doit offrir un bon rapport coût-efficacité, garantir la sécurité des données et pouvoir monter en charge.

Description technique

a. explication couches Bronze/Silver/Gold

Couche Bronze : stockage des données brutes

La couche Bronze constitue la première étape du traitement des données dans une architecture Big Data. Son objectif principal est de collecter et de conserver les données telles qu'elles sont reçues depuis les sources d'origine, sans effectuer de transformations métier importantes.

La couche Bronze peut contenir des fichiers CSV, Excel, JSON ou d'autres formats de données.

Les données sont conservées dans leur état initial, ce qui signifie que les éventuelles erreurs, valeurs manquantes, incohérences ou données dupliquées ne sont pas nécessairement corrigées à cette étape. Néanmoins, certaines données trop confidentielles et non utiles pour le suite du processus d'analyse peuvent déjà être supprimées de l'import de données afin de limiter le stockage de données personnelles.

Des métadonnées techniques peuvent également être ajoutées, notamment la date d'importation, le nom du fichier source et la date de collecte, afin de garantir la traçabilité des données.

À la fin de cette étape, les données d'origine sont disponibles dans un espace de stockage organisé. Elles pourront être utilisées pour les traitements ultérieurs, sans devoir repartir systématiquement des sources initiales.

2. Couche Silver : nettoyage et fiabilisation des données

La couche Silver a pour objectif de transformer les données brutes de la couche Bronze en données propres, cohérentes et structurées. Elle représente une étape essentielle, car la qualité des analyses dépend directement de la qualité des données utilisées.

Cette couche permet de rendre les données homogènes et exploitables, tout en identifiant les éventuelles anomalies qui pourraient fausser les résultats.

La couche Silver contient des données nettoyées et standardisées, organisées dans des tables ou des fichiers structurés. Elle peut notamment comprendre les valeurs normalisées ou les catégories harmonisées par exemple. De la même manière, les dates peuvent être converties dans un format unique, les types de données peuvent être corrigés et les valeurs manquantes peuvent être identifiées. Les doublons peuvent également être détectés et traités selon des règles clairement définies.

Enfin, cette étape doit intégrer les précautions nécessaires à la protection des données personnelles, notamment en limitant les informations identifiantes conservées lorsque

celles-ci ne sont pas nécessaires à l'étude. Ou le chiffrement et la pseudo-anonymisation des données qui ont été importées.

À la fin de cette étape, les données sont suffisamment fiables et homogènes pour être utilisées dans les analyses. La couche Silver constitue une base de travail structurée, dans laquelle les anomalies sont traitées ou documentées et les règles de nettoyage sont explicites. Elle permet ainsi de réduire les risques d'erreur dans les calculs et de garantir une meilleure cohérence des résultats obtenus dans la couche Gold.

3. Couche Gold : récupération des données et analyse

La couche Gold constitue la dernière étape de l'architecture. Son objectif est de transformer les données fiabilisées de la couche Silver en informations directement exploitables pour répondre aux besoins de l'analyse métier.

Contrairement aux couches précédentes, qui se concentrent respectivement sur la conservation et la qualité des données, la couche Gold est organisée autour des questions auxquelles le projet cherche à répondre.

La couche Gold contient des tables analytiques, des indicateurs calculés et des données agrégées.

Les traitements de cette couche reposent principalement sur des calculs, des regroupements et des agrégations à partir des données Silver.

Ils peuvent comprendre le calcul de moyennes, de pourcentages et de volumes de réponses, ainsi que la comparaison des résultats. Des tables spécifiques peuvent être créées pour faciliter l'utilisation des données dans des outils de visualisation.

À la fin de cette étape, les données sont organisées de manière à faciliter l'analyse, la visualisation et l'interprétation des résultats. La couche Gold fournit une base directement exploitable pour construire des tableaux de bord, réaliser des graphiques et rédiger les conclusions du projet.

b. technologies retenues

Les technologies retenues reposent sur des choix open source, organisées selon le paradigme Lakehouse en trois couches (Bronze / Silver / Gold), complété par un entrepôt de données dédié à la restitution.

Orchestration : Airflow est le chef d’orchestre de la chaîne. Il planifie et déclenche l’ensemble des traitements : l’ingestion par Spark, les transformations dbt et la copie des données vers l’entrepôt. Il gère également les dépendances entre les tâches, les reprises sur erreur et conserve l’historique des exécutions.

Ingestion : Spark (PySpark) se charge de l'extraction et du chargement des données. Il lit les sources hospitalières (base PostgreSQL, fichiers CSV, fichiers récupérés via File Transfer Protocol (FTP)), applique la pseudo-anonymisation et le chiffrement, puis écrit les données brutes dans la couche Bronze.

Stockage : Le stockage objet S3 héberge les trois couches du lakehouse (Bronze, Silver et Gold) sous forme de fichiers au format colonne de type Parquet.

Transformation : dbt (data build tool) définit, sous forme de modèles SQL versionnés, l'ensemble des transformations : le passage de Bronze à Silver (nettoyage, normalisation) puis de Silver à Gold (construction des tables de faits, des dimensions et des agrégations).

Moteur de requêtes : Trino exécute les requêtes SQL générées par dbt directement sur les fichiers stockés dans S3, sans qu'il soit nécessaire de les charger au préalable dans une base de données.

Entrepôt de données : ClickHouse reçoit une copie des tables de la couche Gold et sert de base analytique à faible latence pour la restitution des données.

Visualisation : Superset interroge ClickHouse pour construire les tableaux de bord destinés aux deux profils d'utilisateurs : les praticiens et la direction.

Centralisation des journaux : Elasticsearch collecte et indexe les journaux produits par l'ensemble des briques de la chaîne (Airflow, Spark, dbt, Trino, ClickHouse, Superset). Il permet de rechercher rapidement un message d'erreur, de retrouver l'historique d'un traitement et de conserver une trace des accès et des opérations sensibles.

Supervision : Grafana s'appuie sur Elasticsearch pour afficher des tableaux de bord de supervision technique : état des exécutions des pipelines, erreurs par brique, durée des traitements, volume de lignes rejetées. Il permet également de déclencher des alertes lorsqu'un traitement échoue ou qu'un seuil anormal est atteint.

c. justification des choix

Les choix ont été guidés par les exigences non fonctionnelles du sujet :

- **Coût-efficacité** : uniquement des briques open source, sans coût de licence.
- **Sécurité des données de santé** : possibilité de tout déployer sur une infrastructure maîtrisée, chez un hébergeur certifié HDS, sans dépendre d'un service SaaS hors UE.
- **Élasticité et scalabilité** : séparation du stockage (S3) et du calcul (Spark, Trino), qui peuvent évoluer indépendamment.
- **Réversibilité** : formats ouverts (Parquet, SQL standard), pas d'enfermement propriétaire.

Apache Airflow (orchestration)

Airflow est le standard du marché pour orchestrer des pipelines de données. Les workflows sont décrits en Python Directed Acyclic Graph(DAG), ce qui permet de les versionner avec Git. Il fournit nativement la gestion des dépendances entre tâches, les relances automatiques, l'alerting et une interface de suivi, ce qui répond aux exigences de traçabilité des flux du plan de gouvernance.

Alternative écartée : Apache NiFi, plus orienté routage de flux en temps réel et moins adapté à l'orchestration de traitements batch dépendants les uns des autres.

Apache Spark (ingestion)

Spark traite les données en parallèle sur plusieurs nœuds, ce qui permet d'absorber la volumétrie importante des sources (historique de plusieurs années, fichier national des décès Institut National de la Statistique et des Etudes Economiques (INSEE)). Il dispose de connecteurs pour toutes nos sources (Java Database Connectivity (JDBC) pour PostgreSQL, lecture CSV/JSON) et permet d'appliquer la pseudo-anonymisation dès l'ingestion, avant tout stockage dans le lakehouse : aucune donnée directement identifiante n'atteint la couche Bronze.

Alternative écartée : Talend, dont la version open source n'est plus maintenue, et dont la version commerciale est payante.

Stockage objet S3 (Lakehouse)

Le stockage objet est peu coûteux, quasi illimité et découplé du calcul. Le paradigme Lakehouse permet de conserver l'historique complet des données brutes (Bronze) tout en exposant des données propres et modélisées (Silver, Gold). Le protocole S3 est proposé par les hébergeurs certifiés Hébergeur de Données de Santé, ce qui garantit la conformité de l'hébergement.

Alternative écartée : Hadoop Distributed File System (HDFS) / Hive, plus lourds à administrer et aujourd'hui considérés comme des technologies vieillissantes.

dbt (transformations)

dbt permet d'écrire toutes les transformations en SQL, langage maîtrisé par toute l'équipe et par les futurs analystes. Les modèles sont versionnés, documentés automatiquement (lignage des données, dictionnaire), et dbt intègre des tests de qualité (unicité, non-nullité, intégrité référentielle des codes FINESS) qui alimentent directement le rapport de qualité du Livrable 2.

Trino (moteur de requêtes)

Trino exécute du SQL distribué directement sur les fichiers du stockage S3, sans avoir à les charger dans une base. Il sert de moteur d'exécution à dbt pour les transformations Bronze → Silver → Gold. Il peut aussi interroger plusieurs sources à la fois (fédération), ce qui facilitera l'intégration de nouvelles sources.

ClickHouse (entrepôt de données)

ClickHouse est un Système de Gestion de Base de Données (SGBD) analytique orienté colonnes, conçu pour des requêtes d'agrégation très rapides sur de gros volumes. Trino est adapté aux transformations lourdes, mais ses temps de réponse sur fichiers S3 ne conviennent pas à des tableaux de bord interactifs. Copier la couche Gold dans ClickHouse permet d'obtenir des temps de réponse de l'ordre de la seconde pour les utilisateurs finaux, et d'appliquer des stratégies de partitionnement (par date) et de tri (par établissement, région) mesurables dans le benchmark du Livrable 2.

Alternatives écartées : PostgreSQL, orienté transactionnel (lignes) et moins performant sur les agrégations massives ; BigQuery, service cloud américain soumis au Cloud Act, problématique pour des données de santé.

Apache Superset (visualisation)

Superset est open source, se connecte nativement à ClickHouse et propose des graphiques variés, dont des cartes géographiques nécessaires aux indicateurs par région (décès, satisfaction). Il gère des rôles et des droits d'accès par tableau de bord et par jeu de données, ce qui permet de distinguer les vues praticiens et direction, et peut s'intégrer à un fournisseur d'identité via OpenId Connect (OIDC) (cf. partie 4).

Alternatives écartées : Power BI, payant par utilisateur et lié à l'écosystème cloud Microsoft ; Metabase, plus simple mais moins riche en visualisations et en gestion fine des droits.

Elasticsearch (centralisation des journaux)

Notre chaîne repose sur de nombreuses briques qui produisent chacune leurs propres journaux. Sans centralisation, diagnostiquer un incident obligerait à consulter chaque outil séparément. Elasticsearch regroupe l'ensemble de ces journaux en un point unique et permet de les interroger par mots-clés, par période ou par brique, ce qui réduit fortement le temps de résolution des problèmes. Il complète la traçabilité apportée par Airflow : là où Airflow trace l'exécution des flux, Elasticsearch conserve la trace des accès aux données, des exports et des opérations sensibles, conformément à la mesure de sécurisation de l'environnement d'analyse décrite dans le plan de gouvernance. Les journaux sont configurés pour ne contenir aucune donnée de santé ni identifiant patient, afin de ne pas créer une copie non maîtrisée des données sensibles.

Alternative écartée : OpenSearch, fork d'Elasticsearch sous licence Apache 2.0 aux fonctionnalités équivalentes, qui reste une option de repli si la licence d'Elasticsearch devenait contraignante.

Grafana (supervision)

Les alertes d'Airflow se limitent à l'échec de ses propres tâches. Grafana offre une vue d'ensemble de l'état de la plateforme en s'appuyant sur les journaux centralisés dans Elasticsearch : erreurs par brique, durée des traitements, volume de lignes rejetées lors du nettoyage. Il permet de détecter des anomalies qui ne provoquent pas d'échec, comme une transformation dbt anormalement longue ou un taux de rejet inhabituel, et de prévenir l'équipe avant que les tableaux de bord métier n'affichent des données erronées ou périmées.

Nous avons fait le choix de séparer la supervision technique (Grafana), destinée à l'équipe technique, de la restitution métier (Superset), destinée aux praticiens et à la direction. Cette séparation évite d'exposer des informations d'exploitation aux utilisateurs métier et simplifie la gestion des droits d'accès.

Alternative écartée : Kibana, l'outil de visualisation natif d'Elasticsearch, moins adapté au croisement de plusieurs sources de données et dont certaines fonctionnalités d'alerte sont réservées aux offres payantes.

Limites identifiées

- La copie Gold → ClickHouse duplique les données : il faut garantir leur synchronisation (déclenchée par Airflow après chaque exécution dbt réussie).
- Le nombre de briques augmente la complexité d'exploitation ; une conteneurisation (Docker / Kubernetes) est recommandée pour le déploiement.

d. Flux technologique

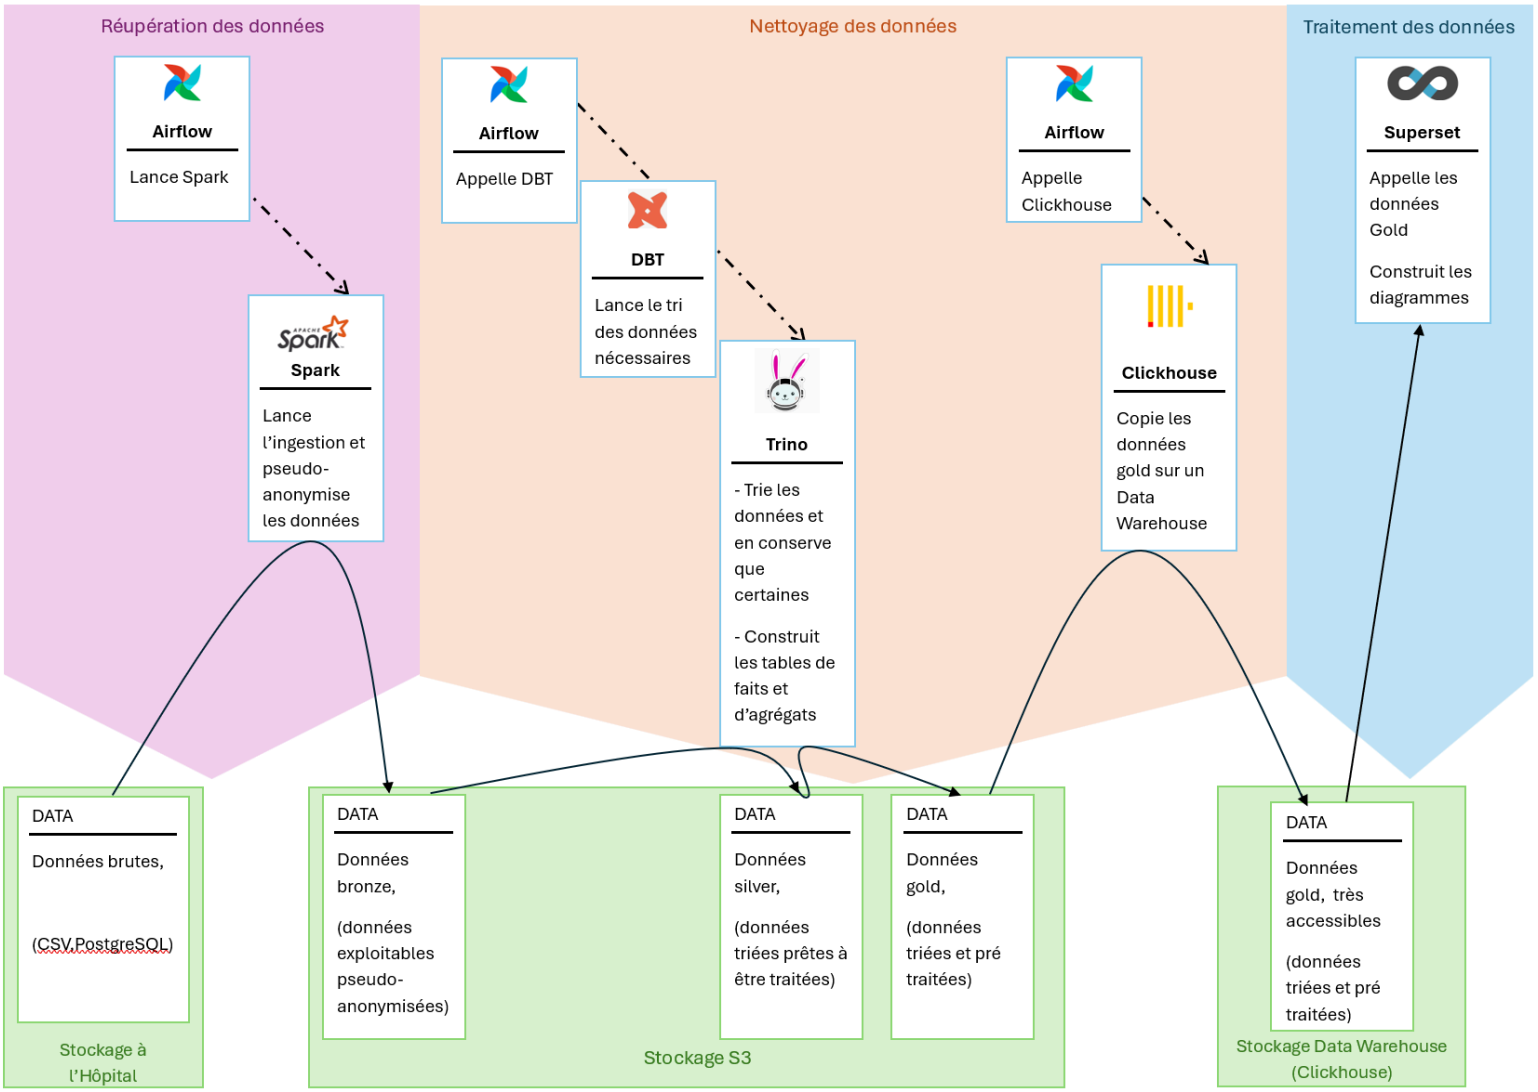


Figure 1 - Flux de données dans l'ETL

Le transit des données s'effectue en plusieurs étapes, depuis les sources hospitalières jusqu'à leur visualisation dans Superset. Dans un premier temps, Airflow déclenche Spark, qui récupère les données provenant des fichiers CSV et de PostgreSQL, applique les premiers traitements de protection, notamment la pseudo-anonymisation, puis stocke les données dans la couche Bronze du stockage S3.

Ensuite, Airflow lance dbt, qui utilise Trino pour exécuter les requêtes de nettoyage et de transformation. Les données sont ainsi normalisées, contrôlées et structurées dans la couche Silver, avant d'être transformées en tables de faits, dimensions et agrégats dans la couche Gold.
Une fois ces traitements validés, Airflow déclenche le transfert des données Gold vers ClickHouse, qui sert d'entrepôt analytique.
Enfin, Superset interroge ClickHouse pour générer les graphiques et les tableaux de bord, permettant aux utilisateurs de consulter les indicateurs statistiques issus des données hospitalières.

Plan de gouvernance des données

a. Réglementaire

Nous avons basé notre réflexion sur les documents réglementaires rédigés par l'Agence du Numérique en Santé (ANS) , l'Assurance Maladie (AM) et le code de la santé. Ainsi que sur les guides pratiques de l'ANS faisant partie des guides pratiques spécifiques de la Politique Générale de Sécurité des Systèmes d'Information de Santé (PGSSI-S). Ces documents encadrent la gestion et l'utilisation de données de santé.

Nous avons identifié les réglementations qui s'appliquent sur notre contexte et allons donc suivre les mesures suivantes

1. **Minimiser les données**
   Convenir du besoin avec les clients pour récupérer uniquement les données autorisées. Ne recevoir que les champs nécessaires aux calculs. Éviter les noms, coordonnées, numéros de sécurité sociale et identifiants directs si les statistiques peuvent être produites sans eux.

2. **Pseudo- anonymisation les données**
   Ne recevoir que les champs nécessaires aux calculs. Éviter les noms, coordonnées, numéros de sécurité sociale et identifiants directs si les statistiques peuvent être produites sans eux.

3. **Sécurisation de l'environnement d'analyse**
   Utiliser un environnement dédié, contrôlé, mis à jour et accessible uniquement aux analystes autorisés. Les changements et données analysées doivent êtres journalisés.

4. **Anonymisation des résultats**
   Avant diffusion, vérifier que les tableaux et statistiques ne permettent pas de réidentifier des patients, notamment via de très petits effectifs ou des croisements de variables rares.

b. RGPD

Finalité et minimisation.

Conformément au RGPD et aux recommandations de la CNIL, le traitement doit répondre à une finalité précise : la production de statistiques hospitalières. Seules les données nécessaires doivent être conservées dans la couche Silver. Les champs directement identifiants (nom, prénom, numéro de dossier) doivent être supprimés ou exclus lorsqu'ils ne sont pas indispensables aux analyses. Les données de santé étant des

données sensibles, leur traitement doit reposer sur une base juridique et une exception autorisant leur traitement au titre des articles 6 et 9 du RGPD.

Pseudo-anonymisation et sécurité.

Selon les recommandations de la CNIL, les identifiants doivent être remplacés par des identifiants techniques lorsque le suivi individuel reste nécessaire. Les accès doivent être limités aux personnes autorisées, avec des droits adaptés aux rôles, une journalisation des opérations et une protection des données lors de leur stockage et de leur transfert. La pseudo-anonymisation réduit les risques, mais les données restent soumises au RGPD tant qu'elles demeurent ré-identifiables.

Conservation et traçabilité.

Le RGPD et les recommandations de la CNIL imposent de définir une durée de conservation justifiée par la finalité. Le traitement doit être documenté dans un registre et les personnes concernées doivent recevoir une information appropriée. Une Analyse d'Impact relative à la Protection des Données (AIPD) doit être réalisée lorsque le traitement est susceptible d'engendrer un risque élevé, conformément aux critères définis par la CNIL.

c. HDS

Champ d'application.

La certification HDS, encadrée par le Code de la santé publique et documentée par l'ANS, concerne les prestataires qui hébergent des données de santé à caractère personnel pour le compte d'un tiers dans les conditions prévues par l'article L. 1111-8 du Code de la santé publique. Elle s'applique à l'hébergeur et aux activités d'hébergement concernées, et non directement au pipeline Silver. Le recours à un hébergeur certifié doit donc être évalué au regard du périmètre réel du système et des activités d'hébergement mises en œuvre.

Sécurité de l'hébergement.

Selon le référentiel de certification HDS publié par l'ANS, il convient de sélectionner un prestataire dont la certification couvre les activités concernées : infrastructure physique ou virtuelle, plateforme applicative, administration ou sauvegarde, selon les services utilisés. Le référentiel HDS s'appuie notamment sur ISO 27001 et comporte des exigences spécifiques à l'hébergement des données de santé.

Confidentialité et maîtrise des accès.

Le référentiel HDS de l'ANS encadre la sécurité de l'hébergement, la confidentialité des données et les responsabilités du prestataire. Ces principes sont traduits dans l'architecture par le chiffrement des données, la gestion des habilitations, la journalisation des opérations, la protection des sauvegardes et la définition de procédures de restauration et de suppression. La PGSSI-S, portée par l'ANS et présentée sur le portail G_NIUS, fournit un cadre complémentaire pour intégrer la sécurité dès la conception du système d'information de santé.

d. OIDC

Principe.

OpenID Connect (OIDC) est un protocole d'authentification standard, construit au-dessus d'OAuth 2.0. Il confie l'identification des utilisateurs à un service unique, le fournisseur d'identité. Quand un utilisateur ouvre un outil de la plateforme, il est redirigé vers ce fournisseur et s'y authentifie. L'outil reçoit ensuite un jeton signé qui contient son identité et ses rôles. Les outils ne stockent donc plus de mots de passe et l'utilisateur ne se connecte qu'une fois pour tous les outils (Single Sign-On, SSO). C'est ce mécanisme qui applique la mesure « accès limités aux personnes autorisées, avec des droits adaptés aux rôles » du plan de gouvernance.

Fournisseur d'identité retenu.

Nous avons choisi Keycloak comme fournisseur d'identité. C'est une solution open source, sans coût de licence, qui implémente OIDC nativement. Il est déployé sur la même infrastructure que le reste de la chaîne, chez l'hébergeur certifié HDS. Les identités et les journaux de connexion restent ainsi sur une infrastructure maîtrisée, sans dépendre d'un service hors UE. Keycloak gère les comptes, les groupes, les politiques de mot de passe et l'authentification à plusieurs facteurs (MFA). Il peut aussi se raccorder à un annuaire existant de l'établissement (LDAP, Active Directory).

Intégration aux briques de la plateforme.

Superset, Airflow et Grafana prennent en charge OIDC nativement et délèguent directement l'authentification à Keycloak. Les interfaces d'administration san, catalogue de données, stockage S3) sont placées derrière un proxy d'authentification (oauth2-proxy) : il vérifie la session Keycloak avant de laisser passer les requêtes. C'est le cas d'Airflow qui pilote Spark et dbt, ou de dbt qui interroge Trino. Ces échanges restent cloisonnés dans un réseau interne et utilisent des comptes de service dédiés.

Gestion des rôles et des habilitations.

Les droits sont définis une seule fois, dans Keycloak, sous forme de groupes. Le jeton OIDC transmet ces groupes à chaque outil, qui les traduit en rôles :

- Équipe technique : administration d'Airflow, de Grafana et des interfaces techniques.
- Direction : accès en lecture aux tableaux de de l'activité.
- Praticiens : accès en lecture aux tableaux de bord Superset qui concernent leur activité médicale.

Un utilisateur sans groupe n'obtient que des droits minimaux. Les rôles sont recalculés à chaque connexion. Un changement de groupe, ou la désactivation/départ, s'applique donc à tous les outils en une seule opération. Une revue périodique des habilitations peut être menée depuis cette console unique.

Sécurité et traçabilité.

Keycloak journalise les connexions, les échecs et modifications de droits. Ces journaux rejoignent la centralisation des journaux décrite plus haut et complètent la trace des accès aux données exigée par le RGPD et le référentiel HDS. La protection con brute, la durée de vie limitée des jetons et des sessions, ainsi que la MFA pour les comptes à privilèges, réduisent le risque d'usurpation de compte. En production, tous les échanges doivent être l'exige la protection des données lors de leur transfert.

Perspectives.

Pour les praticiens, Keycloak peut être fédéré avec le fournisseur d'identité de l'ANS (Pro Santé Connect (PSC)) basé sur OIDC. Les professionnels de santé pourraient alors se connecter avec leur carte professionnelle CPx (CPS, CPE, ou CPF), sans créer de compte supplémentaire, conformément aux recommandations.

Spécifications fonctionnelles

a. Sources

Sources CSV

Les sources mises à disposition nous proviennent du groupe HCG. Les données sont données dans différents formats dont des fichiers CSV et une base de données PostgreSQL.

Plusieurs des fichiers CSV concernent les établissements de santé. On peut notamment y retrouver les informations des professionnels de santé avec leurs informations personnelles, leurs professions ainsi que leurs spécificités. Un autre fichier stocke les informations des établissements tel que leurs adresses, coordonnées ainsi que leur finess. Enfin, un troisième fichier permet de connaître le mode d'exercice d'un professionnel dans un établissement.

Les sources contiennent également un fichier csv sur les avis de décès. Y sont regroupées les données personnelles des personnes avec également les informations de naissance et de décès.

Un des fichiers les plus importants pour les besoins utilisateurs est le fichier d'hospitalisation. On y retrouve les détails du séjour en hôpital des patients dans les établissements. Le fichier contient alors le diagnostic retenu et les détails de la période de séjour.

Des données de satisfaction sont également données à travers des fichiers CSV. Dans la globalité, on peut retrouver deux types de fichiers, les données et le lexique. Les fichiers de lexique servent à traduire les noms de colonnes des données en des descriptions compréhensibles. Les fichiers de données regroupent différents scores, répartis sur plusieurs années avec quelques détails comme la FINESS. Pour chacun des scores, on peut y retrouver le dénominateur, la valeur, l'intervalle de confiance haut et bas.

Sources PostgreSQL

Pour les sources PostgreSQL, nous avons à disposition les sources sur un PostgreSQL, qui concernent la gestion des actes médico-administratifs des patients. Dedans, on retrouve une base de données : sante. Dedans, nous pouvons retrouver le schéma public dans lesquelles nous avons toutes les différentes tables

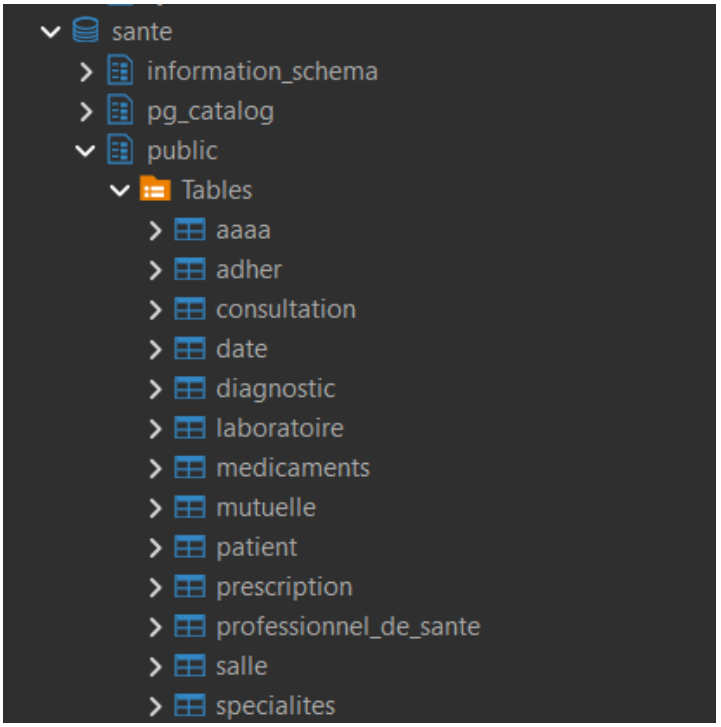


Figure 2 - Architecture de la base Postgres

Les tables qui nous sont le plus utiles sont les tables diagnostic et professionnel_de_sante et consultation, c'est principalement ces 3 tables que nous utiliserons en tant que dimensions, pour les 2 premières tables, pour filtrer sur les tables de faits hospitalisation et consultation. La table consultation sera utilisée en tant que dimension afin de récupérer les données liées aux consultations des patients. Les autres tables ne nous sont pas utiles pour notre besoin.

Étant donné que ces données proviennent d'un groupe de santé, il faut bien respecter les différentes conditions dues à cela et transformer les données.

b. Nettoyage

Les données traitées étant issues du milieu hospitalier, une attention particulière est portée à la protection des informations sensibles dès leur ingestion dans notre architecture. Avant leur stockage dans la couche Bronze, une sélection des champs présents dans les données sources est effectuée afin de ne conserver que les informations strictement nécessaires aux traitements statistiques envisagés. Les colonnes contenant des informations directement identifiantes, telles que les noms, prénoms, adresses postales, numéros de téléphone ou adresses électroniques des patients, sont exclues du périmètre de stockage lorsqu'elles ne sont pas nécessaires au projet. Les identifiants administratifs ou hospitaliers permettant de retrouver directement un patient sont également écartés, sauf lorsqu'un besoin fonctionnel justifié impose leur traitement. Dans ce cas, des mesures de protection adaptées, telles que le chiffrement ou la pseudo-anonymisation de l'identifiant, doivent être mises en place.

Une attention particulière est également accordée aux informations indirectement identifiantes, telles que les dates de naissance complètes, les dates précises d'hospitalisation, les données géographiques détaillées ou certaines combinaisons de caractéristiques médicales susceptibles de permettre une réidentification. Selon les besoins statistiques, ces informations peuvent être supprimées, généralisées ou transformées, par exemple en remplaçant une date de naissance par une tranche d'âge. Cette sélection préalable permet de limiter la quantité de données sensibles stockées dans l'environnement du projet et de réduire les risques liés à leur conservation.

La couche Bronze contient ainsi une version limitée des données sources, conservant les attributs utiles aux traitements futurs sans intégrer systématiquement l'ensemble des informations présentes dans les fichiers d'origine. Lors de l'ingestion, des contrôles techniques permettent également de vérifier la lisibilité des fichiers et d'éviter qu'un même chargement soit effectué plusieurs fois à la suite d'une relance du pipeline.

Les valeurs manquantes sont identifiées et traitées selon leur importance : les lignes peuvent être conservées, corrigées ou exclues lorsque l'information absente empêche leur exploitation. Les doublons sont également détectés à partir de clés métier ou de combinaisons de champs pertinentes, en distinguant les enregistrements réellement identiques des événements distincts.

Enfin, des contrôles de cohérence permettent de repérer les données incorrectes, comme des dates d'hospitalisation incohérentes, des valeurs numériques invalides ou des codes d'établissement inconnus. Les anomalies sont corrigées lorsque cela est possible ou rejetées si elles ne peuvent pas être exploitées de manière fiable. Le suivi des erreurs et des lignes rejetées permet ainsi d'évaluer la qualité des données avant leur transformation en couche Gold.

c. Transformation

Après les premiers contrôles de qualité, les données sont normalisées afin de garantir une structure homogène entre les différentes sources. Les noms des colonnes sont uniformisés en utilisant une convention commune, avec une casse cohérente, des noms explicites et des séparateurs homogènes. Les types de données sont également vérifiés et corrigés si nécessaire : les dates sont converties vers un type temporel adapté, les valeurs numériques sont stockées sous un type approprié et les champs textuels sont harmonisés.

Les dates font l'objet d'une attention particulière, car elles sont essentielles aux analyses temporelles des consultations et des hospitalisations. Les différents formats rencontrés sont convertis vers un format commun. Les valeurs numériques sont contrôlées afin de détecter les erreurs de conversion, les séparateurs incohérents et les valeurs situées hors des plages autorisées.

Les données issues des différentes sources sont ensuite préparées pour faciliter leur rapprochement. Ces opérations permettent d'obtenir des données cohérentes et prêtes à être utilisées dans les modèles analytiques.

Le passage de Silver à Gold consiste à organiser les données selon les besoins du projet. Cette étape repose sur la construction du modèle en constellation avec plusieurs tables de faits et de dimensions.

Les dimensions décrivent les éléments permettant de filtrer les analyses, notamment les établissements, les diagnostics, les professionnels de santé, les périodes et les localisations. Les tables de faits regroupent les informations nécessaires à l'étude des hospitalisations, des consultations, de la mortalité et de la satisfaction. Les clés de correspondance entre les tables sont définies afin de garantir la cohérence des relations et d'éviter les doubles comptages.

Des agrégations sont ensuite réalisées pour calculer les indicateurs attendus, tels que les volumes de consultations et d'hospitalisations, les durées de séjour ou les mesures de satisfaction. Les calculs doivent respecter les définitions métier, les périodes de référence et les dénominateurs adaptés à chaque indicateur.

d. Gestion des erreurs

Types d'erreurs.
Nous distinguons trois types d'erreurs :

- techniques : une source ou une brique est indisponible ;
- de format : un fichier est mal formé ou une colonne manque ;
- de qualité : doublons, valeurs manquantes, codes FINESS ou diagnostics inconnus, dates incohérentes.

Traitement.

Les tâches du pipeline s'exécutent dans un ordre strict : chacune ne démarre que si la précédente a réussi, ce qui empêche une erreur de se propager. Si une étape échoue, ClickHouse n'est pas mis à jour et les tableaux de bord continuent d'afficher la dernière version valide des données. Airflow relance automatiquement les erreurs techniques, souvent passagères, et ces relances ne créent pas de doublons. Un changement de structure d'une source bloque l'ingestion, tandis que les lignes illisibles sont écartées dans une table de rejets. Enfin, les règles de qualité sont écrites sous forme de tests dbt. Un test bloquant qui échoue arrête le pipeline, alors qu'un test non bloquant le laisse continuer et produit un avertissement.

Suivi et traçabilité.

Chaque échec déclenche une alerte vers l'équipe technique. Grafana suit en plus le taux de rejet et la durée des traitements. Les journaux sont centralisés et ne contiennent aucune donnée de santé : une erreur y est décrite par sa source, la règle non respectée et le nombre de lignes concernées.

e. Planification des tâches

Orchestration.

Airflow planifie et déclenche toute la chaîne de traitement. Le pipeline est décrit en Python dans un DAG versionné. Il s'exécute une fois par jour, la nuit, en dehors des heures d'utilisation des tableaux de bord.

Enchaînement.

Les tâches s'exécutent dans un ordre fixe, et chacune ne démarre que si la précédente a réussi :

1. récupération de la dernière version du code (jobs Spark, projet dbt) ;
2. ingestion des sources par Spark vers la couche Bronze ;
3. transformations et tests dbt vers les couches Silver puis Gold ;
4. copie de la couche Gold vers ClickHouse.

Règles d'exécution.

Une seule exécution du pipeline peut tourner à la fois, ce qui évite que deux traitements écrivent en même temps dans les mêmes tables. Si une exécution est manquée, par exemple pendant une maintenance, elle n'est pas rejouée : l'exécution suivante traite les données à jour. Un administrateur peut aussi lancer le pipeline à la main depuis l'interface Airflow, par exemple après l'arrivée d'une nouvelle source.

Suivi.

Airflow conserve l'historique de chaque exécution : date, durée, statut et journaux de chaque tâche. Ces informations alimentent les tableaux de supervision de Grafana.

Plan conceptuel de données

Pour ce plan conceptuel de données, nous nous sommes concentrés sur les tables de faits et de dimensions, laissant les agrégations de côté pour cette première modélisation. Ainsi, cela nous permet de nous concentrer sur les données à récupérer et les besoins utilisateurs demandés. Pour répondre au mieux aux demandes des utilisateurs, nous avons choisi la représentation par un schéma en constellation. Nous pouvons donc retrouver différentes tables de faits qui nous permettent de nous concentrer sur les données sur lesquelles sont basées nos statistiques. Les tables de dimensions répertorient les données servant à filtrer et affiner nos recherches et nos analyses.

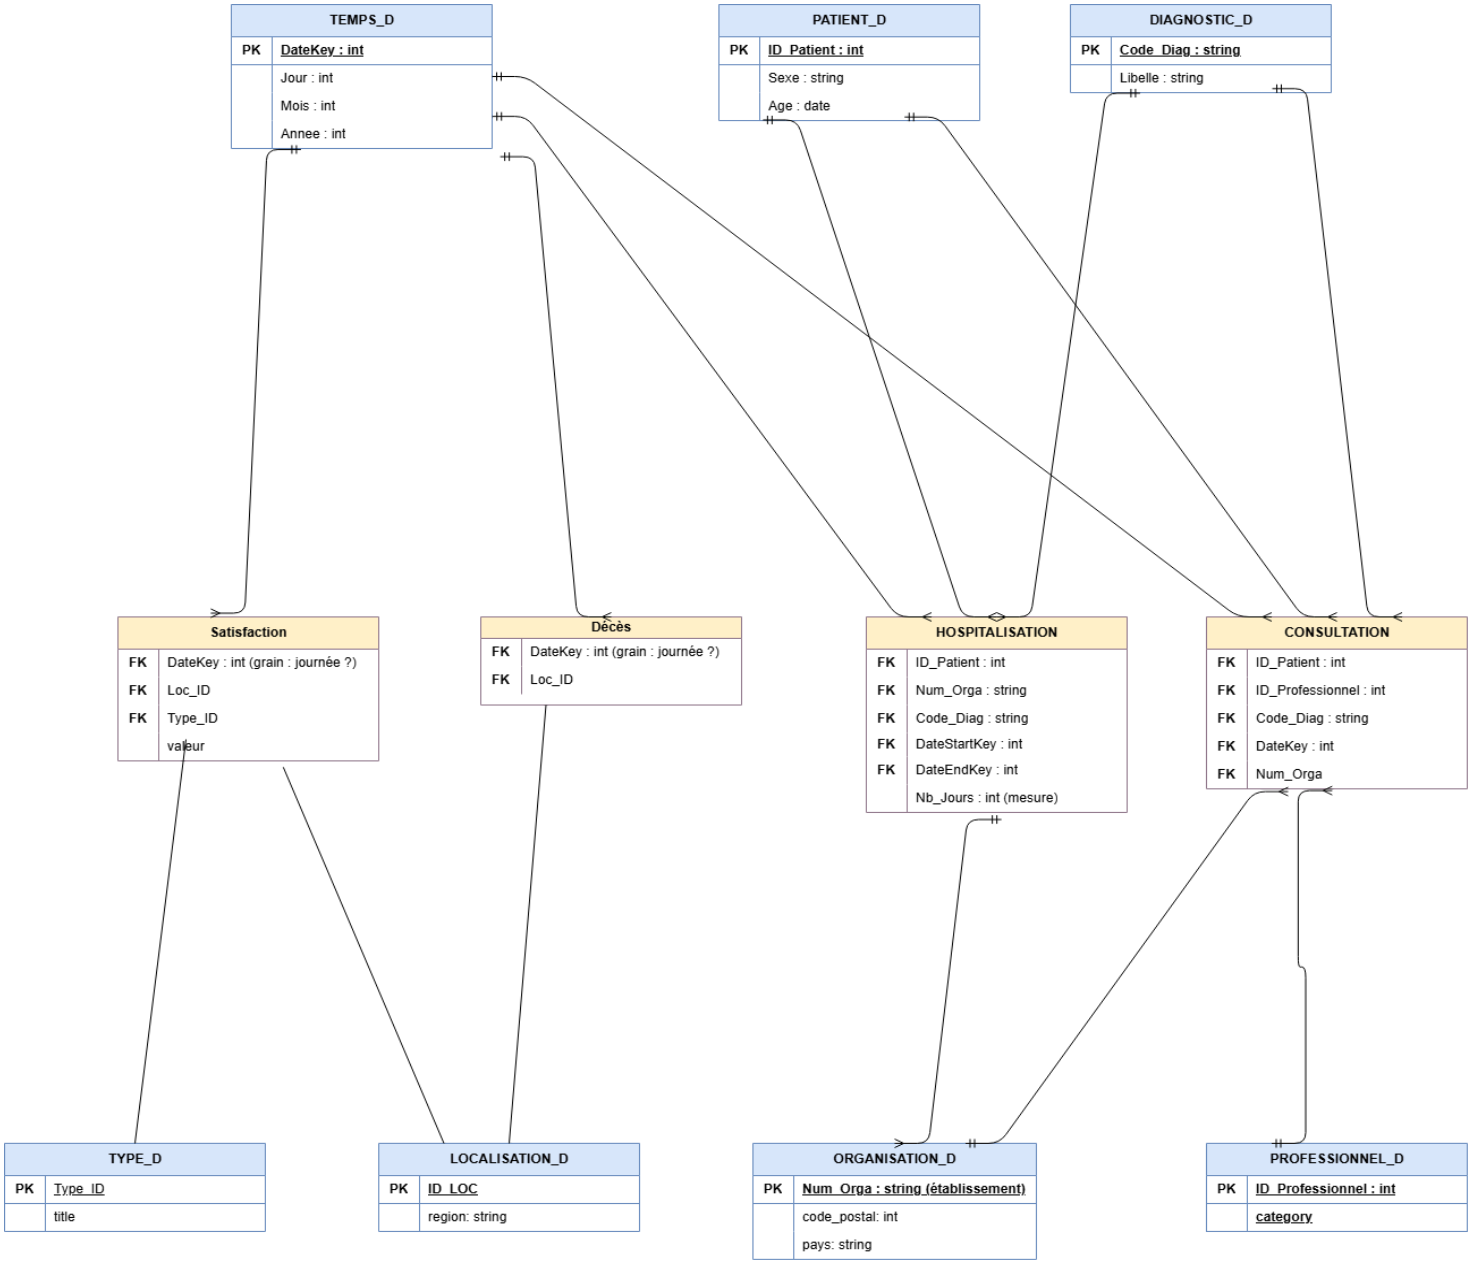


Figure 3 - Plan conceptuel de Données

a. Tables de faits

Parmi les besoins utilisateurs, nous retrouvons des analyses sur les taux d'hospitalisation et de consultation des patients, de décès et de satisfaction. Ainsi, nous avons séparé ces quatre types en des tables différentes, regroupant chacune des données spécifiques.

Hospitalisation

L'hospitalisation des patients est un fait important de ce schéma, que ce soit de par les différentes analyses portant dessus ou les nombreuses dimensions liées. Nous pouvons donc y retrouver l'identifiant du patient hospitalisé, le numéro de l'établissement concerné ainsi que le code du diagnostic établi. Toutes ces données sont des identifiants référençant les tables de dimensions associées. Afin de pouvoir filtrer sur une période, nous avons choisi de mettre une date début et une date de fin, toutes deux reliées à la dimension de temps. Cette table des faits contient également le nombre de jours hospitalisés en tant que mesure.

Consultation.

Une autre table importante de ce schéma est la consultation des patients. Celle-ci contient, semblablement à la table précédente, des identifiants du patient, du diagnostic et de l'établissement, de même que la date de la consultation. L'identifiant du professionnel de santé s'occupant de la consultation est également présent, relié à la dimension correspondante.

Décès et Satisfactions.

Les décès et les satisfactions sont des tables de faits plus petites, avec moins de dimensions. Les deux possèdent une clé de date et une clé de localisation. En revanche, la satisfaction contient l'identifiant du type de satisfaction et la mesure de la valeur.

b. Table de Dimensions

Les différentes tables de dimensions servent à filtrer les données pour affiner les analyses. On y retrouve des données utilisées par plusieurs tables de faits. Ainsi, nous pouvons retrouver la dimension de temps, utilisée par toutes les tables de faits précédemment décrites. Le découpage y est fait en jour de l'année avec le stockage du jour, du mois et de l'année. Nous retrouvons également la présence d'une dimension de diagnostique avec son libellé et de Professionnel de santé avec leurs catégorie de profession. Les patients sont représentés dans une dimension avec leurs sexe ainsi que leurs age. Les faits d'hospitalisation et de consultation des patients ont également une dimension d'établissement reprenant leurs codes postaux et leurs pays de localisation. La dimension de Localisation permet de filtrer sur une région, sans avoir à passer par un établissement. Enfin, La satisfaction a besoin d'une dimension de type pour séparer les différents scores.

Conclusion

Le projet Cloud Healthcare Unit vise à concevoir une plateforme décisionnelle permettant de centraliser et d'exploiter des données hospitalières et nationales à des fins statistiques. L'architecture retenue repose sur un modèle Lakehouse organisé en trois couches : Bronze, pour l'ingestion et le stockage des données après filtrage initial ; Silver, pour leur nettoyage, leur normalisation et leur fiabilisation ; et Gold, pour la construction des indicateurs et des données destinées à l'analyse. Les technologies sélectionnées, notamment PySpark, S3, Trino, dbt, Airflow, ClickHouse et Superset, répondent aux besoins de traitement, de stockage, d'orchestration et de restitution. La modélisation en constellation permettra de structurer les données autour de plusieurs tables de faits et de dimensions afin de répondre aux besoins des utilisateurs.

Sécurité et qualité des données

La qualité des données sera assurée par des opérations de nettoyage portant notamment sur les formats, les dates, les valeurs manquantes, les doublons et la cohérence des informations. En parallèle, les données directement identifiantes qui ne sont pas nécessaires aux analyses seront exclues dès l'ingestion, afin de limiter les informations sensibles stockées. Des mesures complémentaires de pseudo-anonymisation, de chiffrement et de contrôle des accès seront mises en place conformément aux exigences applicables du RGPD et aux règles relatives à l'hébergement des données de santé. Des contrôles automatisés permettent également de suivre la qualité des données et de détecter les anomalies avant leur exploitation.

Actions à venir

La prochaine étape consistera à mettre en œuvre l'architecture technique et à configurer les connexions entre les différents composants. Nous développerons ensuite les scripts PySpark nécessaires à l'ingestion des fichiers CSV, des données PostgreSQL et des sources FTP, en intégrant les règles de filtrage et de traçabilité. Les requêtes SQL et les modèles dbt permettront de réaliser les transformations entre les couches Bronze, Silver et Gold, puis de construire les tables de faits, les dimensions et les indicateurs attendus. L'ensemble des traitements sera orchestré avec Airflow, avant la synchronisation des données Gold vers ClickHouse et la création des tableaux de bord dans Superset. Enfin, des tests fonctionnels, des contrôles de qualité et des mesures de performance permettront de vérifier la fiabilité des résultats et le bon fonctionnement de la chaîne de traitement. Ces étapes permettront de transformer l'architecture conçue en une plateforme décisionnelle opérationnelle, évolutive et adaptée aux besoins statistiques du groupe hospitalier.

Annexes

Annexe 1 : Glossaire

AIPD	Analyse d'Impact relative à la Protection des Données
AM	Assurance Maladie
ANS	Agence du Numérique en Santé
DAG	Directed Acyclic Graph
DBT	DataBase Tool
CHU	Cloud Healthcare Unit
CNIL	Commission Nationale de l'Informatique et des Libertés
CPE	Carte de Professionnel d'Établissement
CPF	Carte de Professionnel en Formation
CPS	Carte de Professionnel de Santé
CPx	Carte de Professionnel de tous types
ELT	Extract, Load, Transform
ETL	Extract, Transform, Load
FINESS	Fichier National des Établissements Sanitaires et Sociaux
FTP	File Transfert Protocol
HCG	Health Care Group
HDFS	Hadoop Distributed File System
HDS	Hébergeur de Données de Santé
INSEE	Institut National de la Statistique et des Etudes Economiques
JDBC	Java Database Connectivity
LDAP	Lightweight Directory Access Protocol
MFA	Multi-Factor Authentication
PSC	Pro Santé Connect
OIDC	OpenId Connect

PGSSI-S	Politique Générale de Sécurité des Systèmes d'Information de Santé
RGPD	Règlement Général de la Protection des Données
SGBD	Système de Gestion de Base de Donnée
SSO	Single Sign-On
UE	Union Européenne