PROJET Cloud Healthcare Unit

Livrable 3

Présentation des Résultats

CESI
ÉCOLE D'INGÉNIEURS

FISA INFO A4 - 2026/2027

Lisa ACHOUR - Enzo CADIÈRE - Romain TOUZÉ- Thaïs VIANES

Sommaire

Sommaire **2**
Table des figures **3**
Remise en contexte **4**
Description technique **5**
a. explication couches Bronze/Silver/Gold 5
b. technologies retenues 5
c. Flux technologique 6
Plan de gouvernance des données **8**
a. Réglementaire 8
b. RGPD 8
c. HDS 8
d. OIDC 9
Spécifications fonctionnelles **11**
a. Sources 11
b. Nettoyage 11
c. Transformation 11
d. Gestion des erreurs 12
e. Planification des tâches 12
Plan conceptuel de données **13**
a. Tables de faits 13
b. Table de Dimensions 14
Script d'ingestion de données **15**
Scripts de création des données **16**
Scripts de chargement des données **16**
Rapport de qualité de données **18**
Logs et traces **18**
Benchmark et performances **20**
Présentation des tableaux de bord **22**
Analyse des résultats obtenus **26**
Gestion des erreurs, supervision et observabilité **28**
a. Gestion des erreurs dans le pipeline 28
b. Supervision de la plateforme 28
c. Diagnostic d'un incident 28
Évolutions à venir **30**
a. Qualité et enrichissement des données 30
b. Performances et montée en charge 30
c. Sécurité et gouvernance 30
d. Tableaux de bord 31
Conclusion **32**
Annexes **33**
Annexe 1 : Glossaire **33**

Table des figures

Figure 1 - Flux de données dans l'ETL **6**
Figure 2 - Plan conceptuel de Données **13**
Figure 3 - Lecture des fichiers CSV depuis S3. **15**
Figure 4 - Exclusion des colonnes sensibles. **15**
Figure 5 - Consultations par établissement (top 15) **22**
Figure 6 - Part des patients ayant consulté, par diagnostic (top 15) **23**
Figure 7 - Professionnels les plus sollicités (top 15) **23**
Figure 8 - Consultations par département (top 15) **23**
Figure 9 - Part des hospitalisations par diagnostic (top 15) **24**
Figure 10 - Taux d'hospitalisation par tranche d'âge **24**
Figure 11 - Taux d'hospitalisation par sexe **24**
Figure 12 - Décès par région (2019) **25**
Figure 13 - Satisfaction globale par région (2020) **25**

Remise en contexte

Le groupe hospitalier CHU mène une transformation numérique de son système d'information. Il souhaite exploiter les grandes quantités de données produites par ses outils de gestion des soins pour mieux piloter son activité et améliorer la qualité des soins. Dans le cadre du projet *Cloud Healthcare Unit*, notre équipe doit concevoir un entrepôt de données décisionnel. Celui-ci rassemblera des données d'origines variées : l'activité médicale des patients, les informations sur les établissements, la satisfaction des usagers et les données nationales de mortalité. L'objectif est d'offrir une plateforme d'analyse unique aux praticiens comme à la direction des établissements.

Les analyses attendues portent principalement sur les taux de consultation et d'hospitalisation, que l'on pourra observer selon l'établissement, le diagnostic, le professionnel, le sexe, l'âge ou la période. La mortalité et la satisfaction par région viennent en complément.

Comme il s'agit de données de santé à caractère personnel, la solution doit respecter le Règlement Général sur la Protection des Données (RGPD), la certification Hébergeur de Données de Santé (HDS) et les recommandations de la Commission Nationale de l'Informatique et des libertés (CNIL), ce qui impose une gouvernance des données rigoureuse. Sur le plan technique, l'architecture suit le modèle Lakehouse en trois couches, avec une modélisation en étoile. Enfin, la solution doit offrir un bon rapport coût-efficacité, garantir la sécurité des données et pouvoir monter en charge.

Description technique

a. explication couches Bronze/Silver/Gold

1. Couche Bronze : stockage des données brutes

La couche Bronze constitue la première étape du traitement des données. Elle permet de collecter et de stocker les données provenant des sources d'origine, sans transformations importantes.

Les données sont conservées dans leur format initial (CSV, Excel, JSON), sans corriger les éventuelles erreurs, doublons ou valeurs manquantes. Certaines données personnelles non nécessaires peuvent toutefois être supprimées dès l'importation.

Des métadonnées peuvent également être ajoutées pour assurer la traçabilité des données.

À la fin de cette étape, les données brutes sont stockées et prêtes à être traitées.

2. Couche Silver : nettoyage et fiabilisation des données

La couche Silver permet de transformer les données brutes en données propres, cohérentes et structurées.

Cette étape consiste à corriger les formats, harmoniser les catégories, traiter les doublons et identifier les valeurs manquantes ou les anomalies.

Des mesures de protection des données personnelles peuvent également être appliquées, comme le chiffrement ou la pseudo-anonymisation.

À la fin de cette étape, les données sont fiabilisées et suffisamment propres pour être utilisées dans les analyses.

3. Couche Gold : récupération des données et analyse

La couche Gold constitue la dernière étape de l'architecture. Elle permet de transformer les données nettoyées en informations directement exploitables pour répondre aux besoins du projet.

Elle contient des tables analytiques et des indicateurs calculés à partir de regroupements, de moyennes, de pourcentages ou de comparaisons.

À la fin de cette étape, les données sont prêtes à être utilisées pour réaliser des graphiques, construire des tableaux de bord et interpréter les résultats.

b. technologies retenues

Pour rappel, l’architecture retenue au livrable 1 repose sur une stack entièrement open source, organisée en Lakehouse (Bronze / Silver / Gold) sur un stockage objet S3 au

format Parquet. Airflow orchestre la chaîne. Spark ingère les sources et applique la pseudo-anonymisation, puis dbt, exécuté par Trino, transforme les données jusqu'à la couche Gold. Cette couche est copiée dans ClickHouse pour être restituée sous Superset. Grafana assurent la centralisation des journaux et la supervision. Ces choix répondent aux exigences de coût, d'hébergement HDS, de scalabilité et de réversibilité du sujet.

c. Flux technologique

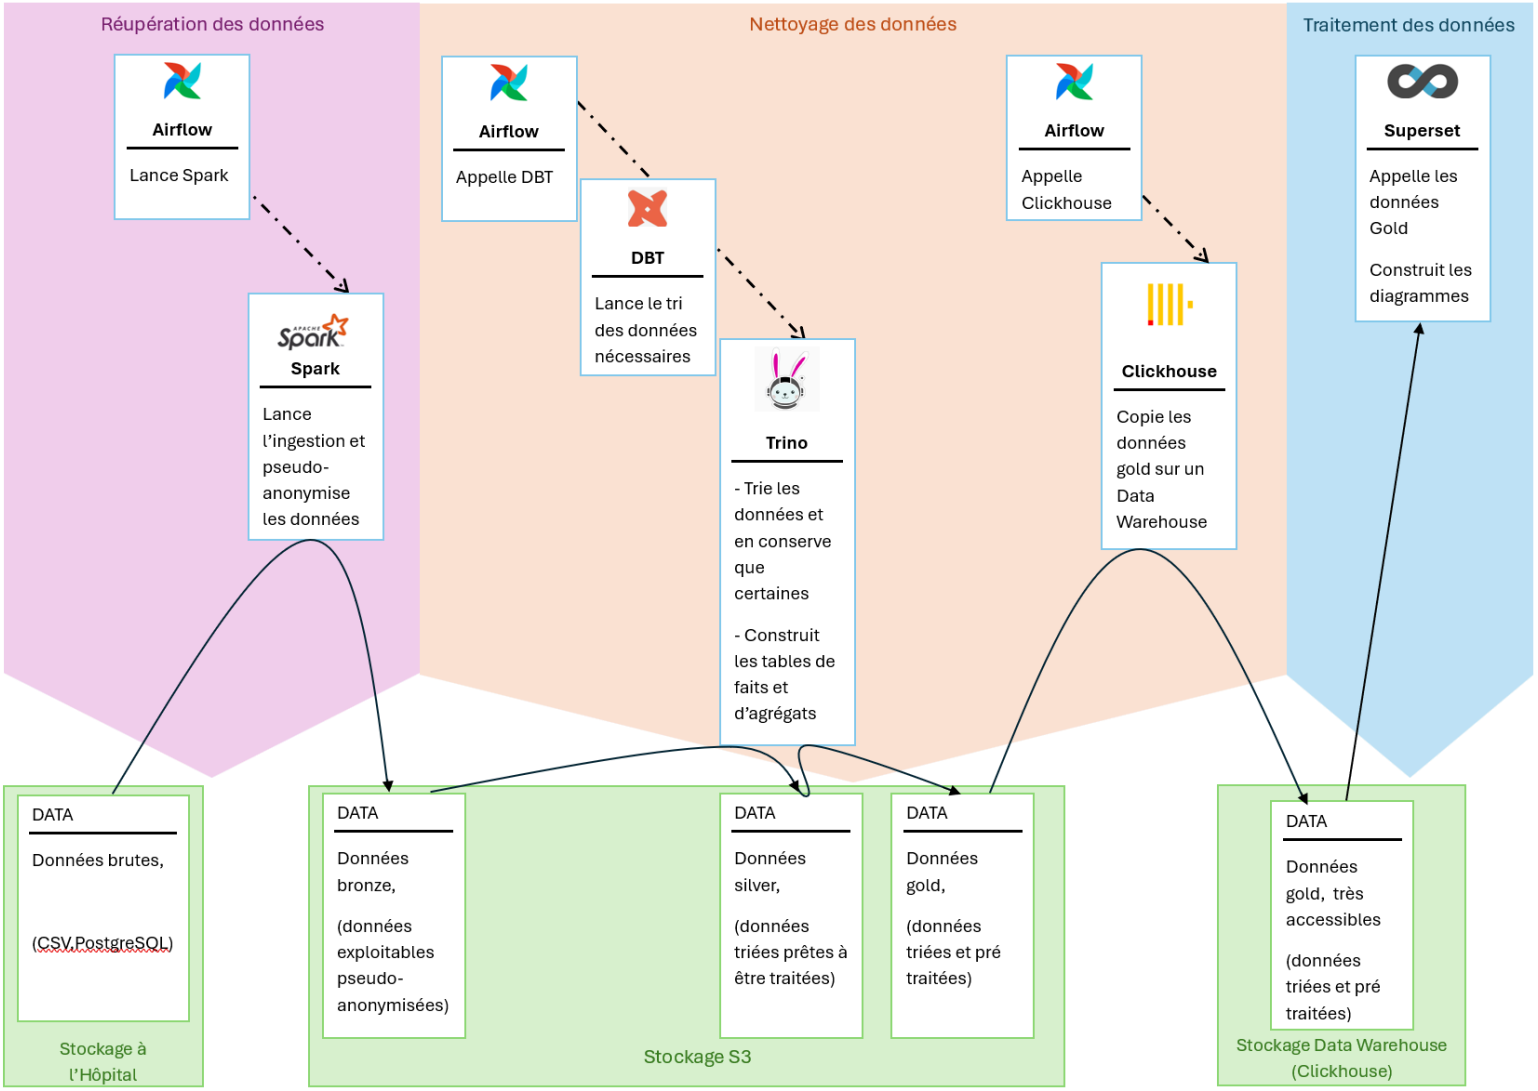


Figure 1 - Flux de données dans l'ETL

Le transit des données s'effectue en plusieurs étapes, des sources hospitalières jusqu'à leur visualisation dans Superset.

Dans un premier temps, Airflow déclenche Spark, qui récupère les données CSV et PostgreSQL, applique les premiers traitements de protection, comme la pseudo-anonymisation, puis les stocke dans la couche Bronze sur S3.

Ensuite, Airflow lance dbt, qui utilise Trino pour nettoyer, normaliser et structurer les données dans la couche Silver, avant de créer les tables analytiques et les agrégats dans la couche Gold.

Une fois les traitements terminés, les données Gold sont transférées vers ClickHouse, qui sert d'entrepôt analytique.

Enfin, Superset interroge ClickHouse pour générer des graphiques et des tableaux de bord permettant de visualiser les indicateurs statistiques issus des données hospitalières.

Plan de gouvernance des données

a. Réglementaire

Pour rappel, notre plan de gouvernance s'appuie sur les textes de l'ANS (dont les guides de la PGSSI-S), de l'Assurance Maladie (AM) et du Code de la santé publique. Il retient quatre mesures.

La première est de minimiser les données, en ne collectant que les champs nécessaires aux calculs.

La deuxième est de pseudo-anonymiser les données dès l'ingestion. La troisième est de sécuriser l'environnement d'analyse, qui doit être dédié, à accès restreint et journalisé. La dernière est d'anonymiser les résultats avant diffusion, pour éviter toute réidentification par les petits effectifs ou par le croisement de variables rares.

b. RGPD

1. Finalité et minimisation

Conformément au RGPD et aux recommandations de la CNIL, les données doivent être utilisées uniquement pour produire des statistiques hospitalières. Seules les informations nécessaires doivent être conservées, en supprimant les données directement identifiantes lorsqu'elles ne sont pas indispensables. Le traitement des données de santé doit également reposer sur une base juridique adaptée.

2. Pseudo-anonymisation et sécurité

Les identifiants personnels doivent être remplacés par des identifiants techniques lorsque le suivi individuel est nécessaire. L'accès aux données doit être limité aux personnes autorisées, avec une gestion des droits et une journalisation des opérations. Les données doivent également être protégées lors de leur stockage et de leur transfert.

3. Conservation et traçabilité

Une durée de conservation adaptée doit être définie selon la finalité du traitement. Les opérations doivent être documentées dans un registre et les personnes concernées doivent être informées. Enfin, une AIPD doit être réalisée lorsque le traitement présente un risque élevé pour les droits et libertés des personnes.

c. HDS

Pour rappel, la certification HDS (article L. 1111-8 du Code de la santé publique) s'applique à l'hébergeur des données de santé, et non directement à notre pipeline. Nous

devons donc choisir un prestataire certifié sur les activités que nous utilisons : infrastructure, plateforme, administration ou sauvegarde.

Le référentiel HDS de l'ANS, qui s'appuie sur ISO 27001, est complété par la PGSSI-S. Dans notre architecture, ces exigences se traduisent par le chiffrement des données, la gestion des habilitations, la journalisation, ainsi que des sauvegardes protégées avec des procédures de restauration et de suppression.

d. OIDC

1. Principe

OpenID Connect (OIDC) est un protocole d'authentification basé sur OAuth 2.0. Il permet de centraliser l'identification des utilisateurs grâce à un fournisseur d'identité. L'utilisateur se connecte une seule fois pour accéder aux différents outils (SSO), sans avoir à stocker plusieurs mots de passe.

2. Fournisseur d'identité retenu

Keycloak a été choisi comme fournisseur d'identité. Cette solution open source permet de gérer les comptes, les groupes, les mots de passe et l'authentification multifacteur (MFA). Hébergé sur une infrastructure certifiée HDS, il permet de conserver la maîtrise des identités et des journaux de connexion.

3. Intégration aux outils

Superset, Airflow et Grafana utilisent directement OIDC pour déléguer leur authentification à Keycloak. Les autres interfaces sont protégées par un proxy d'authentification qui vérifie les sessions avant d'autoriser l'accès.

4. Gestion des rôles et des habilitations

Les droits sont centralisés dans Keycloak sous forme de groupes, puis transmis aux différents outils :

- Équipe technique : administration des outils techniques.
- Direction : accès en lecture aux tableaux de bord d'activité.
- Praticiens : accès aux tableaux de bord concernant leur activité médicale.

Les droits sont mis à jour automatiquement lors des connexions. La désactivation d'un compte ou un changement de groupe s'applique ainsi à l'ensemble des outils.

5. Sécurité et traçabilité

Keycloak conserve les journaux de connexion, les échecs d'authentification et les modifications de droits. La MFA, la limitation de la durée des sessions et la protection contre

les tentatives de connexion réduisent les risques d'usurpation de compte. Les échanges sont également chiffrés pour protéger les données.

6. Perspectives

Keycloak pourra être relié à Pro Santé Connect (PSC), le fournisseur d'identité de l'ANS. Les professionnels de santé pourront ainsi se connecter avec leur carte professionnelle (CPS, CPE ou CPF), sans avoir besoin de créer un compte supplémentaire.

Spécifications fonctionnelles

a. Sources

Les données fournies par le groupe HCG se répartissent entre des fichiers CSV et une base PostgreSQL. Les fichiers CSV portent sur les professionnels et les établissements de santé (avec leur FINESS), les décès, les hospitalisations (séjours et diagnostics) et la satisfaction (scores par établissement et par année, accompagnés d'un lexique). La base PostgreSQL sante regroupe les actes médico-administratifs. Nous en exploitons principalement les tables diagnostic, professionnel_de_sante et consultation. Comme ces données sont des données de santé, elles doivent être transformées dans le respect des règles de gouvernance présentées plus haut.

b. Nettoyage

Les données hospitalières étant sensibles, une sélection des champs est réalisée dès leur ingestion afin de ne conserver que les informations nécessaires aux analyses statistiques. Les données directement identifiantes (noms, prénoms, adresses, téléphones, etc.) sont supprimées lorsqu'elles ne sont pas indispensables. Les identifiants hospitaliers sont également exclus ou protégés par chiffrement et pseudo-anonymisation si leur utilisation est nécessaire.

Les données indirectement identifiantes, comme les dates de naissance ou d'hospitalisation, peuvent être supprimées ou généralisées, par exemple en utilisant des tranches d'âge. Cette sélection permet de limiter les risques de réidentification et de réduire la quantité de données sensibles stockées.

La couche Bronze contient ainsi uniquement les données utiles aux traitements futurs. Des contrôles sont également réalisés lors de l'importation pour vérifier la lisibilité des fichiers et éviter les chargements en double.

Enfin, des contrôles de qualité permettent d'identifier les valeurs manquantes, les doublons et les incohérences. Les données incorrectes sont corrigées ou rejetées selon leur importance. Le suivi des anomalies permet ainsi de garantir une meilleure fiabilité des données avant leur transformation dans les couches suivantes.

c. Transformation

1. Normalisation des données (Silver)

Après les premiers contrôles, les données sont normalisées afin de garantir une structure homogène entre les différentes sources. Les noms des colonnes sont uniformisés et les types de données corrigés si nécessaire.

Les dates sont converties dans un format commun et les valeurs numériques sont contrôlées pour détecter les erreurs ou incohérences.

Les données sont ensuite préparées pour faciliter leur rapprochement et garantir leur cohérence avant les analyses.

2. Modélisation et agrégation des données (Gold)

Le passage de Silver à Gold consiste à organiser les données selon les besoins du projet, grâce à un modèle en constellation composé de tables de faits et de dimensions.

Les dimensions décrivent les établissements, diagnostics, professionnels de santé, périodes et localisations. Les tables de faits regroupent les informations liées aux hospitalisations, consultations, mortalité et satisfaction.

Enfin, des agrégations sont réalisées pour calculer les indicateurs attendus, comme les volumes de consultations, les durées de séjour ou les taux de satisfaction, tout en respectant les règles de calcul définies.

d. Gestion des erreurs

Nous distinguons trois types d'erreurs : techniques (une brique indisponible), de format (un fichier mal formé) et de qualité (doublons, valeurs manquantes, codes inconnus). Les tâches du pipeline s'enchaînent dans un ordre strict. En cas d'échec, ClickHouse n'est pas mis à jour et les tableaux de bord conservent la dernière version valide des données.

Les erreurs techniques font échouer la tâche concernée, qui est relancée à la main depuis Airflow. Les règles de qualité sont écrites sous forme de tests dbt, bloquants ou non selon leur gravité. Grafana suit l'état et la durée des tâches, et les journaux ne contiennent aucune donnée de santé.

e. Planification des tâches

Airflow orchestre la chaîne à l'aide d'un DAG Python versionné, exécuté chaque nuit en dehors des heures d'utilisation. Les tâches s'enchaînent dans un ordre fixe : récupération du code, ingestion Spark vers Bronze, transformations et tests dbt vers Silver puis Gold, et enfin copie vers ClickHouse. Une seule exécution peut tourner à la fois. Une exécution manquée n'est pas rejouée, et un administrateur peut lancer le pipeline à la main. Airflow conserve l'historique de chaque exécution, qui alimente la supervision dans Grafana.

Plan conceptuel de données

Pour ce plan conceptuel de données, nous avons choisi de nous concentrer sur les tables de faits et de dimensions, sans intégrer les agrégations à cette première modélisation.

Nous avons opté pour un schéma en constellation afin de répondre aux besoins des utilisateurs. Les tables de faits regroupent les données sur lesquelles reposent les statistiques, tandis que les tables de dimensions permettent de filtrer et d'affiner les analyses selon différents critères.

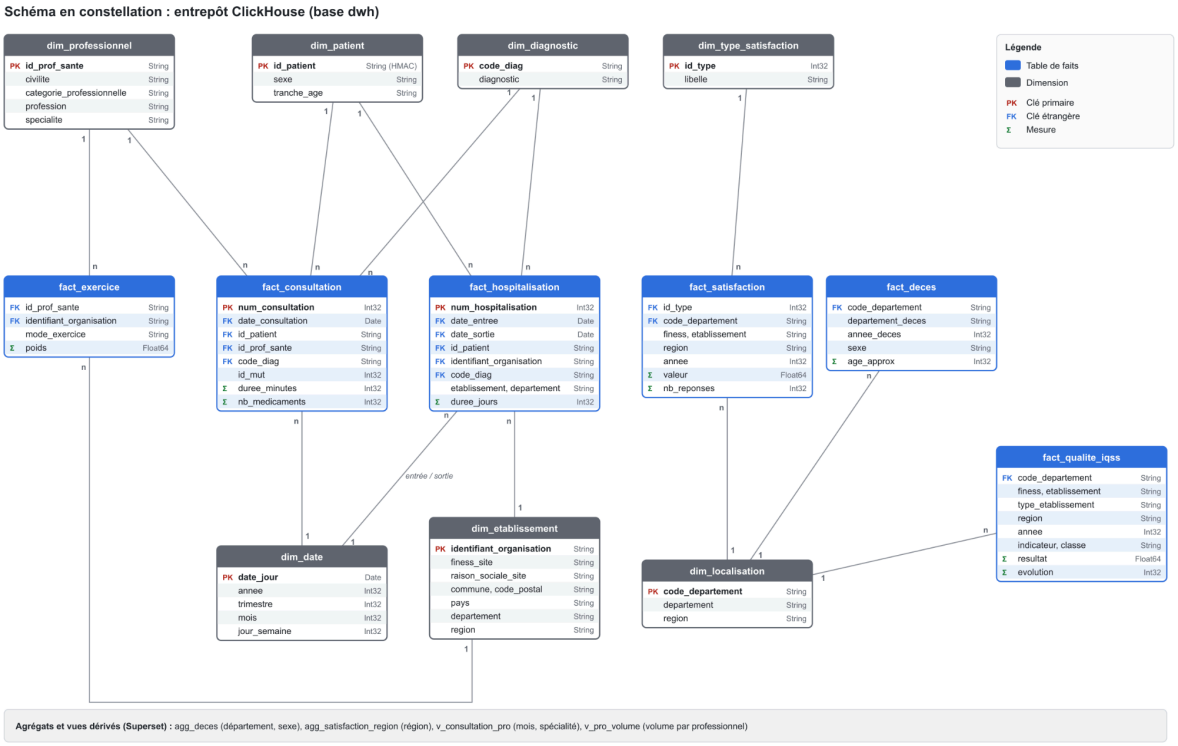


Figure 2 - Plan conceptuel de Données

a. Tables de faits

Parmi les besoins utilisateurs, nous retrouvons quatre types d'analyses : les hospitalisations, les consultations, les décès et la satisfaction. Nous avons donc créé quatre

tables de faits distinctes, chacune regroupant les données nécessaires aux statistiques correspondantes.

1. Hospitalisation

Cette table regroupe les informations liées aux hospitalisations : identifiant du patient, établissement et diagnostic. Elle contient également une date de début, une date de fin et le nombre de jours d'hospitalisation. Ces éléments permettent de réaliser des analyses par période et par établissement.

2. Consultation

Cette table contient les identifiants du patient, du diagnostic, de l'établissement et du professionnel de santé, ainsi que la date de consultation. Elle permet d'analyser l'activité médicale selon différents critères.

3. Décès et satisfaction

Ces deux tables de faits sont plus simples et comportent moins de dimensions. Elles possèdent toutes deux une clé de date et une clé de localisation. La table de satisfaction contient également un identifiant du type de satisfaction et une mesure de sa valeur.

b. Table de Dimensions

Les tables de dimensions permettent de filtrer les faits pour affiner les analyses. La dimension temps, découpée en jours, est partagée par toutes les tables de faits. S'y ajoutent les dimensions diagnostic, professionnel de santé (avec la catégorie de profession), patient (sexe et âge), établissement (code postal et pays) et localisation, qui permet de filtrer par région sans passer par un établissement. Enfin, une dimension type sert à distinguer les différents scores de satisfaction.

Script d’ingestion de données

L’ingestion est la première étape du pipeline. PySpark lit les fichiers CSV stockés sur S3 et la base PostgreSQL, puis stocke les données au format Iceberg dans la couche Bronze.

```
528     df = (
529         spark.read
530         .option("header", True)
531         .option("sep", sep)
532         .option("encoding", enc)
533         .option("multiLine", False)
534         .option("inferSchema", False)
535         .csv(f"{RAW}/{path}")
536     )
```

Figure 3 - Lecture des fichiers CSV depuis S3.

Avant le stockage, seules les colonnes autorisées sont conservées. Les noms, prénoms, adresses, coordonnées et identifiants administratifs inutiles aux analyses sont exclus.

```
401     excluded = EXCLUDED_COLUMNS.get(table_name, [])
402
403     allowed = [
404         column
405         for column in df.columns
406         if column not in excluded
407     ]
408
409     return df.select(*allowed)
```

Figure 4 - Exclusion des colonnes sensibles.

Les identifiants des patients qui restent nécessaires sont pseudonymisés avec HMAC-SHA256. La clé secrète est stockée dans la variable `ENCRYPTION_KEY`. Les tables peuvent ainsi toujours être reliées entre elles.

Les dates de naissance et de décès sont ramenées à la décennie, les lieux au département et les âges à des tranches. Les données restent utiles aux statistiques, mais elles sont moins précises.

Les données sont écrites dans des tables Iceberg sur S3. Les tables issues de PostgreSQL portent le préfixe `pg_`, et celles issues des CSV portent le nom de leur source.

Les noms de colonnes restent ceux des sources. Ils seront normalisés dans la couche Silver.

À la fin de cette étape, les données sont centralisées, filtrées et déjà protégées. Elles sont prêtes pour le nettoyage en couche Silver.

Scripts de création des données

Les tables ont été créées dans ClickHouse avec le moteur MergeTree, triées sur leur identifiant principal. Le type LowCardinality optimise le stockage des colonnes qui ont peu de valeurs différentes. L'ensemble des scripts de création est disponible en annexe 2.

Les dimensions servent à filtrer et à regrouper les faits. `dim_patient` contient l'identifiant pseudonymisé, le sexe et la tranche d'âge de chaque patient. `dim_diagnostic` associe chaque code de diagnostic à son libellé. `dim_professionnel` décrit la civilité, la catégorie, la profession et la spécialité des professionnels de santé. `dim_etablissement` contient l'identifiant, le numéro FINESS, la raison sociale et la localisation des établissements. `dim_date` découpe chaque date en année, trimestre, mois et jour de la semaine. `dim_localisation` associe chaque département à sa région. Enfin, `dim_type_satisfaction` liste les critères de satisfaction : score global, accueil, prise en charge, chambre, repas et sortie.

Les tables de faits sont le cœur du modèle, avec une table par domaine d'analyse. `fact_consultation` contient la date, le patient, le professionnel et le diagnostic de chaque consultation, avec sa durée et le nombre de médicaments prescrits. `fact_hospitalisation` contient les dates, l'établissement, le diagnostic et la durée de chaque séjour. `fact_deces` contient les décès sous une forme généralisée : décennie, département, sexe et âge approximatif. `fact_satisfaction` contient les scores par établissement, région, année et critère, avec le nombre de réponses.

Deux tables d'agrégation complètent le modèle. `agg_deces` donne le nombre de décès et l'âge moyen par décennie, département et sexe. `agg_satisfaction_region` donne le nombre d'établissements et le score moyen par région. Elles fournissent des résultats directement exploitables dans Superset.

Scripts de chargement des données

Scripts de chargement des données

Les tables ClickHouse sont alimentées par des requêtes dbt à partir des données de la couche Silver. Chaque requête correspond à une table : certaines reprennent directement les données, d'autres calculent des agrégats.

Par exemple, `agg_deces` compte les décès et calcule l'âge moyen approximatif par décennie, département et sexe. `dim_patient` reprend l'identifiant pseudonymisé, le sexe et la tranche d'âge, déjà généralisée à l'ingestion. `fact_deces` reprend les décès sous leur forme généralisée, partitionnés par décennie.

Partitionnement et indexation

Une table MergeTree stocke ses données en blocs triés selon sa clé `ORDER BY`. Trois mécanismes permettent de limiter les données lues. Le partitionnement range les données par valeur, par exemple par mois, pour n'ouvrir que les partitions utiles à une requête. L'index primaire, construit sur la clé de tri, écarte les blocs de lignes qui ne contiennent pas la valeur cherchée. Les index de saut font la même chose pour des colonnes qui ne sont pas dans la clé de tri.

Stratégie par table

Les tables de faits sont partitionnées par mois, sauf les décès qui le sont par décennie. Les petites tables comme la satisfaction et les dimensions ne sont pas partitionnées. La clé de tri commence par les colonnes les plus filtrées : l'établissement pour les hospitalisations, le diagnostic pour les consultations et le département pour les décès. Des index de saut sont ajoutés sur l'identifiant patient, les durées, la décennie de naissance et le département.

Les volumes sont très inégaux : environ 25 millions de lignes pour les décès, un million pour les consultations, mais seulement 2 479 hospitalisations et 1 152 lignes de satisfaction.

Cette stratégie est l'hypothèse de départ du benchmark. Les mesures confirment l'intérêt de la clé de tri sur les décès. En revanche, le partitionnement mensuel n'accélère pas les consultations et ralentit les hospitalisations, découpées en 73 partitions pour seulement 2 479 lignes.

Rapport de qualité de données

La qualité est mesurée sur la couche Bronze, avant nettoyage, puis sur la couche Silver, après nettoyage. Trois indicateurs sont calculés. La complétude est la part des valeurs renseignées. Le taux d'orphelins est la part des lignes dont la référence n'existe pas dans la table liée. Le taux de doublons est la part des clés en double.

Complétude

Les tables issues de PostgreSQL et les hospitalisations sont complètes à 100 %. Les manques se concentrent sur trois sources. Dans l'annuaire des établissements, le code FINESS n'est renseigné que pour 200 lignes sur 416 665. Seuls 74,5 % des scores de satisfaction sont renseignés, car certains établissements n'ont pas assez de réponses. Enfin, 99,6 % des décennies de naissance sont exploitables pour les décès.

Cohérence référentielle

Toutes les références des consultations et des hospitalisations vers les patients, les professionnels, les diagnostics et les établissements sont valides. Tous les codes FINESS respectent le format attendu. En revanche, aucun des 1 152 codes FINESS de la satisfaction ne figure dans l'annuaire. La satisfaction ne peut donc pas être reliée aux établissements, mais elle reste exploitable par région. Il faudra obtenir un référentiel FINESS complet.

Doublons

Aucun doublon n'a été trouvé pour les patients, les consultations, les hospitalisations ou les établissements. Pour les décès, 25 millions de lignes ne forment que 15 904 combinaisons distinctes. Ce ne sont pas des doublons : à cause de l'anonymisation, des personnes différentes ont la même décennie, le même département et le même sexe. Les supprimer ferait perdre 99,9 % des décès.

Contrôles automatiques

Ces règles sont rejouées à chaque chargement par des tests dbt. Les tests d'unicité et de présence des clés bloquent le chargement s'ils échouent. Les tests de cohérence et de format FINESS ne déclenchent qu'un avertissement, pour ne pas bloquer le traitement quotidien à cause d'une anomalie de source.

Logs et traces

Un log est une ligne horodatée qui décrit un événement : une erreur, une requête ou une tâche terminée. Une métrique est une mesure chiffrée suivie dans le temps, comme la mémoire utilisée. Une trace suit une même opération à travers plusieurs composants pour voir où le temps est perdu. Dans ce projet, la traçabilité désigne aussi la capacité, exigée par le RGPD et l'HDS, à savoir qui a accédé à quelles données.

Centralisation des logs

Tous les logs sont centralisés dans Grafana Loki, alimenté par Grafana Alloy. Loki a été préféré à Elasticsearch car il est plus léger : il n'indexe que quelques étiquettes et compresse le texte. Alloy récupère les logs de tous les conteneurs et des tâches Airflow, et les étiquette par service et par tâche. Un tableau de bord permet de retrouver rapidement les erreurs. Ces logs sont conservés 30 jours.

Métriques et supervision

Alloy envoie aussi les métriques à Prometheus, également conservées 30 jours. Elles couvrent la machine, les conteneurs et l'ensemble des services de la plateforme. Un tableau de bord permet de repérer les anomalies qui ne provoquent pas d'échec, comme un traitement anormalement long.

Traçabilité des accès aux données

Trino est le point d'accès aux données pour dbt et Superset. Chaque requête terminée est enregistrée par un petit service que nous avons développé, trino-audit. Il conserve l'utilisateur, l'adresse IP, l'application, les tables lues et l'état de la requête. Un tableau de bord permet de savoir qui a consulté quelle table. Ces logs d'audit sont conservés un an, une durée qui reste à confirmer avec le plan de gouvernance.

Traçabilité des exécutions

Airflow garde l'historique de chaque exécution du pipeline, avec les logs de chaque tâche. On peut ainsi savoir quelle tâche a produit quelles données, et pourquoi une tâche a échoué.

Données de santé dans les logs

Les logs ne contiennent aucune donnée de santé sensible. La pseudonymisation et la généralisation sont appliquées dès l'ingestion, donc seuls des identifiants techniques et des valeurs généralisées peuvent y apparaître.

Benchmark et performances

Cette partie mesure l'effet du partitionnement, de la clé de tri et des index de saut sur les temps de réponse de ClickHouse. Les mêmes données sont interrogées par huit requêtes métier dans quatre configurations différentes.

Configurations comparées

Chaque configuration ajoute une seule optimisation à la précédente, ce qui permet d'attribuer chaque écart à sa cause. A0 n'a aucune optimisation. A1 ajoute le partitionnement des tables de faits, par mois ou par décennie pour les décès. A2 ajoute une clé de tri adaptée à chaque table. A3 ajoute les index de saut. La base de production utilisée par Superset n'est pas touchée par le benchmark.

Protocole

Chaque requête est exécutée cinq fois par configuration, à froid puis à chaud, après une exécution de chauffe. On mesure la durée, les lignes lues et les octets lus. Les résultats sont comparés d'une configuration à l'autre pour vérifier que les optimisations ne changent pas les réponses. Les tests tournent sur une machine de 4 cœurs et 15,6 Go de mémoire, partagée avec les autres services de la plateforme.

Requêtes de benchmark

Les huit requêtes reprennent les analyses attendues : consultations par diagnostic, par professionnel, par âge et par sexe, hospitalisations par établissement, décès par département et satisfaction par région. Une requête témoin sans filtre sert de référence. Le fichier des hospitalisations ne contient pas d'identifiant patient, donc les analyses par sexe et par âge portent sur les consultations.

Analyse des résultats

La clé de tri est la seule optimisation vraiment rentable. Sur les décès filtrés par département, elle réduit les lignes lues de 18 millions à 344 000 et divise le temps de réponse par dix, de 500 à 50 ms.

Lire moins de lignes ne suffit pas toujours à gagner du temps. Le temps de la requête sur les diagnostics d'un établissement est divisé par deux, de 400 à 200 ms. En revanche, sur les consultations, le partitionnement ne réduit pas les données lues et ajoute un surcoût : une des requêtes passe de 1 008 à 1 410 ms.

Partitionner une petite table la ralentit. Avec seulement 2 479 lignes, les hospitalisations sont découpées en trop de petites parties, ce qui annule le bénéfice de l'élagage. Le partitionnement doit être réservé aux grosses tables.

Les temps à froid et à chaud sont proches, car les tables restent de taille modérée. L'espace disque varie de moins de 3 % entre les configurations. Le vrai coût est la multiplication des parties, qui passent de 11 à 201. Les petits écarts sur les requêtes très rapides ou sans filtre viennent de la charge de la machine partagée.

Stratégie corrigée

Seules les optimisations utiles sont conservées : la clé de tri sur le département pour les décès, et le partitionnement mensuel des consultations pour faciliter la gestion des données. Les autres partitionnements et les index de saut sont supprimés. Les huit requêtes renvoient les mêmes résultats dans les quatre configurations, ce qui confirme que les optimisations ne modifient pas les réponses.

Limites de la mesure

Les tests ont été faits sur une seule machine, avec le volume de données du projet. Les résultats dépendent aussi des caches, et les accès simultanés n'ont pas été testés. Les performances devront donc être confirmées sur de plus gros volumes et en conditions réelles.

Présentation des tableaux de bord

Sur Superset, nous avons la possibilité de créer différents dashboards avec les graphiques souhaités et ainsi les personnaliser. Nous avons pu représenter les 8 graphiques demandés par l'utilisateur avec différents types de diagramme afin de pouvoir les analyser par la suite. Chaque tableau de bord a des filtres communs (période, établissement, diagnostic, région), qui s'appliquent à tous ses graphiques en même temps. Chaque type de graphique est pensé pour être le plus cohérent avec la donnée affichée.

Des Key Performance Indicator (KPI) sont également présents pour donner une indication numérique et une mesure quantifiable. Ils sont utilisés pour évaluer l'efficacité d'un service, un processus médical ou une action par rapport à des objectifs définis.

Consultations

Le taux de consultation par établissement est affiché dans un diagramme à barres horizontales trié par ordre croissant, qui met en évidence les établissements les plus sollicités. Un filtre de période permet de limiter l'analyse à une plage de dates.



Figure 5 - Consultations par établissement (top 15)

Le taux de consultation par diagnostic suit le même principe. Comme les diagnostics sont très nombreux, seuls les 15 plus fréquents sont affichés.

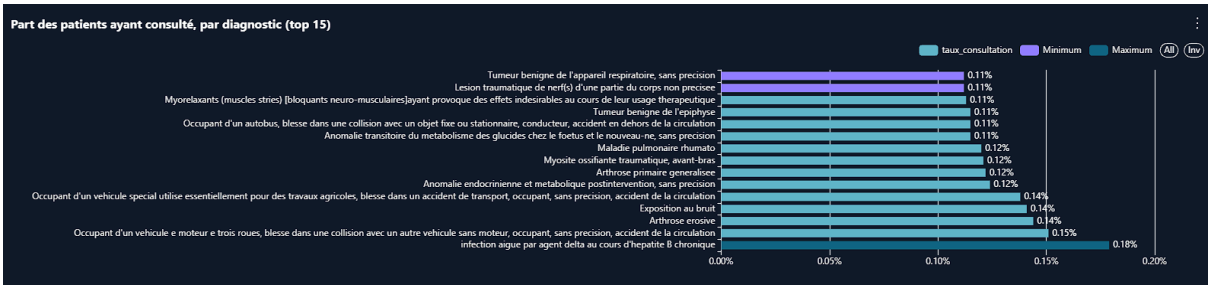


Figure 6 - Part des patients ayant consulté, par diagnostic (top 15)

Le taux de consultation par professionnel de santé peut être filtré par catégorie de profession et par spécialité. On compare ainsi l'activité de professionnels comparables entre eux.

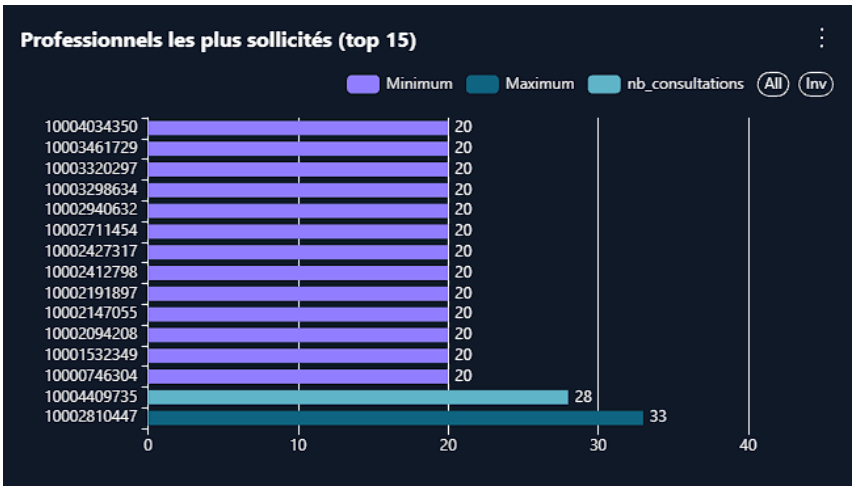


Figure 7 - Professionnels les plus sollicités (top 15)

Hospitalisations

Le taux global d'hospitalisation sur une période est affiché sous forme d'indicateur chiffré (Big Number), accompagné de sa tendance par rapport à la période précédente.



Figure 8 - Consultations par département (top 15)

Le taux d'hospitalisation par diagnostic est représenté par un diagramme à barres, complété par la durée moyenne de séjour pour chaque diagnostic.

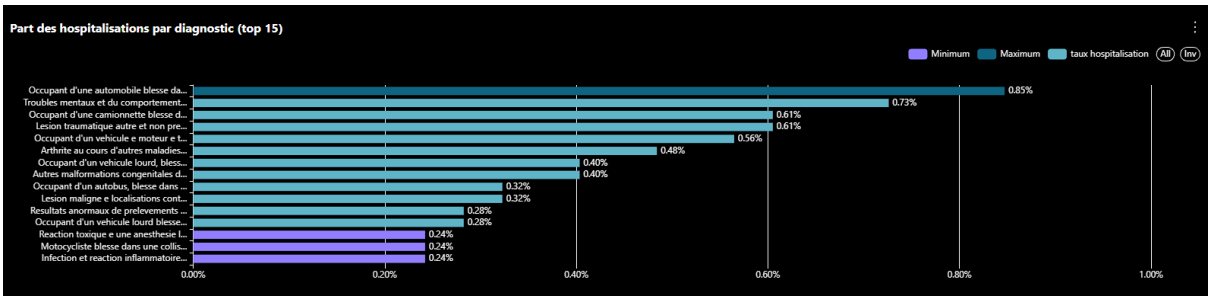


Figure 9 - Part des hospitalisations par diagnostic (top 15)

Les répartitions par sexe et par tranche d'âge utilisent des diagrammes à barres. Ce type de graphique convient bien pour croiser une variable qualitative (le sexe ou la tranche d'âge) avec une valeur quantitative (le nombre ou le taux de séjours). Le sexe et la tranche d'âge peuvent aussi être croisés dans un diagramme à barres groupées.

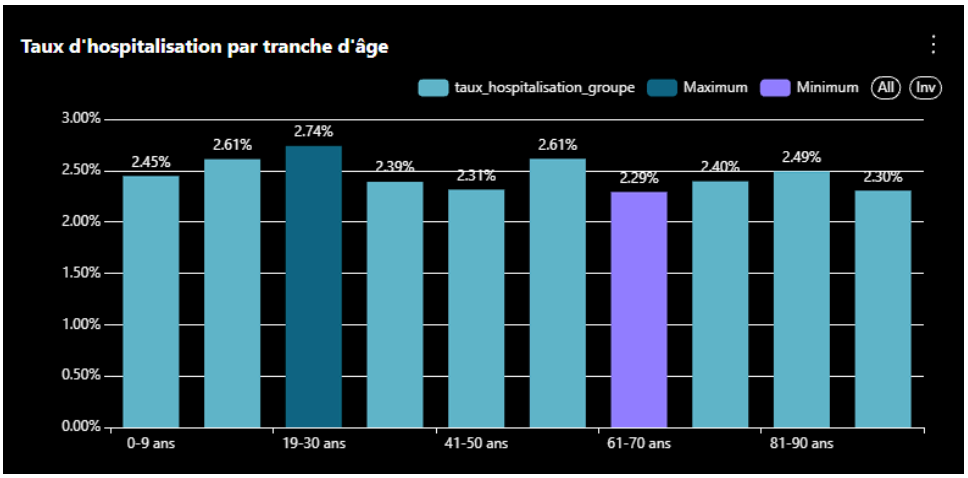


Figure 10 - Taux d'hospitalisation par tranche d'âge

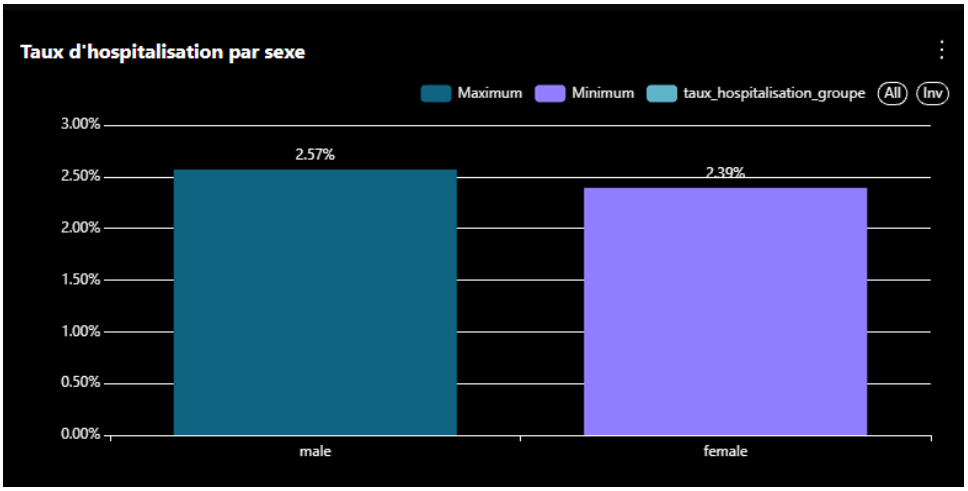


Figure 11 - Taux d'hospitalisation par sexe

Décès (optionnel)

Le nombre de décès par région en 2019. Ce graphique présente la mortalité selon la localisation et permet de comparer les régions entre elles.

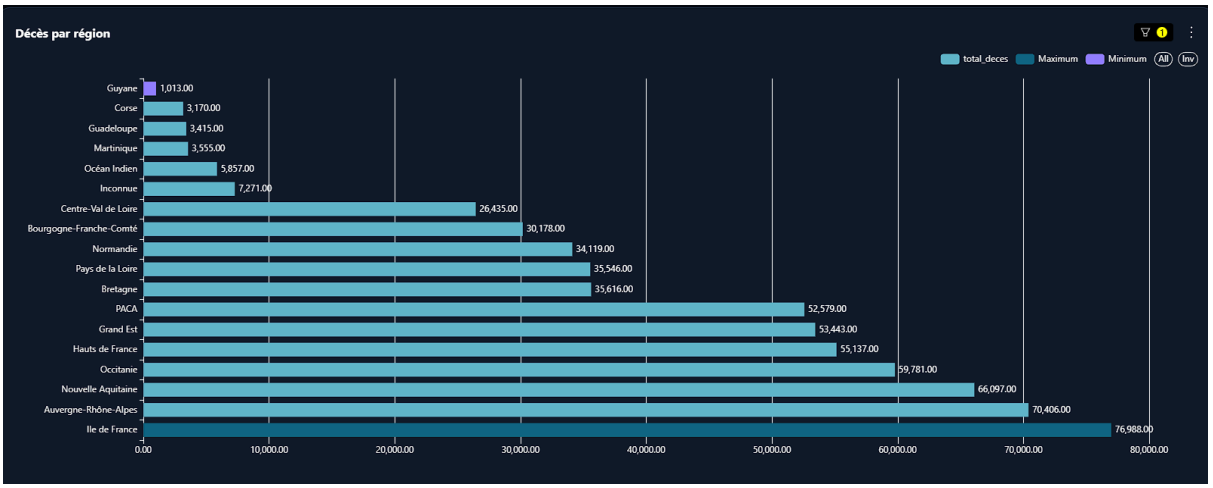


Figure 12 - Décès par région (2019)

Satisfaction

Le score de satisfaction moyen par région sur l'année 2020. Il a également était représenté par un diagramme à barres

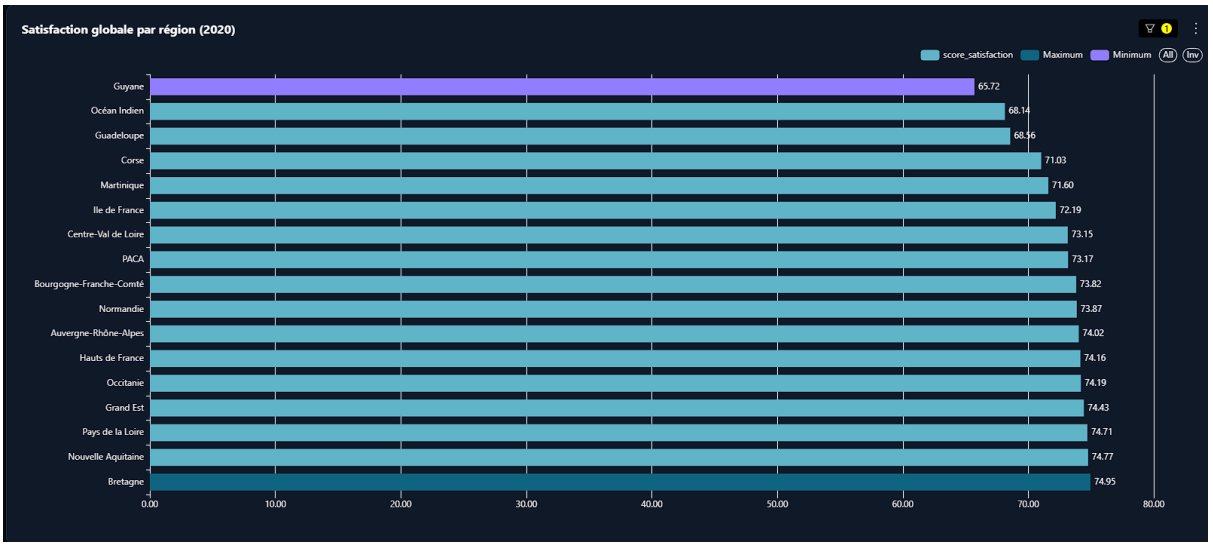


Figure 13 - Satisfaction globale par région (2020)

Analyse des résultats obtenus

Les tableaux de bord couvrent les indicateurs demandés. Cette partie interprète ce qu'ils montrent, puis précise jusqu'où ces résultats sont fiables.

Consultations par établissement

Le Service de santé des armées arrive en tête avec 4 368 consultations, devant l'hôpital Pitié-Salpêtrière (AP-HP) avec 3 408. Viennent ensuite des établissements entre 1 700 et 2 300 consultations, comme l'Hôpital Nord du CHU de Grenoble (2 282) ou le CHU de Nantes (2 117). L'AP-HP est très présente : cinq de ses sites figurent dans le top 15 (Pitié-Salpêtrière, Necker, Cochin, Henri Mondor, Kremlin-Bicêtre).

Le classement contient aussi des organismes qui ne sont pas des hôpitaux, comme la Caisse nationale de l'Assurance Maladie ou le service départemental de l'Éducation nationale. Cela s'explique par la façon dont l'établissement est rattaché à la consultation : il s'agit de la structure d'exercice du professionnel, et pas forcément d'un lieu de soins. Ce point devra être précisé avec les utilisateurs.

Consultations par département

Paris (75) domine nettement avec 61 259 consultations, soit plus du double du deuxième département, les Bouches-du-Rhône (13) avec 26 417. Le Nord (59), le Rhône (69), les Hauts-de-Seine (92) et la Gironde (33) suivent.

La répartition suit logiquement la population et la concentration des grands centres hospitaliers.

Consultations par diagnostic

La part de patients ayant consulté pour un diagnostic donné reste très faible : elle va de 0,11 % à 0,18 % dans le top 15. La valeur la plus élevée concerne l'infection aiguë par agent delta au cours d'une hépatite B chronique. Aucun diagnostic ne domine : les consultations se répartissent sur un très grand nombre de codes, dont beaucoup décrivent des causes externes (accidents de transport, exposition au bruit) plutôt que des pathologies.

Consultations par professionnel

L'activité est très homogène. Le professionnel le plus sollicité réalise 33 consultations et le deuxième 28. Les treize suivants en ont exactement 20 chacun.

Le classement au-delà des deux premiers n'a donc pas de sens, car de nombreux professionnels sont à égalité. Les professionnels sont affichés par leur identifiant et non par leur nom, ce qui respecte la minimisation des données.

Hospitalisations par sexe et par âge

Les hommes sont un peu plus hospitalisés que les femmes : 2,57 % contre 2,39 %, soit un taux global d'environ 2,5 %.

Par tranche d'âge, le taux varie peu, entre 2,29 % (61-70 ans) et 2,74 % (19-30 ans). Ce résultat est surprenant : dans la réalité, le taux d'hospitalisation augmente fortement avec l'âge. Cette absence d'effet de l'âge laisse penser que les données fournies sont partielles ou incomplètes.

Hospitalisations par diagnostic

Le premier motif d'hospitalisation concerne les occupants d'automobile blessés dans un accident (0,85 %), suivis des troubles mentaux et du comportement (0,73 %). Les accidents de transport sont très présents : sept des quinze diagnostics les plus fréquents concernent un véhicule (automobile, camionnette, véhicule lourd, autobus, moto…). Les parts restent toutefois faibles (0,24 % à 0,85 %), car les 2 479 séjours se répartissent sur de nombreux diagnostics.

Décès par région (2019)

L'Île-de-France compte le plus de décès (76 988), devant Auvergne-Rhône-Alpes (70 406) et la Nouvelle-Aquitaine (66 097). La Guyane en compte le moins (1 013). Au total, environ 620 000 décès sont recensés, ce qui correspond à l'ordre de grandeur national annuel. Ce classement reflète surtout la taille de la population. Pour comparer réellement la mortalité entre régions, il faudrait rapporter ces chiffres au nombre d'habitants (données INSEE). Par ailleurs, 7 271 décès (environ 1,2 %) sont classés en région « Inconnue ».

Satisfaction par région (2020)

La Bretagne obtient le meilleur score de satisfaction (74,95), la Guyane le plus faible (65,72). En métropole, les scores sont très proches, entre 71,03 (Corse) et 74,95. Les régions d'outre-mer sont nettement en dessous : Guyane (65,72), Océan Indien (68,14), Guadeloupe (68,56) et Martinique (71,60). L'Île-de-France, avec 72,19, est l'une des régions métropolitaines les moins bien notées. Ces résultats doivent être nuancés : seuls 74,5 % des scores sont renseignés, et la satisfaction ne peut pas être reliée aux établissements car leurs codes FINESS ne correspondent pas à l'annuaire.

Les indicateurs de consultation sont les plus fiables : environ un million de lignes, sans doublon et avec des références toutes valides. Les hospitalisations reposent sur un faible volume (2 479 séjours), donc quelques séjours suffisent à faire varier un taux. Les décès comportent une part de localisations inconnues, et la satisfaction est incomplète. Enfin, la répartition très régulière des valeurs (âge, professionnels, diagnostics) suggère des données incomplètes. La chaîne de traitement est valide, mais les conclusions médicales devront être confirmées sur des données réelles.

La plateforme fournit les indicateurs attendus, actualisés chaque nuit et filtrables. Elle fait déjà ressortir des tendances exploitables : la concentration de l'activité sur Paris et l'AP-HP, le poids des accidents de transport dans les hospitalisations et l'écart de satisfaction entre la métropole et l'outre-mer. Pour aller plus loin, il faudra un référentiel FINESS complet, des données de population pour calculer de vrais taux de mortalité, et un historique d'hospitalisations plus large.

Gestion des erreurs, supervision et observabilité

a. Gestion des erreurs dans le pipeline

Le DAG lakehouse_pipeline enchaîne quatre tâches dans un ordre strict : sync_code, spark_ingest_bronze, dbt_build et load_clickhouse. Une seule exécution peut tourner à la fois (max_active_runs=1). Si une tâche échoue, les suivantes ne sont pas lancées. Une erreur en amont ne peut donc pas se propager vers les tableaux de bord.

Le chargement dans ClickHouse est conçu pour qu'une panne ne laisse jamais de table à moitié remplie. Chaque table Gold est d'abord copiée dans une table temporaire (*<table>__new*). Elle remplace ensuite la table de production en une seule opération (EXCHANGE TABLES). Si la copie échoue, la table temporaire est supprimée et la version précédente reste en place. Superset affiche donc toujours la dernière version valide des données.

Les erreurs de qualité sont gérées par dbt build, qui exécute les tests juste après chaque modèle. Les tests d'unicité et de présence des clés bloquent la suite du pipeline. Les tests de cohérence référentielle et de valeurs autorisées (sexe H/F, par exemple) sont en severity: warn : ils apparaissent dans les logs sans arrêter le traitement quotidien.

b. Supervision de la plateforme

Grafana Alloy collecte les métriques de la machine (CPU, mémoire, disque, réseau), celles de chaque conteneur (cAdvisor) et celles de PostgreSQL, ClickHouse, Trino, SeaweedFS, Nessie, Loki et Grafana. Il les envoie à Prometheus toutes les 30 secondes, avec une conservation de 30 jours. Airflow publie ses métriques via StatsD : état des tâches, durée des exécutions et activité du scheduler. Alloy centralise aussi dans Loki les logs des conteneurs et des tâches Airflow, conservés 30 jours.

Trois tableaux de bord Grafana sont provisionnés. Exploitation lakehouse, la page d'accueil, montre l'état de la machine, les cibles de collecte en erreur, la consommation par service, les tâches Airflow par état et par durée avec leurs erreurs, et l'activité de Trino, ClickHouse, PostgreSQL et S3. Logs lakehouse affiche les lignes d'erreur par service et permet de chercher dans tous les logs. Audit accès données donne les requêtes par utilisateur, les requêtes en échec et le détail de qui a lu quelles tables et colonnes.

L'accès à Grafana passe par Keycloak (OIDC). Le groupe lakehouse-admin obtient le rôle Admin, les autres utilisateurs sont en lecture seule.

c. Diagnostic d'un incident

Quand une exécution échoue, l'opérateur repère la tâche en cause sur le tableau de bord d'exploitation. Il ouvre ensuite ses logs dans Loki, filtrés par dag_id, task_id et niveau. Il vérifie enfin dans les métriques si l'échec vient d'un manque de ressources, comme une

saturation mémoire ou disque. Une fois la cause corrigée, il relance le pipeline à la main depuis Airflow.

Évolutions à venir

La plateforme est opérationnelle de l'ingestion jusqu'aux tableaux de bord. Plusieurs limites identifiées au cours du projet ouvrent toutefois des pistes d'amélioration, sur les données, la plateforme, la sécurité et la restitution.

a. Qualité et enrichissement des données

La première priorité est d'obtenir un référentiel FINESS complet. Aujourd'hui, le code FINESS n'est renseigné que pour 200 établissements sur 416 665, et aucun code de la satisfaction ne correspond à l'annuaire. Avec un référentiel complet, la satisfaction pourrait être analysée par établissement et non plus seulement par région.

Il faudra aussi corriger le rattachement des 7 271 décès classés en région « Inconnue », en complétant la table de correspondance entre départements et régions. L'ajout des données de population de l'INSEE permettrait ensuite de calculer de vrais taux de mortalité, rapportés au nombre d'habitants, plutôt que des nombres de décès bruts.

Enfin, les analyses devront être rejouées sur des données réelles et sur un historique plus long. Les résultats actuels, très réguliers, suggèrent des données de test, et les 2 479 séjours d'hospitalisation constituent un volume trop faible pour des conclusions solides.

b. Performances et montée en charge

Le benchmark a été réalisé sur une seule machine, avec le volume du projet et sans accès simultanés. Il faudra le rejouer sur de plus gros volumes et avec plusieurs utilisateurs connectés en même temps à Superset. Le partitionnement et les index de saut, supprimés car inutiles aujourd'hui, pourront être réévalués lorsque les volumes augmenteront.

Le chargement complet des tables chaque nuit pourra aussi devenir trop long. Un chargement incrémental, qui ne traite que les nouvelles données grâce au format Iceberg, réduirait la durée du pipeline, qui est actuellement de 19 à 25 minutes.

c. Sécurité et gouvernance

Keycloak pourra être relié à Pro Santé Connect, pour que les professionnels de santé se connectent avec leur carte CPS sans créer de compte supplémentaire. Dans Superset, un filtrage par ligne permettrait de n'afficher à chaque praticien que les données de son activité ou de son établissement.

La durée de conservation des logs d'audit, fixée provisoirement à un an, devra être validée dans le cadre du plan de gouvernance, avec la réalisation de l'AIPD. Un seuil de masquage automatique des petits effectifs devra également être ajouté aux tables Gold, afin d'éviter toute réidentification avant la diffusion des résultats.

d. Tableaux de bord

Les tableaux de bord pourront être enrichis avec un indicateur du taux global d'hospitalisation, la durée moyenne de séjour par diagnostic et des cartes de France pour les indicateurs régionaux. L'ajout de courbes d'évolution dans le temps permettrait aussi de repérer les variations saisonnières de l'activité.

Conclusion

Le projet Cloud Healthcare Unit vise à créer une plateforme décisionnelle permettant de centraliser et d'analyser les données hospitalières à des fins statistiques. L'architecture repose sur un modèle Lakehouse organisé en trois couches : Bronze pour le stockage initial, Silver pour le nettoyage et la fiabilisation, et Gold pour la production des indicateurs. Les différentes technologies retenues assurent le traitement, le stockage, l'orchestration et la visualisation des données. La modélisation en constellation permet de répondre aux besoins des utilisateurs grâce aux tables de faits et de dimensions.

Sécurité et qualité des données

La qualité des données repose sur le nettoyage des formats, des dates, des doublons et des valeurs manquantes. Les informations directement identifiantes non nécessaires sont supprimées dès l'ingestion. Des mesures de pseudo-anonymisation, de chiffrement et de contrôle des accès sont également prévues afin de respecter le RGPD et les exigences liées aux données de santé.

Performances

Le benchmark montre que les clés de tri sont l'optimisation la plus efficace, avec un temps de réponse divisé par dix sur les décès. Le partitionnement mensuel est inutile à ce volume et pénalise les petites tables. Nous conservons donc les clés de tri et supprimons le partitionnement ainsi que les index de saut inutilisés.

Perspectives

Plusieurs améliorations restent à prévoir : compléter le référentiel FINESS, valider la conservation des logs, tester la plateforme en charge et intégrer Pro Santé Connect. L'architecture et la chaîne de données sont opérationnelles, de l'ingestion à ClickHouse. La prochaine étape consiste à exploiter les indicateurs dans Superset pour répondre aux besoins des praticiens et de la direction.

Restitution des résultats

Les indicateurs sont désormais exploités dans Superset, à travers des tableaux de bord qui couvrent les huit besoins exprimés. Ils font ressortir des tendances utiles à la décision : pour la direction, la concentration de l'activité sur Paris et l'AP-HP et le retard de satisfaction en outre-mer ; pour les praticiens, le poids des accidents de transport et des troubles mentaux dans les hospitalisations. Ces résultats restent à confirmer sur des données réelles, car les données actuelles semblent simulées.

Annexes

Annexe 1 : Glossaire

AIPD	Analyse d'Impact relative à la Protection des Données
AM	Assurance Maladie
AP-HP	Assistance Publique – Hôpitaux de Paris
DAG	Directed Acyclic Graph
DBT	DataBase Tool
CHU	Cloud Healthcare Unit
CNIL	Commission Nationale de l'Informatique et des Libertés
CPE	Carte de Professionnel d'Établissement
CPF	Carte de Professionnel en Formation
CPS	Carte de Professionnel de Santé
CPx	Carte de Professionnel de tous types
ELT	Extract, Load, Transform
ETL	Extract, Transform, Load
FINESS	Fichier National des Établissements Sanitaires et Sociaux
FTP	File Transfert Protocol
HCG	Health Care Group
HDFS	Hadoop Distributed File System
HDS	Hébergeur de Données de Santé
INSEE	Institut National de la Statistique et des Etudes Economiques
JDBC	Java Database Connectivity
KPI	Key Performance Indicator
LDAP	Lightweight Directory Access Protocol
MFA	Multi-Factor Authentication
PSC	Pro Santé Connect

OIDC	OpenId Connect
PGSSI-S	Politique Générale de Sécurité des Systèmes d'Information de Santé
RGPD	Règlement Général de la Protection des Données
SGBD	Système de Gestion de Base de Donnée
SSD	Solid-State Drive
SSO	Single Sign-On
UE	Union Européenne