CESI
ÉCOLE D'INGÉNIEURS

Livrable 1

Référentiel de données de l'entrepôt CHU



Cloud Healthcare Unit

Groupe

RIVET Alexandre
AFANE Youcef
STOFFEL Maxime
RABATEL Antonin

26 octobre 2026

Sommaire

1. Objet et périmètre **3**
2. Sources retenues **4**
3. Modèle en étoile **6**
4. Hiérarchie du datalake **11**
5. Contextes et variables **13**
6. Jobs des dimensions **15**
6.1 Dimension Patient 15
6.2 Dimension Professionnel 15
6.3 Dimension Diagnostic 16
6.4 Dimension Localisation 16
6.5 Dimension Temps 17
6.6 Dimension Établissement 17
7. Job des faits **18**
8. Ordonnancement, qualité et limites **20**
9. Architecture et choix techniques **23**
10. Plan de gouvernance des données **27**
10.1 Responsables 27
10.2 Matrice des accès 27
10.3 Conservation et purge 28
10.4 Secrets, transferts et sauvegardes 28
10.5 Traçabilité 29
10.6 Périmètre HDS 29
10.7 Base légale, droits des personnes et cadre de la CNIL 29
Annexe : dictionnaire de données **31**

1. Objet et périmètre

Ce livrable définit le référentiel de données de l'entrepôt CHU. Il comprend une constellation de 4 tables de faits et 6 dimensions conformes, un lac HDFS en trois couches (Bronze, Silver, Gold) et les jobs Apache Hop qui l'alimentent chaque mois selon un flux ELT. Hop extrait et charge les sources en Bronze ; Hive transforme vers Silver puis Gold. Avant le stockage, Hop ne fait que deux choses : protéger les données personnelles (colonnes non extraites, identifiant du patient et identité des décès remplacés par un hachage salé) et convertir les fichiers en CSV UTF-8.

Le document suit les volets attendus pour ce livrable :

Volet	Sections
Analyse des sources	2
Modèle conceptuel et logique, dictionnaire de données	3 et annexe
Architecture cible : couches, flux de bout en bout, technologies et justification des choix	4 et 9
Spécifications fonctionnelles des jobs : sources, règles de transformation, valeurs nulles et doublons, erreurs et rejets, fréquence	5 à 8
Plan de gouvernance des données	10

La création physique des tables, le chargement des données et les tests sur les données réelles relèvent de l'implémentation physique (livrable 2). Les noms de jobs cités ici sont ceux que cette implémentation reprendra.

2. Sources retenues

L'entrepôt est alimenté par 5 tables PostgreSQL, 3 fichiers du référentiel santé et 5 fichiers servis par FTP. Les volumes viennent de l'inventaire du 26/10/2026. Toute colonne dont aucune analyse n'a besoin reste dans la source (principe de minimisation du RGPD).

Source	Table ou fichier	Lignes	Alimente	Jamais extrait
1. PostgreSQL	Patient	100 000	Dim. patient	Nom, prénom, adresse, ville, code postal, e-mail, téléphone, n° de sécurité sociale, âge, groupe sanguin, poids, taille. La date de naissance est réduite à l'année.
1. PostgreSQL	Consultation	1 027 157	Fait consultation	Motif, mutuelle, heures de début et de fin
1. PostgreSQL	Professionnel_de_sante	1 048 575	Dim. professionnel	Nom, prénom, civilité
1. PostgreSQL	Specialites	93	Dim. professionnel	Rien
1. PostgreSQL	Diagnostic	15 490	Dim. diagnostic	Rien
Fichier CHU	Hospitalisations.csv	2 479	Fait hospitalisation, dim. diagnostic	Rien
2. Référentiel	etablissement_sante.csv	416 665	Dim. établissement, dim. localisation	Adresse, téléphones, e-mail, SIREN, SIRET, enseigne. La raison sociale n'est gardée que pour les établissements FINESS.
2. Référentiel	activite_professionnel_sante.csv	1 823 588	Dim. professionnel (lien vers l'établissement)	Rien
4. FTP décès	deces.csv	25 088 208	Fait décès, dim. localisation, dim. temps	Nom, prénom, lieu et pays de naissance, n° d'acte. Ils servent uniquement à calculer la clé de dédoublonnage hachée avant d'être écartés.
3. FTP satisfaction	e-Satis MCO 48 h, campagnes 2019 et 2020	1 152 + 1 150	Fait satisfaction	Raisons sociales (déjà dans le référentiel)

Source	Table ou fichier	Lignes	Alimente	Jamais extrait
3. FTP satisfaction	e-Satis MCO chirurgie ambulatoire, 2019 et 2020	945 + 931	Fait satisfaction	Raisons sociales

Sont écartés : `Medicaments`, `Prescription`, `Laboratoire`, `Mutuelle`, `Adher` et `Salle`, qu'aucun besoin n'utilise ; `AAAA` et `date`, tables de travail non documentées dont l'une contient des noms ; `professionnel_sante.csv`, qui reprend la table PostgreSQL ligne pour ligne (recouvrement de 100 %) ; les fichiers IQSS, DPA, RCP, HPP, IDM, DAN et ETE, qui mesurent la qualité de tenue du dossier et non la satisfaction des patients.

Le hachage salé est une **pseudonymisation, pas une anonymisation** : quiconque détient le sel peut recalculer le pseudonyme d'un identifiant connu. Les données du lac restent donc des données personnelles de santé, soumises au RGPD et à l'hébergement HDS en production. Le hachage a lieu dans Hop, avant tout stockage : l'identifiant interne du patient (`Id_patient`) n'entre jamais dans le lac, ni pour les patients, ni pour les consultations, ni pour les séjours. Le référentiel de la CNIL sur les entrepôts de données de santé l'exige : seul un identifiant pseudonyme peut y être utilisé, jamais un numéro interne (section 10.7). Pour tout le reste, Bronze reste une copie fidèle des sources.

Trois constats de l'inventaire orientent le modèle :

- **La consultation n'a pas de colonne établissement**. Elle se rattache à un lieu par le professionnel, puis par son activité dans une organisation. Ce chemin donne un lieu à 63,9 % des consultations, mais c'est un lieu estimé : un professionnel peut exercer dans plusieurs établissements. Les autres consultations pointent vers le membre « Inconnu ».
- **Les formats de date diffèrent** : yyyy-MM-dd (consultations, décès), dd/MM/yyyy (hospitalisations), M/d/yyyy (naissance des patients), dates partielles dans les décès. La conversion se fait en Silver.
- **Les sources chargées ne se recouvrent qu'en 2019**. Les consultations vont de 2015 à mars 2023, les hospitalisations de 2015 à juin 2021, les décès jusqu'en mars 2020, et la satisfaction chargée couvre les campagnes 2019 et 2020.

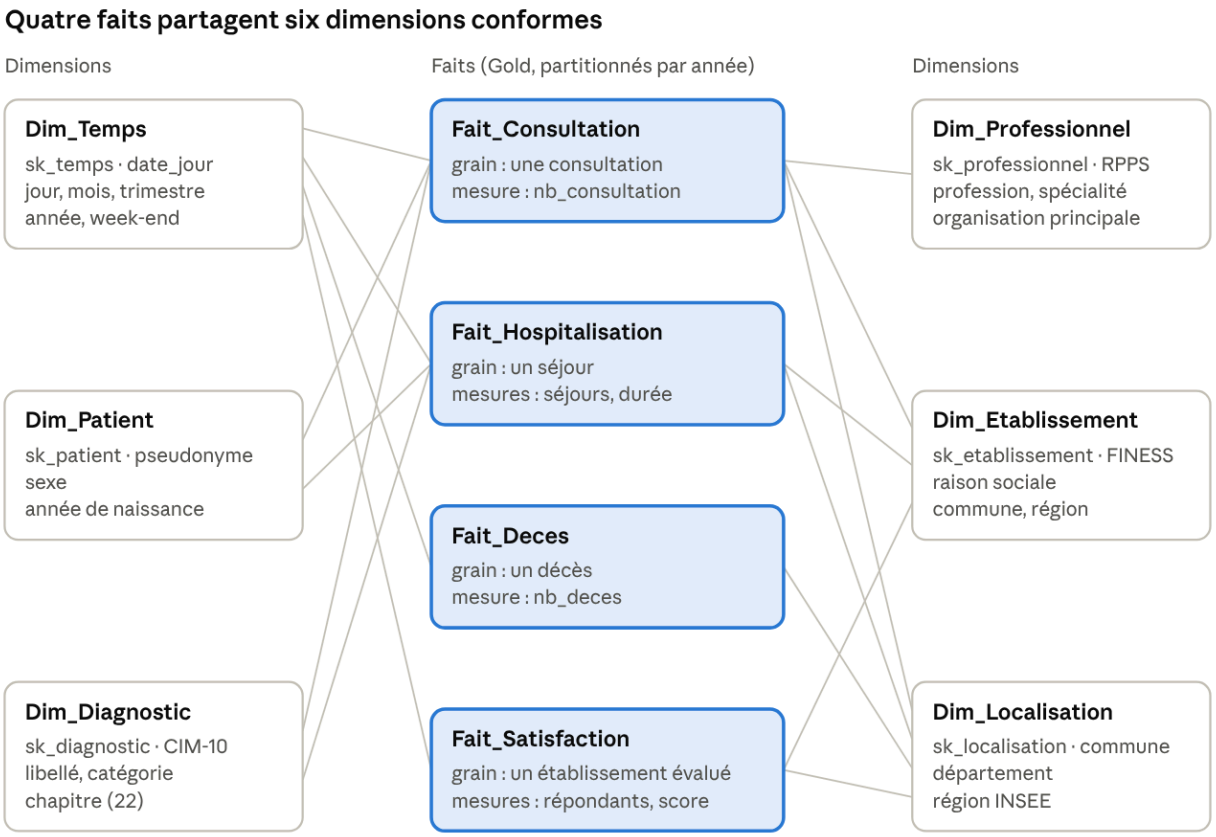
3. Modèle en étoile

Le modèle est une constellation de Kimball : 4 tables de faits partagent 6 dimensions conformes. Les dimensions partagées permettent d'analyser de façon cohérente les faits qui les utilisent : une même période ou une même région filtre les quatre faits, un même diagnostic filtre les consultations et les hospitalisations. Les jointures restent à un seul niveau.

Modèle conceptuel. Six entités d'analyse (les dimensions) et quatre événements à mesurer (les faits) sont reliés par des associations. Les cardinalités sont notées (minimum, maximum) de chaque côté.

Association	Côté fait	Côté dimension	Lecture
Consultation → Temps, Patient, Professionnel, Diagnostic, Établissement, Localisation	(1,1)	(0,n)	Une consultation a un seul jour, un seul patient, un seul professionnel, etc. ; un patient a zéro à plusieurs consultations
Hospitalisation → Temps, Patient, Diagnostic, Établissement, Localisation	(1,1)	(0,n)	Un séjour a une date d'entrée, un patient, un diagnostic, un établissement
Décès → Temps, Localisation	(1,1)	(0,n)	Un décès a une date et une commune ; une commune compte zéro à plusieurs décès
Satisfaction → Temps, Établissement, Localisation	(1,1)	(0,n)	Une évaluation porte sur un établissement et une campagne
Professionnel → Établissement (organisation principale)	(1,1)	(0,n)	Un professionnel a une organisation principale ; un établissement en accueille zéro à plusieurs
Établissement → Localisation	(1,1)	(0,n)	Un établissement est dans une commune

Le côté (1,1) est garanti par le membre « Inconnu » : une correspondance absente pointe vers lui au lieu de laisser la clé vide. Les deux dernières associations relient des dimensions entre elles et ne servent qu'au chargement : le job des faits y lit l'établissement et le lieu à recopier sur chaque consultation. Les analyses joignent toujours un fait directement à ses dimensions, une jointure par axe : le modèle reste une étoile, pas un flocon.



constellation : 4 faits, 6 dimensions

Modèle logique. Le schéma ci-dessus traduit ces associations en tables. Chaque association (1,1)–(0,n) devient une clé étrangère `sk_` dans le fait, vers la clé primaire de la dimension ; les types et les clés de chaque table sont détaillés en annexe. La consultation n'a pas de colonne établissement : son fait reçoit l'établissement et la localisation de l'organisation principale du professionnel (section 6.2).

Dimension	Consultation	Hospitalisation	Décès	Satisfaction
Temps (jour)	date de l'acte	date d'entrée	date du décès	1er janvier de la campagne
Patient	✓	✓	Non	Non
Diagnostic	✓	✓	Non	Non
Professionnel	✓	Non	Non	Non
Établissement	par le professionnel	✓	Non	✓ (FINESS géographique)
Localisation	par le professionnel	par l'établissement	commune du décès	par l'établissement, sinon région du fichier

Le cahier des charges nomme des taux sans les définir. Les définitions ci-dessous sont des **hypothèses métier à valider avec les utilisateurs**. Chaque besoin se calcule sur un fait filtré par ses dimensions. Les comptages de patients distincts excluent toujours le membre Inconnu (`sk_patient <> -1`).

Besoin	Profil	Fait	Numérateur	Dénominateur	Précisions
Taux de consultation dans un établissement X sur une période Y	Direction d'établissement	Consultation	consultations rattachées à X pendant Y	consultations de la période Y	Part d'activité de X. Le lieu est inféré par le professionnel (qualite_localisation = 'INFEREE')
Taux de consultation par diagnostic sur Y	Praticiens	Consultation	consultations du diagnostic D pendant Y	consultations de Y	D au niveau du code, de la catégorie ou du chapitre CIM-10
Taux global d'hospitalisation sur Y	Direction d'établissement	Hospitalisation et Consultation	patients distincts hospitalisés pendant Y	patients distincts ayant au moins une consultation ou une hospitalisation pendant Y	Le dénominateur contient le numérateur : le taux ne dépasse jamais 100 %
Taux d'hospitalisation par diagnostic sur Y	Praticiens	Hospitalisation	séjours pour le diagnostic D pendant Y	séjours de Y	Part des séjours. Diagnostic du séjour, pas de la consultation : l'inventaire n'en relie que 0,12 %
Taux d'hospitalisation par sexe, par âge sur Y	Praticiens et direction	Hospitalisation et Consultation	patients distincts hospitalisés du groupe	patients distincts suivis du même groupe (même population que le taux global)	Groupe : sexe ou tranche d'âge à la date de l'acte
Taux de consultation par professionnel sur Y	Direction d'établissement	Consultation	consultations du professionnel P pendant Y	consultations de Y	Part d'activité de P
Décès par région en 2019	Direction du groupe	Décès	somme de nb_deces, année 2019, par région	Sans objet	Région de la commune du décès. Les décès sans lieu restent visibles dans « Inconnu »

Besoin	Profil	Fait	Numérateur	Dénominateur	Précisions
Satisfaction globale par région en 2020	Direction du groupe	Satisfaction	somme de score_ponderee	somme de nb_repondants	Moyenne pondérée par le nombre de répondants, calculée par enquête : les questionnaires 48 h et ambulatoire ne se mélangent pas. Les établissements sans score (effectif insuffisant) sont exclus

Règles de construction :

- **Clés de substitution**. Chaque dimension a une clé sk_ entière générée par l'entrepôt, différente de la clé de la source, gardée comme clé naturelle. Une nouvelle ligne reçoit la plus grande clé existante plus son rang ; une ligne déjà chargée garde sa clé d'un mois à l'autre.
- **Membre « Inconnu »**. La ligne sk = -1 de chaque dimension reçoit les faits sans correspondance. Une correspondance absente ne supprime donc pas le fait, et aucune clé étrangère n'est vide. Les lignes invalides (identifiant vide, date illisible) suivent, elles, les règles de rejet de la section 8.
- **Clés primaires et intégrité**. Chaque fait a une clé primaire logique : id_consultation, id_hospitalisation, cle_deces et, pour la satisfaction, le triplet FINESS géographique + enquête + année de campagne, unique dans chaque fichier. Hive n'applique pas les contraintes de clé : ce sont les traitements qui les garantissent (COALESCE vers -1, tests d'unicité du job de contrôle wf_30_controles).
- **Première forme normale et dénormalisation**. Chaque cellule porte une valeur atomique. Région et département sont recopiés dans Établissement et Professionnel au lieu d'être des tables séparées : pas de flocon, une jointure par axe.
- **Mesures et attributs**. Les mesures sont additives : comptages (toujours 1 par ligne) et sommes (durée, répondants, score pondéré). Un taux ne s'additionne pas : il se calcule à la requête. L'âge, la tranche d'âge et le sexe portés par les faits sont des attributs d'analyse, pas des mesures.
- **Granularité du temps**. Consultations, hospitalisations et décès sont datés au jour (les 646 dates de décès incomplètes sont signalées par date_deces_approx). La satisfaction est annuelle : rattachée au 1er janvier de la campagne, elle ne s'analyse qu'à l'année.
- **Qualité de la localisation**. Chaque fait porte qualite_localisation : CONNUE (établissement du séjour, commune du décès), INFEREE (consultation, par le professionnel), REGION (satisfaction sans commune) ou INCONNUE.

- **Historisation de type 1**. Un attribut corrigé à la source écrase l'ancienne valeur (MERGE). Conséquence : si un établissement change de commune, son activité passée est relue avec la nouvelle localisation. Les besoins exprimés ne suivent pas l'historique des rattachements ; sinon, il faudrait une historisation de type 2.

4. Hiérarchie du datalake

Le lac HDFS est rangé en quatre niveaux : couche, source, table, chargement. Chaque table externe Hive pointe sur un seul dossier, et chaque chargement mensuel y ajoute un sous-dossier, vu par Hive comme une partition. Ainsi, un chargement de dimension n'écrase jamais celui d'une autre, et un mois se rejoue sans toucher aux autres.

```
/data/bronze/                                      couche (copie fidèle, tables externes)
├── pg/                                             source 1 : PostgreSQL
│   ├── patient/chargement=2026-10/patient.csv            → bronze.pg_patient
│   ├── professionnel/chargement=2026-10/                 → bronze.pg_professionnel
│   ├── specialite/chargement=2026-10/                    → bronze.pg_specialite
│   ├── diagnostic/chargement=2026-10/                    → bronze.pg_diagnostic
│   └── consultation/chargement=2026-10/                  → bronze.pg_consultation
├── referentiel/                                    source 2 : annuaire santé
│   ├── etablissement/chargement=2026-10/                 → bronze.ref_etablissement
│   ├── activite/chargement=2026-10/                      → bronze.ref_activite
│   └── statique/departement_region | chapitre_cim10 | mois/   (versionnés dans Git)
├── fichiers/                                       export du SI du CHU
│   └── hospitalisation/chargement=2026-10/               → bronze.fic_hospitalisation
└── ftp/                                            sources 3 et 4 : serveur FTP
    ├── deces/chargement=2026-10/                         → bronze.ftp_deces
    └── satisfaction/enquete=48h|ca/campagne=2019|2020/ → bronze.ftp_satisfaction

/user/hive/warehouse/
├── silver.db/<table>/                              tables gérées ORC transactionnelles
└── gold.db/dim_<axe>/  fait_<sujet>/annee=<aaaa>/   schéma en étoile, faits partitionnés
```

Niveau	Règle	Raison
1. Couche	bronze, puis les entrepôts silver.db et gold.db	Des droits différents par couche : en production, seuls les jobs écrivent en Bronze et Superset ne lit que Gold.
2. Source	pg, referentiel, fichiers, ftp	L'origine d'un fichier se lit dans son chemin. Ajouter une source revient à ajouter un dossier.
3. Table	un dossier par table ou fichier source	Une table externe Hive lit tout son dossier : deux entités dans le même dossier se mélangeraient. Chaque dimension est donc chargée depuis ses propres répertoires.
4. Chargement	chargement=yyyy-MM (sources mensuelles), enquete= puis campagne= (satisfaction annuelle)	Une partition par mois : Silver ne lit que le mois courant, un mois raté se rejoue seul, l'historique reste disponible pour l'audit.

Trois conventions complètent la hiérarchie. Les tables Bronze sont **externes** : supprimer une table ne supprime pas les fichiers. Toutes leurs colonnes sont en `STRING`, le typage se faisant en Silver (schéma à la lecture). Enfin, la zone de transit du poste reproduit la même arborescence : le job de dépôt copie chaque dossier dans HDFS, puis déclare la nouvelle partition à Hive.

Chaque dimension a ses propres répertoires, en entrée comme en sortie :

Dimension	Répertoires Bronze lus	Répertoire Gold
Patient	pg/patient/	gold.db/dim_patient/
Professionnel	pg/professionnel/, pg/specialite/, referentiel/activite/	gold.db/dim_professionnel/

Dimension	Répertoires Bronze lus	Répertoire Gold
Diagnostic	pg/diagnostic/, plus les codes de pg/consultation/ et fichiers/hospitalisation/	gold.db/dim_diagnostic/
Établissement	referentiel/etablissement/	gold.db/dim_etablissement/
Localisation	referentiel/etablissement/, ftp/deces/, ftp/satisfaction/, referentiel/statique/departement_region/	gold.db/dim_localisation/
Temps	dates de pg/consultation/, fichiers/hospitalisation/, ftp/deces/ et ftp/satisfaction/	gold.db/dim_temps/

Une dimension n'écrit que dans son propre répertoire Gold : recharger l'une ne touche jamais les autres.

5. Contextes et variables

Les contextes Talend deviennent un environnement Hop, `chu-local`, formé de deux fichiers de variables. Aucun pipeline ne contient de chemin propre à un poste, de mot de passe ni de sel : ils lisent tous `${VARIABLE}`. Passer en production revient à créer un environnement `chu-prod` avec d'autres fichiers ; les pipelines ne changent pas.

Variable	Fichier	Utilisée par
PROJECT_DIR, ECHANGE_DIR	hop-env/chu-commun.json (versionné)	Chemins de sortie des pipelines, dossier de travail des commandes du cluster
DATE_CHARGEMENT	chu-commun.json, écrasée par le paramètre de wf_main_mensuel	Nom des partitions Bronze, filtre des scripts Silver
PG_HOST, PG_PORT, PG_DB, PG_USER	chu-commun.json	Connexion pg_sources aux tables PostgreSQL
FTP_HOST, FTP_PORT, FTP_USER	chu-commun.json	Actions « Get a file with FTP » de wf_01
HIVE_HOST, HIVE_PORT	chu-commun.json	Connexion hive_entrepot et adresse de HiveServer2 utilisée pour lancer les scripts Silver et Gold
HIVE_SERVICE, HDFS_SERVICE	chu-commun.json	Services du cluster qui exécutent les commandes Hive et HDFS (conteneurs hiveserver2 et namenode sur la maquette)
BRONZE_ROOT	chu-commun.json	Racine du lac dans HDFS (/data/bronze), utilisée par le job de dépôt
DATA_DIR	hop-env/chu-poste.json (non versionné)	Lecture des fichiers établissements, activité et hospitalisations
PG_PASSWORD, FTP_PASSWORD	chu-poste.json	Connexion PostgreSQL, serveur FTP
PSEUDO_SALT	chu-poste.json, même valeur pour les trois membres	Hachage dans Hop de l'identifiant patient et de l'identité des décès

Des paramètres complètent les variables. Le sous-workflow qui lance un script Hive reçoit le nom du script ; celui qui dépose un dossier dans HDFS reçoit le chemin et la table cible. Les pipelines de satisfaction reçoivent la campagne, le fichier et son encodage : un même pipeline lit ainsi 2019 ou 2020. Les scripts Hive reçoivent le mois chargé comme variable d'exécution.

Exemple, pour la dimension Patient : le pipeline `p_pg_patient` se connecte par `pg_sources`, dont l'hôte, le port, la base et le compte valent `${PG_HOST}`, `${PG_PORT}`, `${PG_DB}` et `${PG_USER}`, le mot de passe `${PG_PASSWORD}`. Il hache l'identifiant avec `${PSEUDO_SALT}` et écrit son fichier dans `${ECHANGE_DIR}/bronze/pg/patient/chargement=${DATE_CHARGEMENT}/`. Le job de dépôt copie ce dossier sous `${BRONZE_ROOT}/pg/patient/` par le service `${HDFS_SERVICE}`, puis les scripts Silver et Gold sont lancés sur `${HIVE_HOST}:${HIVE_PORT}`. Sur un autre poste ou en production, seules les valeurs changent, jamais le job.

6. Jobs des dimensions

Chaque dimension a son workflow Hop. Il enchaîne l'extraction de ses sources propres (pipeline puis dépôt HDFS), le script Silver puis le script Gold. Les sources lues par plusieurs dimensions et par les faits (établissements, hospitalisations, consultations, décès, satisfaction) sont extraites une seule fois par `wf_01_sources_partagees`. Toutes les dimensions sont alimentées **une fois par mois**, le 1er à 02:00 (section 8).

6.1 Dimension Patient

Élément	Contenu
Job	wf_14_dim_patient : extraction de la table Patient et hachage de l'identifiant (Hop) → dépôt en Bronze → typage (Silver) → mise à jour de la dimension (Gold)
Source	Table Patient de PostgreSQL, 100 000 lignes
Champs retenus	Id_patient (haché dans Hop, jamais stocké en clair), Sexe (female/male → F/M), Date réduite à l'année de naissance dans la requête d'extraction (format source M/d/yyyy)
Champs écartés	Les 13 autres colonnes, dont nom, adresse, téléphone et n° de sécurité sociale
Clé	sk_patient, entier généré. Clé naturelle : patient_pseudo = SHA-256(sel + Id_patient)
Chargement	Instantané mensuel complet ; MERGE met à jour les patients connus, INSERT ajoute les nouveaux
Contrôle attendu	100 000 patients plus le membre Inconnu, aucun pseudonyme en double

6.2 Dimension Professionnel

Élément	Contenu
Job	wf_13_dim_professionnel : extraction des professionnels, des spécialités et des activités (Hop) → dépôt en Bronze → jointures et choix de l'organisation principale (Silver) → mise à jour de la dimension (Gold)
Sources	Professionnel_de_sante (1 048 575 lignes) et Specialites (93) de PostgreSQL. activite_professionnel_sante.csv de l'annuaire santé (1 823 588 lignes) : c'est le second schéma de données qui donne l'établissement des professionnels. L'inventaire ne trouve pas d'autre schéma dans PostgreSQL.
Champs retenus	Identifiant RPPS ou ADELI, type d'identifiant, catégorie, profession, spécialité (code, libellé, fonction), organisation principale, mode d'exercice, nombre d'organisations
Jointures	Professionnel → spécialité par Code_specialite ; professionnel → activité par identifiant (86,7 % trouvés) ; activité → établissement par identifiant_organisation (100 %)

Élément	Contenu
Organisation principale	131 399 professionnels exercent dans plusieurs organisations. On retient la première localisable, en préférant un établissement FINESS, puis le plus petit identifiant. La règle est reproductible d'un mois à l'autre.
Clé	sk_professionnel, entier généré. Clé naturelle : identifiant
Contrôle attendu	Environ 63,9 % des consultations reçoivent par ce chemin un lieu estimé (qualité INFEREE), et non le lieu réel de l'acte

6.3 Dimension Diagnostic

Élément	Contenu
Job	wf_15_dim_diagnostic : extraction de la table Diagnostic (Hop) → dépôt en Bronze → nettoyage des codes et union avec les codes des faits (Silver) → mise à jour de la dimension (Gold)
Sources	Table Diagnostic de PostgreSQL (15 490 codes CIM-10) ; colonnes Code_diagnostic et Suite_diagnostic_consultation (libellé) du fichier Hospitalisations ; codes de la table Consultation
Transformations	Codes nettoyés (majuscules, sans espace ni point). Libellé de PostgreSQL prioritaire, puis celui du fichier. Ajout de la catégorie (3 caractères) et du chapitre CIM-10 (22 chapitres, référentiel versionné).
Clé	sk_diagnostic, entier généré. Clé naturelle : code_diag
Contrôle attendu	15 490 codes ; 100 % des codes d'hospitalisation et de consultation trouvés (étude des sources)

Le fichier des établissements ne contient aucun diagnostic : ses 24 colonnes décrivent l'identité et l'adresse des organisations. Il n'alimente donc pas cette dimension.

6.4 Dimension Localisation

Élément	Contenu
Job	wf_11_dim_localisation : union des codes commune déjà en Bronze et du référentiel départements et régions (Silver) → mise à jour de la dimension (Gold)
Sources	Codes commune INSEE des établissements (12 556 codes) et des communes de décès (13 169 codes), référentiel départements → régions (107 départements, 18 régions plus outre-mer et étranger)
Lien avec les faits	Consultation : professionnel → organisation → commune. Hospitalisation : organisation → commune. Décès : commune du décès. Satisfaction : FINESS géographique → commune, sinon libellé de région du fichier.
Transformations	Département = 2 premiers caractères du code, 3 pour l'outre-mer. Corse en 2A/2B et ancien code 20. Une ligne de niveau Région par région, pour les faits dont seule la région est connue.
Clé	sk_localisation, entier généré. Clé naturelle : code_lieu (code commune ou REG-<code région>)

Élément	Contenu
Contrôle attendu	Plus de 98,9 % des décès rattachés à une région (étude des sources)

6.5 Dimension Temps

Élément	Contenu
Job	wf_10_dim_temps : union des dates des quatre faits, converties en DATE (Silver) → génération du calendrier et mise à jour de la dimension (Gold)
Sources	Dates des quatre faits, réunies dans silver.dates_sources : consultations (yyyy-MM-dd), hospitalisations (dd/MM/yyyy), décès (complètes ou partielles), campagnes de satisfaction (année seule → 1er janvier)
Transformations	Conversion de chaque format en DATE. Calendrier continu du 1er janvier de la plus ancienne année au 31 décembre de la plus récente, soit environ 51 900 jours de 1882 à 2023 : un jour sans événement existe quand même.
Attributs	Jour, jour de la semaine et libellé, semaine, mois et libellé, annee_mois, trimestre, semestre, année, week-end
Clé	sk_temps, rang chronologique attribué une fois. Clé naturelle : date_jour
Contrôle attendu	Une seule ligne par jour, aucun fait sans date

6.6 Dimension Établissement

Élément	Contenu
Job	wf_12_dim_etablissement : typage et nettoyage du référentiel établissements déjà en Bronze (Silver) → mise à jour de la dimension (Gold)
Source	etablissement_sante.csv, 416 665 organisations
Transformations	Type déduit du préfixe de l'identifiant (F FINESS, R RPPS, C SIRET). Zéro initial du code postal rétabli. Raison sociale gardée pour les seuls établissements FINESS, celle d'un cabinet pouvant contenir le nom d'un praticien. Département et région recopiés depuis la localisation.
Clé	sk_etablissement, entier généré. Clé naturelle : identifiant_organisation
Contrôle attendu	100 % des hospitalisations et 98 à 99 % des établissements e-Satis trouvés (étude des sources)

7. Job des faits

Les quatre faits sont chargés par `wf_20_faits`, après toutes les dimensions : chaque clé étrangère est alors une clé `sk_` existante, ou `-1`. Leurs sources sont extraites en Bronze par `wf_01_sources_partagees`. Le flux est ELT : Hop extrait et charge, puis Hive transforme sur le moteur distribué. Les transformations restent ainsi rejouables depuis Bronze sans relire les sources.

Fait	Grain	Source et pipeline	Mesures additives	Attributs d'analyse	Clés étrangères	Lignes attendues
fait_consultation	une consultation	Consultation, p_pg_consultation	nb_consultation (1)	âge, tranche d'âge, qualité du lieu	temps, patient, professionnel, diagnostic, établissement, localisation	1 027 157
fait_hospitalisation	un séjour	Hospitalisations.csv, p_fic_hospitalisation	nb_hospitalisation (1), duree_sejour_jours	âge, tranche d'âge, qualité du lieu	temps (entrée), patient, diagnostic, établissement, localisation	2 479
fait_deces	un décès	deces.csv par FTP, p_ftp_deces	nb_deces (1)	sexe, âge, tranche d'âge, date approchée, qualité du lieu	temps, localisation	24 875 168 (25 088 208 moins 213 040 doublons)
fait_satisfaction	un établissement, une enquête, une campagne	e-Satis 2019 et 2020 par FTP, p_ftp_esatis*	nb_evaluations, nb_repondants, score_pondere, nb_recommandations	enquête, classement, qualité du lieu	temps (campagne), établissement, localisation	4 178

Quatre traitements méritent d'être signalés :

- **Consultation**. Établissement et localisation viennent de l'organisation principale du professionnel, la consultation n'ayant pas de colonne lieu. Ce lieu est une estimation, marquée INFEREE. L'âge est calculé à la date de l'acte, à un an près, puisque seule l'année de naissance est conservée.
- **Décès**. Le pipeline Hop calcule cle_deces = SHA-256(sel + nom, prénom, date de naissance, date et lieu du décès), puis écarte l'identité. Silver dédoublonne sur cette clé. Les 646 dates partielles sont ramenées au 1er du mois ou de l'année et marquées date_deces_approx.
- **Satisfaction**. Les deux enquêtes et les deux formats sont ramenés à dix colonnes communes. score_pondere vaut score_global × nb_repondants quand le score existe, et

reste vide sinon (effectif insuffisant, classement DI). Le score d'une région se calcule par enquête : somme de score_pondere divisée par la somme de nb_repondants.

Le mode de rechargement dépend de la source :

Source	Livraison	Ce que lit Silver	Gold	Purge de Bronze
Tables PostgreSQL, référentiel, hospitalisations	Instantané complet chaque mois	La partition du mois seulement	Dimensions mises à jour (MERGE), faits reconstruits	Les 3 derniers instantanés sont gardés
Décès INSEE	Stock initial, puis un fichier par mois (delta)	Toutes les partitions, dédoublonnées	Fait reconstruit depuis tout l'historique	Jamais : chaque delta est une partie de l'historique
Satisfaction e-Satis	Une campagne par an et par enquête	Toutes les campagnes	Fait reconstruit	Jamais : une campagne remplace seulement sa propre partition

Une correction à la source arrive ainsi par l'instantané suivant ; une campagne republiée écrase sa partition `campagne=`. Les clés des dimensions étant stables, deux chargements successifs donnent les mêmes clés aux mêmes lignes.

8. Ordonnancement, qualité et limites

Le workflow `wf_main_mensuel` charge tout l'entrepôt le 1er de chaque mois à 02:00. Il s'arrête à la première étape en échec, et le chargement du mois est alors déclaré en échec. Les contrôles s'exécutant après l'écriture des faits, ils alertent mais ne retirent pas ce qui est déjà écrit. Une vraie publication après contrôle (tables temporaires, puis bascule) est prévue pour la production, pas pour la maquette. `wf_00_initialisation` crée bases, tables et référentiels une seule fois avant le premier chargement.

1. `wf_01_sources_partagees` : FTP puis extraction en Bronze des établissements, hospitalisations, consultations, décès et satisfaction.
2. `wf_10_dim_temps`, qui a besoin des dates de toutes les sources.
3. `wf_11_dim_localisation`.
4. `wf_12_dim_etablissement`, qui reprend la localisation.
5. `wf_13_dim_professionnel`, qui reprend l'établissement principal.
6. `wf_14_dim_patient` puis `wf_15_dim_diagnostic`, indépendantes.
7. `wf_20_faits`, une fois toutes les dimensions chargées.
8. `wf_30_controles`.

Le planificateur du système (cron sous Linux et macOS, Planificateur de tâches sous Windows) lance ce workflow le 1er de chaque mois à 02:00, avec le mois à charger en paramètre.

Le mois chargé nomme les partitions Bronze. Le sujet prévoit une mise à jour des sources tous les trois mois : le job mensuel la couvre sans modification, un mois sans nouvelle donnée produisant simplement le même résultat.

Contrôle	Règle	Effet en cas d'échec
Unicité des clés	`sk_` et clé naturelle uniques dans chaque dimension	Bloquant (assert_true)
Unicité du grain	Un identifiant de consultation, de séjour, de décès par ligne ; un triplet FINESS géographique, enquête, année par ligne de satisfaction	Bloquant
Exhaustivité	Autant de lignes en Gold qu'en Silver pour chaque fait	Bloquant
Format du pseudonyme	Tout patient_pseudo est un hachage SHA-256 de 64 caractères hexadécimaux. Le test vérifie le format attendu du pseudonyme, rien de plus	Bloquant
Lignes écartées	Écart entre Bronze et Silver, source par source	Rapport dans le journal Hop
Valeurs hors plage	Âge hors 0–120 ans, durée de séjour absente ou négative, score hors 0–100	Rapport
Complétude	Part des faits rattachés au membre -1, par dimension	Rapport

Valeurs nulles, doublons, erreurs et rejets sont traités ainsi, de la source au fait :

Anomalie	Action	Où la voir	Reprise
Identifiant vide (patient, consultation, séjour, décès, établissement)	Ligne écartée en Silver	Contrôle « Lignes écartées »	Corriger la source ; l'instantané suivant la reprend
Date illisible	Ligne écartée en Silver	Contrôle « Lignes écartées »	Idem
Date de décès incomplète	Ramenée au 1er du mois ou de l'année, gardée	date_deces_approx = true	Aucune nécessaire
Doublon exact, ou même clé avec des valeurs différentes	Doublon exact : une seule ligne gardée. Même clé et valeurs différentes dans un même instantané : pour une consultation, dont le numéro est clé primaire dans PostgreSQL, c'est un conflit d'extraction, et toutes les lignes en conflit sont rejetées plutôt que d'en choisir une au hasard. Pour un décès, la clé reprend déjà l'identité, la date et le lieu : seuls le sexe ou l'année de naissance peuvent différer, et la ligne la plus renseignée est gardée. Entre deux chargements de décès, le plus récent gagne	Contrôle « Lignes écartées »	Consultation en conflit : corriger la source, l'instantané suivant reprend la ligne, et le rejet reste visible dans audit.journal_chargement. Décès : aucune, la règle est déterministe
Correspondance absente (patient, diagnostic, lieu…)	Fait gardé, rattaché au membre -1	Contrôle « Complétude »	Automatique dès que la dimension contient la ligne
Durée de séjour négative	Durée mise à vide, séjour gardé	Contrôle « Valeurs hors plage »	Corriger la source
Score e-Satis absent	Évaluation gardée, exclue de la moyenne	`score_pondere` vide	Aucune nécessaire
Attribut vide (sexe, année de naissance, commune)	Ligne gardée : sexe à I, tranche d'âge « Inconnu », âge vide, lieu rattaché au membre -1	Contrôle « Complétude »	Automatique dès que la source est complétée
Source injoignable, fichier absent ou script en erreur	Le workflow s'arrête à l'étape en échec, le mois est déclaré en échec	Journal Hop du workflow	Relancer le mois après correction : les partitions du mois sont écrasées, sans doublon

Les lignes Bronze ne sont jamais modifiées : toute reprise consiste à rejouer Silver et les faits depuis Bronze. Les dimensions Gold, elles, sont mises à jour mais jamais reconstruites de zéro, pour garder leurs clés.

Chaque script Silver et Gold se termine aussi par une requête de comptage, affichée dans le journal de son action. C'est le suivi du chargement, mois après mois.

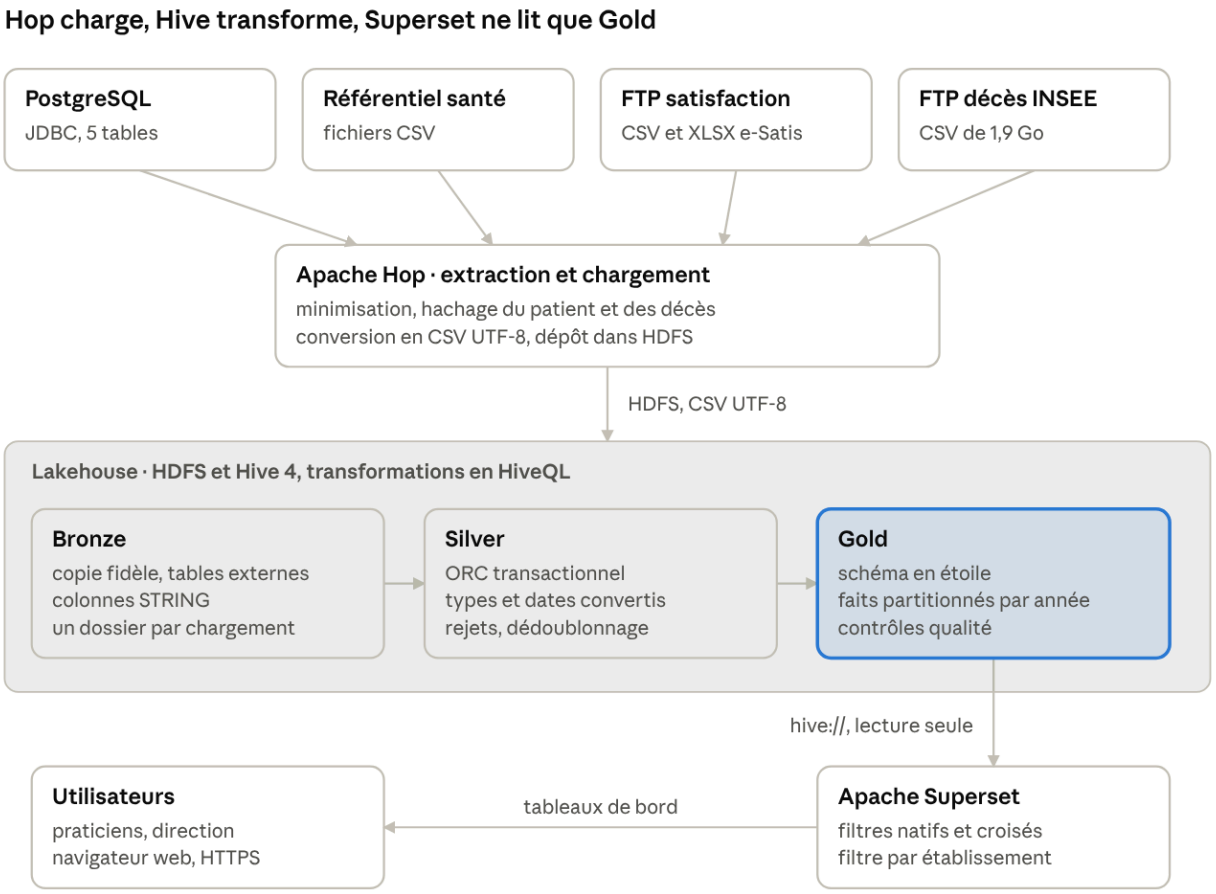
Limites connues :

- **Le lieu de 36 % des consultations est inconnu, celui des autres est estimé**. Le professionnel n'a pas d'activité dans l'annuaire, ou son organisation n'a pas de commune. Quand il exerce dans plusieurs établissements, la règle d'organisation principale ne dit pas où l'acte a eu lieu. Les analyses par établissement et par région des consultations doivent l'afficher. La commune du fichier professionnel_sante.csv pourrait servir de repli, au prix d'une jointure par nom de commune.
- **Le stock des décès pèse 1,9 Go**. Tant que le FTP ne sert que ce stock, il est relu chaque mois et dédoublonné en Silver. En production, le dossier FTP ne recevrait que le fichier mensuel de l'INSEE.
- **Le sel de pseudonymisation est stocké dans un fichier du poste**. Ce fichier est exclu de Git, et c'est acceptable sur un poste isolé, les services n'écoutant que sur 127.0.0.1. La cible de production le lit dans un coffre de secrets, derrière Kerberos.
- **Les données semblent synthétiques par endroits**. 2 479 séjours ont lieu dans 2 479 établissements différents, et l'annuaire des professionnels est tronqué à 1 048 575 lignes, la limite d'Excel. Les sources chargées ne se recouvrent qu'en 2019.

La restitution n'entre pas dans ce livrable. Superset lira uniquement la base `gold`, et les tableaux de bord feront l'objet du livrable 3. Le choix de Superset, sa place dans l'architecture et la cible de production sont justifiés en section 9.

9. Architecture et choix techniques

L'architecture est un lakehouse en trois couches alimenté en ELT : Hop extrait et charge, Hive transforme sur le moteur distribué, Superset restitue Gold aux utilisateurs. Chaque composant est open source et peut tourner chez un hébergeur certifié HDS.



flux de bout en bout : sources → Hop → lakehouse → Superset

Les contrôles suivent le flux : minimisation et pseudonymisation dans Hop avant tout stockage, rejets en Silver, tests de qualité sur Gold, lecture seule pour Superset.

Le bloc prévoyait Talend, une machine virtuelle Cloudera et Power BI. Talend Open Studio n'est plus distribué depuis janvier 2024 et la machine Cloudera n'est plus maintenue depuis 2020 : l'équipe a retenu des équivalents maintenus et open source, qui gardent les mêmes notions.

Notion Talend / Cloudera	Équivalent dans ce projet
Job	Workflow Hop (.hwf)
Sous-job de lecture et d'écriture	Pipeline Hop (.hpl)
Contexte et variables de contexte	Environnement Hop et ses fichiers de variables
Métadonnée de connexion	Connexion `pg_sources` du projet Hop
Cluster Cloudera (HDFS, Hive)	Conteneurs namenode, datanode et hiveserver2 du compose.yaml

Composant	Rôle	Pourquoi ce choix	Limite dans la maquette
Apache Hop 2.19	Extraction, chargement, orchestration	Projet de la fondation Apache, maintenu, alors que Talend Open Studio n'est plus distribué depuis janvier 2024. Pipelines en fichiers texte versionnés dans Git, connecteurs JDBC, FTP et Excel, contextes par environnement	Lancé sur le poste par hop-run, pas sur un serveur
HDFS 3	Stockage du lac	Accepte tout format sans schéma préalable, réplique les blocs, s'étend en ajoutant des nœuds	Un seul DataNode, réplication 1
Hive 4, tables ORC transactionnelles	Transformations et entrepôt	SQL standard sur données distribuées, tables externes sur Bronze, stockage ORC compressé en colonnes. Les tables ACID permettent MERGE et les vues matérialisées du livrable d'optimisation	Exécution Tez en mode local, sans YARN
PostgreSQL	Source opérationnelle, métadonnées de Hive	Base existante, conservée telle quelle sans migration	Aucune
Apache Superset 6	Restitution	Application web identique sur Windows, macOS et Linux, connecteur Hive natif, filtres natifs et croisés, rôles et filtrage par ligne. Installable chez l'hébergeur HDS retenu, sans licence par utilisateur. Power BI Desktop ne fonctionne que sous Windows, et le partage par le service Power BI, accessible par navigateur, demande une licence par utilisateur ou une capacité dédiée, et passe par le cloud de Microsoft	Compte local, sans authentification d'entreprise
Docker Compose	Déploiement	Même environnement pour les trois membres, démarré en une commande, versions figées	Remplacé par un cluster en production

Chaque rôle a été comparé aux options citées par le cahier des charges, sur les mêmes critères : outil maintenu, coût de licence, fonctionnement identique sous Windows, macOS et Linux, déploiement possible chez un hébergeur certifié HDS, adéquation au flux ELT sur Hive.

Rôle	Option	Atout principal	Décision
Intégration	Talend Open Studio	Outil graphique connu, connecteurs Hadoop	Écarté : plus distribué ni corrigé depuis janvier 2024

Rôle	Option	Atout principal	Décision
Intégration	Apache NiFi	Flux continus, traçabilité de chaque donnée	Écarté : conçu pour des flux continus, alors que nos sources arrivent en lots mensuels et que les jobs s'enchaînent dans un ordre strict
Intégration	dbt	Transformations SQL versionnées et testées, fait pour l'ELT	Écarté pour ce lot : dbt ne fait que la transformation, il faudrait un second outil pour extraire PostgreSQL et le FTP ; son adaptateur Hive est maintenu par la communauté. Piste d'évolution pour les scripts Silver et Gold
Intégration	Apache Hop	Extraction, chargement et orchestration dans un seul outil maintenu	Retenu
Stockage	PostgreSQL	Simple, suffit au volume actuel	Écarté comme entrepôt : il grandit en renforçant un seul serveur, alors que la cible doit s'étendre en ajoutant des nœuds. Il reste la source opérationnelle
Stockage	BigQuery	Aucun serveur à gérer, très rapide	Écarté : service d'un fournisseur extra-européen facturé à la requête, impossible à faire tourner sur un poste pour la maquette ; l'hébergement et les transferts hors UE seraient à justifier dans l'AIPD
Stockage	Hive 4 sur HDFS	Tables externes sur le lac, partitionnement, vues matérialisées	Retenu
Restitution	Power BI	Très répandu, riche en visuels	Écarté : Desktop limité à Windows, partage soumis à une licence par utilisateur et au cloud de Microsoft
Restitution	Metabase	Simple, open source, questions sans SQL	Écarté : pas de connecteur Hive officiel, et le filtrage des lignes par utilisateur est réservé aux éditions payantes
Restitution	Apache Superset	Connecteur Hive natif, filtres croisés, filtrage par ligne inclus	Retenu

Sources : arrêt de Talend Open Studio (Qlik), bases prises en charge par Metabase, filtrage par ligne de Metabase.

Aspect	Maquette locale	Cible de production
Hébergement	Postes des membres, conteneurs Docker	Hébergeur certifié HDS, données en France ou dans l'UE

Aspect	Maquette locale	Cible de production
Calcul	Tez local dans le conteneur HiveServer2	Hive sur YARN, plusieurs nœuds de calcul
Stockage	1 DataNode, réplication 1	Au moins 3 DataNodes, réplication 3, zones chiffrées
Ordonnancement	cron et hop-run	Serveur Hop ou ordonnanceur d'entreprise, alertes en cas d'échec
Sécurité	Ports liés à 127.0.0.1, pas d'authentification	Kerberos, Apache Ranger, TLS, authentification unique sur Superset
Transferts	FTP local	SFTP
Sauvegarde	Aucune : données pédagogiques reconstructibles	Snapshots HDFS de Bronze, copie chiffrée sur un second site

- **Coût**. Tous les composants sont sous licence Apache 2.0 ou PostgreSQL : aucune licence à payer, ni pour la maquette ni pour la production. Le coût de production n'est pas nul pour autant : hébergement HDS, intégration, sécurisation, maintenance et sauvegardes en forment l'essentiel, et demandent des compétences Hadoop.
- **Montée en charge**. Les sources pèsent environ 2,6 Go aujourd'hui (2,2 Go de fichiers, 343 Mo dans PostgreSQL), un volume qu'un PostgreSQL bien indexé absorberait. Le choix d'Hadoop répond au cadre pédagogique du projet et à la perspective de croissance : nouvelles sources, historique sur plusieurs années, autres établissements du groupe. Ajouter des DataNodes et des nœuds de calcul augmente la capacité sans changer le code. Le partitionnement par année borne le volume lu par une requête sur une période. Superset, sans état, se réplique derrière un répartiteur de charge.
- **Protection des données**. Minimisation et pseudonymisation à l'extraction, accès par couche, chiffrement et journalisation en production : le détail est dans le plan de gouvernance (section 10).

10. Plan de gouvernance des données

L'entrepôt traite des données de santé à caractère personnel, catégorie particulière au sens de l'article 9 du RGPD. Le plan fixe qui décide, qui accède à quelle couche, combien de temps les données restent et comment chaque traitement est tracé. Pour chaque point, il distingue ce que la maquette applique déjà de ce que la production devra ajouter. Les durées marquées « proposition » sont à arrêter par le responsable de traitement avec le DPO, dans l'analyse d'impact (AIPD).

10.1 Responsables

Rôle	Tenu par	Responsabilités
Responsable de traitement	Direction du groupe CHU	Fixe la finalité (pilotage de l'activité et de la qualité des soins), valide l'AIPD, contracte avec l'hébergeur certifié HDS
Délégué à la protection des données (DPO)	DPO du groupe	Inscrit le traitement au registre, conduit l'AIPD avec l'équipe projet, contrôle les accès et les durées, reste le contact de la CNIL
Propriétaires des données	Département d'information médicale (activité), direction qualité (satisfaction), DSI (référentiels)	Valident les règles métier (définitions des taux, règles de rejet) et arbitrent les corrections à la source
Responsable technique	Équipe projet (ingénierie des données)	Maintient jobs et contrôles, détient le sel et les secrets, exécute les purges ; seul profil humain à accéder à Bronze
Administrateur de plateforme	Hébergeur HDS ou DSI	Infrastructure, comptes, chiffrement, sauvegardes, journaux système
Utilisateurs	Praticiens, direction d'établissement, chercheurs	Consultent les tableaux de bord Superset, sans accès direct aux tables

10.2 Matrice des accès

Compte	Bronze	Silver	Gold	Superset
Service d'extraction (pipelines Hop, dépôt HDFS)	Lecture, écriture	Aucun	Aucun	Aucun
Service de transformation (scripts Hive lancés par Hop)	Lecture	Lecture, écriture	Lecture, écriture (dimensions lues pour charger les faits)	Aucun
Service Superset	Aucun	Aucun	Lecture seule	Aucun
Responsable technique	Lecture (diagnostic d'incident)	Lecture	Lecture	Administration

Compte	Bronze	Silver	Gold	Superset
Propriétaires des données	Aucun	Lecture	Lecture	Création de tableaux de bord
Praticiens et direction	Aucun	Aucun	Aucun	Lecture, filtrée sur leur établissement
Chercheurs	Aucun	Aucun	Aucun	Tableaux agrégés uniquement
DPO	Journaux d'accès	Journaux d'accès	Journaux d'accès	Journaux d'accès

Les humains ne modifient jamais les couches directement : toute écriture passe par un compte de service, donc par un job tracé.

Cette matrice est la cible ; la maquette n'en applique qu'une partie. Superset n'y est connecté qu'à la base `gold`, et l'écoute sur `127.0.0.1` ferme les services au réseau. En revanche, Hive n'a pas d'authentification et les permissions HDFS sont désactivées : tout compte du poste peut lire et écrire toutes les couches, et la séparation des droits n'existe donc pas sur la maquette. En production, elle est assurée par des comptes de service distincts, Kerberos pour l'authentification, Apache Ranger pour les droits par base Hive et par répertoire HDFS, et les rôles de Superset avec filtrage par ligne sur l'établissement.

10.3 Conservation et purge

Données	Durée	Purge
echange/ et zone de transit FTP sur le poste	Jusqu'au dépôt dans HDFS	Vidées à chaque chargement (wf_01)
Bronze, sources en instantané (PostgreSQL, référentiel, hospitalisations)	3 derniers chargements mensuels ; les dimensions Gold sauvegardées gardent l'historique au-delà	Suppression des dossiers chargement= plus anciens
Bronze, décès et satisfaction	Tout l'historique : données ouvertes, et seule trace des deltas	Revue annuelle
Silver et Gold	Proposition : 10 années glissantes d'événements	Suppression annuelle de la partition annee la plus ancienne des faits
Journaux de chargement et d'accès	Proposition : 12 mois	Purge mensuelle
Sel de pseudonymisation	Aussi longtemps que des données pseudonymisées existent	Un changement de sel impose de réextraire les identifiants historiques ou de passer par une table de correspondance sécurisée (section 10.4)

10.4 Secrets, transferts et sauvegardes

- **Secrets**. Sur la maquette, mots de passe et sel sont dans .env et hop-env/chu-poste.json, exclus de Git et transmis entre membres hors du dépôt. En production, ils sont dans un coffre de secrets, lus par des comptes de service. Les mots de passe changent selon une

périodicité définie. Le sel de pseudonymisation, lui, ne change jamais en routine : un nouveau sel produirait d'autres pseudonymes et casserait les rapprochements avec l'historique. Il ne change qu'en cas de compromission. Le recalcul ne peut alors pas partir du lac, qui ne contient que des pseudonymes. Il faut soit réextraire de PostgreSQL les identifiants historiques, soit calculer dans une zone sécurisée une table de correspondance entre ancien et nouveau pseudonyme, puis la détruire après usage.

- **Transferts**. La maquette reste sur localhost. En production, le chiffrement TLS protège les flux vers HiveServer2 et Superset, et le FTP en clair est remplacé par SFTP.
- **Chiffrement au repos**. En production, les répertoires /data et l'entrepôt Hive sont placés dans des zones chiffrées HDFS.
- **Sauvegardes**. Deux couches sont sauvegardées. Bronze d'abord, d'où se reconstruisent Silver et les faits. Les dimensions Gold ensuite : elles gardent les membres disparus des sources et la correspondance entre clés naturelles et clés de substitution, que les trois derniers instantanés de Bronze ne suffiraient pas à retrouver. En production, les deux font l'objet de snapshots HDFS quotidiens et d'une copie chiffrée sur un second site. Le Metastore Hive est sauvegardé par pg_dump chaque jour, le code par le dépôt Git.

10.5 Traçabilité

- **Traitements**. Chaque exécution du job de contrôle wf_30_controles écrit une ligne par source dans audit.journal_chargement : horodatage, mois chargé, lignes lues en Bronze, lignes gardées en Silver, lignes écartées. Le journal Hop de chaque workflow complète cette trace (début, fin, statut de chaque étape), et le commit Git désigne la version du traitement.
- **Accès**. En production, Ranger journalise chaque requête sur Hive et HDFS (qui, quand, quelle table), et Superset conserve le journal des consultations de tableaux de bord. Le DPO consulte ces journaux.

10.6 Périmètre HDS

La certification HDS est celle de l'hébergeur, pas de l'architecture. Ni Docker, ni Kerberos, ni le chiffrement ne rendent à eux seuls une plateforme conforme. La cible place toute la chaîne chez un hébergeur certifié HDS : HDFS, Hive et son Metastore, serveur Hop, Superset et sauvegardes. Le contrat doit couvrir l'infrastructure physique, l'infrastructure matérielle et virtuelle, la plateforme d'exécution, l'administration et l'exploitation, ainsi que la sauvegarde externalisée.

La maquette tourne sur des postes personnels avec le jeu de données pédagogique du projet. Elle n'est pas un hébergement HDS et ne doit jamais recevoir de données réelles de patients.

10.7 Base légale, droits des personnes et cadre de la CNIL

Le groupe CHU étant un établissement public de santé, l'entrepôt se fonde sur l'exécution d'une mission d'intérêt public (article 6.1.e du RGPD). Pour ce cas, la CNIL a adopté le 7 octobre 2021 un référentiel des entrepôts de données de santé : un responsable conforme déclare sa conformité, sinon il doit demander une autorisation à la CNIL. Le tableau confronte ses principales exigences au plan.

Exigence du référentiel	Réponse du plan
Analyse d'impact (AIPD) réalisée, documentée et mise à jour	Conduite par le DPO avec l'équipe projet (10.1), mise à jour à chaque nouvelle source
Seul un identifiant pseudonyme dans l'entrepôt, aucun numéro interne	Identifiant patient haché dans Hop avant Bronze (section 2). Point ouvert : les numéros de consultation et de séjour, gardés comme clés des faits, sont aussi des numéros internes ; l'AIPD doit trancher entre les garder ou les hacher de la même façon
Information des patients sur le versement de leurs données dans l'entrepôt	Mention dans le livret d'accueil et l'affichage des établissements, à la charge du responsable de traitement
Droits d'accès, de rectification, d'effacement, de limitation et d'opposition ; opposition exerçable par tout moyen	Demandes reçues par le DPO. Une opposition rejoint une liste d'exclusion appliquée à l'extraction : le patient sort de la dimension et des faits au chargement suivant
Conservation de 20 ans au plus après la collecte, puis anonymisation ou destruction	Proposition de 10 années glissantes (10.3), sous ce plafond
Hébergeur de données de santé certifié, établi dans l'UE ou un pays adéquat	Section 10.6
Habilitations individuelles, journalisation des actions, traces gardées de 6 mois à 1 an	Matrice des accès (10.2), journaux gardés 12 mois (10.3 et 10.5)

Sources : référentiel de la CNIL sur les entrepôts de données de santé, annonce de son adoption.

Annexe : dictionnaire de données

Les 10 tables de la couche Gold, attribut par attribut. Les clés étrangères ne sont pas déclarées dans Hive : les traitements les garantissent (section 3).

Table	Attribut	Type	Clé	Nullable	Définition
dim_temps	sk_temps	BIGINT	PK	Non (-1 = Inconnu)	Clé de substitution du jour
dim_temps	date_jour	DATE	Clé naturelle, unique	Oui (membre Inconnu)	Date du jour (vide pour le membre Inconnu)
dim_temps	jour	INT	Aucune	Oui	Jour du mois, 1 à 31
dim_temps	jour_semaine	INT	Aucune	Oui	1 = lundi … 7 = dimanche
dim_temps	libelle_jour	STRING	Aucune	Oui	Lundi … Dimanche
dim_temps	semaine	INT	Aucune	Oui	Semaine de l'année
dim_temps	mois	INT	Aucune	Oui	1 à 12
dim_temps	libelle_mois	STRING	Aucune	Oui	Janvier … Décembre
dim_temps	annee_mois	STRING	Aucune	Oui	yyyy-MM
dim_temps	trimestre	INT	Aucune	Oui	1 à 4
dim_temps	semestre	INT	Aucune	Oui	1 ou 2
dim_temps	annee	INT	Aucune	Oui	Année
dim_temps	est_week_end	BOOLEAN	Aucune	Oui	Vrai le samedi et le dimanche
dim_temps	date_maj	TIMESTAMP	Aucune	Non	Horodatage du dernier chargement de la ligne
dim_localisation	sk_localisation	BIGINT	PK	Non (-1 = Inconnu)	Clé de substitution du lieu

Table	Attribut	Type	Clé	Nullable	Définition
dim_localisation	code_lieu	STRING	Clé naturelle, unique	Non	Code commune INSEE, ou REG-<code région> pour une ligne de niveau région
dim_localisation	niveau	STRING	Aucune	Oui	COMMUNE, REGION ou INCONNU
dim_localisation	nom_commune	STRING	Aucune	Oui	Nom de la commune (référentiel établissements)
dim_localisation	code_departement	STRING	Aucune	Oui	2 caractères, 3 en outre-mer
dim_localisation	nom_departement	STRING	Aucune	Oui	Libellé du département (COG INSEE)
dim_localisation	code_region	STRING	Aucune	Oui	Code région INSEE
dim_localisation	nom_region	STRING	Aucune	Oui	Libellé de la région
dim_localisation	date_maj	TIMESTAMP	Aucune	Non	Horodatage du dernier chargement de la ligne
dim_etablissement	sk_etablissement	BIGINT	PK	Non (-1 = Inconnu)	Clé de substitution de l'organisation
dim_etablissement	identifiant_organisation	STRING	Clé naturelle, unique	Non	Clé de l'annuaire santé : F+FINESS, R+RPPS, C+SIRET
dim_etablissement	type_organisation	STRING	Aucune	Oui	FINESS, RPPS ou SIRET, déduit du préfixe
dim_etablissement	finess	STRING	Aucune	Oui	FINESS géographique, pour les identifiants F
dim_etablissement	finess_juridique	STRING	Aucune	Oui	FINESS de l'entité juridique

Table	Attribut	Type	Clé	Nullable	Définition
dim_etablissement	raison_sociale	STRING	Aucune	Oui	Nom de l'établissement, gardé pour les FINESS uniquement
dim_etablissement	code_commune	STRING	Aucune	Oui	Code commune INSEE de l'organisation
dim_etablissement	nom_commune	STRING	Aucune	Oui	Nom de la commune (référentiel établissements)
dim_etablissement	code_postal	STRING	Aucune	Oui	5 caractères, zéro initial rétabli
dim_etablissement	nom_departement	STRING	Aucune	Oui	Libellé du département (COG INSEE)
dim_etablissement	nom_region	STRING	Aucune	Oui	Libellé de la région
dim_etablissement	sk_localisation	BIGINT	FK → dim_localisation	Non (-1 si absent)	Lieu de l'organisation, reporté sur les faits au chargement
dim_etablissement	date_maj	TIMESTAMP	Aucune	Non	Horodatage du dernier chargement de la ligne
dim_professionnel	sk_professionnel	BIGINT	PK	Non (-1 = Inconnu)	Clé de substitution du professionnel
dim_professionnel	identifiant	STRING	Clé naturelle, unique	Non	RPPS ou ADELI
dim_professionnel	type_identifiant	STRING	Aucune	Oui	RPPS ou ADELI
dim_professionnel	categorie_professionnelle	STRING	Aucune	Oui	Civil, Étudiant, Militaire
dim_professionnel	profession	STRING	Aucune	Oui	Médecin, Infirmier, etc. (26 valeurs)
dim_professionnel	code_specialite	STRING	Aucune	Oui	Code de la table Specialites
dim_professionnel	specialite	STRING	Aucune	Oui	Libellé de la spécialité
dim_professionnel	fonction	STRING	Aucune	Oui	Fonction associée à la spécialité

Table	Attribut	Type	Clé	Nullable	Définition
dim_professionnel	mode_exercice	STRING	Aucune	Oui	Salarié, Libéral ou Bénévole, dans l'organisation principale
dim_professionnel	nb_organisations	INT	Aucune	Non	Nombre d'organisations où il exerce
dim_professionnel	identifiant_organisation_principale	STRING	Aucune	Oui	Organisation retenue par la règle de la section 6.2
dim_professionnel	raison_sociale_principale	STRING	Aucune	Oui	Raison sociale de cette organisation
dim_professionnel	nom_commune	STRING	Aucune	Oui	Nom de la commune (référentiel établissements)
dim_professionnel	nom_region	STRING	Aucune	Oui	Libellé de la région
dim_professionnel	sk_etablissement_principal	BIGINT	FK → dim_etablissement	Non (-1 si absent)	Organisation principale, reportée sur les consultations
dim_professionnel	sk_localisation_principale	BIGINT	FK → dim_localisation	Non (-1 si absent)	Lieu de l'organisation principale, reporté sur les consultations
dim_professionnel	date_maj	TIMESTAMP	Aucune	Non	Horodatage du dernier chargement de la ligne
dim_patient	sk_patient	BIGINT	PK	Non (-1 = Inconnu)	Clé de substitution du patient
dim_patient	patient_pseudo	STRING	Clé naturelle, unique	Non	SHA-256(sel + Id_patient), 64 caractères hexadécimaux
dim_patient	sexe	STRING	Aucune	Oui	F, M ou I (inconnu)
dim_patient	libelle_sexe	STRING	Aucune	Oui	Femme, Homme ou Inconnu
dim_patient	annee_naissance	INT	Aucune	Oui	Année de naissance, seule partie conservée de la date

Table	Attribut	Type	Clé	Nullable	Définition
dim_patient	date_maj	TIMESTAMP	Aucune	Non	Horodatage du dernier chargement de la ligne
dim_diagnostic	sk_diagnostic	BIGINT	PK	Non (-1 = Inconnu)	Clé de substitution du diagnostic
dim_diagnostic	code_diag	STRING	Clé naturelle, unique	Non	Code CIM-10 compact, sans point
dim_diagnostic	libelle	STRING	Aucune	Oui	Libellé du diagnostic
dim_diagnostic	code_categorie	STRING	Aucune	Oui	3 premiers caractères du code
dim_diagnostic	code_chapitre	STRING	Aucune	Oui	Chapitre CIM-10 en chiffres romains (I à XXII)
dim_diagnostic	libelle_chapitre	STRING	Aucune	Oui	Libellé du chapitre
dim_diagnostic	origine	STRING	Aucune	Oui	Source du libellé
dim_diagnostic	date_maj	TIMESTAMP	Aucune	Non	Horodatage du dernier chargement de la ligne
fait_consultation	id_consultation	BIGINT	PK logique	Non	Num_consultation de la source (dimension dégénérée)
fait_consultation	sk_temps	BIGINT	FK → dim_temps	Non (-1 si absent)	Date de la consultation
fait_consultation	sk_patient	BIGINT	FK → dim_patient	Non (-1 si absent)	Patient de la consultation
fait_consultation	sk_professionnel	BIGINT	FK → dim_professionnel	Non (-1 si absent)	Professionnel de la consultation
fait_consultation	sk_diagnostic	BIGINT	FK → dim_diagnostic	Non (-1 si absent)	Diagnostic de la consultation

Table	Attribut	Type	Clé	Nullable	Définition
fait_consultation	sk_etablissement	BIGINT	FK → dim_etablissement	Non (-1 si absent)	Organisation principale du professionnel
fait_consultation	sk_localisation	BIGINT	FK → dim_localisation	Non (-1 si absent)	Lieu estimé de cette organisation
fait_consultation	age_patient	INT	Aucune	Oui	Année de l'acte − année de naissance (attribut d'analyse)
fait_consultation	tranche_age	STRING	Aucune	Non	00-17, 18-29, 30-44, 45-59, 60-74, 75 ans et plus, Inconnu
fait_consultation	nb_consultation	INT	Aucune	Non	Toujours 1, s'additionne
fait_consultation	qualite_localisation	STRING	Aucune	Non	INFEREE ou INCONNUE
fait_consultation	annee	INT	Partition	Non	Année de la consultation
fait_hospitalisation	id_hospitalisation	BIGINT	PK logique	Non	Num_Hospitalisation de la source (dimension dégénérée)
fait_hospitalisation	sk_temps	BIGINT	FK → dim_temps	Non (-1 si absent)	Date d'entrée
fait_hospitalisation	sk_patient	BIGINT	FK → dim_patient	Non (-1 si absent)	Patient hospitalisé
fait_hospitalisation	sk_diagnostic	BIGINT	FK → dim_diagnostic	Non (-1 si absent)	Diagnostic du séjour
fait_hospitalisation	sk_etablissement	BIGINT	FK → dim_etablissement	Non (-1 si absent)	Établissement du séjour
fait_hospitalisation	sk_localisation	BIGINT	FK → dim_localisation	Non (-1 si absent)	Lieu de cet établissement

Table	Attribut	Type	Clé	Nullable	Définition
fait_hospitalisation	age_patient	INT	Aucune	Oui	Année d'entrée − année de naissance (attribut d'analyse)
fait_hospitalisation	tranche_age	STRING	Aucune	Non	00-17, 18-29, 30-44, 45-59, 60-74, 75 ans et plus, Inconnu
fait_hospitalisation	nb_hospitalisation	INT	Aucune	Non	Toujours 1, s'additionne
fait_hospitalisation	duree_sejour_jours	INT	Aucune	Oui	Jour_Hospitalisation ; vide si négative
fait_hospitalisation	qualite_localisation	STRING	Aucune	Non	CONNUE ou INCONNUE
fait_hospitalisation	annee	INT	Partition	Non	Année d'entrée
fait_deces	cle_deces	STRING	PK logique	Non	SHA-256 de l'identité, clé de dédoublonnage (dimension dégénérée)
fait_deces	sk_temps	BIGINT	FK → dim_temps	Non (-1 si absent)	Date du décès
fait_deces	sk_localisation	BIGINT	FK → dim_localisation	Non (-1 si absent)	Commune du décès
fait_deces	sexe	STRING	Aucune	Non	F, M ou I
fait_deces	age_deces	INT	Aucune	Oui	Année du décès − année de naissance (attribut d'analyse)
fait_deces	tranche_age	STRING	Aucune	Non	00-17, 18-29, 30-44, 45-59, 60-74, 75 ans et plus, Inconnu
fait_deces	date_deces_approx	BOOLEAN	Aucune	Non	Vrai si le jour ou le mois manquait
fait_deces	nb_deces	INT	Aucune	Non	Toujours 1, s'additionne
fait_deces	qualite_localisation	STRING	Aucune	Non	CONNUE ou INCONNUE
fait_deces	annee	INT	Partition	Non	Année du décès

Table	Attribut	Type	Clé	Nullable	Définition
fait_satisfaction	sk_temps	BIGINT	FK → dim_temps	Non (-1 si absent)	1er janvier de la campagne
fait_satisfaction	sk_etablissement	BIGINT	FK → dim_etablissement	Non (-1 si absent)	Établissement évalué
fait_satisfaction	sk_localisation	BIGINT	FK → dim_localisation	Non (-1 si absent)	Lieu de l'établissement, sinon ligne de sa région
fait_satisfaction	finess_geo	STRING	PK logique (avec enquete, annee)	Non	FINESS géographique du fichier ; PK logique composée avec enquete et annee
fait_satisfaction	enquete	STRING	Aucune	Non	48h ou ca
fait_satisfaction	libelle_enquete	STRING	Aucune	Non	Nom de l'enquête e-Satis
fait_satisfaction	participation	STRING	Aucune	Oui	Obligatoire ou facultative
fait_satisfaction	depot	STRING	Aucune	Oui	Résultats déposés (Oui / Non)
fait_satisfaction	classement	STRING	Aucune	Oui	A à D, DI (données insuffisantes), NV
fait_satisfaction	nb_evaluations	INT	Aucune	Non	Toujours 1, s'additionne
fait_satisfaction	nb_repondants	INT	Aucune	Oui	Répondants au score global ; vide si pas de score
fait_satisfaction	score_global	DOUBLE	Aucune	Oui	Score ajusté sur 100 ; ne pas additionner
fait_satisfaction	score_pondere	DOUBLE	Aucune	Oui	score_global × nb_repondants, s'additionne
fait_satisfaction	taux_recommandation	DOUBLE	Aucune	Oui	Taux brut de recommandation ; ne pas additionner
fait_satisfaction	nb_recommandations	INT	Aucune	Oui	Nombre de recommandations, s'additionne

Table	Attribut	Type	Clé	Nullable	Définition
fait_satisfaction	qualite_localisation	STRING	Aucune	Non	CONNUE, REGION ou INCONNUE
fait_satisfaction	annee	INT	Partition	Non	Année de la campagne