Prosit 1 - Boucle Architecture

Rôles

- Alexandre : Scribe
- Youcef : Gestionnaire du temps
- Antonin : Animateur
- Maxime : Secrétaire

Contexte

L'entreprise doit livrer dans 3 semaines une maquette complète pour le projet CHU (Cloud Healthcare Unit), démontrant l'exploitation des données selon les attentes des utilisateurs décrites dans le cahier des charges.

Un stagiaire, Archie, a réalisé la veille et l'étude de faisabilité : le projet a reçu un go, mais est resté en stand-by faute de budget pour des ressources externes. Trois collaborateurs en sont désormais responsables.

Archie a livré un schéma d'architecture Big Data et un environnement virtualisé. Les données, volumineuses et personnelles, sont stockées en l'état dans un dossier « Mes documents ». Le planning prévoit 2 j d'architecture et de modèle logique, 4 j d'intégration, 4 j de modèle physique et 4 j d'exploitation et de visualisation.

Mots inconnus

Mot	Définition
Maquette	Prototype fonctionnel démontrant la faisabilité et la valeur d'une solution, sans être le produit final.
Veille	Collecte et analyse continue d'informations sur un sujet (technologies, marché, réglementation).
Étude de faisabilité	Analyse déterminant si un projet est réalisable techniquement, financièrement et dans les délais.
Go / No-go	Décision formelle de poursuivre ou d'arrêter un projet à une étape donnée.
Cahier des charges	Document formalisant les besoins, contraintes et attendus d'un projet.

Big Data	Données dont le volume, la variété et la vitesse dépassent les capacités d'un SGBD classique. Elles nécessitent un stockage et un traitement distribués.
Architecture Big Data	Ensemble de composants (ingestion, stockage distribué, traitement, restitution) conçus pour gérer de très grands volumes de données variées.
Environnement virtualisé	Infrastructure où plusieurs machines virtuelles ou conteneurs tournent sur des ressources physiques partagées.
Entrepôt de données (Data Warehouse)	Stockage centralisé de données historisées et structurées par sujet, alimenté par des sources multiples et dédié à l'analyse et à l'aide à la décision.
Base de données multidimensionnelle (OLAP)	Base organisant les données en faits (mesures) et dimensions (axes d'analyse) pour des agrégations rapides.
Modèle en étoile	Schéma reliant une table de faits centrale à des tables de dimensions dénormalisées.
Modélisation des données	Conception de la structure des données selon les usages visés (ici, modélisation dimensionnelle).
Modèle logique	Représentation des données (entités, relations, attributs) indépendante de la technologie de stockage.
Implémentation physique des données	Traduction du modèle logique dans un système de stockage réel (tables, index, partitions, fichiers).
Intégration des données (ETL)	Collecte, nettoyage, transformation et chargement de données issues de sources multiples vers la cible (Extract, Transform, Load).
Data Lake	Stockage brut et peu coûteux de données hétérogènes, organisé en zones (raw, curated).
Données à caractère personnel	Toute information permettant d'identifier directement ou indirectement une personne physique. Les données de santé en sont une catégorie sensible au sens du RGPD.
Pseudonymisation	Remplacement des identifiants directs par des pseudonymes. La ré-identification reste possible avec une information conservée séparément.
RGPD / HDS	Le RGPD est le règlement européen de protection des données personnelles. HDS est la certification française exigée pour l'hébergement de données de santé.

HDFS	Système de fichiers distribué de Hadoop. Il découpe les fichiers en blocs répartis et répliqués sur plusieurs nœuds (DataNodes), sous la coordination d'un nœud maître (NameNode), afin de stocker de très grands volumes et de les lire en parallèle.

Problématique

Comment évaluer et adapter l'architecture proposée par Archie, puis concevoir un modèle dimensionnel répondant aux besoins d'analyse du CHU, en tenant compte des performances, de la protection des données et du délai de réalisation ?

Plan d'action

1. Analyser la production d'Archie et la relier à l'environnement virtualisé (0,5 j) : identifier le rôle de chaque composant du schéma et vérifier ce qui est réellement installé.

2. Valider le choix d'une architecture Big Data et l'adapter au besoin (0,75 j) : justifier le Big Data, étudier le stockage et le traitement distribués, arrêter les outils.

3. Relier les analyses du cahier des charges aux données disponibles (0,5 j) : rechercher dans les sources les données qui répondent à chaque analyse.

4. Concevoir le modèle dimensionnel des données (0,75 j) : appliquer les principes de l'entreposage de données et des bases multidimensionnelles.

5. Identifier les contraintes de protection des données personnelles (0,5 j) : qualifier les données et recenser les obligations légales et organisationnelles.

Réalisation

Pour répondre à la problématique, nous avons d'abord évalué le travail d'Archie, puis adapté son architecture, relié les besoins aux données et commencé la modélisation, en intégrant la protection des données personnelles.

1. Analyser la production d'Archie et la relier à l'environnement virtualisé

Le schéma d'Archie contient des sources (CSV, Excel, MySQL, PostgreSQL), un stockage HDFS, un bloc ETL, une distribution Cloudera (MapReduce, Hive) pour l'analyse, puis Power BI et des requêtes. Nous avons relié chaque composant à l'environnement :

Composant du schéma	Rôle	Constat
CSV, Excel, MySQL, PostgreSQL	Sources	MySQL et Excel n'existent pas dans le sujet ; les deux sources FTP (satisfaction, décès) sont absentes
HDFS	Stockage distribué des données brutes	Pertinent
ETL	Transformation des données	Aucun outil nommé
Cloudera (MapReduce, Hive)	Traitement et interrogation	Lourde pour une seule machine ; sa VM de démonstration a été retirée en 2020
Power BI, Requêtes	Restitution	Power BI ne fonctionne que sous Windows
Flèches doubles	Flux	Sens des flux non défini

Pour vérifier ce qui tourne réellement, nous listons les services actifs :

```
docker compose ps
```

Nous vérifions ensuite les points d'accès : PostgreSQL sur le port 5432, HiveServer2 sur les ports 10000 et 10002, Superset sur le port 8088.

Validation : chaque composant du schéma a un équivalent dans l'environnement, ou son absence est justifiée.

2. Valider le choix d'une architecture Big Data et l'adapter au besoin

Les 5V justifient le recours au Big Data :

V	Constat
Volume	Plusieurs années d'historique sur quatre sources
Variété	Base relationnelle, CSV, fichiers plats
Vélocité	À préciser avec les utilisateurs ; données historiques, donc a priori traitement par lots
Véracité	À contrôler : doublons, formats, valeurs absentes
Valeur	Indicateurs d'activité, de mortalité et de satisfaction

Nous gardons le principe d'Archie (sources, stockage HDFS, transformation, entrepôt Hive, restitution) et l'adaptons :

- les sources deviennent celles du sujet (PostgreSQL, CSV, FTP) ;
- les flux deviennent à sens unique ;
- **Apache Hop** remplace l'ETL non nommé ;
- **HDFS et Hive 4 sous Docker Compose** remplacent Cloudera ;
- **Superset** remplace Power BI, car il est multiplateforme et se connecte nativement à Hive.

L'architecture est organisée en trois couches :

Couche	Rôle	Choix
Bronze	Copie fidèle des sources	HDFS + tables externes Hive
Silver	Nettoyage, pseudonymisation	Tables Hive ORC
Gold	Modèle dimensionnel pour l'analyse	Tables Hive

Stockage. Le cluster est simulé par des conteneurs sur une seule machine : il démontre le fonctionnement, pas la résistance à une panne matérielle.

Solution	Principe	Rôle ici
NAS	Fichiers partagés par le réseau	Dépôt des fichiers sources
SAN	Volumes en mode bloc	Volumes des serveurs virtualisés
HDFS	Fichiers répartis sur plusieurs nœuds	Stockage des données, lecture parallèle

HDFS découpe les fichiers en blocs répartis sur des DataNodes, le NameNode gérant leur localisation. La réplication protège de la perte d'un nœud, mais ne remplace pas une

sauvegarde. Le cloud apporterait de l'élasticité, mais exige un hébergeur certifié HDS : la maquette tourne en local pour le coût.

Traitement. Hive traduit le SQL en traitement distribué selon le principe de MapReduce. Pour compter les séjours par établissement et par mois : *Map* émet `((établissement, mois), 1)`, *Shuffle* regroupe les clés identiques, *Reduce* additionne.

Difficulté	Réponse
Panne d'un nœud	Reprise des tâches
Partitions déséquilibrées	Surveiller la répartition
Échanges réseau lourds	Filtrer tôt
Relance créant des doublons	Traitements rejouables
Trop de petits fichiers	Regrouper les fichiers

Le distribué n'est pas automatiquement plus rapide : sur un faible volume, la coordination coûte plus qu'elle ne rapporte.

Réponse au manager. Les 2 jours suffisent parce que nous ne repartons pas de zéro : nous gardons le principe d'Archie et un environnement dont les outils sont déjà installés. Le risque restant est couvert par la modélisation, lancée en parallèle.

Validation :

```
docker compose exec namenode hdfs dfsadmin -report

docker compose exec namenode hdfs fsck /data -files -blocks
```

Sur une requête, `EXPLAIN` doit montrer les étapes Map et Reducer, et `docker stats` suit la consommation mémoire.

3. Relier les analyses du cahier des charges aux données disponibles

Les données retrouvées dans « Mes documents » sont réparties dans quatre sources : une base PostgreSQL (actes, admissions, consultations, diagnostics, séjours), un référentiel d'établissements en CSV (localisation par code INSEE/FINESS), des notes de satisfaction et le répertoire des décès INSEE en fichiers plats. Pour chaque analyse, nous avons recherché les données qui y répondent :

Analyse	Sources	Données nécessaires
Taux de consultation par établissement et période	1	Consultations, établissement, date
Taux de consultation par diagnostic	1	Consultations, diagnostic, date
Taux global d'hospitalisation sur une période	1	Séjours, date
Taux d'hospitalisation par diagnostic	1	Séjours, diagnostic
Taux d'hospitalisation par sexe et âge	1	Séjours, sexe et date de naissance du patient
Taux de consultation par professionnel	1	Consultations, professionnel
Décès par région en 2019 (optionnel)	4	Décès, lieu, date
Satisfaction par région en 2020 (optionnel)	3 + 2	Notes, établissement, localisation

Cette recherche explique pourquoi l'exploitation directe est intenable : chaque analyse oblige à parcourir toutes les données brutes, sans index, et à croiser plusieurs sources. Elle fait aussi apparaître trois difficultés :

- la région n'apparaît pas dans les données d'activité et doit se déduire de l'établissement ;
- l'âge doit se calculer à partir de la date de naissance ;
- les formats diffèrent selon les sources.

Validation : aucune analyse sans source ; la matrice est relue par le groupe.

4. Concevoir le modèle dimensionnel des données

Un entrepôt de données est orienté sujet, intégré, historisé et non volatile, à la différence de la base opérationnelle, optimisée pour les transactions. Une base multidimensionnelle organise les données en faits (ce que l'on mesure) et en dimensions (les axes d'analyse). Nous appliquons la méthode de Kimball avec un schéma en étoile, et nous définissons le grain avant les mesures.

Fait	Grain	Mesure
fait_consultation	une consultation	nb_consultation
fait_hospitalisation	un séjour	nb_hospitalisation, durée
fait_deces	un décès	nb_deces

fait_satisfaction	une note	note

Dimension	Consultation	Hospitalisation	Décès	Satisfaction
Temps	✓	✓	✓	✓
Établissement	✓	✓		✓
Patient	✓	✓		
Diagnostic	✓	✓		
Professionnel	✓			
Région	via établissement	via établissement	✓	via établissement

Le Data Mart **Activité hospitalière** (consultations et hospitalisations) couvre les analyses prioritaires. La mortalité et la satisfaction sont optionnelles. La dimension Patient ne contient que la clé pseudonymisée, le sexe et la tranche d'âge. Les faits sont séparés pour ne jamais compter deux fois un même séjour. Les taux sont calculés au moment de la requête, car un ratio ne s'additionne pas.

```sql
SELECT p.sexe, p.tranche_age, SUM(f.nb_hospitalisation) AS nb_sejours
FROM fait_hospitalisation f
JOIN dim_patient p ON p.id_patient = f.id_patient
JOIN dim_temps t ON t.id_temps = f.id_temps
WHERE t.annee = 2019 GROUP BY p.sexe, p.tranche_age;
```

Deux jointures simples suffisent, ce qui justifie le schéma en étoile pour les performances.

Validation :

- Chaque analyse de l'étape 3 est reliée à un fait et à ses dimensions.
- Le total des mesures est comparé au `COUNT(*)` de la source, pour détecter un double comptage.
- Le modèle est relu avec le manager.

5. Identifier les contraintes de protection des données personnelles

Les données de santé sont une catégorie particulière au sens de l'article 9 du RGPD : leur traitement est interdit sauf exception, donc la base légale et la finalité sont fixées avec le

DPO. Une analyse d'impact (AIPD) est nécessaire, et l'hébergement de production doit être certifié HDS. Cette responsabilité dépasse la technique : l'équipe met en place une gouvernance qui définit qui accède à quoi, pour quelle finalité et pour combien de temps.

Le principe de minimisation s'applique : nom, adresse et numéro de sécurité sociale ne sont jamais extraits, car aucune analyse n'en a besoin. Le patient est représenté par une clé pseudonymisée :

```
sha2(concat('${hivevar:sel}', id_patient), 256) AS patient_sk
```

La pseudonymisation n'est pas une anonymisation : la donnée reste personnelle. Le sel est donc stocké dans un `.env` exclu de Git. Les accès sont attribués par rôles (administration, alimentation, consultation) et journalisés. Les ports Docker sont liés à `127.0.0.1`, et aucune donnée de santé n'entre dans le dépôt.

Validation : `DESCRIBE` des tables du modèle, comparé à une liste de colonnes interdites.

Conclusion

Pour évaluer l'architecture d'Archie, nous avons relié chaque composant de son schéma à l'environnement réellement installé et au sujet. Son principe est juste (stockage distribué HDFS, transformation, entrepôt Hive, restitution), mais il ne s'applique pas tel quel : sources inexactes, flux non définis, ETL non nommé et outils inadaptés à une seule machine. Nous l'avons adapté en gardant son principe, avec des sources conformes au sujet, des flux à sens unique, une organisation en trois couches et des outils disponibles et compatibles : Apache Hop, HDFS et Hive 4 sous Docker, Superset.

En reliant les analyses du cahier des charges aux quatre sources, nous avons conçu un modèle dimensionnel en étoile. Il comporte quatre tables de faits au grain défini et des dimensions communes. Il répond à chaque analyse, sans double comptage. Ce modèle répond aussi à la contrainte de performance : à la place de données brutes dispersées et intenables à exploiter, il offre des agrégations par jointures simples, exécutées sur un moteur distribué. La protection des données est intégrée dès la conception : minimisation, pseudonymisation, accès par rôles, et une AIPD et un hébergement HDS pour la production. Enfin, partir du principe d'Archie et d'un environnement déjà installé, avec une modélisation lancée en parallèle, permet de tenir les 2 jours prévus pour l'architecture. Viennent ensuite l'intégration des données, l'implémentation physique et la visualisation.