Prosit 2 - Boucle Transformers

Rôles

Alexandre : Gestionnaire du temps

Youcef : Animateur

Antonin : Secrétaire

Maxime : Scribe

Contexte

L'équipe du projet CHU dispose désormais d'une première vision de l'architecture de son système décisionnel. Les données proviennent de sources hétérogènes : base PostgreSQL, fichiers CSV et fichiers accessibles par FTP. L'architecture envisagée comporte un stockage intermédiaire centralisant ces données et un entrepôt destiné aux analyses des utilisateurs. L'équipe doit maintenant construire l'alimentation de l'entrepôt à partir d'un modèle multidimensionnel déjà amorcé. Certaines informations sont réparties entre plusieurs sources, les régions ne figurent pas directement dans toutes les données et les formats de dates ne correspondent pas toujours à ceux attendus dans Hive. Le positionnement de l'ETL dans l'architecture soulève également une question sur le moment auquel effectuer les transformations. Le premier livrable d'intégration doit être produit dans le délai du projet.

Mots inconnus

Notion	**Définition**
ETL	Extract, Transform, Load : extraire, transformer puis charger dans la cible.
ELT	Extract, Load, Transform : charger dans une zone intermédiaire, puis transformer dans la plateforme de stockage.
Schéma à la lecture	Structure interprétée lors de l'interrogation de fichiers, sans exiger un schéma strict dès leur arrivée.
Bronze / Silver / Gold	Couches de données brutes, fiabilisées puis organisées pour les besoins décisionnels.

Table externe Hive	Table dont la définition est gérée par Hive, tandis que les fichiers de données sont conservés à leur emplacement.
Grain	Niveau de détail correspondant à une ligne d'une table de faits.
Clé de substitution	Identifiant technique stable affecté à une ligne de dimension ou de fait.
Table de correspondance	Référentiel permettant de relier différents codes ou identifiants d'une source à une autre.
Idempotence	Propriété d'un traitement qui peut être relancé sans créer de résultat supplémentaire indésirable.
Quarantaine	Zone regroupant les lignes invalides, conservées avec le motif de rejet.

Problématique

Comment intégrer les sources hétérogènes du CHU dans un entrepôt dimensionnel permettant de calculer les indicateurs métier par période, établissement, diagnostic et région, tout en maîtrisant les transformations à réaliser dans HDFS/Hive et en garantissant la qualité, la confidentialité et les performances des traitements ?

Plan d'action

1. Analyser les sources et les correspondances avec les indicateurs (1h30) : Recenser champs, formats, identifiants, volumes et règles de liaison nécessaires aux analyses.

2. Définir le processus d'intégration et les règles de transformation (1h30) : Décrire les étapes, les contrôles et les modalités de reprise du flux de données.

3. Préparer les dimensions et les tables de faits cibles (2h) : Préciser le grain, les clés, les axes d'analyse et l'alimentation attendue.

4. Détailler un chargement reproductible de bout en bout (2h) : Documenter les opérations, les commandes et les dépendances de chargement.

5. Vérifier la qualité, la sécurité et le fonctionnement (1h) : Préparer les tests, les mesures et les éléments de supervision du livrable.

Réalisation

1. Analyser les sources et les correspondances avec les indicateurs

Nous partons des quatre sources décrites dans le sujet. PostgreSQL apporte l'activité médico-administrative ; les CSV décrivent les établissements ; les deux flux FTP concernent respectivement la satisfaction et les décès INSEE. Le référentiel géographique constitue une dépendance à identifier : le code INSEE de commune ou le FINESS ne fournit pas, à lui seul, une région directement exploitable sans table de correspondance adaptée et datée.

Source	**Données utiles**	**Contrôles prioritaires**
PostgreSQL	Patient, consultation, diagnostic, séjour, praticien, établissement, dates	Clés primaires, liens entre tables, dates, événements doublonnés
CSV établissements	FINESS, code commune INSEE, capacité, certification	Unicité des codes, encodage, codes absents
FTP satisfaction	Établissement, date, note, éventuellement nombre de réponses	Échelle des notes, doublons, exhaustivité, format
FTP décès INSEE	Date de décès, localisation, éventuel identifiant disponible	Qualité de la localisation et du millésime ; niveau d'identification
Référentiel géographique à obtenir	Commune INSEE → département → région, avec période de validité	Correspondance temporelle et couverture géographique

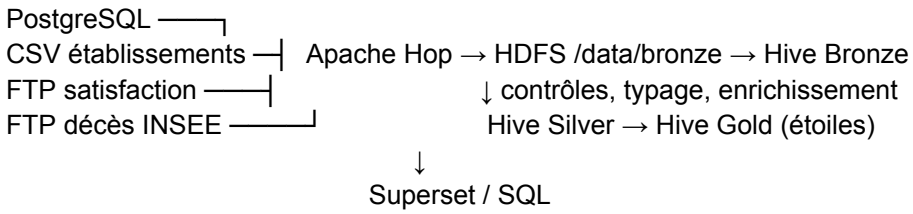
Dans ce tableau, on a recensé les différents indicateurs que les utilisateurs veulent analyser, comme le nombre de consultations, les hospitalisations ou encore la satisfaction des patients.

Pour chaque indicateur, on a identifié quatre éléments. D'abord, l'indicateur, c'est ce qu'on veut mesurer. Ensuite, le numérateur, c'est la valeur qu'on va calculer, par exemple le nombre de consultations. Le dénominateur, c'est ce qui permet de calculer un taux ou un pourcentage. On a mis "à valider" parce que selon le besoin métier, on ne va pas forcément diviser par la même chose.
Enfin, les axes et liaisons, ce sont les données qu'on doit relier pour permettre les analyses. Par exemple, pour analyser les consultations par diagnostic, on doit relier les consultations aux diagnostics et aux dates.

Indicateur	**Numérateur / mesure**	**Dénominateur à valider**	**Axes et liaison**
Consultations dans X sur Y	Nombre de consultations dans X sur Y	Patients suivis, actes ou population éligible ?	Consultation → établissement → temps
Consultations par diagnostic	Nombre de consultations pour un diagnostic	Toutes consultations ou patients exposés ?	Consultation → diagnostic → temps
Hospitalisations globales et par diagnostic	Nombre de séjours éligibles	Patients suivis ou admissions éligibles ?	Séjour → diagnostic → temps
Hospitalisations par sexe et âge	Nombre de séjours par tranche	Population de référence selon tranche ?	Séjour → patient pseudonymisé → temps
Consultations par professionnel	Nombre de consultations	Volume total de consultations ou patients du praticien ?	Consultation → professionnel
Décès 2019 par région (optionnel)	Nombre de décès en 2019	Pas requis pour un simple nombre	Décès → commune/région → temps
Satisfaction 2020 par région (optionnel)	Moyenne pondérée ou proportion de réponses positives	Total des répondants ; seuil de satisfaction à définir	Satisfaction → établissement → région → temps

2. Définir le processus d'intégration et les règles de transformation

Nous retenons l'ELT vu dans le Prosit 1 plutôt qu'un ETL entièrement réalisé avant l'arrivée dans HDFS. Apache Hop orchestre l'extraction et le dépôt des fichiers bruts ; Hive transforme ensuite ces fichiers en tables Silver, puis en tables Gold. Ce choix garde une copie retraçable des sources, facilite les corrections de règles métier et évite d'imposer un schéma unique à des données hétérogènes dès leur réception. L'ETL reste un terme générique pour la chaîne d'intégration ; son ordre effectif est ici Extract–Load–Transform.



Le flux est organisé par lots identifiés (source, date d'extraction, identifiant du lot, somme de contrôle, nombre de lignes). En Bronze, les valeurs sont conservées sans conversion destructive, avec une métadonnée de provenance. En Silver sont appliqués typage, gestion des valeurs vides, dédoublonnage, normalisation des codes, pseudonymisation des identifiants et enrichissement géographique. En Gold sont produites les dimensions et les tables de faits au grain défini.

Pour la date, la conversion doit être explicite : la source peut contenir « 31/12/2020 », tandis que le champ DATE de Hive attend une date normalisée telle que « 2020-12-31 ». Une date invalide ne doit pas devenir silencieusement un événement sans date ; elle est signalée et orientée en quarantaine.

```
SELECT
  CAST(id_consultation AS BIGINT) AS id_consultation,
  TO_DATE(FROM_UNIXTIME(UNIX_TIMESTAMP(date_consultation, 'dd/MM/yyyy')))
    AS date_consultation,
  UPPER(TRIM(code_diagnostic)) AS code_diagnostic
FROM bronze.consultation
WHERE id_consultation IS NOT NULL;
```

Dans le Prosit 1 on utilisait SELECT DISTINCT, SHA2 avec un sel et INSERT OVERWRITE. Nous conservons l'idée du chargement rejouable, mais remplaçons le simple DISTINCT par une règle métier de sélection d'une ligne par identifiant d'événement ; deux enregistrements avec le même identifiant et des valeurs différentes doivent être arbitrés suivant la date de modification ou mis en anomalie. Le sel de pseudonymisation ne doit jamais apparaître dans les scripts, les commandes affichées ou les journaux. Son exploitation sera réservée à un processus sécurisé hors du dépôt Git, avec gestion des accès. Une empreinte salée reste pseudonymisée, et non anonyme.

L’enrichissement régional utilise une jointure sur le code commune INSEE des établissements vers une table géographique. Si l’historique couvre des réorganisations territoriales, la correspondance tient compte de la date. Un FINESS inconnu ou un code commune absent est conservé comme anomalie et non associé à une région inventée.

```sql
SELECT e.id_etablissement, e.code_commune_insee, g.code_region
FROM silver.etablissement e
LEFT JOIN silver.ref_geographie g
  ON e.code_commune_insee = g.code_commune_insee
 AND e.date_reference >= g.date_debut_validite
 AND (g.date_fin_validite IS NULL OR e.date_reference < g.date_fin_validite);
```

3. Préparer les dimensions et les tables de faits cibles

Nous conservons le schéma en étoile annoncé dans le Prosit 1. La règle de modélisation est de fixer un grain pour chaque table avant de définir les mesures : une consultation, un séjour, un décès ou une évaluation. Les dimensions communes (temps, établissement, région) sont conformes entre faits pour autoriser des analyses cohérentes. Les détails des champs restent à confronter au schéma PostgreSQL fourni en annexe du projet.

Objet Gold	**Grain / clé métier**	**Attributs ou mesures attendus**
dim_temps	Une date calendaire	date, jour, mois, trimestre, année
dim_etablissement	Un établissement / version si historique	FINESS, commune, département, région, dates de validité
dim_patient	Un patient pseudonymisé / version utile	patient_sk, sexe, tranche d’âge calculée au moment du fait
dim_diagnostic	Un code de diagnostic	code, libellé, classification si disponible
dim_professionnel	Un professionnel pseudonymisé ou identifiant professionnel autorisé	professionnel_sk, spécialité si disponible
dim_region	Une région / période de validité	code région, nom, dates de validité
fait_consultation	Une consultation	clés dimensions, nb_consultations = 1
fait_hospitalisation	Un séjour	clés dimensions, nb_sejours = 1, durée si calculable
fait_deces	Un décès ou un agrégat selon source admissible	date, région, nb_deces

fait_satisfaction	Une réponse/note ou un agrégat source	note, nb_reponses, somme_notes selon granularité

Lorsque plusieurs diagnostics sont associés à un séjour, nous prévoyons une table de liaison distincte séjour–diagnostic ou une règle confirmée de diagnostic principal. Une jointure directe avec plusieurs diagnostics sans précaution compterait plusieurs fois le séjour. Pour l'âge, une tranche à la date de l'événement est préférable à l'âge courant, qui fausserait les analyses historiques. Les données d'identité directe ne figurent pas dans Gold.

L'alimentation Gold s'effectue à partir de Silver en résolvant les clés des dimensions. Un fait dont l'établissement n'est pas résolu est bloqué ou dirigé vers une ligne technique « inconnu » explicitement suivie : il ne doit pas disparaître sans trace. Le découpage temporel par année peut être appliqué aux grosses tables de faits, comme proposé dans le Prosit 1, après vérification de la taille réelle des données.

```
INSERT OVERWRITE TABLE gold.fait_consultation PARTITION (annee)
SELECT
  c.patient_sk, p.professionnel_sk, e.etablissement_sk,
  d.diagnostic_sk, t.id_temps, 1 AS nb_consultation, t.annee
FROM silver.consultation c
JOIN gold.dim_temps t ON c.date_consultation = t.date_complete
JOIN gold.dim_etablissement e ON c.id_etablissement = e.id_source
JOIN gold.dim_diagnostic d ON c.code_diagnostic = d.code_diagnostic
LEFT JOIN gold.dim_professionnel p ON c.id_professionnel = p.id_source;
```

Cette requête est un gabarit : les noms de colonnes et les types doivent correspondre aux DDL réellement créés. Pour éviter de perdre des consultations faute de dimension, le nombre de lignes non appariées est vérifié avant l'insertion. La pseudonymisation et les droits d'accès sont traités en amont.

4. Détailler un chargement reproductible de bout en bout

L'exemple de réalisation porte sur les consultations ; les trois autres flux utilisent le même principe avec leurs règles propres. L'orchestration Apache Hop comporte l'extraction PostgreSQL, la normalisation minimale du format d'échange, l'ajout de métadonnées de lot et l'écriture dans un répertoire partagé. Un second traitement dépose les fichiers sur HDFS, puis exécute les requêtes Hive Bronze → Silver → Gold dans cet ordre.

```
# Exemple de dépôt d'un fichier préparé par Hop
docker compose exec namenode hdfs dfs -mkdir -p /data/bronze/pg/consultation
docker compose exec namenode hdfs dfs -put -f \
  /echange/bronze/pg/consultation.csv /data/bronze/pg/consultation/

# Contrôle du dépôt
docker compose exec namenode hdfs dfs -ls /data/bronze/pg/consultation
```

Le chemin /échange désigne un volume monté et partagé avec le conteneur namenode ; il doit être déclaré dans Docker Compose. Sans ce montage, la commande échoue. Les paramètres de connexion et d'authentification ne doivent jamais être incorporés en clair dans le workflow versionné.

```
CREATE EXTERNAL TABLE IF NOT EXISTS bronze.consultation (
  id_consultation STRING, id_patient STRING, id_etablissement STRING,
  id_professionnel STRING, code_diagnostic STRING, date_consultation STRING
)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ';'
STORED AS TEXTFILE
LOCATION '/data/bronze/pg/consultation';
```

Le séparateur « ; », les en têtes et l'encodage sont à confirmer sur les fichiers. En présence de CSV comportant des guillemets, des sauts de ligne ou des séparateurs dans les champs, une conversion contrôlée préalable vers un format non ambigu (par exemple Parquet) est préférable à un simple SerDe délimité. La table Bronze demeure consultable pour audit et relecture des anomalies.

Pour rendre le chargement idempotent, les fichiers d'un même lot sont identifiés, le staging est remplacé lorsque l'outil le permet, et les partitions ou tables cibles sont reconstruites avec des données dédoublonnées. Un journal conserve lot, heure, étape, statut, nombre lu, nombre rejeté et durée. Le traitement Silver précède la publication Gold : Superset n'accède qu'aux données validées.

Étape	**Entrée / sortie**	**Condition de passage**
Extraction Hop	PostgreSQL / FTP / CSV → fichiers de lot	Source accessible ; compte de lignes et checksum
Dépôt Bronze	Fichiers de lot → HDFS / tables externes	Fichiers présents ; format exploitable
Transformation Silver	Bronze → tables nettoyées	Dates, codes, identifiants et rejets contrôlés
Construction Gold	Silver → dimensions puis faits	Clés résolues ; agrégations sans doublons
Publication	Gold → requêtes / Superset	Rapprochement des indicateurs et droits validés

5. Vérifier la qualité, la sécurité et le fonctionnement

Les tests sont conçus dès maintenant ; leur exécution et leurs résultats chiffrés devront être ajoutés lorsque les données et les conteneurs seront disponibles. Le premier contrôle est la réconciliation des volumes : lignes lues en Bronze = lignes acceptées en Silver + lignes rejetées, avec prise en compte explicite des doublons isolés. Le deuxième vérifie les clés de faits ; le troisième compare les indicateurs Gold à des calculs de référence sur un échantillon maîtrisé.

```sql
-- Doublons de consultations : résultat attendu = 0 ligne
SELECT id_consultation, COUNT(*) AS n
FROM silver.consultation
GROUP BY id_consultation HAVING COUNT(*) > 1;

-- Dates invalides / non converties à surveiller
SELECT COUNT(*) AS nb_dates_manquantes
FROM silver.consultation WHERE date_consultation IS NULL;

-- Etablissements non résolus avant la publication Gold
SELECT COUNT(*) AS nb_sans_etablissement
FROM silver.consultation c LEFT JOIN gold.dim_etablissement e
  ON c.id_etablissement = e.id_source
WHERE e.id_source IS NULL;
```

Un essai de relance du même lot doit produire le même nombre de consultations et les mêmes agrégats. Les temps de chargement sont chronométrés séparément pour l'ingestion HDFS, la transformation Silver et la construction Gold. Les performances des requêtes de restitution seront ensuite évaluées au regard du seuil de deux minutes exposé dans le contexte du Prosit 3, sans présenter ce seuil comme déjà atteint.

La supervision s'appuie sur les journaux Apache Hop, les logs Docker Compose, l'état des conteneurs et les métriques de ressources locales. Les commandes suivantes servent au diagnostic opérationnel :

```
docker compose ps
docker compose logs --tail=100 namenode hiveserver2
docker stats --no-stream
docker compose exec namenode hdfs dfs -du -h /data/bronze
```

Conclusion de la réalisation

Le livrable du Prosit 2 est une chaîne d'intégration conçue de la source jusqu'aux tables analytiques : chargement brut dans HDFS, transformations contrôlées sous Hive, enrichissement géographique, constitution des dimensions et faits, puis publication des données validées. Le choix ELT est cohérent avec l'architecture héritée du Prosit 1 et avec la variété des sources. Les points de validation prioritaires sont la disponibilité du schéma source, la définition des dénominateurs des « taux », le référentiel commune–région et l'exécution effective des tests sur l'environnement pédagogique.