Prosit 4 - Boucle Visualisation

Rôles

Alexandre : Secrétaire

Youcef : Gestionnaire du temps

Antonin : Scribe

Maxime : Animateur

Contexte

La maquette décisionnelle du projet CHU est désormais fonctionnelle et permet d'exploiter les données pour produire plusieurs analyses. La dernière étape consiste à présenter une version « quick win » aux médecins, soignants, chercheurs et administrateurs afin qu'ils identifient rapidement les indicateurs utiles à leurs décisions.

L'équipe doit définir les graphiques, l'organisation des informations et les interactions du tableau de bord. Une proposition de graphes génériques et paramétrables avec des filtres a été formulée, mais l'équipe s'interroge sur le nombre de vues à préparer et sur la capacité de cette solution à couvrir les usages attendus.

Mots inconnus

Notion	**Définition**
KPI (Key Performance Indicator)	Indicateur quantifié permettant de suivre un objectif métier défini.
Quick win	Premier résultat utilisable qui montre la valeur de l'outil sur un besoin précis
Business Intelligence (BI)	Ensemble des méthodes et outils permettant d'explorer et restituer des données décisionnelles.
Data storytelling	Organisation d'analyses en un récit visuel qui guide l'interprétation et la décision.
UX (User Experience)	Qualité de l'expérience vécue par une personne pendant l'utilisation d'une interface.
Dashboard	Écran regroupant des mesures, graphiques et filtres cohérents.
Cross-filtering	Filtrage d'autres graphiques par sélection d'un élément dans une visualisation.
Drill-down	Passage d'un niveau agrégé à un niveau de détail pertinent.
Vue matérialisée	Résultat précalculé, stocké et actualisé pour accélérer des analyses.
Granularité	Niveau de détail d'une mesure ou d'une observation.
Accessibilité	Conception permettant une compréhension et une utilisation par des profils variés.
Seuil de confidentialité	Règle masquant certains petits effectifs pour limiter la réidentification.

Problématique

Comment restituer dans un tableau de bord interactif les KPI hospitaliers issus de Hive afin d'aider les différents profils du CHU à décider rapidement, tout en limitant les requêtes coûteuses et en garantissant une expérience claire, accessible, performante et respectueuse de la confidentialité ?

Plan d'action

1. Recenser les parcours utilisateurs et formaliser les KPI (1h30) : Associer chaque besoin confirmé à une mesure, une population, un axe d'analyse et un utilisateur cible.

2. Définir les visualisations et le scénario de lecture (1h30) : Comparer les formes graphiques et organiser la hiérarchie de lecture des tableaux de bord.

3. Concevoir l'interactivité et préparer les jeux de données BI (2h) : Décrire les filtres, les interactions, les requêtes et les niveaux de détail nécessaires.

4. Construire la maquette de restitution dans Superset (2h) : Préciser les configurations des graphiques, des tableaux de bord et des droits d'accès.

5. Tester l'expérience, la sécurité et les performances (1h30) : Prévoir les vérifications métier, UX, confidentialité, rafraîchissement et temps de réponse.

Réalisation

1. Recenser les parcours utilisateurs et formaliser les KPI

Nous partons des huit besoins répertoriés dans l'énoncé et re confirmés au Prosit 3 : les six indicateurs d'activité sont prioritaires, tandis que décès 2019 et satisfaction 2020 sont optionnels. Le premier choix consiste à distinguer les volumes observés, les parts relatives et les véritables taux. Le mot « taux » ne définit pas toujours le dénominateur ; la restitution affiche donc une mesure sans ambiguïté jusqu'à validation par le métier.

Public / question	KPI et axes	Restitution utile
Direction : où se concentre l'activité ?	Nb de consultations et séjours ; année, mois, établissement, région	Cartes KPI, série temporelle, classement des établissements
Praticiens : quelles pathologies ?	Consultations et séjours par diagnostic, période	Barres horizontales, recherche de diagnostic
Cadres : pour quelles populations ?	Séjours par sexe et tranche d'âge à l'événement	Barres groupées ; comparaison par période
Responsables : activité des professionnels ?	Nb de consultations par professionnel autorisé	Barres triées ; filtre établissement
Direction : évolution territoriale ?	Nb de décès régionaux 2019 (optionnel)	Carte si géométrie fiable, sinon barres
Qualité : satisfaction des usagers ?	Moyenne pondérée des notes ou part positive en 2020 (optionnel)	Barres régionales avec effectif répondants

Chaque indicateur reçoit une fiche : nom affiché, formule, unité, grain, source Gold, filtres compatibles, date de mise à jour, responsable métier et règles de confidentialité. Une consultation et un séjour restent distincts ; pour une analyse « par diagnostic », une association un-à-plusieurs ne doit jamais multiplier artificiellement les séjours.

Exemple métier. Une carte « Consultations enregistrées » mesure la somme des événements observés ; elle n'est pas nommée « taux de consultation ». Un taux d'hospitalisation exigerait un numérateur (hospitalisations éligibles) et une population de référence clairement validée. Les taux ne se somment pas entre régions : on recalcule leur ratio à partir des composantes.

2. Définir les visualisations et le scénario de lecture

Le dashboard doit suivre les questions que se pose l'utilisateur plutôt que d'accumuler des graphiques. Nous proposons une narration en trois niveaux : 1) observer la situation globale, 2) localiser une évolution ou un écart, 3) comprendre par établissement, diagnostic, profil et période. Cette progression constitue le data storytelling « situation → écart → explication → action » demandé par le scénario.

Écran / position	Graphique retenu	Justification UX
En haut : activité globale	Cartes KPI : consultations, séjours, variation vs période précédente	Lecture immédiate et unités visibles
Sous les KPI : évolution	Courbe mensuelle des consultations et séjours (axes ou graphes distincts)	Repérage des tendances sans surcharge

Activité par diagnostic	Barres horizontales triées, top 10 + « autres »	Libellés longs et classement lisibles
Segmentation hospitalisation	Barres groupées sexe / tranche d'âge	Comparaison de catégories, pas de fausse précision
Répartition territoriale	Barres par région ; carte uniquement si fond géographique fiable	Comparaison robuste, y compris pour les petits territoires
Qualité perçue optionnelle	Barres régionales avec moyenne et nombre de réponses	Éviter d'interpréter une moyenne sans effectif

Nous évitons les camemberts à nombreuses catégories, les doubles axes difficiles à interpréter et les codes couleur qui portent seuls le sens. Les graphiques partagent des intitulés explicites, une légende stable, des couleurs cohérentes et des périodes affichées. Les variations utilisent un point de comparaison annoncé ; un graphique vide indique « aucune donnée sur la sélection » plutôt que 0.

L'écran initial s'ouvre sur une période pertinente et le périmètre autorisé. À droite ou sous les KPI, un court texte donne un constat illustratif sans inventer un résultat : « Sur la période sélectionnée, consulter la tendance puis comparer les établissements ». Le véritable commentaire sera alimenté par les chiffres validés, non par une conclusion automatique non contrôlée.

3. Concevoir l'interactivité et préparer les jeux de données BI

L'idée de graphes génériques paramétrables est pertinente à condition de conserver des questions métier claires. Dans Superset, un même dataset analytique peut alimenter plusieurs graphiques et les filtres natifs évitent de fabriquer une vue physique pour chaque combinaison de paramètres. En revanche, un indicateur nécessitant une formule, un grain ou des droits différents garde son dataset ou sa requête spécifique.

Les filtres principaux sont période, établissement, région, diagnostic et, pour les personnes habilitées, professionnel. La région découle du référentiel établissements lié à l'historique ; elle n'est pas déduite arbitrairement de la consultation. L'utilisateur peut sélectionner une barre pour filtrer des vues compatibles puis réinitialiser les filtres. Un tableau de détail ne présente pas d'identité patient.

Jeu analytique « consultations par mois et établissement ». Un agrégat Gold réduit le volume transféré à Superset et facilite les interactions ; les clés de période sont conservées pour filtrer proprement les partitions. Exemple adapté aux noms de tables proposés dans les Prosits 2 et 3 :

```
CREATE MATERIALIZED VIEW gold.mv_consult_etab_mois AS
SELECT f.annee, t.mois, f.etablissement_sk,
       SUM(f.nb_consultation) AS nb_consultations
FROM gold.fait_consultation f
JOIN gold.dim_temps t ON f.id_temps = t.id_temps
GROUP BY f.annee, t.mois, f.etablissement_sk;
```

La création ou la réécriture de la vue matérialisée dépend de la configuration Hive et des propriétés transactionnelles effectivement activées. Une alternative simple est une table Gold d'agrégats reconstruite à chaque lot trimestriel. Le dataset Superset exploite uniquement les colonnes autorisées et évite les jointures répétées sur les faits bruts.

```
SELECT annee, mois, etablissement_sk, nb_consultations
FROM gold.mv_consult_etab_mois
WHERE annee = 2020
ORDER BY mois, etablissement_sk;
```

Pour la satisfaction, la moyenne régionale doit être pondérée lorsqu'un enregistrement résume plusieurs réponses. Un « taux de satisfaction » n'est fourni que si la définition des avis positifs, l'échelle et le dénominateur ont été confirmés :

```sql
SELECT code_region,
       ROUND(SUM(somme_notes) / NULLIF(SUM(nb_reponses), 0), 2)
         AS note_moyenne,
       SUM(nb_reponses) AS reponses
FROM gold.agg_satisfaction_region_annee
WHERE annee = 2020
GROUP BY code_region;
```

Ici, gold.agg_satisfaction_region_annee est une table de synthèse à créer si les champs source autorisent ces mesures ; ce n'est pas une table dont la présence a été vérifiée. On choisit des filtres « dépendants » lorsque la région doit restreindre les établissements, et on documente leur portée sur chacun des graphiques.

4. Construire la maquette de restitution dans Superset

Nous conservons Apache Superset, déjà retenu au Prosit 1, afin de ne pas ajouter de technologie au dernier moment. Depuis la connexion SQLAlchemy au service HiveServer2, l'administrateur BI enregistre les datasets autorisés de la couche Gold. Les métriques sont définies une fois dans le dataset : SUM(nb_consultation), SUM(nb_sejours), nombre d'établissements couverts ou moyenne pondérée si la source le permet.

Élément Superset	Paramétrage proposé	Bénéfice
Dataset Gold	Colonnes métier explicites ; métriques enregistrées	Cohérence entre graphiques
Dashboard « Activité CHU »	Cartes KPI, courbe temporelle, barres diagnostic	Lecture du global au détail
Filtres natifs	Année/période, région, établissement, diagnostic	Exploration sans coder une vue par filtre
Cross-filtering	Sélection depuis les barres compatibles	Réduit le nombre d'actions
Dashboard « Qualité & territoire »	Mortalité et satisfaction, si sources exploitables	Séparation des indicateurs optionnels
Rôles Superset	Consultation BI limitée aux datasets Gold	Réduit l'exposition des données

L'interface vise une grille simple : quatre cartes maximum en première ligne, un grand graphe temporel puis deux graphiques de comparaison. Une seule action claire de « Réinitialiser les filtres » doit être visible. Titres et descriptions reprennent les termes métiers ; les infobulles donnent unité, période, valeur et effectif. Les libellés et les palettes restent lisibles sur ordinateur portable et en projection.

Exemple de validation du service Docker et de l'accès aux tableaux de bord (ports et noms de services à confirmer avec le docker-compose réel) :

```
docker compose ps
# Consulter les traces de Superset en cas de problème
docker compose logs --tail=100 superset
# Surveiller les ressources pendant la consultation
docker stats --no-stream
```

5. Tester l'expérience, la sécurité et les performances

Nous organisons une recette courte autour de tâches représentatives : « voir le nombre de consultations d'un établissement sur un trimestre », « comparer deux diagnostics », « afficher les hospitalisations par sexe et âge » et « revenir au périmètre national ». Les utilisateurs pilotes doivent pouvoir comprendre l'intitulé des KPI et retrouver le filtre actif sans aide. Les remarques recueillies conduisent à corriger labels, ordre des écrans et interactions avant la présentation.

Vérification	Méthode	Critère de validation
Exactitude KPI	Comparer le graphique à une requête Hive indépendante avec filtres identiques	Même résultat, mêmes exclusions et même période
UX et accessibilité	Parcours avec soignant et administrateur ; clavier, contrastes et tailles	Actions identifiables ; informations lisibles
Temps de réponse	Mesurer ouverture initiale et changements de filtres en conditions fixes	Objectif projet : au plus 120 s pour les analyses
Confidentialité	Contrôler les droits et les effectifs faibles, tester profils distincts	Aucun détail nominatif ; petits effectifs masqués
Robustesse	Tester sélections vides, filtre invalide et service indisponible	Message explicite et récupération possible
Actualisation	Rafraîchir les données de Gold et vider/invalider le cache BI concerné	Date du dernier lot et chiffres concordants

Un temps d'affichage doit être mesuré de bout en bout dans Superset, et pas seulement en Hive : temps de la requête, échanges réseau, cache, rendu du graphique et interactions. Nous relevons au minimum trois passages à froid et trois à chaud, en notant configuration de la machine, volumétrie, sélection des filtres et durée observée. Aucun temps réel n'est annoncé sans mesure. Les écrans les plus lents privilégieront les agrégats Gold et des limites d'affichage cohérentes.

Pour vérifier un indicateur et son plan d'exécution, on utilise une interrogation de référence et EXPLAIN sur la requête lourde. Les partitions doivent effectivement apparaître dans le prédicat :

```
EXPLAIN
SELECT SUM(nb_consultation) AS nb_consultations
FROM gold.fait_consultation
WHERE annee = 2020 AND etablissement_sk = 125;
```

La confidentialité constitue un critère de recette : pas d'identifiant direct, pseudonymisation non assimilée à une anonymisation, masquage des effectifs inférieurs au seuil approuvé par le DPO et attention aux recoupements par filtres successifs. Les vues régionales optionnelles ne doivent pas autoriser une réidentification par croisement de valeurs. Une vérification juridique et de sécurité reste nécessaire avant tout usage en production.

Enfin, la mise à jour trimestrielle suit l'ordre Hop → Bronze → Silver → Gold → agrégats/vues matérialisées → contrôle métier → invalidation du cache Superset → publication. Le tableau de bord affiche la date effective de fraîcheur des données et prévient quand une source optionnelle est indisponible. Le suivi opérationnel repose sur les logs Docker/Hive/Superset, la durée des jobs, les volumes traités, les rejets et les erreurs de chargement.

Conclusion

Ce dernier Prosit transforme les analyses produites au Prosit 3 en un parcours de décision utilisable : les KPI sont explicités, les graphiques rendent les comparaisons visibles, les filtres proposent une exploration maîtrisée et les contrôles sécurisent l'exploitation. Il couvre les trois objectifs d'apprentissage : exploitation des données Big Data, représentation graphique des KPI et amélioration de l'expérience utilisateur. La validation finale des chiffres et des temps de réponse doit être apportée à partir de la maquette réellement exécutée.