

CHU
Big Data

CESI
ÉCOLE D'INGÉNIEURS

Projet
Big Data

Réalisé par

Allan BOUHAMED

Philippe LUU

Matheo CARVAL

Maeva CHALLIES

Projet encadré par

Djamel AOUAM / Ali SKAF / Lea BEYRIS

Année universitaire 2026/2027

Livrable 1 - 26/10/2026

Informations générales

Historique des versions

Version	Date	Auteurs	Objet
0.1	20/10/2026	Allan Bouhamed	Première rédaction du référentiel
1.0	23/10/2026	Allan Bouhamed ; Philippe Luu ; Matheo Carval ; Maeva Challies	Mise au format du livrable officiel : cadre documentaire, synthèse, figures, glossaire, annexes
1.1	26/10/2026	Allan Bouhamed ; Philippe Luu ; Matheo Carval ; Maeva Challies	Mise en conformité avec les attendus : dictionnaire complet, modèles conceptuel et logique avec clés et cardinalités, alternatives techniques, fiches des jobs ETL, cadre RGPD, correspondance HDS
1.2	26/10/2026	Allan Bouhamed ; Philippe Luu ; Matheo Carval ; Maeva Challies	Prise en compte des évolutions du 23 au 25/10 : durée des consultations (passage de minuit), âge inconnu si la naissance suit l'acte, ordonnancement quotidien, constats qualité du chargement du 26/10
1.3	26/10/2026	Allan Bouhamed ; Philippe Luu ; Matheo Carval ; Maeva Challies	Adaptation à la grille d'évaluation : dénormalisation et 1FN, hiérarchie du datalake, job d'alimentation par dimension (clé, fréquence), contextes et paramétrage, correspondance avec la grille
1.4	26/10/2026	Allan Bouhamed ; Philippe Luu ; Matheo Carval ; Maeva Challies	Assistant IA documenté (composant, alternative open source, gouvernance) ; matrice des droits détaillée par écran ; calendrier sans membre -1 et borne 2025 justifiée ; localisation du patient ; cadrage joint au dépôt
1.5	26/10/2026	Allan Bouhamed ; Philippe Luu ; Matheo Carval ; Maeva Challies	Gestion de projet : équipe et rôles, calendrier du bloc et jalons, phases, tâches, responsables, avancement et charge
1.6	26/10/2026	Allan Bouhamed ; Philippe Luu ; Matheo Carval ; Maeva Challies	Réorganisation de la grille et des annexes

Tableau 1 -Historique des versions du document

Liste de diffusion

Organisme	Destinataire	Contact	Rôle
CESI	AOUAM Djamel	daouam@cesi.fr	Directeur informatique
CESI	SKAF Ali	askaf@cesi.fr	Responsable informatique
CESI	BEYRIS Lea	lbeyris@cesi.fr	Responsable informatique
CHU	LUU Philippe	philippe.luu@chu.fr	Ingénieur Data
CHU	BOUHAMED Allan	allan.bouhamed@chu.fr	Architecte Data
CHU	CARVAL Matheo	matheo.carval@chu.fr	Ingénieur Data
CHU	CHALLIES Maeva	maeva.challies@chu.fr	Ingénieur Data

Tableau 2 - Liste de diffusion.

Synthèse managériale

Objectif. Le groupe hospitalier CHU souhaite répondre aux questions de ses praticiens et de sa direction (taux de consultation, taux d'hospitalisation, mortalité, satisfaction). Les données nécessaires sont dispersées dans quatre sources indépendantes : la base opérationnelle PostgreSQL de l'hôpital, le référentiel national des établissements et professionnels, les enquêtes de satisfaction e-Satis déposées sur un serveur FTP et le fichier des décès de l'INSEE. Aucune source ne permet seule de calculer les indicateurs attendus. Ce premier livrable définit le référentiel de données et l'architecture cible qui les réunit.

Solution retenue. L'équipe a conçu un *lakehouse* en couches successives (landing, Bronze, Silver, Gold) reposant sur Apache Spark et Delta Lake, stocké sur MinIO (stockage objet compatible S3) et orchestré par Apache Airflow. La couche Gold suit un modèle décisionnel en constellation (quatre tables de faits partageant six dimensions conformes). Elle est interrogée par Trino et restituée dans une application web développée par l'équipe (FastAPI et React), protégée par Keycloak.

Résultats clés.

- Les huit indicateurs du sujet sont définis sans ambiguïté (numérateur, dénominateur) et calculés, y compris les deux indicateurs optionnels (décès 2019 et satisfaction 2020 par région).
- La couche Gold contient 25,9 millions de lignes, dont 24,9 millions de décès, 1 027 157 consultations et 2 479 séjours.
- Les contrôles qualité sont bloquants : au chargement du 26/10/2026, les 17 clés étrangères de Gold ne présentent aucun orphelin et tous les contrôles sont satisfaits. Lors du premier chargement, un contrôle a empêché la publication de données incomplètes, ce qui démontre l'efficacité du garde-fou.
- La plateforme est alimentée automatiquement chaque nuit : les sources sont rechargées entre 00:00 et 01:00 UTC et la couche Gold est republiée à 03:00 UTC.
- Les données patients sont pseudonymisées dès la couche Silver, et aucune donnée directement identifiante ne dépasse la couche Bronze. Les droits d'accès sont vérifiés côté serveur pour quatre rôles.
- La plateforme est en ligne sur https://chu.allanbouhamed.fr. Les requêtes de l'application répondent en moins de 0,7 seconde (détail dans le livrable 2).

Conformité aux attentes. Les quatre sources sont intégrées, l'architecture Bronze / Silver / Gold est respectée et les huit indicateurs sont couverts. Un écart au manuel est

assumé et justifié : la pile Cloudera QuickStart et Talend, obsolète, a été remplacée par des outils open source maintenus couvrant les mêmes notions (partitionnement, bucketing, stockage distribué). Chaque critère de la grille d'évaluation du livrable est rattaché à la partie qui y répond (annexe A).

Ressources. La plateforme fonctionne sur un poste local avec Docker (8 Go de RAM au minimum, environ 15 Go de disque) et sur un serveur hébergé dans l'Union européenne (8 cœurs, 24 Go de RAM). Tous les logiciels de la plateforme sont open source et gratuits. Seul l'assistant IA, optionnel, appelle pour la démonstration une API de modèle de langage payante ; la cible de production est un modèle à poids ouverts hébergé avec la plateforme (annexe E). La charge planifiée est de 464 heures, soit environ 66 jours-personne sur les quatre semaines du bloc (§ 3.3). Le coût du serveur d'hébergement est de 30€/mois TTC.

Conclusion. Le référentiel et l'architecture décrits ici sont implémentés, alimentés et vérifiés. Ils constituent une base solide pour les livrables suivants (implémentation physique et performance, puis restitution). Trois actions sont recommandées au métier : compléter le rattachement des professionnels aux établissements, corriger les dates incohérentes de la source S1 et obtenir la version complète de l'annuaire des professionnels.

Sommaire

Informations générales 3
Historique des versions 3
Liste de diffusion 4
Synthèse managériale 5
Sommaire 7
1. Contexte et présentation du projet 10
1.1 La demande 10
1.2 Les sources à réunir 10
2. Objectifs, indicateurs et contraintes 11
2.1 Indicateurs 11
2.2 Choix de définition 12
2.3 Contraintes 12
3. Gestion de projet 14
3.1 Organisation de l'équipe 14
3.2 Calendrier et jalons 15
3.3 Chiffrage 16
3.4 Déroulement, outils et aléas 16
4. Choix techniques et justifications 17
4.1 Une architecture lakehouse 17
4.2 Composants retenus 17
4.3 Écarts au manuel d'installation 18
5. Référentiel des sources de données 19
5.1 S1 -Base opérationnelle PostgreSQL 19
5.2 S2 -Référentiel des établissements 21
5.3 S3 -Satisfaction des patients 21
5.4 S4 -Décès INSEE 22
6. Architecture et hiérarchie du datalake 23
6.1 Rôle des couches 23
6.2 Parcours d'une donnée 23
6.3 Hiérarchie du datalake 24
7. Modèle en étoile (couche Gold) 27
7.1 Démarche de modélisation 27
7.2 Matrice de bus 27
7.3 Modèle conceptuel 28

7.4 Modèle logique 29
7.5 Cardinalités 31
7.6 Grain et mesures 32
8. Alimentation du modèle en étoile 34
8.1 Chaînes de traitement 34
8.2 Alimentation, dimension par dimension 35
8.2.1 Dimension patient 35
8.2.2 Dimension professionnel 36
8.2.3 Dimension diagnostic 36
8.2.4 Dimension localisation 37
8.2.5 Dimension temps 37
8.2.6 Dimension établissement 38
8.2.7 Faits 38
8.3 Contextes et paramétrage 39
8.4 Gestion des erreurs et reprise 40
9. Qualité et gouvernance des données 43
9.1 Qualité des données 43
9.2 Gouvernance en synthèse 44
10. Perspectives et recommandations 46
Table des figures et des tableaux 48
Glossaire 51
Annexes 54
Annexe A -Correspondance avec la grille d'évaluation 54
Annexe B -Dictionnaire de données 55
B.1 dim_temps 56
B.2 dim_localisation 57
B.3 dim_etablissement 58
B.4 dim_patient 59
B.5 dim_diagnostic 60
B.6 dim_professionnel 60
B.7 fait_consultation 61
B.8 fait_hospitalisation 63
B.9 fait_deces 64
B.10 fait_satisfaction 65
Annexe C -Spécifications ETL détaillées 67
C.1 Règles de transformation 67

C.2 Fiches de spécification des jobs....67
Annexe D -Gestion de projet détaillée....71
D.1 Phases, tâches et avancement....71
D.2 Outils....75
D.3 Aléas et décisions....75
Annexe E -Alternatives techniques étudiées....76
Annexe F -Gouvernance détaillée....78
F.1 Protection des données personnelles....78
F.2 Cadre RGPD du traitement....79
F.3 Rôles et droits....81
F.4 Traçabilité....82
F.5 Conformité HDS....83
Annexe G -Liens....84
Annexe H -Organisation du dépôt....85
Annexe I -Document de cadrage....85

1. Contexte et présentation du projet

1.1 La demande

Le projet s'inscrit dans le bloc " Stockage et Big Data ". Il place l'équipe dans la situation d'une cellule data au service du groupe hospitalier fictif CHU (Cloud Healthcare Unit). Le CHU veut un outil décisionnel qui réponde à deux publics : les praticiens, qui s'intéressent à l'activité de consultation et d'hospitalisation, et la direction, qui pilote les établissements, la mortalité et la satisfaction des patients.

Le cadrage du projet (document " Projet Cloud Healthcare Unit : présentation, fonctionnement et stack technique ", 14 pages, voir annexe I) impose quatre sources, une architecture en couches Bronze / Silver / Gold, huit indicateurs et trois livrables. Il fixe aussi trois exigences non fonctionnelles : uniquement des briques open source déployables sans licence, conformité RGPD avec une trajectoire vers un hébergement certifié HDS, et une architecture qui passe d'un poste local à un cluster sans réécriture. Le projet est mené par une équipe de quatre, sur un bloc de quatre semaines du 19/10 au 13/11/2026 (§ 3.1 et 3.2).

1.2 Les sources à réunir

Les données utiles sont réparties dans quatre systèmes qui ne communiquent pas entre eux.

Source	Contenu	Format	Mode d'accès
S1	Base opérationnelle de l'hôpital : patients, consultations, diagnostics, professionnels, prescriptions ; export des hospitalisations	Dump PostgreSQL et CSV	JDBC
S2	Référentiel des établissements de santé, annuaire et activités des professionnels	CSV (;)	Fichiers locaux
S3	Indicateurs qualité et enquêtes de satisfaction e-Satis de la HAS	CSV et XLSX	Serveur FTP
S4	Fichier des personnes décédées de l'INSEE	CSV (1,9 Go)	Serveur FTP

Tableau 3 -Sources de données imposées par le sujet.

2. Objectifs, indicateurs et contraintes

2.1 Indicateurs

Le sujet emploie le mot " taux " sans le définir. Pour lever toute ambiguïté, chaque indicateur est fixé par un numérateur et un dénominateur. Ces définitions sont implémentées à l'identique dans l'API et dans le benchmark , ce qui garantit que l'application et les mesures portent sur le même calcul.

N°	Indicateur	Numérateur	Dénominateur	Fait	Statut
1	Taux de consultation par établissement	consultations rattachées à l'établissement	consultations rattachées à un établissement sur la période	fait_consultation	obligatoire
2	Taux de consultation par diagnostic	consultations portant le diagnostic	consultations de la période	fait_consultation	obligatoire
3	Taux global d'hospitalisation	patients distincts hospitalisés	patients distincts suivis (au moins une consultation ou une hospitalisation)	fait_hospitalisation, fait_consultation	obligatoire
4	Taux d'hospitalisation par diagnostic	séjours portant le diagnostic (code ou chapitre CIM-10)	séjours de la période	fait_hospitalisation	obligatoire
5	Taux d'hospitalisation par sexe et âge	séjours du couple (sexe, tranche d'âge à l'admission)	séjours de la période	fait_hospitalisation	obligatoire
6	Taux de consultation par professionnel	consultations du professionnel	consultations de la période	fait_consultation	obligatoire
7	Décès par région en 2019	décès dont le lieu (commune INSEE) est dans la région durant l'année	-(comptage)	fait_deces	optionnel, réalisé
8	Satisfaction par région en 2020	moyenne des scores e-Satis	–	fait_satisfaction	optionnel, réalisé

N°	Indicateur	Numérateur	Dénominateur	Fait	Statut
		ajustés des établissements de la région (au moins 30 répondants), avec une variante pondérée par le nombre de répondants durant l'année			

Tableau 5 -Définition des huit indicateurs.

2.2 Choix de définition

Trois points du sujet ont nécessité un arbitrage, documenté ici car il conditionne la lecture des résultats.

Établissement d'une consultation. La table `Consultation` de S1 ne porte pas l'établissement. Celui-ci est déduit du rattachement principal du professionnel dans le fichier `activite_professionnel_sante` de S2 : l'exercice salarié est privilégié, puis l'exercice libéral, puis l'identifiant d'organisation le plus petit. 36 % des consultations concernent des professionnels sans organisation connue. Elles sont rattachées au membre " Non rattaché " (clé -1), exclues du dénominateur de l'indicateur 1 et affichées à part dans l'application.

Tranches d'âge. Les tranches sont décennales (00-09 à 80-89, puis 90 ans et plus). L'âge est calculé à la date de l'acte ou de l'admission, et non à la date du jour.

Enquête de satisfaction. Deux enquêtes e-Satis sont intégrées : hospitalisation de plus de 48 heures en médecine, chirurgie et obstétrique (MCO), et chirurgie ambulatoire. L'indicateur 8 utilise par défaut l'enquête " +48 h " ; l'autre est accessible par un filtre.

2.3 Contraintes

Contrainte	Origine	Conséquence sur la conception
Données de santé (RGPD, article 9)	Nature des données S1	Pseudonymisation dès Silver, minimisation, seuil de diffusion, contrôle d'accès par rôle
Hébergement de données de santé (HDS)	Réglementation française	Architecture alignée sur les exigences HDS sans certification (projet pédagogique), écarts et trajectoire décrits (annexe F.5)

Contrainte	Origine	Conséquence sur la conception
Sources intégrées sans modification	Sujet	Couche Bronze en copie brute, rejouable
Exécution sur un poste local	Moyens de l'équipe	Docker Compose ; un seul job Spark à la fois (pool Airflow) ; 8 Go de RAM au minimum
Volumétrie : 25 millions de décès	Source S4	Spark, format colonnaire, partitionnement par année et région
Stack proposée par le manuel (Cloudera, Talend)	Manuel d'installation	Remplacée et justifiée (§ 4.3)

Tableau 6 -Contraintes du projet et réponses apportées.

3. Gestion de projet

3.1 Organisation de l'équipe

L'équipe compte quatre membres. Les rôles ont été répartis selon les compétences de chacun, de façon que chaque partie du projet ait un responsable et un appui.

Membre	Profil	Rôle dans le projet	Responsabilités principales
Allan Bouhamed	data engineer, référent technique data	architecte de la plateforme	architecture, pipelines Spark Bronze / Silver / Gold, modèle Gold, ordonnancement Airflow, benchmark
Mathéo Carval	développeur	responsable applicatif	API FastAPI, application React, Keycloak, assistant IA, déploiement et mise en ligne
Philippe Luu	profil mixte data et développement	analyste de données et rédacteur de livrable	étude des sources, indicateurs, contrôles qualité, dictionnaire de données, spécifications ETL, gouvernance technique, livrables
Maeva Challies	profil mixte data et développement	analyste de données et cheffe de projet	planning et suivi, recette fonctionnelle par profil, cadre réglementaire RGPD / HDS, mise en forme des livrables, soutenance

Tableau 7 -Composition de l'équipe et rôles.

Chaque tâche a un responsable, qui la mène et en rend compte, et un appui, qui relit ou contribue. Les tâches techniques lourdes sont confiées aux profils les plus expérimentés, chacune étant relue par un profil différent : le code de données par Philippe, la documentation par Maeva. Cette relecture croisée permet à chacun de comprendre l'ensemble de la plateforme pour la soutenance.

3.2 Calendrier et jalons

Le bloc s'étend sur quatre semaines, du 19/10 au 13/11/2026. Le travail sur le projet se fait pendant les créneaux prévus à l'emploi du temps : lancement, prosits, workshops et tutorats. Les cours d'anglais, le contrôle (CCTL) et le jour férié du 11/11 n'en font pas partie.

Semaine	Dates	Créneaux projet à l'emploi du temps	Heures projet par personne	Objectif de la semaine	Jalon
Sem. 1	19 au 23/10	lancement et prosit aller 1 (19/10), tutorat (20/10, journée), tutorat (21/10 matin), prosit retour 1 (22/10), prosit aller 2 et workshop (23/10)	31 h	cadrage, étude des sources, plateforme complète, premier chargement	–
Sem. 2	26 au 30/10	workshop 2 et tutorat pédagogique (26/10), workshop 2 et prosit retour 2 (27/10), tutorat projet (28/10 matin), tutorat projet (29/10), prosit aller 3 et tutorat projet (30/10)	31 h	remise du livrable 1, rédaction du livrable 2, tableau de bord complémentaire	**L1 : lundi 26/10, 23:00**
Sem. 3	2 au 6/11	workshop 3 et prosit retour 3 (2/11), tutorat pédagogique et projet (3/11, journée), tutorat (4/11 après-midi), tutorat (5/11), tutorat et workshop 4 (6/11)	31 h	remise du livrable 2, support de soutenance, démonstration	**L2 : lundi 2/11, 23:00**
Sem. 4	9 au 13/11	prosit retour et tutorat (9/11), tutorat projet (10/11, journée), soutenance et retour d'expérience (13/11)	23 h	répétitions, remise du livrable 3, soutenance, clôture	**L3 : jeudi 12/11, 18:30** ; **soutenance : vendredi 13/11, matin**

Tableau 8 -Calendrier du bloc, créneaux de travail et jalons.

Chaque personne dispose ainsi de 116 heures de créneaux projet sur le bloc, soit 464 heures pour l'équipe (§ 3.3). Les tutorats servent de points d'étape avec les encadrants

: le tutorat du 26/10 précède la remise du livrable 1, ceux des 29 et 30/10 permettent de valider le contenu du livrable 2, ceux des 9 et 10/11 servent de répétition générale.

3.3 Chiffrage

La charge est calculée à partir des créneaux projet de l'emploi du temps (§ 3.2), sur la base de journées de 7 heures.

Semaine	Heures par personne	Heures pour l'équipe (4 personnes)	Jours-personne
Sem. 1 (19 au 23/10)	31	124	17,7
Sem. 2 (26 au 30/10)	31	124	17,7
Sem. 3 (2 au 6/11)	31	124	17,7
Sem. 4 (9 au 13/11)	23	92	13,1
Total	**116**	**464**	**66,3**

Tableau 9 -Charge de travail planifiée.

Au 26/10, 156 heures ont été consommées (environ 22 jours-personne), soit 34 % de la charge, pour quatre phases techniques terminées sur neuf.

Côté coûts, tous les logiciels sont open source et gratuits. Le seul coût est le serveur de démonstration : 30€/mois. Il doit être résilié après la soutenance, avant son renouvellement automatique (tâche 9.1). L'assistant IA ajoute un coût d'usage de l'API du modèle de langage, limité par le quota de 30 questions par heure et par compte.

3.4 Déroulement, outils et aléas

Le projet est découpé en neuf phases, de P1 (cadrage) à P9 (clôture). Au 26/10/2026, les quatre phases techniques sont terminées : cadrage, étude des sources, socle technique et mise en ligne, pipelines avec qualité et ordonnancement. L'application est avancée à 85 %, le livrable 1 est en finalisation, le livrable 2 est à 70 % et le livrable 3 est à venir. L'équipe travaille avec Git et GitHub, Docker Compose pour un environnement identique sur chaque poste, et un serveur de démonstration en HTTPS.

Les principaux aléas ont porté sur la mémoire disponible (traitement des 25 millions de décès, benchmark), la stabilité de Docker Desktop et deux anomalies de données détectées puis corrigées : la durée de consultation vide et les âges négatifs. Le détail des phases et des tâches, les outils et le registre complet des aléas figurent en annexe D.

4. Choix techniques et justifications

4.1 Une architecture lakehouse

Le choix d'un *lakehouse* en couches répond directement au cadrage. Il combine le stockage de fichiers bon marché d'un lac de données et la rigueur d'un entrepôt (transactions, schéma contrôlé, historique). La séparation en couches présente trois avantages : chaque étape peut être rejouée à partir de la précédente, l'origine de chaque chiffre peut être auditée, et les données sensibles restent confinées aux couches basses.

4.2 Composants retenus

Fonction	Composant	Justification
Stockage	MinIO (compatible S3)	Stockage objet distribué ; le même code fonctionne sur tout stockage S3 (OVHcloud, Scaleway, Amazon)
Format de table	Delta Lake sur Parquet	Transactions ACID, MERGE, *time travel*, schéma contrôlé à l'écriture
Traitement	Apache Spark 3.5 (PySpark)	Traitement parallèle des gros volumes ; passage d'un poste (`local[*]`) à un cluster en changeant la seule variable `SPARK_MASTER`
Catalogue	Hive Metastore	Définition unique des tables partagée par Spark et Trino
Requêtes interactives	Trino	Réponses rapides pour l'application, sans le temps de démarrage de Spark
Orchestration	Apache Airflow	Planification, dépendances par Datasets, reprises automatiques, alertes
Qualité	Great Expectations	Règles déclaratives, rapports HTML et JSON, sévérité bloquante ou d'avertissement
Restitution	FastAPI, React, ECharts, Leaflet	Application développée par l'équipe, requêtes paramétrées, cartes
Identité	Keycloak (OIDC)	Comptes, rôles et jetons courts (15 min)
Lignage (option)	OpenLineage, Marquez	Traçabilité des tables, profil `lineage`
Assistant d'analyse (option)	Modèle de langage appelé par l'API en mode " outils " : Claude (Anthropic) pour la démonstration, modèle	Répond en langage naturel aux questions sur les indicateurs, en n'utilisant que les indicateurs de l'API ; désactivé si aucune clé n'est configurée

Fonction	Composant	Justification
	DeepSeek à poids ouverts visé en production	

Tableau 10 -Composants de la plateforme et justification.

La Figure 1 présente l'assemblage de ces composants.

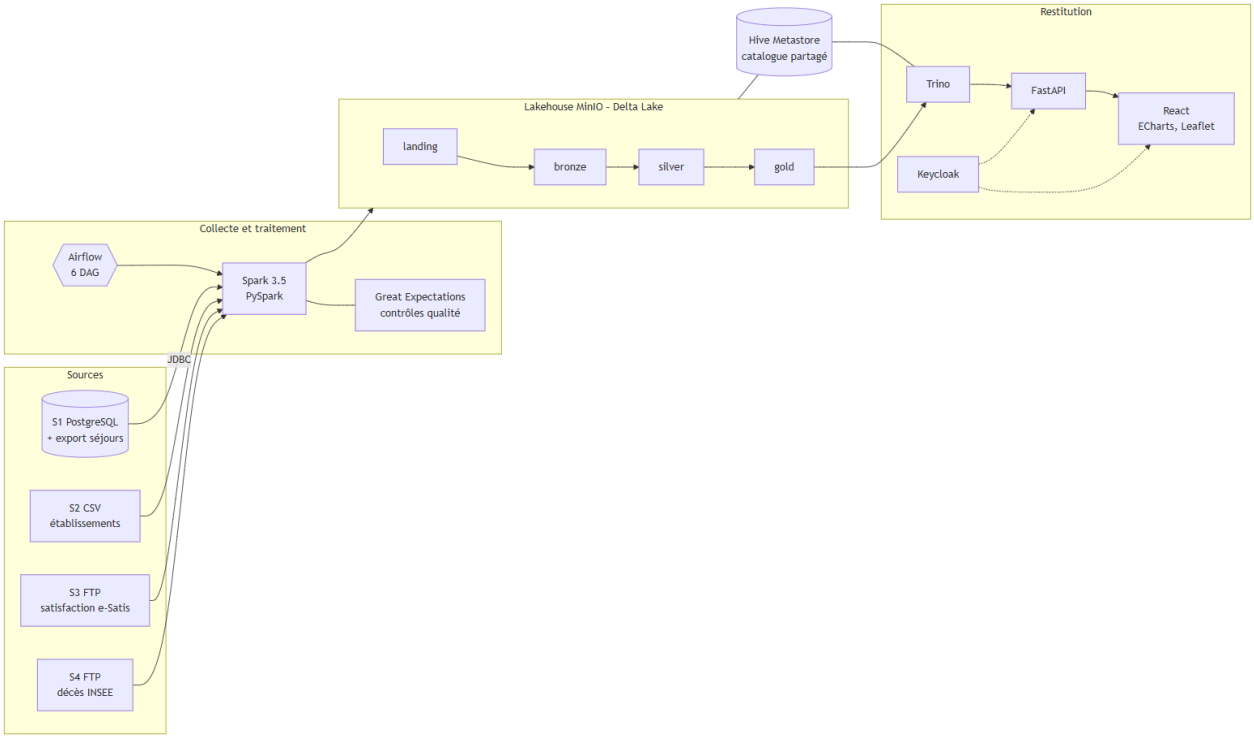


Figure 1 -Architecture d'ensemble de la plateforme

4.3 Écarts au manuel d'installation

Le manuel proposait Cloudera QuickStart et Talend. Cette pile a été remplacée pour trois raisons : Talend Open Studio a été retiré en 2024 ; la machine virtuelle QuickStart 5.12 date de 2017 et n'est plus maintenue ; Hive n'y gère pas les transactions ACID par défaut. Spark et Delta Lake couvrent les mêmes notions du cours (partitionnement, bucketing, stockage distribué) et sont utilisés en entreprise. Enfin, les images officielles MinIO n'étant plus publiées, la redistribution communautaire `pgsty/minio`, compatible à l'identique, est utilisée.

5. Référentiel des sources de données

Les quatre sources sont intégrées telles quelles, sans modification à la source.

5.1 S1 -Base opérationnelle PostgreSQL

La source S1 est un dump PostgreSQL (`DATA2023`) de 13 tables.

Table	Lignes	Clé	Attributs principaux	Usage
Patient	100 000	Id_patient	Nom, Prénom, Sexe (male/female), Adresse, Ville, Code_postal, Email, Tel, Date (naissance M/d/yyyy), Age, Num_Secu, Groupe_sanguin, Poids, Taille	dim_patient (pseudonymisée)
Consultation	1 027 157	Num_consultation	Id_patient, Id_prof_sante, Code_diag, Id_mut, Motif, Date, Heure_debut, Heure_fin	fait_consultation
Diagnostic	15 490	Code_diag	Diagnostic (libellé CIM-10)	dim_diagnostic
Professionnel_de_sante	1 048 575	Identifiant (RPPS / ADELI)	Civilité, Catégorie, Nom, Prénom, Profession, Type_identifiant, Code_specialite	dim_professionnel
Specialites	93	Code_specialite	Fonction, Spécialité	dim_professionnel
Prescription	1 003 845	(Num_consultation, Code_CIS)	–	Silver uniquement
Medicaments	15 455	Code_CIS	Dénomination, forme, voies, statut, AMM, titulaire	Silver uniquement
Laboratoire	677	Id_labo	Laboratoire, Pays	Silver uniquement
Mutuelle	254	Id_Mut	Nom, Adresse	Silver uniquement

Table	Lignes	Clé	Attributs principaux	Usage
Adher	96 671	(Id_patient, Id_mut)	–	Silver uniquement
Salle	201 735	Id_salle	Num_consultation, bloc, étage, salle	Silver uniquement
date	82 216	–	date1, date2 (texte)	Bronze uniquement (table technique)
AAAA	82 216	Id	Nom, Prénom, Adresse fictifs, Code_diag	Bronze uniquement (table de test)

Tableau 11 -Tables de la source S1.

Les relations entre ces tables, portées par les clés étrangères du dump, sont représentées par la Figure 2.

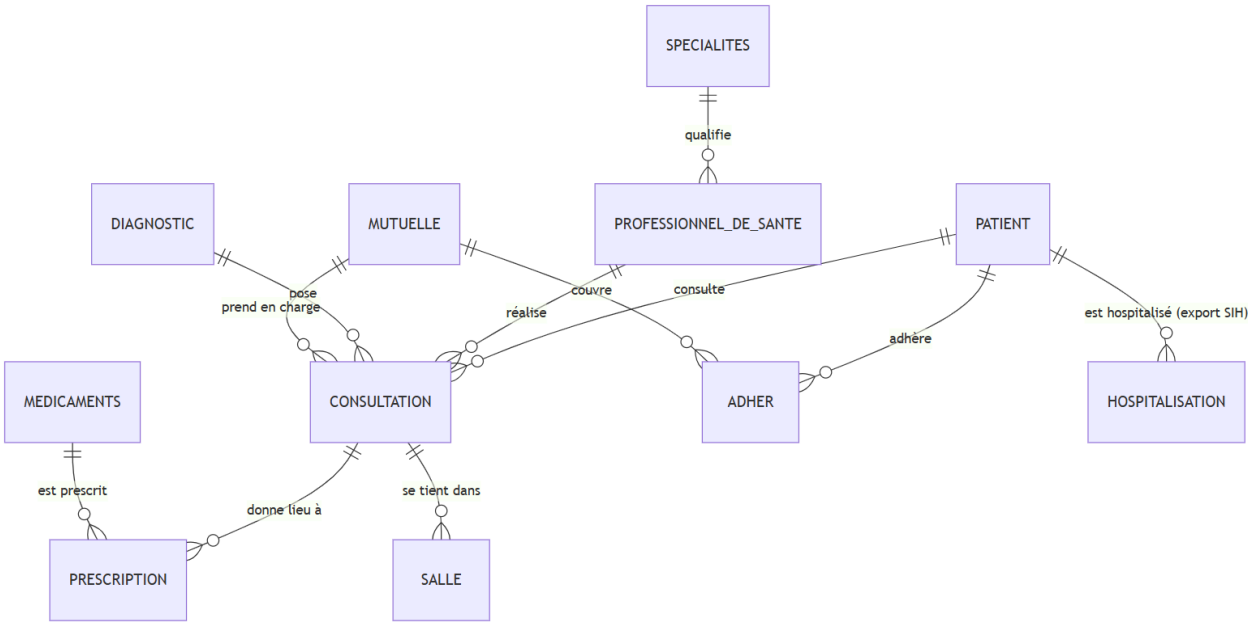


Figure 2 -Modèle conceptuel de la source S1

L'export des hospitalisations (`Hospitalisation/Hospitalisations.csv`) compte 2 479 séjours entre 2015 et 2021. Il contient Num_Hospitalisation, Id_patient (même identifiant que S1), identifiant_organisation (établissement S2), Code_diagnostic, le libellé, Date_Entree (dd/MM/yyyy) et Jour_Hospitalisation (durée en jours). Il est intégré au pipeline S1 comme export du système d'information hospitalier.

5.2 S2 -Référentiel des établissements

Fichier	Lignes	Encodage	Clé	Attributs principaux
etablissement_sante.csv	416 665	UTF-8	identifiant_organisation (unique)	finess_site, finess_etablissement_juridique, raison sociale, enseigne, SIRET, adresse, code_commune INSEE (renseigné à 67 %), code_postal, commune, téléphone, e-mail
professionnel_sante.csv	1 048 575	ISO-8859-1	identifiant	civilité, catégorie, nom, prénom, profession, spécialité, type d'identifiant
activite_professionnel_sante.csv	1 823 588	UTF-8	(identifiant, identifiant_organisation)	mode d'exercice (Salarié, Libéral, Bénévole)

Tableau 12 -Fichiers de la source S2 (séparateur ;).

Deux anomalies ont été relevées. D'une part, `professionnel_sante.csv` compte exactement 1 048 575 lignes de données, soit la limite d'une feuille Excel : le fichier est probablement tronqué, ce qui a été signalé au métier. D'autre part, le référentiel ne contient ni capacités ni certifications. La dimension établissement porte donc un type dérivé de la raison sociale (CHU/CHR, CH, clinique, pharmacie, laboratoire, etc.).

5.3 S3 -Satisfaction des patients

Le serveur FTP met à disposition les résultats publics de la HAS : indicateurs qualité (IQSS, DPA, RCP, etc.) et enquêtes e-Satis, en CSV (Windows-1252) ou en XLSX selon les années. Seuls les résultats e-Satis mesurent la satisfaction des patients ; ce sont eux qui alimentent l'indicateur 8.

Fichier	Année d'enquête	Établissements
ESATIS48H_MCO_recueil2017_donnees.csv	2017	1 157
resultats-esatis48h-mco-open-data-2019.csv	2019	1 152
resultats-esatisca-mco-open-data-2019.csv	2019	945
resultats-esatis48h-mco-open-data-2020.xlsx	2020	environ 1 150
resultats-esatisca-mco-open-data-2020.xlsx	2020	environ 950

Tableau 13 -Fichiers e-Satis exploités.

Les attributs comprennent les codes FINESS juridique et géographique, les raisons sociales, la région, la participation, le nombre de répondants, les scores ajustés, le classement A à D, l'évolution, les scores par dimension et le taux de recommandation. Le lien avec S2 s'établit par la règle `identifiant_organisation = 'F' || finess_geo`. Les autres fichiers du FTP sont archivés sans transformation dans le bucket `landing`.

5.4 S4 -Décès INSEE

Le fichier `deces.csv` compte 25 088 208 lignes (1,9 Go) et couvre les décès de 1970 à mars 2020. Il contient le nom, les prénoms, le sexe (1/2), la date et le lieu de naissance (code commune, libellé, pays), la date de décès, le code commune du lieu de décès et le numéro d'acte. Les dates peuvent être partielles (mois ou jour à `00`) et les codes `99xxx` désignent un décès à l'étranger. Le profilage a également révélé des décès plus anciens, le premier datant de 1882 (annexe D.3).

6. Architecture et hiérarchie du datalake

6.1 Rôle des couches

Chaque couche correspond à un bucket MinIO, avec une règle de gestion et un public précis.

Couche	Bucket MinIO	Contenu	Règle principale	Accès
Landing	`landing`	fichiers FTP déposés, à l'identique	archive, expiration à 365 jours	data engineers
Bronze	`bronze`	copie brute des sources en Delta, enrichie de `_ingestion_ts`, `_source` et `_batch_id`	ajout seul, rejouable	data engineers
Silver	`silver`	une table par entité métier, typée, dédoublonnée, pseudonymisée ; tables `rejets_*`	aucune donnée directement identifiante	data engineers
Gold	`gold`	schéma en constellation, partitionné, Z-ordonné	seule couche exposée (via Trino)	application
Audit	`bronze/_audit`	`audit.job_runs` : lignes lues, écrites, rejetées et doublons par exécution	ajout seul	data engineers

Tableau 14 -Couches du lakehouse.

Le catalogue Hive Metastore référence toutes les tables (`bronze.*`, `silver.*`, `gold.*`). Spark et Trino partagent ainsi une définition unique des données.

6.2 Parcours d'une donnée

La Figure 3 suit une donnée de la source jusqu'à l'application. Les fichiers déposés sur le FTP transitent par la zone landing ; les sources JDBC et CSV sont copiées directement en Bronze. Le passage en Silver applique les règles de nettoyage et isole les lignes invalides dans des tables de rejets. La publication en Gold n'a lieu que si les contrôles qualité sont satisfaits.

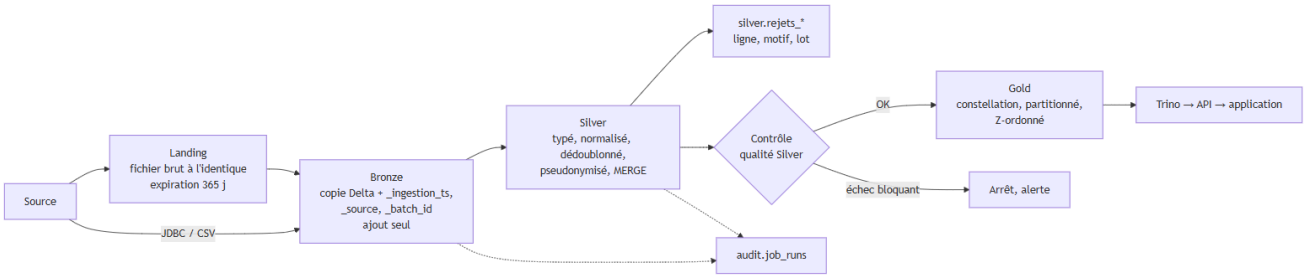


Figure 3 -Parcours d'une donnée à travers les couches

6.3 Hiérarchie du datalake

L'organisation des répertoires découle d'une règle unique, appliquée par la fonction `path_of` de `pipelines/common/io.py` : **un bucket par couche, un répertoire par table**. Chaque table est déclarée dans le Hive Metastore comme table externe pointant sur son répertoire (`CREATE TABLE IF NOT EXISTS <couche>.<table> USING DELTA LOCATION 's3a://<couche>/<table>'`). Supprimer la table du catalogue ne supprime donc pas les données, et Spark comme Trino lisent le même répertoire.

s3a://landing/ Fichiers FTP déposés à l'identique (chemin d'origine conservé). Expiration au bout de 365 jours.

Tableau A : s3a://bronze/ : données brutes ingérées

Répertoire	Contenu	Source
pg_patient/, pg_consultation/, pg_diagnostic/, pg_professionnel_de_sante/, …	Une table PostgreSQL par répertoire	S1
csv_hospitalisations/	Export SIH	–
csv_etablissement_sante/, csv_professionnel_sante/, csv_activite_professionnel_sante/	Fichiers CSV	S2
ftp_satisfaction_<enquête>/	Un répertoire par enquête	S3
ftp_deces/annee_deces_brute=<AAAA>/	Partitionné par année	S4
_audit/job_runs/	Journal des exécutions	–

Tableau B : s3a://silver/ : données nettoyées

Répertoire	Contenu
patient/, diagnostic/, professionnel/, etablissement/, …	Tables nettoyées
consultation/annee=<AAAA>/	Partitionné par année
rejets_<source>/	Lignes rejetées

Tableau C : s3a://gold/ : modèle en étoile

Type	Répertoire	Partitionnement
Dimension	dim_temps/, dim_localisation/, dim_etablissement/, dim_patient/, dim_diagnostic/, dim_professionnel/	–
Fait	fait_consultation/	annee=<AAAA>
Fait	fait_hospitalisation/	annee=<AAAA>
Fait	fait_deces/	annee=<AAAA>/code_region=<RR>
Fait	fait_satisfaction/	annee=<AAAA>/code_region=<RR>

Tableau D : s3a://benchmark/ Versions naïves utilisées par le benchmark.

Figure 4 -Hiérarchie des répertoires du datalake

Cette hiérarchie est justifiée par quatre besoins.

Besoin	Réponse de la hiérarchie
Charger chaque table indépendamment	Chaque dimension et chaque fait a son propre répertoire : le chargement d'une dimension n'écrit que dans le sien et peut être rejoué seul
Créer des tables externes dans Hive	Un répertoire par table donne une clause `LOCATION` unique ; le catalogue ne porte que la définition, les données restent dans MinIO

Besoin	Réponse de la hiérarchie
Lire le moins de données possible	Les sous-répertoires de partition (`annee=`, `code_region=`) permettent à Spark et Trino de ne lire que les années ou régions demandées
Séparer les droits et les durées de conservation	Un bucket par couche permet des règles distinctes : expiration de landing, accès restreint à Bronze et Silver, seul Gold exposé

Tableau 15 -Justification de la hiérarchie du datalake.

Chaque chargement d'une dimension est stocké dans son propre répertoire. dim_patient, dim_professionnel, dim_diagnostic, dim_localisation, dim_temps et dim_etablissement ont chacune leur répertoire (s3a://gold/<dimension>/), déclaré comme table externe dans le Hive Metastore. Le job d'une dimension n'écrit que dans ce répertoire : il peut être relancé seul, sans toucher aux autres tables.

Dans ce répertoire, chaque chargement est en plus conservé séparément grâce au journal Delta (_delta_log). Chaque chargement y crée une version numérotée et datée. Une version précédente reste lisible (time travel) et peut être restaurée en une commande (§ 8.4). On obtient ainsi l'historique des chargements sans multiplier les répertoires datés, qui obligeraient à redéclarer la table externe à chaque chargement. En Bronze, chaque ligne porte aussi l'identifiant de son lot (_batch_id) et sa date d'ingestion : un chargement donné peut être retrouvé, rejoué ou purgé.

7. Modèle en étoile (couche Gold)

7.1 Démarche de modélisation

La couche Gold suit l'approche de Kimball : quatre tables de faits partagent des dimensions conformes, ce qui forme une constellation. Les clés de substitution sont déterministes (`abs(xxhash64(clé métier))`) : une reconstruction redonne les mêmes clés, ce qui rend les traitements rejouables. Chaque dimension, sauf le calendrier, possède un membre " Non renseigné " de clé -1, afin qu'aucun fait ne soit perdu faute de correspondance. Le calendrier n'en a pas besoin : une ligne dont la date est absente ou invalide est rejetée dès Silver, et le contrôle d'intégrité vérifie que chaque date des faits existe dans `dim_temps`.

Le modèle est volontairement **dénormalisé**, ce qui distingue le schéma en étoile du modèle relationnel de la source. Chaque dimension est une table unique, sans sous-table : la spécialité et la fonction sont recopiées dans `dim_professionnel` au lieu de rester dans une table `Specialites`, et le département, la région et leurs libellés sont répétés dans `dim_etablissement` et `dim_patient` au lieu d'être obtenus par une chaîne de jointures. Cette redondance est acceptée car elle réduit le nombre de jointures des requêtes d'analyse. Le modèle respecte en revanche la **première forme normale** : chaque colonne contient une valeur atomique (pas de liste ni de groupe répété), chaque table possède une clé primaire, et les mesures sont des nombres directement agrégeables (`nb_consultation`, `nb_sejour`, `nb_deces`, `score_global`). Le modèle répond ainsi à la problématique d'analyse des données médicales : chaque indicateur du Tableau 5 se calcule par une agrégation sur un fait, filtrée ou regroupée par ses dimensions.

7.2 Matrice de bus

Dimension	Consultation	Hospitalisation	Décès	Satisfaction
dim_temps	oui (`id_date`)	oui (`id_date_entree`, `id_date_sortie`)	oui	oui (1er janvier de l'année d'enquête)
dim_etablissement	oui (rattachement du professionnel)	oui	non	oui
dim_localisation	via l'établissement	via l'établissement	oui (commune du décès)	via l'établissement
dim_patient	oui	oui	non	non
dim_diagnostic	oui	oui	non	non
dim_professionnel	oui	non	non	non

Tableau 16 -Matrice de bus : dimensions partagées par les faits.

7.3 Modèle conceptuel

Le sujet demande un schéma en étoile. Une étoile est une table de faits entourée de ses dimensions. Le modèle retenu en compte quatre (consultation, hospitalisation, décès, satisfaction) qui partagent les mêmes dimensions conformes : cet assemblage d'étoiles s'appelle une **constellation**. Chaque étoile, prise seule, reste un schéma en étoile classique, et le partage des dimensions permet de croiser les indicateurs (par exemple l'activité et la mortalité d'une même région).

Deux dimensions sont reliées à une autre dimension (léger " flocon ") : un établissement est situé dans une localisation, et un professionnel est rattaché à un établissement principal. Ces liens sont conservés parce qu'ils sont nécessaires aux règles de gestion : l'établissement d'une consultation est celui du professionnel (§ 2.2), et la région d'un établissement vient de sa commune. Pour éviter une jointure supplémentaire au moment des requêtes, le département et la région sont aussi recopiés dans `dim_etablissement`.

`dim_patient`, en revanche, n'est pas reliée à `dim_localisation`. Pour la résidence du patient, la source S1 ne donne qu'un code postal. Or un code postal ne désigne pas une commune INSEE (il peut en couvrir plusieurs), et la minimisation RGPD conduit à ne conserver que le département. Le département et la région de résidence sont donc portés directement par `dim_patient`, comme le veut la dénormalisation du § 7.1. Le cadrage prévoyait une clé de localisation sur le patient ; elle a été écartée pour ces deux raisons. Aucun des huit indicateurs n'utilise la résidence du patient.

La Figure 5 représente le modèle conceptuel : les entités, leurs identifiants, leurs relations et leurs cardinalités (notation " patte d'oie " : | | = exactement un, `o{` = zéro ou plusieurs).

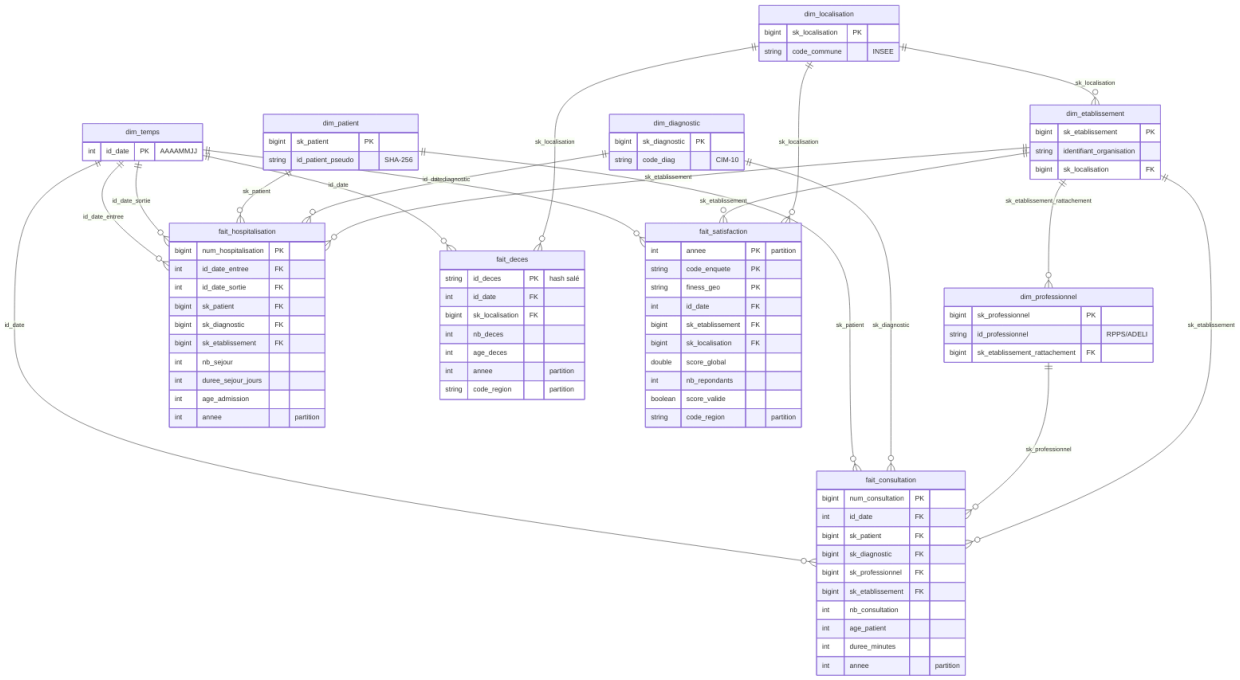


Figure 5 -Modèle conceptuel de la couche Gold, constellation de quatre étoiles

7.4 Modèle logique

Le modèle logique ci-dessous liste toutes les tables avec leur clé primaire (PK), leurs clés étrangères (FK, avec la table visée) et leurs colonnes de partitionnement. Les types et les règles de chaque colonne figurent dans le dictionnaire de données (annexe B).

Tableau E : Dimensions

Table	Clé primaire	Clés étrangères	Attributs
dim_temps	id_date	–	date, jour, mois, libelle_mois, trimestre, annee, annee_mois, jour_semaine, libelle_jour, est_weekend
dim_localisation	sk_localisation	–	code_commune, commune, departement, libelle_departement, code_region, libelle_region

Table	Clé primaire	Clés étrangères	Attributs
dim_etablissement	sk_etablissement	sk_localisation → dim_localisation	identifiant_organisation, finess_site, finess_juridique, raison_sociale, type_etablissement, departement, code_region, libelle_region
dim_patient	sk_patient	–	id_patient_pseudo, sexe, annee_naissance, departement, code_region, libelle_region
dim_diagnostic	sk_diagnostic	–	code_diag, libelle, chapitre_cim10, libelle_chapitre
dim_professionnel	sk_professionnel	sk_etablissement_rattachement → dim_etablissement	id_professionnel, profession, categorie_professionnelle, type_identifiant, code_specialite, specialite, fonction, nb_organisations

Tableau F Faits

Table	Clé primaire	Clés étrangères	Mesures et attributs	Partitionnement
fait_consultation	num_consultation	id_date → dim_temps sk_patient → dim_patient sk_diagnostic → dim_diagnostic sk_professionnel → dim_professionnel sk_etablissement → dim_etablissement	motif, age_patient, tranche_age, duree_minutes, nb_consultation, annee	annee
fait_hospitalisation	num_hospitalisation	id_date_entree → dim_temps id_date_sortie → dim_temps sk_patient → dim_patient	duree_sejour_jours, age_admission, tranche_age, nb_sejour, annee	annee

Table	Clé primaire	Clés étrangères	Mesures et attributs	Partitionnement
		sk_etablissement → dim_etablissement sk_diagnostic → dim_diagnostic		
fait_deces	id_deces	id_date → dim_temps sk_localisation → dim_localisation	sexe, age_deces, tranche_age, nb_deces, annee, code_region	annee, code_region
fait_satisfaction	(annee, code_enquete, finess_geo)	id_date → dim_temps sk_etablissement → dim_etablissement sk_localisation → dim_localisation	enquete, raison_sociale_geo, score_global, nb_repondants, taux_recommandation, classement, participation, score_valide, nb_etablissement, code_region	annee, code_region

Figure 6 -Modèle logique de la couche Gold

Les clés primaires des faits sont des **dimensions dégénérées** : le numéro de consultation ou de séjour d'origine (S1), le hash salé de l'identité pour les décès, et la clé composite (année, enquête, FINESS géographique) pour la satisfaction, qui est aussi la clé de dédoublonnage en Silver.

Delta Lake ne fait pas respecter les clés primaires et étrangères : ce sont des contraintes logiques. Elles sont garanties par le pipeline (clés de substitution déterministes, membre " Non renseigné " -1, dédoublonnage sur la clé métier) et vérifiées à chaque chargement par les contrôles qualité : unicité de chaque clé primaire et absence d'orphelin sur chacune des 17 clés étrangères (§ 9.1).

7.5 Cardinalités

Toutes les relations sont de type " un à plusieurs ". Côté fait, la cardinalité est toujours (1,1) : grâce au membre " Non renseigné " de clé -1, chaque ligne de fait pointe vers exactement un membre de chaque dimension, même quand la source ne permet pas de le déterminer. Pour le calendrier, la même garantie vient du rejet en Silver des lignes

sans date valide (§ 7.1). Côté dimension, elle est (0,n) : un membre peut n'avoir aucun fait (un jour sans décès, un établissement sans consultation).

Table enfant (côté n)	Clé étrangère	Table parent (côté 1)	Cardinalité enfant → parent	Cardinalité parent → enfant
fait_consultation	id_date	dim_temps	(1,1)	(0,n)
fait_consultation	sk_patient	dim_patient	(1,1)	(0,n)
fait_consultation	sk_diagnostic	dim_diagnostic	(1,1)	(0,n)
fait_consultation	sk_professionnel	dim_professionnel	(1,1)	(0,n)
fait_consultation	sk_etablissement	dim_etablissement	(1,1)	(0,n)
fait_hospitalisation	id_date_entree	dim_temps	(1,1)	(0,n)
fait_hospitalisation	id_date_sortie	dim_temps	(1,1)	(0,n)
fait_hospitalisation	sk_patient	dim_patient	(1,1)	(0,n)
fait_hospitalisation	sk_diagnostic	dim_diagnostic	(1,1)	(0,n)
fait_hospitalisation	sk_etablissement	dim_etablissement	(1,1)	(0,n)
fait_deces	id_date	dim_temps	(1,1)	(0,n)
fait_deces	sk_localisation	dim_localisation	(1,1)	(0,n)
fait_satisfaction	id_date	dim_temps	(1,1)	(0,n)
fait_satisfaction	sk_etablissement	dim_etablissement	(1,1)	(0,n)
fait_satisfaction	sk_localisation	dim_localisation	(1,1)	(0,n)
dim_etablissement	sk_localisation	dim_localisation	(1,1)	(0,n)
dim_professionnel	sk_etablissement_rattachement	dim_etablissement	(1,1)	(0,n)

Tableau 17 -Cardinalités des 17 relations du modèle Gold (notation Merise : minimum, maximum).

Un patient est relié à plusieurs consultations et à plusieurs séjours : la relation métier " patient -diagnostic ", qui est de type plusieurs à plusieurs, passe donc par les tables de faits, comme le veut le modèle en étoile.

7.6 Grain et mesures

Fait	Grain	Mesures
fait_consultation	une consultation	nb_consultation, age_patient, duree_minutes
fait_hospitalisation	un séjour	nb_sejour, duree_sejour_jours, age_admission
fait_deces	un décès enregistré par l'INSEE	nb_deces, age_deces
fait_satisfaction	un établissement géographique × une enquête × une année	score_global, nb_repondants, taux_recommandation

Tableau 18 -Grain et mesures des tables de faits.

Le dictionnaire complet des dix tables (type, clé, nullité, description et règle de chaque colonne) est donné en annexe B.

8. Alimentation du modèle en étoile

Ce chapitre décrit comment le modèle en étoile est alimenté : l'enchaînement des traitements, le job de chaque dimension et des faits, le paramétrage des connexions et la reprise sur erreur. Les règles de transformation détaillées et les fiches de tous les jobs Bronze, Silver et Gold sont en annexe C.

8.1 Chaînes de traitement

Chaque source dispose de son DAG Airflow, rechargé chaque nuit. La couche Gold est construite par un DAG distinct, déclenché chaque jour à 03:00 UTC, une fois les sources quotidiennes terminées, ou plus tôt dès que les quatre couches Silver ont été mises à jour, grâce au mécanisme des Datasets d'Airflow (`DatasetOrTimeSchedule`). Le déclenchement horaire garantit une publication quotidienne même lorsque la satisfaction (S3) n'a pas reçu de nouveau fichier.

DAG	Source	Fréquence	Étapes
`dag_postgres`	S1 et export des séjours	chaque jour à 00:00 UTC	extraction JDBC parallélisée (8 partitions sur les grandes tables) vers Bronze ; nettoyage, pseudonymisation et MERGE vers Silver
`dag_etablissements`	S2	chaque jour à 00:30 UTC	lecture CSV avec encodage explicite vers Bronze ; normalisation FINESS / INSEE, rattachement régional et rattachement principal des professionnels vers Silver
`dag_satisfaction`	S3	capteur FTP (toutes les 30 min)	détection des nouveaux fichiers (manifeste taille et date) vers landing ; détection du format vers Bronze ; harmonisation vers Silver
`dag_deces`	S4	chaque jour à 01:00 UTC (sans effet si l'INSEE n'a pas publié de nouveau fichier)	détection d'un nouveau fichier, téléchargement, Bronze partitionné par année, MERGE incrémental en Silver

DAG	Source	Fréquence	Étapes
`dag_gold`	Silver	chaque jour à 03:00 UTC, ou dès que les 4 Silver sont à jour (Datasets)	contrôle qualité Silver (bloquant), mémorisation des versions Gold, dimensions, faits, contrôle Gold (bloquant), OPTIMIZE / Z-ORDER / VACUUM / ANALYZE ; restauration de la version valide en cas d'échec
`dag_benchmark`	Gold	après publication de Gold	versions naïves, mesures, graphiques

Tableau 19 -DAG Airflow de la plateforme.

Toutes les tâches Spark partagent un pool Airflow à un seul emplacement, ce qui évite de saturer la mémoire d'un poste local en exécutant les traitements l'un après l'autre.

8.2 Alimentation, dimension par dimension

Cette section décrit, pour chaque table du modèle Gold, le job qui l'alimente : les sources et les jointures, les champs retenus, la clé de substitution et la fréquence d'alimentation. Les dimensions sont construites par `pipelines/gold/dimensions.py` et les faits par `pipelines/gold/facts.py`, à partir des tables Silver.

Clé de substitution. Chaque dimension reçoit une clé technique `sk_<dimension>`, distincte de l'identifiant de la source et calculée par `abs(xxhash64(clé métier))` (`cle_substitution` dans `pipelines/common/normalize.py`). Elle est générée automatiquement par le job, comme une séquence, mais reste identique d'un chargement à l'autre, ce qui évite de recalculer les clés étrangères des faits. La clé métier d'origine est conservée à côté pour la traçabilité. Seule `dim_temps` utilise une clé intelligente (`id_date` au format AAAAMMJJ), conformément à l'usage pour une dimension calendrier.

Fréquence d'alimentation. La fréquence d'alimentation retenue pour les dimensions et les faits est mensuelle, comme le prévoit le cadrage : les données de consultation, d'hospitalisation et de référentiel évoluent au rythme du mois, et les indicateurs sont lus par période. Le projet ne dure qu'un mois. Un rythme mensuel n'aurait donc produit qu'un seul chargement pendant tout le projet, sans possibilité de vérifier la reprise sur erreur, le chargement incrémental ou les contrôles qualité. Pendant le projet, les DAG tournent donc chaque nuit (sources entre 00:00 et 01:00 UTC, Gold à 03:00 UTC). Passer au rythme mensuel demande seulement de changer l'expression cron des DAG, par exemple 0 3 1 * * (le 1er du mois à 03:00) ; aucun code de traitement ne change.

8.2.1 Dimension patient

Élément	Spécification
Source	table `Patient` de la base PostgreSQL (S1), lue par JDBC dans `dag_postgres`
Chaîne	`bronze.pg_patient` → `silver.patient` (pseudonymisation, typage) → `gold.dim_patient`
Champs retenus	identifiant pseudonymisé, sexe (M / F / NR), année de naissance, département et région déduits du code postal
Champs écartés	nom, prénom, adresse, ville, e-mail, téléphone, numéro de sécurité sociale, groupe sanguin, poids, taille : non pertinents pour les indicateurs et identifiants (minimisation RGPD)
Clé	`sk_patient` = hash de `id_patient_pseudo` ; l'identifiant source `Id_patient` ne dépasse pas Silver
Fréquence	Mensuelle (cible) ; quotidienne pendant le projet : source extraite à 00:00 UTC (S1), dimension reconstruite à 03:00 UTC

Tableau 20 -Job d'alimentation de dim_patient.

8.2.2 Dimension professionnel

Élément	Spécification
Sources	tables `Professionnel_de_sante` et `Specialites` de PostgreSQL (S1) ; fichier `activite_professionnel_sante.csv` du référentiel S2
Jointures	professionnel ⋈ spécialité sur `code_specialite` ; professionnel ⋈ `silver.rattachement_professionnel` sur l'identifiant, pour récupérer l'établissement d'exercice principal (salarié, puis libéral, puis plus petit identifiant d'organisation)
Champs retenus	identifiant RPPS / ADELI normalisé, profession, catégorie, type d'identifiant, spécialité, fonction, établissement de rattachement, nombre d'organisations
Champs écartés	civilité, nom, prénom
Clé	`sk_professionnel` = hash de l'identifiant ; `sk_etablissement_rattachement` pointe vers `dim_etablissement`
Fréquence	Mensuelle (cible) ; quotidienne pendant le projet : sources extraites à 00:00 UTC (S1) et 00:30 UTC (S2), dimension reconstruite à 03:00 UTC

Tableau 21 -Job d'alimentation de dim_professionnel.

8.2.3 Dimension diagnostic

Élément	Spécification
Sources	table `Diagnostic` de PostgreSQL (S1) ; colonnes `Code_diagnostic` et libellé du fichier des hospitalisations
Jointures	union du référentiel S1 et des codes présents dans les hospitalisations mais absents de S1 (anti-jointure sur `code_diag`), avec le libellé de l'export ; aucun code de séjour ne reste ainsi sans libellé
Champs retenus	code CIM-10, libellé, chapitre CIM-10 (I à XXII) et son libellé, dérivés des plages de codes
Clé	`sk_diagnostic` = hash de `code_diag`
Fréquence	Mensuelle (cible) ; quotidienne pendant le projet : source extraite à 00:00 UTC, dimension reconstruite à 03:00 UTC

Tableau 22 -Job d'alimentation de dim_diagnostic.

Le référentiel des établissements (S2) ne comporte pas de colonne de diagnostic ; il n'alimente donc pas cette dimension.

8.2.4 Dimension localisation

Élément	Spécification
Sources	codes commune des établissements (S2), codes commune du lieu de décès (S4) ; table de correspondance département → région
Jointures	union des communes des établissements et des communes de décès, dédoublonnée sur le code INSEE ; ajout d'un membre par département pour les établissements localisés par leur seul code postal (`D<département>`) ; jointure département → région
Rattachement des faits	consultation et hospitalisation via l'établissement (`dim_etablissement.sk_localisation`) ; décès directement par la commune du décès ; satisfaction via l'établissement, et en propre (`fait_satisfaction.sk_localisation`)
Champs retenus	code commune, commune, département et libellé, région et libellé (découpage 2016, `99` étranger, `COM` outre-mer)
Clé	`sk_localisation` = hash du code commune

Élément	Spécification
Fréquence	Mensuelle (cible) ; quotidienne pendant le projet : sources extraites à 00:30 UTC (S2) et 01:00 UTC (S4), dimension reconstruite à 03:00 UTC

Tableau 23 -Job d'alimentation de dim_localisation.

8.2.5 Dimension temps

Élément	Spécification
Source	générée par le job (calendrier du 01/01/1880 au 31/12/2025), sans source externe
Couverture des faits	date de consultation (S1), dates d'entrée et de sortie d'hospitalisation (export), date de décès (S4, dont les décès antérieurs à 1970), 1er janvier de l'année d'enquête de satisfaction (S3) ; le contrôle d'intégrité vérifie que chacune de ces dates existe dans le calendrier
Champs retenus	date, jour, mois et libellé, trimestre, année, année-mois, jour de la semaine et libellé, week-end
Clé	`id_date` au format AAAAMMJJ, générée par le job à partir de la date (aucune source ne fournit de calendrier ni de clé de date)
Fréquence	Mensuelle (cible) ; quotidienne pendant le projet : calendrier régénéré à 03:00 UTC

Tableau 24 -Job d'alimentation de dim_temps.

8.2.6 Dimension établissement

Élément	Spécification
Source	`etablissement_sante.csv` (S2)
Champs retenus	identifiant d'organisation, FINESS site et juridique sur 9 caractères, raison sociale, type dérivé de la raison sociale, localisation, département, région
Clé	`sk_etablissement` = hash de l'identifiant d'organisation ; membre -1 " Non rattaché à un établissement "
Fréquence	Mensuelle (cible) ; quotidienne pendant le projet : source extraite à 00:30 UTC (S2), dimension reconstruite à 03:00 UTC

Tableau 25 -Job d'alimentation de dim_etablissement.

8.2.7 Faits

Le job `gold.facts` construit les quatre tables de faits après les dimensions. Chaque clé étrangère est obtenue par jointure de la clé métier du fait avec la dimension ; une clé introuvable reçoit le membre -1. Les mesures sont portées au grain le plus fin, ce qui permet toutes les agrégations des indicateurs.

Fait	Sources	Clés étrangères	Mesures pour les agrégations
fait_consultation	`silver.consultation`, date de naissance de `silver.patient`	temps, patient, diagnostic, professionnel, établissement (via le rattachement du professionnel)	`nb_consultation` (= 1), âge, durée du créneau
fait_hospitalisation	`silver.hospitalisation`	temps (entrée et sortie), patient, établissement, diagnostic	`nb_sejour` (= 1), durée du séjour, âge à l'admission
fait_deces	`silver.deces` (fichier INSEE)	temps, localisation	`nb_deces` (= 1), âge au décès
fait_satisfaction	`silver.satisfaction` (e-Satis)	temps, établissement, localisation	`score_global`, `nb_repondants`, `taux_recommandation`, `nb_etablissement` (= 1)

Tableau 26 -Job d'alimentation des faits.

Les faits sont reconstruits chaque jour à 03:00 UTC et partitionnés par année, et par région pour les décès et la satisfaction.

8.3 Contextes et paramétrage

Les outils ETL graphiques comme Talend regroupent les paramètres de connexion dans des **contextes**, dont on change les valeurs selon l'environnement. La plateforme applique le même principe avec trois niveaux de paramètres. Aucune adresse, aucun identifiant ni aucun mot de passe n'est écrit dans le code des jobs.

Niveau	Mise en œuvre	Exemples
Variables de contexte	fichier `.env` (non versionné, modèle `.env.example`), injecté dans les conteneurs par Docker Compose	`SOURCE_DB_URL`, `SOURCE_DB_USER`, `SOURCE_DB_PASSWORD`, `MINIO_ENDPOINT`, `FTP_HOST`, `HIVE_METASTORE_URI`, `PSEUDO_SALT`, `ASSISTANT_MODEL`

Niveau	Mise en œuvre	Exemples
Lecture centralisée	`pipelines/common/config.py` lit chaque variable une seule fois ; les jobs importent `config` au lieu de recopier des valeurs	`config.SOURCE_DB_URL`, `config.BRONZE`, `config.VACUUM_RETENTION_HOURS`
Contexte d'exécution	`SPARK_MASTER` choisit entre un poste (`local[*]`) et un cluster (`spark://spark-master:7077`) ; `docker-compose.prod.yml` surcharge la configuration pour le serveur (ports fermés, HTTPS)	contexte " local " et contexte " production "
Paramètres de lancement	paramètres de DAG saisis dans Airflow au déclenchement	" Simuler un échec du contrôle Gold " (`dag_gold`), `scenario` (`dag_demo_alerte`)

Tableau 27 -Niveaux de paramétrage, équivalents des contextes Talend.

Passer du poste local au serveur, ou d'une base source à une autre, revient donc à changer le fichier `.env`, sans toucher aux jobs.

8.4 Gestion des erreurs et reprise

Airflow relance automatiquement deux fois une tâche en échec, puis émet une alerte. L'alerte est écrite dans le journal d'Airflow et dans `reports/alerts/alertes.jsonl`, et peut être envoyée par mail et sur Discord. Un compte rendu est également envoyé en cas de succès.

La publication de la couche Gold est protégée par deux contrôles bloquants (Figure 7). Avant toute reconstruction, les versions valides des tables Gold sont mémorisées. Si le contrôle Gold échoue, l'optimisation est annulée et chaque table est restaurée dans sa dernière version valide grâce au *time travel* de Delta Lake. L'application continue ainsi d'afficher des données cohérentes.

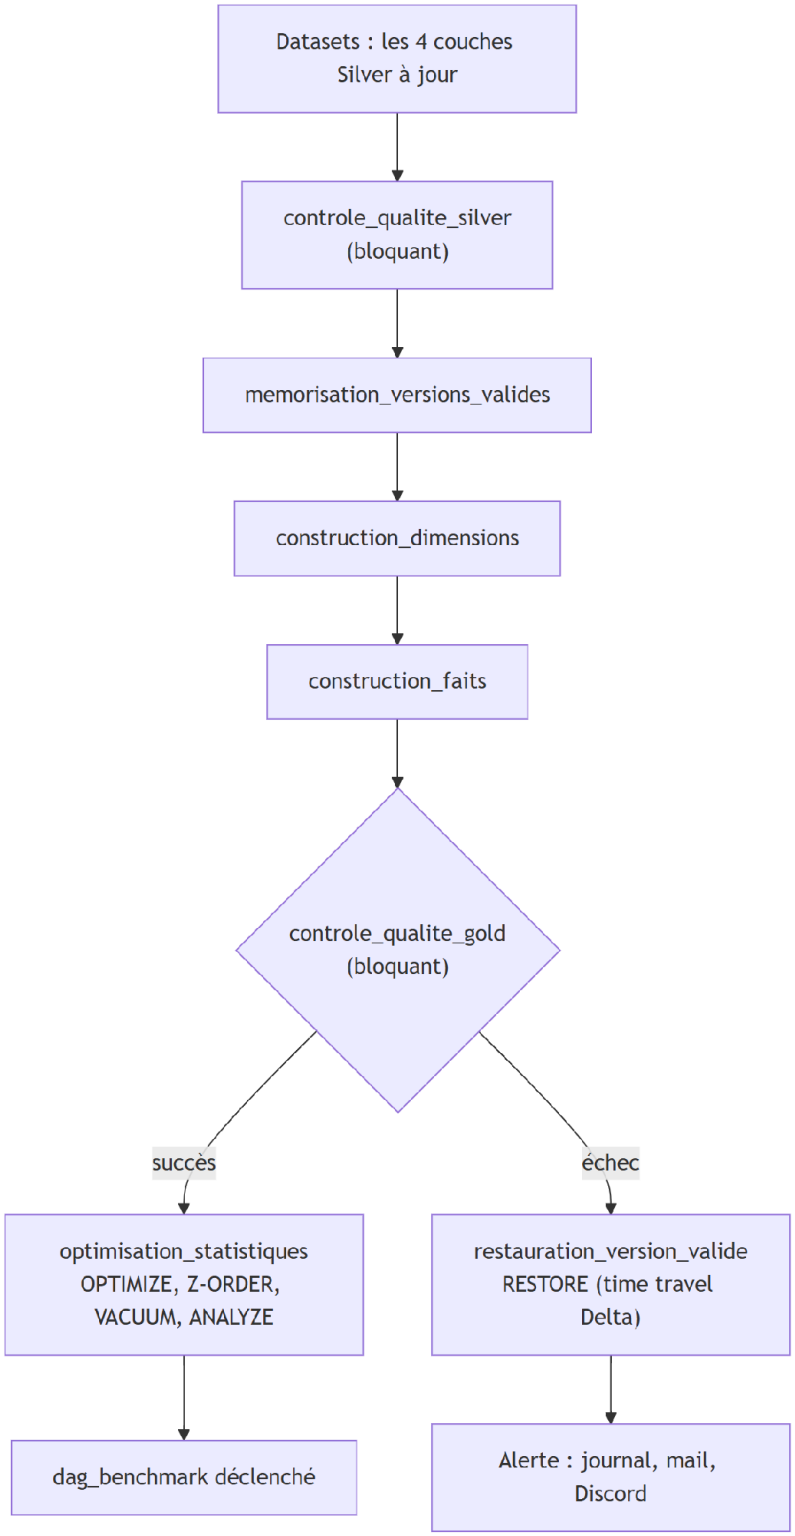


Figure 7 -Enchaînement des tâches de `dag_gold` et reprise sur version valide

Ce mécanisme a été testé le 20/10/2026 en simulant un échec du contrôle Gold. Le résultat est consigné dans le journal de bord.

Version de `gold.fait_consultation`	Opération	Signification
6	RESTORE	retour à la version 4, la dernière valide
5	WRITE	reconstruction faite pendant le run en échec, annulée
4	OPTIMIZE	dernière version valide, publiée par le run précédent

Tableau 28 -Historique Delta après le test de restauration.

La table contenait toujours ses 1 027 157 consultations après le test : aucune donnée non validée n'a été exposée.

9. Qualité et gouvernance des données

Ce chapitre résume les contrôles de qualité et les règles de gouvernance. Le détail des mesures de protection, du cadre RGPD, des droits par écran, de la traçabilité et de la correspondance HDS est en annexe F.

9.1 Qualité des données

Les contrôles Great Expectations (`pipelines/quality/checks.py`) couvrent la complétude de chaque colonne, l'unicité des clés, la validité des codes (FINESS, INSEE, sexe, âges), la cohérence (pas de date future, pas de durée négative, score entre 0 et 100) et l'intégrité référentielle des 17 clés étrangères de Gold. Chaque règle est bloquante ou d'avertissement. Delta Lake ne gérant pas de clés étrangères, ces contrôles sont la preuve, à chaque chargement, de la cohérence du modèle. Lors du premier chargement, 13 de ces liens étaient contrôlés ; les quatre autres (date de sortie, date et localisation de la satisfaction, rattachement des professionnels) ont été ajoutés lors de la rédaction de ce livrable. Le rattachement des professionnels est en avertissement, car il dépend de la complétude du référentiel S2.

Constat du premier chargement	Sévérité	Traitement
0 orphelin sur les 13 liens fait vers dimension contrôlés	bloquant	intégrité garantie
36,1 % des consultations sans établissement	information	documenté, affiché à part dans l'application
2,35 % des consultations (24 145) antérieures à la naissance du patient	avertissement	âge laissé vide en Gold et tranche " Non renseigné " ; anomalie signalée à la source
33 % des établissements sans code commune	avertissement	localisation au département via le code postal
58 lignes e-Satis avec la région " Océan Indien "	avertissement	région reprise du référentiel établissement
1 308 décès rejetés (dates invalides, âges incohérents)	information	rangés dans `silver.rejets_s4`
169 671 décès en double	information	écartés et comptés
Durée de consultation vide sur 100 % des lignes : les heures PostgreSQL de type `time` sont lues en	avertissement ajouté	transformation corrigée en Silver, passage de minuit compris

Constat du premier chargement	Sévérité	Traitement
horodatage par JDBC et n'étaient pas reconnues		

Tableau 29 -Constats qualité du premier chargement

Le chargement nocturne du 26/10/2026, qui intègre l'ensemble des corrections, confirme leur effet.

Contrôle	Résultat au 26/10/2026
Intégrité référentielle	17 liens contrôlés, 0 orphelin
Contrôles bloquants et d'avertissement	tous satisfaits
Complétude de `duree_minutes`	100 % (1 027 157 consultations) ; durées de 180 à 360 minutes, moyenne 268,7
Âges négatifs	aucun ; `age_patient` renseigné à 97,65 %, `age_admission` à 97,5 %
Consultations sans établissement (membre -1)	371 094, soit 36,13 %
Volumes Gold	1 027 157 consultations, 2 479 séjours, 24 917 229 décès, 5 335 résultats de satisfaction

Tableau 30 -Constats qualité après corrections (source : rapport qualité du chargement nocturne du 26/10/2026 sur le serveur de démonstration, consultable dans Airflow ; requête Trino sur gold.fait_consultation)

La durée de consultation mesure un créneau et non la durée réelle de l'acte : la source S1 ne contient que quatre créneaux (08:00-12:00, 13:00-18:00, 20:00-23:00 et 20:00-02:00).

9.2 Gouvernance en synthèse

Domaine	Mesures principales	Détail
Protection des personnes	pseudonymisation salée de l'identifiant patient dès Silver ; noms, adresses, numéros de sécurité sociale et données physiologiques arrêtés en Bronze ; âge généralisé à l'année puis à la tranche ; effectifs inférieurs à 10 masqués	annexe F.1
Cadre RGPD	finalité limitée aux huit indicateurs, base légale, registre, AIPD et DPO à formaliser	annexe F.2

Domaine	Mesures principales	Détail
	par le CHU ; durées de conservation par couche	
Droits d'accès	quatre rôles Keycloak (data engineer, praticien, direction, administrateur sécurité) ; droits par domaine vérifiés côté serveur par l'API ; l'administrateur sécurité n'a accès à aucune donnée	annexe F.3
Traçabilité	journal des traitements (`audit.job_runs`), journal d'accès de l'API, historique des versions Delta, lignage OpenLineage en option	annexe F.4
Hébergement	architecture alignée sur les exigences HDS sans certification (projet pédagogique) ; chiffrement au repos, MFA et sauvegarde sur un second site à activer en production	annexe F.5

Tableau 31 -Synthèse des mesures de gouvernance.

10. Perspectives et recommandations

Le référentiel et l'architecture sont implémentés et alimentés. Les analyses menées font ressortir des pistes d'amélioration, reprises du guide de soutenance et du journal de bord.

Recommandations au métier.

- Compléter le rattachement des professionnels aux établissements dans le référentiel S2 : 36 % des consultations ne peuvent pas être attribuées à un établissement.
- Corriger la source S1 : 2,35 % des consultations sont datées avant la naissance du patient.
- Obtenir la version complète de l'annuaire des professionnels, qui semble tronqué à la limite d'Excel (1 048 575 lignes).

Évolutions techniques.

- Héberger la plateforme chez un prestataire certifié HDS pour un passage en production, et y fermer les écarts du Tableau 59 : chiffrement au repos (SSE MinIO), chiffrement du trafic interne, authentification multifacteur, sauvegardes sur un second site.
- Remplacer l'API externe de l'assistant IA par un modèle DeepSeek à poids ouverts servi chez l'hébergeur HDS (annexe E).
- Faire réaliser par le CHU l'analyse d'impact (AIPD) et la fiche du registre des traitements, à partir du chapitre 9 et de l'annexe F, et désigner le DPO comme interlocuteur.
- Passer d'un rechargement nocturne à une alimentation en flux continu une fois la plateforme installée sur un serveur dédié.
- Demander au CHU les heures réelles de début et de fin des consultations : la source ne fournit que des créneaux, ce qui limite l'intérêt de la durée comme indicateur.
- Passer Spark en mode cluster (profil `cluster`) si les volumes augmentent, sans réécriture du code.
- Mettre en service le lignage avec Marquez (profil `lineage`), prévu mais non encore testé.

- Brancher sur l'API le tableau de bord complémentaire prévu par l'équipe.

Table des figures et des tableaux

Tableau 1 -Historique des versions du document..... 3
Tableau 2 - Liste de diffusion..... 4
Tableau 3 -Sources de données imposées par le sujet..... 10
Tableau 5 -Définition des huit indicateurs..... 12
Tableau 6 -Contraintes du projet et réponses apportées..... 13
Tableau 7 -Composition de l'équipe et rôles..... 14
Tableau 8 -Calendrier du bloc, créneaux de travail et jalons..... 15
Tableau 9 -Charge de travail planifiée..... 16
Tableau 10 -Composants de la plateforme et justification..... 18
Figure 1 -Architecture d'ensemble de la plateforme..... 18
Tableau 11 -Tables de la source S1..... 20
Figure 2 -Modèle conceptuel de la source S1..... 20
Tableau 12 -Fichiers de la source S2 (séparateur ;)..... 21
Tableau 13 -Fichiers e-Satis exploités..... 21
Tableau 14 -Couches du lakehouse..... 23
Figure 3 -Parcours d'une donnée à travers les couches..... 24
Tableau A : s3a://bronze/ : données brutes ingérées..... 24
Tableau B : s3a://silver/ : données nettoyées..... 25
Tableau C : s3a://gold/ : modèle en étoile..... 25
Tableau D : s3a://benchmark/ Versions naïves utilisées par le benchmark..... 25
Figure 4 -Hiérarchie des répertoires du datalake..... 25
Tableau 15 -Justification de la hiérarchie du datalake..... 26
Tableau 16 -Matrice de bus : dimensions partagées par les faits..... 28
Figure 5 -Modèle conceptuel de la couche Gold, constellation de quatre étoiles..... 29
Tableau E : Dimensions..... 29
Tableau F Faits..... 30
Figure 6 -Modèle logique de la couche Gold..... 31
Tableau 17 -Cardinalités des 17 relations du modèle Gold (notation Merise : minimum, maximum)..... 32
Tableau 18 -Grain et mesures des tables de faits..... 33
Tableau 19 -DAG Airflow de la plateforme..... 35
Tableau 20 -Job d'alimentation de dim_patient..... 36
Tableau 21 -Job d'alimentation de dim_professionnel..... 36

Tableau 22 -Job d'alimentation de dim_diagnostic..... 37
Tableau 23 -Job d'alimentation de dim_localisation..... 37
Tableau 24 -Job d'alimentation de dim_temps..... 38
Tableau 25 -Job d'alimentation de dim_etablissement..... 38
Tableau 26 -Job d'alimentation des faits..... 39
Tableau 27 -Niveaux de paramétrage, équivalents des contextes Talend..... 40
Figure 7 -Enchaînement des tâches de dag_gold et reprise sur version valide..... 41
Tableau 28 -Historique Delta après le test de restauration..... 42
Tableau 29 -Constats qualité du premier chargement..... 44
Tableau 30 -Constats qualité après corrections (source : rapport qualité du chargement nocturne du 26/10/2026 sur le serveur de démonstration, consultable dans Airflow ; requête Trino sur gold.fait_consultation)..... 44
Tableau 31 -Synthèse des mesures de gouvernance..... 45
Tableau 32 -Correspondance entre la grille d'évaluation et le document..... 55
Tableau 33 -Tables de la couche Gold : volumes (membre -1 compris, sauf dim_temps qui n'en a pas) et organisation physique..... 56
Tableau 34 -Dictionnaire de dim_temps..... 57
Tableau 35 -Dictionnaire de dim_localisation..... 58
Tableau 36 -Dictionnaire de dim_etablissement..... 59
Tableau 37 -Dictionnaire de dim_patient..... 60
Tableau 38 -Dictionnaire de dim_diagnostic..... 60
Tableau 39 -Dictionnaire de dim_professionnel..... 61
Tableau 40 -Dictionnaire de fait_consultation..... 63
Tableau 41 -Dictionnaire de fait_hospitalisation..... 64
Tableau 42 -Dictionnaire de fait_deces..... 65
Tableau 43 -Dictionnaire de fait_satisfaction..... 67
Tableau 44 -Règles de transformation..... 67
Tableau 45 -Spécification des jobs Bronze..... 68
Tableau 46 -Spécification des jobs Silver..... 70
Tableau 47 -Spécification des jobs Gold et des contrôles..... 71
Tableau 48 -Phases du projet et avancement au 26/10/2026..... 72
Tableau 49 -Tâches, responsables et avancement au 26/10/2026..... 74
Tableau 50 -Étapes de réalisation d'après le journal de bord..... 75

Tableau 51 -Outils de travail de l'équipe..... 75
Tableau 52 -Aléas rencontrés et décisions prises..... 76
Tableau 53 -Alternatives étudiées pour chaque brique..... 78
Tableau 54 -Mesures de protection des données personnelles..... 79
Tableau 55 -Cadre RGPD du traitement..... 81
Tableau 56 -Matrice des rôles et des droits..... 81
Tableau 57 -Écrans de l'application et droits par rôle..... 82
Tableau 58 -Dispositifs de traçabilité..... 83
Tableau 59 -Correspondance entre les exigences HDS et la plateforme..... 84

Glossaire

Terme	Définition
ACID	Propriétés garantissant qu'une écriture s'effectue entièrement ou pas du tout, de façon isolée et durable
AIPD	Analyse d'impact relative à la protection des données (article 35 du RGPD), obligatoire pour les traitements de données de santé à grande échelle
Airflow	Orchestrateur qui planifie et enchaîne les traitements sous forme de DAG
Anonymisation	Transformation irréversible qui rend toute ré-identification impossible ; les données anonymes sortent du champ du RGPD
API	Interface permettant à un programme d'en interroger un autre ; ici, l'API FastAPI sert les indicateurs à l'application
Bronze / Silver / Gold	Couches successives du lakehouse : copie brute, données nettoyées, modèle prêt pour l'analyse
Bucketing	Répartition des données en paniers selon une clé pour accélérer les jointures
Cardinalité	Nombre minimum et maximum d'occurrences d'une entité liées à une occurrence d'une autre, par exemple (1,1) ou (0,n)
CIM-10	Classification internationale des maladies, dixième révision, utilisée pour coder les diagnostics
Clé de substitution	Identifiant technique attribué par le pipeline, distinct de l'identifiant d'origine
Constellation	Modèle décisionnel dans lequel plusieurs tables de faits partagent des dimensions
DAG	Graphe orienté acyclique ; dans Airflow, ensemble de tâches et de leurs dépendances
Datasets (Airflow)	Mécanisme déclenchant un DAG lorsque les données qu'il consomme ont été mises à jour
Delta Lake	Format de table sur fichiers Parquet apportant transactions, MERGE et historique des versions
Dimension	Table décrivant le contexte d'un fait (qui, où, quand, quoi)
Dimension dégénérée	Identifiant d'origine (numéro de consultation, de séjour) conservé dans la table de faits sans table de dimension associée
DPO	Délégué à la protection des données, obligatoire dans un organisme public ; conseille et contrôle la conformité au RGPD

Terme	Définition
e-Satis	Dispositif national de mesure de la satisfaction des patients hospitalisés, piloté par la HAS
ETL	*Extract, Transform, Load* : extraction, transformation et chargement des données
Fait	Table enregistrant des événements mesurables
FINESS	Fichier national des établissements sanitaires et sociaux ; numéro à 9 caractères identifiant un établissement
FTP	Protocole de transfert de fichiers vers et depuis un serveur
Grain	Ce que représente exactement une ligne d'une table de faits
HAS	Haute Autorité de santé
HDS	Hébergeur de données de santé : certification obligatoire en France pour héberger des données de santé réelles
Hive Metastore	Catalogue décrivant l'emplacement et le schéma des tables, partagé par Spark et Trino
Idempotence	Propriété d'un traitement qui, relancé, produit le même résultat sans doublon
INSEE (code)	Code officiel à 5 caractères d'une commune française
ISO/IEC 27001	Norme internationale de management de la sécurité de l'information, socle de la certification HDS
JDBC	Interface standard de connexion d'un programme à une base de données
Kimball	Méthode de modélisation décisionnelle fondée sur les faits et les dimensions conformes
Lakehouse	Architecture combinant le stockage objet d'un lac de données et la rigueur d'un entrepôt
Landing	Zone de dépôt des fichiers bruts, conservés à l'identique avant intégration
Lignage	Capacité à retracer l'origine d'une donnée de table en table
Modèle de langage (LLM)	Modèle d'IA qui comprend et produit du texte ; utilisé par l'assistant, qui l'autorise seulement à appeler les indicateurs de l'API
Modèle à poids ouverts	Modèle de langage dont les paramètres sont publiés sous une licence libre (MIT pour DeepSeek), ce qui permet de l'exécuter sur ses propres serveurs
Matrice de bus	Tableau croisant les faits et les dimensions qu'ils partagent

Terme	Définition
MCD / MLD	Modèle conceptuel de données (entités, relations, cardinalités) et modèle logique de données (tables, colonnes, clés primaires et étrangères)
MERGE	Opération qui met à jour les lignes existantes et insère les nouvelles en une fois
MinIO	Stockage objet compatible avec l'interface Amazon S3
OIDC	OpenID Connect, protocole d'authentification utilisé par Keycloak
OPTIMIZE	Compactage de nombreux petits fichiers en fichiers plus gros, plus rapides à lire
Parquet	Format de fichier colonnaire et compressé
Partitionnement	Rangement des données par valeur d'une colonne (année, région) afin de ne lire que l'utile
Pseudonymisation	Remplacement de l'identité d'une personne par un code non réversible sans secret
Registre des traitements	Document obligatoire (article 30 du RGPD) qui décrit chaque traitement de données personnelles : finalité, données, destinataires, durées, sécurité
RGPD	Règlement général sur la protection des données
RPPS / ADELI	Répertoires nationaux d'identification des professionnels de santé
Sel	Valeur secrète ajoutée avant le calcul d'un hash pour empêcher de retrouver la valeur d'origine
Seuil de diffusion	Règle masquant tout résultat portant sur moins de 10 personnes
Spark	Moteur de traitement distribué de grands volumes de données
Time travel	Accès ou retour à une version antérieure d'une table Delta
Trino	Moteur SQL distribué pour les requêtes interactives
VACUUM	Suppression des fichiers Delta devenus inutiles au-delà d'une durée de rétention
Z-ORDER	Tri multicolonne des données permettant de sauter les fichiers inutiles lors d'une lecture

Annexes

Annexe A -Correspondance avec la grille d'évaluation

Le tableau suivant indique, pour chaque critère de la grille d'évaluation du livrable 1, la partie du document qui y répond.

Critère (coefficient)	Attendu principal	Réponse dans ce document
Modèle en étoile (2)	modèle dénormalisé, première forme normale, modèle conceptuel répondant à l'analyse des données médicales	§ 7.1 (dénormalisation, 1FN), § 7.2 à 7.6, Figure 5, dictionnaire en annexe B
Hiérarchie du datalake (1)	hiérarchie des répertoires justifiée pour des tables externes Hive, un répertoire par chargement de dimension	§ 6.3, Figure 4, Tableau 15
Dimension patient (1)	job sur la table patient, champs pertinents, clé automatique, fréquence	§ 8.2.1, Tableau 20
Dimension professionnel (1)	job sur les professionnels, jointure avec le référentiel pour l'établissement, clé, fréquence	§ 8.2.2, Tableau 21
Dimension diagnostic (1)	job sur les diagnostics PostgreSQL et ceux des hospitalisations, clé, fréquence	§ 8.2.3, Tableau 22
Dimension localisation (2)	jointure des localisations des consultations, hospitalisations, décès et satisfaction, clé	§ 8.2.4, Tableau 23
Dimension temps (2)	jointure des dates des quatre faits, clé	§ 8.2.5, Tableau 24
Faits (4)	job préparant les mesures : consultations, hospitalisations, décès, satisfaction	§ 8.2.7, Tableau 26, § 7.6

Critère (coefficient)	Attendu principal	Réponse dans ce document
Utilisation des contextes (1)	variables et contextes pour les connexions aux sources et à l'environnement d'exécution	§ 8.3, Tableau 27

Tableau 32 -Correspondance entre la grille d'évaluation et le document.

La grille vise la pile Cloudera et Talend du manuel. La plateforme utilise les outils équivalents justifiés au § 4.3 : tables externes du Hive Metastore sur MinIO au lieu de HDFS, jobs PySpark orchestrés par Airflow au lieu de jobs Talend, fichier d'environnement au lieu des contextes Talend.

Annexe B -Dictionnaire de données

Le dictionnaire décrit **toutes** les colonnes des dix tables de la couche Gold, seule couche exposée. Il a été établi à partir du code qui construit les tables (`pipelines/gold/dimensions.py`, `pipelines/gold/facts.py`) et des transformations Silver qui les alimentent (`pipelines/silver/*.py`). Les volumes et les taux de complétude sont produits automatiquement à chaque chargement dans le rapport qualité (`reports/quality/qualite_gold_dernier.html`).

Conventions.

- **Type** : type Spark / Delta Lake. `bigint` est un entier sur 64 bits (clés de substitution), `int` un entier sur 32 bits, `string` une chaîne, `double` un nombre décimal, `date` une date, `boolean` vrai / faux. La longueur est indiquée lorsqu'elle est fixe, par exemple `string(9)`.
- **Clé** : PK pour la clé primaire, FK pour une clé étrangère (avec la table visée), PART pour une colonne de partitionnement.
- **Null** : " Non " signifie que la colonne est toujours renseignée. Une valeur descriptive absente prend la valeur " Non renseigné ", un code absent `NR`, une clé introuvable le membre -1 (toutes les dimensions sauf `dim_temps`). Le membre -1 peut porter des valeurs vides sur ses colonnes descriptives.
- **Clés de substitution** : `abs(xxhash64(clé métier))`. Le calcul est déterministe, donc une reconstruction redonne les mêmes clés.

Table	Type	Lignes (premier chargement)	Partitionnement	Z-ORDER
dim_temps	dimension	53 326	–	–

Table	Type	Lignes (premier chargement)	Partitionnement	Z-ORDER
dim_localisation	dimension	39 537	–	–
dim_etablissement	dimension	416 666	–	–
dim_patient	dimension	100 001	–	–
dim_diagnostic	dimension	15 491	–	–
dim_professionnel	dimension	1 048 576	–	sk_professionnel
fait_consultation	fait	1 027 157	annee	sk_etablissement, sk_diagnostic
fait_hospitalisation	fait	2 479	annee	sk_diagnostic, sk_etablissement
fait_deces	fait	24 917 229	annee, code_region	sk_localisation
fait_satisfaction	fait	5 335	annee, code_region	sk_etablissement

Tableau 33 -Tables de la couche Gold : volumes (membre -1 compris, sauf `dim_temps` qui n'en a pas) et organisation physique.

B.1 dim_temps

Calendrier généré par le pipeline, un jour par ligne du 01/01/1880 au 31/12/2025, sans membre -1 (53 326 jours). Il commence en 1880 pour couvrir les décès les plus anciens du fichier INSEE. Il s'arrête en 2025 parce que le projet porte sur le jeu de données fourni, dont les dates les plus récentes sont en 2023 (dernières consultations en mars 2023). Si une source devait livrer des dates postérieures, il suffirait de repousser la borne dans `pipelines/gold/dimensions.py` ; d'ici là, le contrôle d'intégrité bloquant empêcherait toute publication avec une date hors calendrier.

Attribut	Type	Clé	Null	Description	Origine / règle
id_date	int	PK	Non	date au format AAAAMMJJ (ex. 20190315)	générée
date	date		Non	date du jour	générée
jour	int		Non	jour du mois (1 à 31)	`dayofmonth(date)`
mois	int		Non	mois (1 à 12)	`month(date)`
libelle_mois	string		Non	nom du mois en français (janvier…)	table de libellés

Attribut	Type	Clé	Null	Description	Origine / règle
trimestre	int		Non	trimestre (1 à 4)	`quarter(date)`
annee	int		Non	année	`year(date)`
annee_mois	string(7)		Non	année et mois (AAAA-MM), utilisé pour les évolutions mensuelles	`date_format(date, 'yyyy-MM')`
jour_semaine	int		Non	jour de la semaine (1 = dimanche … 7 = samedi, convention Spark)	`dayofweek(date)`
libelle_jour	string		Non	nom du jour en français	table de libellés
est_weekend	boolean		Non	vrai le samedi et le dimanche	`jour_semaine IN (1, 7)`

Tableau 34 -Dictionnaire de dim_temps.

B.2 dim_localisation

Une ligne par commune connue (S2 et S4), plus une ligne par département pour les établissements dont seule la commune est inconnue.

Attribut	Type	Clé	Null	Description	Origine / règle
sk_localisation	bigint	PK	Non	clé de substitution ; -1 = non renseigné	hash de `code_commune`
code_commune	string(5)		Non	code INSEE de la commune sur 5 caractères ; `D<dép.>` si seul le département est connu ; `NR` pour le membre -1	S2 `code_commune`, S4 `code_lieu_deces`, zéros initiaux restitués
commune	string		Non	libellé de la commune ; " Non renseigné " si inconnu (communes de S4, membres départementaux)	S2 `commune`
departement	string		Non	code du département (01 à 95, 2A, 2B, 971 à 989) ; `99` = étranger ; `NR` si inconnu	déduit du code commune
libelle_departement	string		Non	nom du département	référentiel `pipelines/common/referentiels.py`

Attribut	Type	Clé	Null	Description	Origine / règle
code_region	string		Non	code de la région (découpage 2016) ; `99` = étranger ; `COM` = collectivités d'outre-mer ; `NR` si inconnu	déduit du département
libelle_region	string		Non	nom de la région	référentiel des régions

Tableau 35 -Dictionnaire de dim_localisation.

B.3 dim_etablissement

Une ligne par organisation du référentiel S2, plus le membre -1 " Non rattaché à un établissement ".

Attribut	Type	Clé	Null	Description	Origine / règle
sk_etablissement	bigint	PK	Non	clé de substitution ; -1 = non rattaché	hash de `identifiant_organisation`
identifiant_organisation	string		Non	identifiant national de l'organisation (clé métier, ex. `F750712184`)	S2, majuscules, espaces retirés
finess_site	string(9)		Oui	numéro FINESS géographique sur 9 caractères ; vide si invalide	S2, zéros initiaux restitués, format contrôlé
finess_juridique	string(9)		Oui	numéro FINESS de l'entité juridique ; vide si invalide	S2, même règle
raison_sociale	string		Non	raison sociale du site	S2 `raison_sociale_site`

Attribut	Type	Clé	Null	Description	Origine / règle
type_etablissement	string		Non	catégorie : CHU / régional, centre hospitalier, clinique, pharmacie, laboratoire, médico-social, centre de santé, cabinet libéral, imagerie, autre	expressions régulières sur la raison sociale (S2 ne fournit pas la catégorie)
sk_localisation	bigint	FK → dim_localisation	Non	commune de l'établissement , à défaut son département ; -1 si inconnu	code commune, à défaut code postal
departement	string		Non	département de l'établissement (copie pour éviter une jointure)	code commune, à défaut code postal
code_region	string		Non	région de l'établissement	déduite du département
libelle_region	string		Non	nom de la région	référentiel des régions

Tableau 36 -Dictionnaire de dim_etablissement.

B.4 dim_patient

Une ligne par patient de S1, pseudonymisé. Aucune donnée directement identifiante.

Attribut	Type	Clé	Null	Description	Origine / règle
sk_patient	bigint	PK	Non	clé de substitution ; -1 = non renseigné	hash de `id_patient_pseudo`

Attribut	Type	Clé	Null	Description	Origine / règle
id_patient_pseudo	string(64)		Non	pseudonyme : SHA-256 de `sel ‖ Id_patient`	S1 `Id_patient`, sel secret `PSEUDO_SALT`
sexe	string		Non	`M`, `F` ou `NR`	S1 `Sexe` (male / female)
annee_naissance	int		Oui	année de naissance (la date complète ne dépasse pas Silver)	S1 `Date` au format M/d/yyyy
departement	string		Non	département de résidence ; `NR` si inconnu	S1 `Code_postal` (le code postal lui-même n'est pas conservé)
code_region	string		Non	région de résidence	déduite du département
libelle_region	string		Non	nom de la région	référentiel des régions

Tableau 37 -Dictionnaire de dim_patient.

B.5 dim_diagnostic

Une ligne par code CIM-10 du référentiel S1, complété des codes présents dans l'export des séjours mais absents de S1.

Attribut	Type	Clé	Null	Description	Origine / règle
sk_diagnostic	bigint	PK	Non	clé de substitution ; -1 = non renseigné	hash de `code_diag`
code_diag	string		Non	code CIM-10 (ex. `J45`, `I10`)	S1 `Code_diag`, majuscules
libelle	string		Non	libellé du diagnostic	S1 `Diagnostic`, à défaut libellé de l'export des séjours
chapitre_cim10	string		Non	chapitre CIM-10 en chiffres romains (I à XXII) ; `NR` si hors plage	plages de codes (`referentiels.CHAPITRES_CIM10`)
libelle_chapitre	string		Non	intitulé du chapitre (ex. " Tumeurs ")	idem

Tableau 38 -Dictionnaire de dim_diagnostic.

B.6 dim_professionnel

Une ligne par professionnel de S1.

Attribut	Type	Clé	Null	Description	Origine / règle
sk_professionnel	bigint	PK	Non	clé de substitution ; -1 = non renseigné	hash de `id_professionnel`
id_professionnel	string		Non	identifiant RPPS ou ADELI, sans zéros initiaux	S1 `Identifiant`
profession	string		Non	profession (ex. Médecin)	S1
categorie_professionnelle	string		Non	catégorie professionnelle	S1
type_identifiant	string		Non	type d'identifiant (RPPS ou ADELI)	S1
code_specialite	string		Non	code de la spécialité ; `NR` si absent	S1 `Code_specialite`
specialite	string		Non	libellé de la spécialité	S1 `Specialites`
fonction	string		Non	fonction associée à la spécialité	S1 `Specialites`
sk_etablissement_rattachement	bigint	FK → dim_etablissement	Non	établissement principal ; -1 si aucune organisation connue	S2 activités : exercice salarié, puis libéral, puis plus petit identifiant
nb_organisations	bigint		Non	nombre d'organisations où le professionnel	S2 activités

Attribut	Type	Clé	Null	Description	Origine / règle
				exerce (0 si aucune)	

Tableau 39 -Dictionnaire de dim_professionnel.

B.7 fait_consultation

Grain : une consultation. Indicateurs 1, 2, 3 (dénominateur) et 6.

Attribut	Type	Clé	Null	Description	Origine / règle
num_consultation	bigint	PK	Non	numéro de la consultation (dimension dégénérée)	S1 `Num_consultation`
id_date	int	FK → dim_temps	Non	date de la consultation	S1 `Date` ; ligne rejetée si absente ou future
sk_patient	bigint	FK → dim_patient	Non	patient	pseudonyme de S1 `Id_patient` ; ligne rejetée si absent
sk_diagnostic	bigint	FK → dim_diagnostic	Non	diagnostic posé ; -1 si inconnu	S1 `Code_diag`
sk_professionnel	bigint	FK → dim_professionnel	Non	professionnel ; ligne rejetée si absent	S1 `Id_prof_sante`
sk_etablissement	bigint	FK → dim_etablissement	Non	établissement de rattachement du professionnel ; -1 si non rattaché (36 %)	`dim_professionnel.sk_etablissement_rattachement`
motif	string		Non	motif de la consultation	S1 `Motif`
age_patient	int		Oui	âge en années révolues à la date de la	date de naissance Silver

Attribut	Type	Clé	Null	Description	Origine / règle
				consultation ; vide si la consultation précède la naissance (anomalie de S1, 24 145 lignes)	
tranche_age	string		Non	tranche décennale (00-09 … 80-89, 90+) ; " Non renseigné " si âge inconnu ou négatif	dérivée de `age_patient`
duree_minutes	int		Oui	durée du créneau de consultation en minutes (0 à 1 440)	S1 `Heure_fin` − `Heure_debut`, plus 24 h si la consultation passe minuit
nb_consultation	int		Non	mesure de comptage, toujours 1	constante
annee	int	PART	Non	année de la consultation	`year(date)`

Tableau 40 -Dictionnaire de fait_consultation.

B.8 fait_hospitalisation

Grain : un séjour hospitalier. Indicateurs 3, 4 et 5.

Attribut	Type	Clé	Null	Description	Origine / règle
num_hospitalisation	bigint	PK	Non	numéro du séjour (dimension dégénérée)	export `Num_Hospitalisation`
id_date_entree	int	FK → dim_temps	Non	date d'admission	`Date_Entree` (dd/MM/yyyy) ; ligne rejetée si invalide

Attribut	Type	Clé	Null	Description	Origine / règle
id_date_sortie	int	FK → dim_temps	Non	date de sortie	date d'entrée + durée
sk_patient	bigint	FK → dim_patient	Non	patient	pseudonyme de `Id_patient` ; ligne rejetée si absent
sk_etablissement	bigint	FK → dim_etablissement	Non	établissement du séjour ; -1 si inconnu	`identifiant_organisation`
sk_diagnostic	bigint	FK → dim_diagnostic	Non	diagnostic du séjour	`Code_diagnostic`
duree_sejour_jours	int		Non	durée du séjour en jours (0 à 365)	`Jour_Hospitalisation` ; ligne rejetée si négative
age_admission	int		Oui	âge à l'admission ; calculé sur l'année seule si la date de naissance est inconnue ; vide si l'admission précède la naissance	date de naissance Silver
tranche_age	string		Non	tranche décennale à l'admission	dérivée de `age_admission`
nb_sejour	int		Non	mesure de comptage, toujours 1	constante
annee	int	PART	Non	année d'admission	`year(date_entree)`

Tableau 41 -Dictionnaire de fait_hospitalisation.

B.9 fait_deces

Grain : un décès enregistré par l'INSEE. Indicateur 7. L'identité ne dépasse pas Bronze.

Attribut	Type	Clé	Null	Description	Origine / règle
id_deces	string (64)	PK	Non	hash salé de l'identité complète (nom, prénoms, date et lieu de naissance, date et lieu de décès, numéro d'acte)	S4 ; sert aussi de clé de dédoublonnage
id_date	int	FK → dim_temps	Non	date du décès	S4 `date_deces` ; ligne rejetée si invalide ou future
sk_localisation	bigint	FK → dim_localisation	Non	commune du décès ; -1 si inconnue (0,04 %)	S4 `code_lieu_deces`
sexe	string		Non	`M`, `F` ou `NR`	S4 `sexe` (1 / 2)
age_deces	int		Non	âge au décès (0 à 125) ; calculé sur l'année seule si la date de naissance est partielle	S4 ; ligne rejetée si incohérent
tranche_age	string		Non	tranche décennale au décès	dérivée de `age_deces`
nb_deces	int		Non	mesure de comptage, toujours 1	constante
annee	int	PART	Non	année du décès	`year(date_deces)`
code_region	string	PART	Non	région du lieu de décès ; `99` = étranger	déduite du code commune

Tableau 42 -Dictionnaire de fait_deces.

B.10 fait_satisfaction

Grain : un établissement géographique pour une enquête e-Satis et une année.
Indicateur 8.

Attribut	Type	Clé	Null	Description	Origine / règle
annee	int	PK, PART	Non	année de l'enquête	nom du fichier S3

Attribut	Type	Clé	Null	Description	Origine / règle
code_enquete	string	PK	Non	`esatis48h_mco` ou `esatisca_mco`	fichier source
finess_geo	string(9)	PK	Non	FINESS géographique de l'établissement évalué	S3 `finess_geo` ; ligne rejetée si invalide
id_date	int	FK → dim_temps	Non	1er janvier de l'année d'enquête	`make_date(annee, 1, 1)`
enquete	string		Non	libellé de l'enquête (e-Satis 48h MCO, e-Satis chirurgie ambulatoire)	constante par fichier
raison_sociale_geo	string		Non	raison sociale de l'établissement selon la HAS	S3 `rs_finess_geo`
sk_etablissement	bigint	FK → dim_etablissement	Non	établissement du référentiel ; -1 si absent (1,3 %)	lien `'F' ‖ finess_geo = identifiant_organisation`
sk_localisation	bigint	FK → dim_localisation	Non	localisation de l'établissement	reprise de `dim_etablissement`
score_global	double		Oui	score de satisfaction ajusté sur 100	S3 `score_all_rea_ajust` ou `score_all_ajust` selon l'année
nb_repondants	int		Oui	nombre de répondants au score	S3 `nb_rep_score_*`
taux_recommandation	double		Oui	taux brut de recommandation de	S3 `taux_reco_brut`

Attribut	Type	Clé	Null	Description	Origine / règle
				l'établissement (%)	
classement	string		Oui	classe HAS (A à D)	S3 `classement`
participation	string		Non	statut de participation à l'enquête	S3 `participation`
score_valide	boolean		Non	vrai si le score existe et repose sur au moins 30 répondants (seuil HAS)	dérivée
nb_etablissement	int		Non	mesure de comptage, toujours 1	constante
code_region	string	PART	Non	région de l'établissement ; celle du référentiel si le fichier HAS ne la donne pas	S3 `region`, à défaut `dim_etablissement`

Tableau 43 -Dictionnaire de fait_satisfaction.

Annexe C -Spécifications ETL détaillées

Cette annexe complète le chapitre 8 avec les règles de transformation et les fiches de tous les jobs.

C.1 Règles de transformation

Règle	Mise en œuvre
Typage	conversion explicite des dates (`M/d/yyyy`, `dd/MM/yyyy`, `yyyy-MM-dd`), des nombres au format français (`75,09`) et des codes
Normalisation	FINESS sur 9 caractères, INSEE sur 5 caractères avec zéros initiaux, libellés de jointure en majuscules sans accents, identifiants professionnels sans zéros initiaux
Valeurs nulles	attribut obligatoire nul : ligne envoyée dans `silver.rejets_<source>` (ligne en JSON, motif, date, job, lot) ; attribut descriptif nul : " Non renseigné "

Règle	Mise en œuvre
Doublons	détectés sur la clé métier ; l'enregistrement le plus récent (horodatage d'ingestion `_ingestion_ts` le plus grand) est conservé, une seule ligne en cas d'égalité, et les doublons écartés sont comptés dans `audit.job_runs` (clés par job au annexe C.2)
Dérivées	âge à la date de l'acte, tranche d'âge, département et région depuis le code commune (ou postal), chapitre CIM-10, durée de consultation, date de sortie
Chargement	MERGE Delta sur la clé métier en Silver ; reconstruction atomique en Gold
Idempotence	Silver lit le dernier lot Bronze et fusionne sur la clé ; Gold utilise des clés déterministes. Relancer un job redonne le même résultat sans doublon

Tableau 44 -Règles de transformation.

C.2 Fiches de spécification des jobs

Chaque job Spark est un module Python (`pipelines/<couche>/<source>.py`) lancé par une tâche Airflow. Tous écrivent une ligne dans `audit.job_runs` (lignes lues, écrites, rejetées, doublons, durée, statut). Les rejets vont dans `silver.rejets_<source>` avec la ligne d'origine en JSON, le motif, la date, le job et le lot.

Jobs Bronze (communs aux quatre sources). Copie brute en ajout seul (`append`), sans aucune transformation, enrichie de `_ingestion_ts`, `_source` et `_batch_id`. Aucun rejet : une ligne illisible reste en Bronze et sera traitée ou rejetée en Silver. Une erreur de connexion ou de lecture fait échouer la tâche, qui est relancée deux fois.

Job	Entrée	Sortie Bronze	Particularités
`bronze.postgres`	13 tables PostgreSQL par JDBC, export `Hospitalisations.csv`	`bronze.pg_<table>`, `bronze.csv_hospitalisations`	lecture parallèle en 8 partitions sur la clé numérique des grandes tables (Patient, Consultation, Prescription, Adher, Salle, AAAA), `fetchsize` 20 000
`bronze.etablissements`	3 CSV S2 (`;`)	`bronze.csv_etablissement_sante`, `csv_professionnel_sante`, `csv_activite_professionnel_sante`	encodage fixé par fichier (UTF-8, ou ISO-8859-1 pour l'annuaire)
`bronze.satisfaction`	fichiers déposés sur le FTP	`landing/…` (copie à l'identique), `bronze.ftp_satisfaction_<enquête>`	manifeste FTP (taille et date) : un fichier n'est ingéré qu'une fois ou s'il a changé ; CSV ou XLSX détecté automatiquement ; les

Job	Entrée	Sortie Bronze	Particularités
			autres indicateurs HAS restent archivés dans landing
`bronze.deces`	`deces.csv` (et format INSEE à largeur fixe de 198 caractères pour les dépôts mensuels)	`bronze.ftp_deces`, partitionnée par année de décès	même manifeste FTP : chargement incrémental

Tableau 45 -Spécification des jobs Bronze.

Jobs Silver. Chaque job lit le dernier lot Bronze, applique les règles de l'annexe C.1, écarte les rejets, dédoublonne puis fusionne (MERGE) dans la table Silver sur la clé de dédoublonnage.

Table Silver	Clé de dédoublonnage	Motifs de rejet (attributs obligatoires)	Transformations spécifiques
patient	id_patient_pseudo	identifiant manquant ; date de naissance future	pseudonymisation, sexe M / F / NR, date M/d/yyyy, département depuis le code postal ; nom, prénom, adresse, e-mail, téléphone, n° de sécurité sociale, groupe sanguin, poids et taille non repris
consultation	num_consultation	numéro manquant ; patient manquant ; professionnel manquant ; date manquante ; date future	pseudonymisation du patient, identifiant professionnel sans zéros initiaux, heures `time` ramenées à HH:mm:ss, durée en minutes ; partition par année
diagnostic	code_diag	code manquant	code en majuscules, chapitre CIM-10
professionnel	id_professionnel	identifiant manquant	identifiant sans zéros initiaux
specialite	code_specialite	code manquant	–

Table Silver	Clé de dédoublonnage	Motifs de rejet (attributs obligatoires)	Transformations spécifiques
prescription, medicament, laboratoire, mutuelle, adhesion, salle	clé de la table source	clé manquante	tables du SIH conservées en Silver, non utilisées par les indicateurs ; date d'AMM typée ; patient pseudonymisé dans `adhesion`
hospitalisation	num_hospitalisation	numéro manquant ; patient manquant ; date d'entrée invalide ; durée absente ou négative	date dd/MM/yyyy, date de sortie = entrée + durée, pseudonymisation ; partition par année
etablissement	identifiant_organisation	identifiant manquant	FINESS sur 9 caractères, INSEE sur 5, département (commune puis code postal), région, type d'établissement
annuaire_professionnel, activite_professionnel	id_professionnel ; (id_professionnel, identifiant_organisation)	identifiant vide (ligne ignorée)	identifiants normalisés
rattachement_professionnel	id_professionnel	–	une organisation principale par professionnel (salarié, puis libéral, puis plus petit identifiant) et nombre d'organisations ; table recalculée entièrement
satisfaction	(annee, code_enquete, finess_geo)	FINESS géographique ou année invalide	projection des fichiers de chaque année sur un schéma commun, nombres au format français, code région depuis le libellé, lien `'F' ‖ finess_geo`, `score_valide` (≥ 30 répondants) ; toutes les livraisons sont lues et la plus récente est gardée
deces	id_deces (hash de l'identité complète)	date de décès invalide ; date future ; âge absent,	identité remplacée par le hash, âge (sur l'année si date partielle), département et région du lieu de décès, `99` pour l'étranger ; doublons

Table Silver	Clé de dédoublonnage	Motifs de rejet (attributs obligatoires)	Transformations spécifiques
		négatif ou supérieur à 125 ans	strictement identiques supprimés ; partition par année

Tableau 46 -Spécification des jobs Silver.

Jobs Gold et contrôles.

Job	Entrée	Sortie	Règles
`quality.checks silver`	tables Silver	rapport `qualite_silver_*.json/html`	un contrôle bloquant en échec arrête `dag_gold` avant toute écriture
`gold.optimize snapshot`	tables Gold	`reports/state/gold_versions_valides.json`	mémorise la version Delta valide de chaque table
`gold.dimensions`	Silver	6 dimensions	reconstruction complète (`overwrite`), clés déterministes, ajout du membre -1
`gold.facts`	Silver et dimensions Gold	4 faits partitionnés	résolution des clés étrangères par jointure sur la clé métier, membre -1 si absente ; dimensions de moins de 2 M de lignes diffusées (broadcast)
`quality.checks gold`	tables Gold	rapport `qualite_gold_*.json/html`	unicité des clés primaires, 17 contrôles d'intégrité référentielle, cohérence des mesures ; en cas d'échec, `gold.optimize restore`
`gold.optimize optimize`	tables Gold	tables compactées	OPTIMIZE et Z-ORDER, VACUUM (7 jours), ANALYZE côté Trino

Tableau 47 -Spécification des jobs Gold et des contrôles.

Annexe D -Gestion de projet détaillée

Cette annexe détaille le déroulement résumé au § 3.4.

D.1 Phases, tâches et avancement

Le projet est découpé en neuf phases, rattachées aux semaines du Tableau 8.
L'avancement est arrêté au lundi 26/10/2026, jour de la remise du livrable 1.

Phase	Période	Livrable servi	Avancement	Statut
P1 -Cadrage et organisation	Sem. 1 (19/10)	tous	100 %	terminée
P2 -Étude des sources	Sem. 1 (19-20/10)	L1	100 %	terminée
P3 -Socle technique et mise en ligne	Sem. 1 (20/10)	L2	100 %	terminée
P4 -Pipelines, qualité et ordonnancement	Sem. 1 (20-25/10)	L1, L2	100 %	terminée
P5 -Application décisionnelle et API	Sem. 1 (20/10), puis Sem. 2-3	L3	85 %	en cours
P6 -Livrable 1	Sem. 1-2 (20-26/10)	L1	100%	en finalisation, remise ce jour à 23:00
P7 -Livrable 2	Sem. 1 (mesures), Sem. 2 (rapport)	L2	70 %	en cours, remise le 2/11
P8 -Livrable 3 et soutenance	Sem. 3-4	L3	10 %	à venir, remise le 12/11
P9 -Clôture	Sem. 4 (13/11)	–	0 %	à venir

Tableau 48 -Phases du projet et avancement au 26/10/2026.

N°	Tâche	Responsable	Appui	Période	Avancement
1.1	Analyse du sujet, choix de l'architecture et de la stack	Allan	Philippe	19/10 (lancement, prosit aller 1)	100 %
1.2	Rédaction du document de cadrage	Allan	Philippe	19/10	100 %
1.3	Planning, répartition des tâches, suivi d'avancement	Maeva	–	en continu	en continu
2.1	Profilage des quatre sources (DuckDB, dump PostgreSQL)	Allan	Philippe	19-20/10	100 %
2.2	Modèle conceptuel de S1, volumétrie et anomalies des sources	Philippe	Allan	20/10	100 %

N°	Tâche	Responsable	Appui	Période	Avancement
2.3	Définition des huit indicateurs (numérateur, dénominateur)	Philippe	Allan	20/10	100 %
3.1	Plateforme Docker Compose (MinIO, Hive, Trino, Airflow, Keycloak)	Allan	Mathéo	20/10	100 %
3.2	Serveur, HTTPS, mise en ligne des outils	Mathéo	Allan	20/10	100 %
3.3	Dépôt GitHub et guide d'équipe	Mathéo	Maeva	20/10	100 %
4.1	Jobs Bronze des quatre sources	Allan	Philippe	20/10	100 %
4.2	Jobs Silver : nettoyage, rejets, dédoublonnage, pseudonymisation	Allan	Philippe	20/10	100 %
4.3	Modèle Gold : dimensions et faits	Allan	Philippe	20/10	100 %
4.4	Contrôles qualité Great Expectations et rapports	Philippe	Allan	20/10	100 %
4.5	DAG Airflow, alertes, ordonnancement quotidien	Allan	Mathéo	20-25/10	100 %
4.6	Corrections issues des contrôles (durée des consultations, âges)	Allan	Philippe	23-25/10	100 %
5.1	API : requêtes paramétrées, seuil de diffusion, journal d'accès	Mathéo	Allan	20/10	100 %
5.2	Application React : écrans, cartes, exports	Mathéo	–	20/10	100 %
5.3	Comptes, rôles et matrice des droits (Keycloak)	Mathéo	Philippe	20/10	100 %
5.4	Assistant IA	Mathéo	Allan	20/10	100 %
5.5	Recette fonctionnelle des écrans pour chaque profil	Maeva	Philippe	21-22/10	100 %

N°	Tâche	Responsable	Appui	Période	Avancement
5.6	Tableau de bord complémentaire branché sur l'API	Mathéo	Maeva	27/10 au 6/11	0 %
6.1	Modèles conceptuel et logique, dictionnaire de données	Philippe	Allan	20-23/10	100 %
6.2	Architecture, choix techniques et alternatives	Allan	Philippe	20-23/10	100 %
6.3	Spécifications ETL et jobs d'alimentation par dimension	Philippe	Allan	23-26/10	100 %
6.4	Plan de gouvernance : mesures techniques	Philippe	Allan	23/10	100 %
6.5	Plan de gouvernance : cadre RGPD et HDS	Maeva	Philippe	23/10	100 %
6.6	Correspondance avec la grille d'évaluation	Philippe	Maeva	26/10 (workshop 2)	100 %
6.7	Mise en forme, synthèse, glossaire, relecture finale	Maeva	Philippe	26/10 (tutorat)	80 %
6.8	Informations administratives, chiffrage et remise	Maeva	–	26/10, avant 23:00	100 %
7.1	Benchmark : huit requêtes, Spark et Trino, avant et après	Allan	Philippe	20/10	100 %
7.2	Rapport qualité Silver et Gold	Philippe	Allan	20/10, mis à jour le 26/10	100 %
7.3	Rédaction du livrable 2 au format officiel et archive ZIP	Philippe	Maeva	27/10 au 2/11	40 %
8.1	Déroulé de la soutenance, récit praticien et direction	Maeva	Philippe	3 au 5/11	30 %
8.2	Support de présentation	Maeva	Mathéo	3 au 6/11	0 %

N°	Tâche	Responsable	Appui	Période	Avancement
8.3	Démonstration en direct et captures de secours	Mathéo	Allan	5 au 10/11	0 %
8.4	Répétitions et remise du livrable 3	tous	–	9 au 12/11	0 %
8.5	Soutenance	tous	–	13/11 matin	0 %
9.1	Retour d'expérience et résiliation du serveur avant son renouvellement automatique	Allan	Maeva	13/11 après-midi	0 %

Tableau 49 -Tâches, responsables et avancement au 26/10/2026.

Le socle technique a été construit dès la première semaine. Ce choix a permis de rédiger le livrable 1 à partir de la plateforme réelle et non d'hypothèses : volumes, taux de complétude et anomalies du référentiel sont mesurés sur les données. Il laisse aussi de la marge pour la suite : au 26/10, 39 des 116 heures de créneaux par personne sont écoulées (34 %), alors que les quatre phases techniques sont terminées. Les semaines 2 et 3 sont consacrées aux livrables 2 et 3 et au tableau de bord complémentaire, la semaine 4 aux répétitions et à la soutenance.

Le tableau suivant retrace, d'après le journal de bord et l'historique Git, l'ordre dans lequel les étapes ont été réalisées.

Étape	Contenu
1. Étude du cadrage et des données	Lecture du cadrage ; profilage des données avec DuckDB et une restauration temporaire du dump PostgreSQL
2. Remise en état du poste	Réparation de Docker Desktop, libération d'espace disque
3. Écriture de la plateforme	`docker-compose.yml` (11 services de base), pipelines, 6 DAG, API, application, Keycloak
4. Premier chargement	Lancement manuel job par job, corrections successives
5. Tests de l'application	Connexion, écrans, droits vérifiés côté serveur
6. Livrables	Rédaction du L1, benchmark, rédaction du L2
7. Outillage d'équipe	Dépôt GitHub privé `wSimbaa/chu-lakehouse`, configuration de production
8. Stabilisation	Premier passage complet via Airflow, test de restauration, guide d'utilisation
9. Mise en ligne	Serveur dédié, HTTPS, publication de tous les outils

Étape	Contenu
10. Consolidation (23 au 25/10)	Livrable 1 mis au format officiel ; durée des consultations corrigée ; âge laissé vide quand la naissance suit l'acte ; contrôles d'intégrité étendus à 17 liens ; traitements rendus quotidiens

Tableau 50 -Étapes de réalisation d'après le journal de bord.

D.2 Outils

Besoin	Outil
Gestion de versions et partage	Git, GitHub (dépôt privé)
Environnement reproductible	Docker, Docker Compose
Profilage initial des données	DuckDB
Hébergement	Serveur Ubuntu 24.04, reverse proxy Caddy (HTTPS)
Alertes	Mail et Discord, depuis Airflow

Tableau 51 -Outils de travail de l'équipe.

D.3 Aléas et décisions

Plusieurs incidents ont été rencontrés. Chacun a donné lieu à une décision documentée.

Aléa	Décision
Docker Desktop refusait de démarrer (sockets orphelins après un arrêt brutal)	Procédure de réparation documentée ; mémoire Docker portée à 12 Go
Manque de mémoire sur le traitement Silver des décès (25 M de lignes)	Mode " gros volume " : 4 cœurs, 200 partitions
Images officielles MinIO plus publiées	Redistribution communautaire `pgsty/minio`, compatible à l'identique
Great Expectations envoyait des statistiques d'usage vers Internet	Envoi désactivé (plateforme de santé)
Le contrôle qualité a bloqué la première publication de Gold (décès antérieurs à 1970 absents du calendrier)	Calendrier étendu à 1880, puis republication
Deux plantages du benchmark par manque de mémoire	Script rendu reprenable, découpé en phases Spark puis Trino
Le serveur FTP ne redémarrait pas un conteneur existant	Contrôle de santé ajouté ; arrêt par `docker compose down` au lieu de `stop`

Aléa	Décision
Mot de passe root du serveur ayant circulé dans un message	Mot de passe changé, accès par clé SSH dédiée
Durée de consultation vide sur 100 % des lignes, non détectée car les contrôles ignorent les valeurs nulles	Heures extraites correctement, passage de minuit pris en compte ; contrôle de complétude ajouté et contrôle des bornes rendu bloquant
24 145 consultations antérieures à la naissance du patient donnaient un âge négatif dans les indicateurs	Âge laissé vide en Gold, tranche " Non renseigné "

Tableau 52 -Aléas rencontrés et décisions prises.

Annexe E -Alternatives techniques étudiées

Pour chacune des trois briques structurantes (ETL, stockage, restitution), ainsi que pour l'assistant IA, les outils cités par le sujet ou envisagés ont été comparés aux exigences du cadrage : open source sans licence, données de santé, passage d'un poste à un cluster sans réécriture, et volume des décès (25 millions de lignes).

Brique	Option	Décision	Raison
ETL	Talend Open Studio	écartée	retiré par Qlik en janvier 2024, plus maintenu ni distribué gratuitement
ETL	Apache NiFi	écartée	excellent pour router des fichiers (FTP), mais orienté flux unitaires : les jointures et agrégations sur 25 M de lignes y sont peu adaptées, et les flux se versionnent mal dans Git
ETL	dbt	écartée	ne fait que la transformation (T) en SQL dans un moteur existant ; il faut toujours un outil pour l'extraction JDBC et FTP, et la pseudonymisation salée s'exprime mal en SQL pur. dbt resterait possible au-dessus de Trino ou Spark pour la couche Gold
ETL	**Apache Spark (PySpark), orchestré par Airflow**	**retenue**	couvre E, T et L dans un seul outil, en Python versionné ; traitement distribué adapté aux décès ; un job Spark joue le rôle d'un mapping Informatica, un DAG Airflow celui d'un enchaînement OpCon

Brique	Option	Décision	Raison
Stockage	PostgreSQL	écartée (conservé comme source et pour les bases techniques)	base transactionnelle en lignes, montée en charge verticale ; pas de séparation stockage / calcul ni de format colonnaire pour 25 M de lignes analysées
Stockage	Hive (Cloudera)	partiellement retenue	seul le Hive Metastore est conservé comme catalogue ; le moteur Hive de QuickStart ne gère pas l'ACID par défaut
Stockage	BigQuery	écartée	service propriétaire et payant, impossible à exécuter en local ; dépendance à un fournisseur pour des données de santé
Stockage	**MinIO + Delta Lake + Hive Metastore**	**retenue**	stockage objet compatible S3 (portable chez un hébergeur HDS), format colonnaire, ACID, MERGE, *time travel*
BI	Power BI	écartée	licence nécessaire pour publier et partager, client Windows ; contraire à l'exigence " sans licence "
BI	Metabase, Apache Superset	écartées	open source, mais le contrôle fin exigé ici (seuil de diffusion sous 10 patients, droits par vue vérifiés côté serveur, journal d'accès par écran) aurait demandé de les personnaliser fortement
BI	**Application FastAPI + React**	**retenue**	requêtes paramétrées prédéfinies (pas d'injection SQL), seuil de diffusion et matrice des droits appliqués dans l'API, cartes régionales (Leaflet), vue de performance pour la démonstration

Assistant IA | API Claude (Anthropic) | retenue pour la démonstration | très bonne utilisation des outils, mise en œuvre rapide dans le cadre pédagogique ; mais service payant, hébergé hors du périmètre HDS : incompatible avec l'exigence " open source, sans licence " et avec des données de santé réelles |
Assistant IA | API hébergée de DeepSeek | écartée | les requêtes partiraient vers un service situé hors de l'Union européenne, ce qui est exclu pour des données de santé |
Assistant IA | **Modèle DeepSeek à poids ouverts (licence MIT), auto-hébergé** | **retenue pour la production** | gratuit et sans licence d'usage ; exécuté par un serveur d'inférence open source (par exemple vLLM) chez l'hébergeur HDS, si bien qu'aucune donnée ne sort de l'hébergement |

Tableau 53 -Alternatives étudiées pour chaque brique.

L'assistant est une brique optionnelle. La plateforme et les huit indicateurs fonctionnent sans lui : sans clé configurée, l'écran indique simplement que l'assistant est indisponible. L'appel au modèle est isolé dans un seul module (`app/api/app/assistant.py`). Le passage à un modèle à poids ouverts consiste à y remplacer le client et le format des appels d'outils (les serveurs d'inférence comme vLLM exposent une API standard), et à changer la variable `ASSISTANT_MODEL`. La liste des outils, les droits et le seuil de diffusion restent inchangés. Le choix de Claude pour la démonstration est donc un choix de commodité, pas une dépendance de l'architecture.

Annexe F -Gouvernance détaillée

Cette annexe détaille les mesures résumées au § 9.2.

F.1 Protection des données personnelles

Les données de santé sont des données sensibles au sens de l'article 9 du RGPD. Leur protection est prévue à chaque couche.

Mesure	Mise en œuvre
Pseudonymisation	`sha2(sel ‖ Id_patient, 256)` dès Silver ; le sel est un secret d'environnement (`PSEUDO_SALT`), hors dépôt ; la plateforme refuse de démarrer avec la valeur d'exemple
Minimisation	noms, prénoms, adresses, e-mails, téléphones, numéros de sécurité sociale, groupes sanguins, poids et tailles ne dépassent pas Bronze
Généralisation	date de naissance réduite à l'année (Gold), puis à la tranche d'âge (restitution) ; code postal réduit au département
Seuil de diffusion	l'API masque tout effectif inférieur à 10, ainsi que les taux associés (`app/api/app/db.py`, `masquer`)
Décès INSEE	identité remplacée par un hash salé ; seuls l'âge et le lieu sont conservés
Conservation	landing expiré à 365 jours ; historique Delta limité par `VACUUM` (7 jours) ; purge Bronze par lot (`_batch_id`)
Secrets	fichier `.env` non versionné ; jeton OIDC court (15 min)

Tableau 54 -Mesures de protection des données personnelles.

Pseudonymisation ou anonymisation. Le sujet cite les deux notions, qui n'ont pas la même portée juridique.

- **Pseudonymisation** (RGPD, article 4.5) : l'identité est remplacée par un code, mais la personne reste ré-identifiable par qui détient l'information complémentaire, ici le sel. C'est le cas des couches Silver et Gold : `id_patient_pseudo` permet de suivre un même patient d'une consultation à l'autre, ce qui est nécessaire pour l'indicateur 3 (patients distincts hospitalisés). Les données pseudonymisées **restent des données personnelles** et tout le RGPD s'y applique.
- **Anonymisation** (considérant 26) : la ré-identification devient impossible, de façon irréversible, et les données sortent du champ du RGPD. Dans la plateforme, seuls les **résultats publiés par l'API** relèvent de cette logique : ce sont des agrégats (comptages, taux, moyennes), sans identifiant, dont tout effectif inférieur à 10 est masqué pour empêcher d'isoler une personne. La généralisation (année de naissance, tranche d'âge, département) renforce cette protection.

Le choix de pseudonymiser plutôt que d'anonymiser les couches internes est délibéré : une anonymisation complète dès Silver empêcherait de compter des patients distincts et de relier consultations et séjours d'un même patient.

F.2 Cadre RGPD du traitement

Le CHU est fictif et les données sont des données d'école ; les éléments ci-dessous décrivent ce que le groupe hospitalier devrait formaliser pour mettre la plateforme en production. Le statut indique ce que le projet met déjà en œuvre.

Exigence RGPD	Contenu pour la plateforme	Statut dans le projet
Responsable de traitement	le groupe hospitalier CHU ; l'équipe data agit pour son compte	défini (fictif)
Finalité (art. 5.1.b)	pilotage de l'activité de soins, de la qualité et de la satisfaction ; statistiques agrégées, sans décision individuelle sur un patient	définie : seuls les huit indicateurs sont calculés
Base légale (art. 6 et 9)	pour un établissement public de santé : mission d'intérêt public (art. 6.1.e) et gestion des systèmes de santé (art. 9.2.h) ; un entrepôt de données de santé doit en outre être conforme au référentiel " entrepôts de	à formaliser par le CHU

Exigence RGPD	Contenu pour la plateforme	Statut dans le projet
	données de santé " de la CNIL ou être autorisé par elle	
Minimisation (art. 5.1.c)	seules les colonnes utiles aux indicateurs dépassent Bronze	**en place** (annexe F.1)
Limitation de la conservation (art. 5.1.e)	durées par couche	**en place** : landing 365 jours, historique Delta 7 jours ; durée Bronze à fixer par le CHU
Registre des traitements (art. 30)	fiche décrivant la finalité, les catégories de données et de personnes, les destinataires, les durées et les mesures de sécurité	contenu disponible dans ce livrable (§ 5, chapitre 9 et annexe B)
Analyse d'impact (AIPD, art. 35)	obligatoire : données de santé traitées à grande échelle	à réaliser par le CHU ; les risques et mesures de ce chapitre en constituent la base
Délégué à la protection des données (DPO, art. 37)	obligatoire pour un organisme public ; consulté sur l'AIPD et les droits d'accès	à désigner par le CHU
Droits des personnes (art. 15 à 21)	information des patients ; accès, rectification, opposition	possible : le data engineer recalcule le pseudonyme d'un patient à partir de son identifiant et du sel pour retrouver ses lignes. Une suppression à la source n'est pas propagée automatiquement par le MERGE : suppression en Silver, puis reconstruction de Gold et `VACUUM` (procédure manuelle)
Sécurité (art. 32)	contrôle d'accès, traçabilité, chiffrement, sauvegardes	partiellement en place (annexes F.3, F.4 et F.5)
Sous-traitance (art. 28)	contrat avec l'hébergeur ; avec le fournisseur du modèle de langage tant que l'assistant appelle une API externe	à prévoir avec un hébergeur certifié HDS ; le modèle auto-hébergé visé en production supprime le

Exigence RGPD	Contenu pour la plateforme	Statut dans le projet
		second sous-traitant (annexe F.3)

Tableau 55 -Cadre RGPD du traitement.

F.3 Rôles et droits

Rôle	Bronze	Silver	Gold	Application
Data engineer	lecture / écriture	lecture / écriture	lecture / écriture	tous les écrans, dont Performance technique
Praticien	aucun	aucun	via l'application	domaines consultations et hospitalisations (Tableau 57)
Direction	aucun	aucun	via l'application	domaines consultations, établissements et satisfaction, mortalité (Tableau 57)
Administrateur sécurité	gestion des comptes	gestion des comptes	gestion des comptes	console Keycloak uniquement, aucun écran de données

Tableau 56 -Matrice des rôles et des droits.

Côté application, les droits sont définis par **domaine** (`consultations`, `hospitalisations`, `etablissements`, `mortalite`, `performance`, `assistant`, `exports`), et chaque écran exige un domaine.

Écran	Domaine exigé par l'API	Praticien	Direction	Data engineer
Vue d'ensemble	`consultations` ; chiffres clés et alertes limités aux domaines du rôle	oui	oui	oui
Activité de consultation (indicateurs 1, 2, 6)	`consultations`	oui	oui	oui
Comparer deux périodes	`consultations`	oui	oui	oui
Hospitalisations (indicateurs 3, 4, 5)	`hospitalisations`	oui	non	oui
Pilotage des établissements (indicateur 8)	`etablissements`	non	oui	oui
Fiche établissement	`etablissements`	non	oui	oui

Écran	Domaine exigé par l'API	Praticien	Direction	Data engineer
Mortalité (indicateur 7)	`mortalite`	non	oui	oui
Performance technique	`performance`	non	non	oui
Assistant IA	`assistant` ; outils limités aux domaines du rôle	oui	oui	oui
Exports (PNG, CSV, Excel, PDF)	`exports` ; catalogue limité aux domaines du rôle	oui	oui	oui

Tableau 57 -Écrans de l'application et droits par rôle

La matrice est appliquée côté serveur (`app/api/app/auth.py`, dépendance `acces(vue)`) : chaque requête de l'API vérifie le domaine, et l'interface ne fait que masquer les entrées de menu. Les écrans transverses (Vue d'ensemble, Assistant IA, Exports) n'ouvrent aucun accès supplémentaire, car ils réutilisent les mêmes requêtes et donc les mêmes contrôles. Le rôle d'administrateur sécurité est neutralisé dans l'API : même s'il s'attribuait un rôle métier dans Keycloak, il n'obtiendrait aucune donnée (séparation des tâches). Les tests ont confirmé qu'un praticien reçoit une erreur 403 sur les écrans de la direction, et inversement.

Assistant IA. L'assistant ne lit jamais les tables : il ne dispose que d'" outils " qui sont exactement les indicateurs de l'API, et seuls les outils des domaines du rôle connecté lui sont proposés. Les données transmises au modèle sont donc la question de l'utilisateur et des résultats agrégés déjà soumis au seuil de diffusion (effectifs inférieurs à 10 masqués), sans identifiant de patient ni ligne de détail. Il n'écrit aucune requête SQL. Ses consignes refusent les questions hors du périmètre du CHU et les tentatives de contournement des droits. Chaque appel est tracé dans le journal d'accès de l'API (utilisateur, rôles, statut, durée), et un quota limite chaque compte à 30 questions par heure. Pour la démonstration, le modèle est appelé via l'API d'Anthropic. Ce service externe n'est pas certifié HDS : il est acceptable avec des données d'école et des agrégats anonymisés, mais pas avec des données réelles. En production, l'assistant utiliserait un modèle DeepSeek à poids ouverts hébergé chez l'hébergeur HDS, si bien qu'aucune donnée ne sortirait de la plateforme (annexe E).

F.4 Traçabilité

Objet tracé	Dispositif
Traitements	`audit.job_runs` et `reports/runs/job_runs.jsonl` : dates, volumes lus, écrits et rejetés, doublons, erreurs
Rejets	`silver.rejets_<source>` : ligne d'origine, motif, date, job et lot

Objet tracé	Dispositif
Accès aux données	journal d'accès de l'API : utilisateur, rôles, vue, paramètres, statut et durée (`reports/access/api_access.log`)
Versions des tables	`DESCRIBE HISTORY` et *time travel* Delta
Origine de chaque ligne Bronze	colonnes `_source`, `_batch_id`, `_ingestion_ts` ; manifeste des fichiers FTP ingérés
Lignage	OpenLineage (listener Spark et provider Airflow) vers Marquez, profil `lineage`

Tableau 58 -Dispositifs de traçabilité.

F.5 Conformité HDS

En France, héberger des données de santé pour le compte d'un tiers impose un hébergeur certifié HDS (Code de la santé publique, article L.1111-8). Le référentiel HDS en vigueur s'appuie sur la norme de sécurité ISO/IEC 27001 et y ajoute des exigences propres à la santé, dont l'hébergement des données dans l'Espace économique européen.

Ce projet est pédagogique : ni le poste local ni le serveur de démonstration ne sont certifiés, et les données sont des données d'école dont l'hébergement en ligne a été accepté par l'enseignant. L'objectif est différent : **reproduire une architecture qui répond aux exigences techniques attendues d'une plateforme HDS**, de sorte que sa mise en production chez un hébergeur certifié (OVHcloud, Scaleway, etc.) ne demande que de la configuration, sans réécriture. Comme elle repose sur un stockage compatible S3 et sur des conteneurs, elle se transporte telle quelle.

Exigence (HDS / ISO 27001)	Mise en œuvre dans la plateforme	Statut
Contrôle d'accès et authentification	Keycloak (OIDC), quatre rôles, jetons de 15 minutes, droits vérifiés côté serveur	en place
Authentification forte des comptes sensibles	MFA Keycloak pour data engineers et administrateurs	à activer en production (fonction native de Keycloak)
Séparation des tâches	l'administrateur sécurité gère les comptes sans accès aux données	en place
Traçabilité des accès et des traitements	journal d'accès de l'API, `audit.job_runs`, historique Delta	en place

Exigence (HDS / ISO 27001)	Mise en œuvre dans la plateforme	Statut
Chiffrement en transit	HTTPS (TLS, Let's Encrypt) sur toutes les adresses publiques via Caddy	en place à l'extérieur ; trafic interne entre conteneurs à chiffrer en production
Chiffrement au repos	chiffrement côté serveur (SSE) de MinIO avec un service de gestion de clés	à activer en production
Cloisonnement réseau	réseau Docker interne ; seuls SSH, HTTP et HTTPS ouverts ; outils techniques derrière un écran de connexion	en place
Localisation des données	serveur de démonstration dans l'Union européenne	en place
Gestion des secrets	`.env` hors dépôt, sel de pseudonymisation, accès SSH par clé	en place
Sauvegarde et reprise d'activité	retour à une version valide par *time travel* (testé, § 8.4) ; ce n'est pas une sauvegarde	à prévoir : réplication MinIO vers un second site et sauvegarde des bases techniques
Maîtrise des flux sortants	assistant IA : démonstration via une API externe (agrégats masqués uniquement) ; production via un modèle à poids ouverts hébergé sur place	à basculer en production (annexe E)
Contrat et certification	contrat d'hébergement HDS, audit de certification	hors périmètre d'un projet pédagogique

Tableau 59 -Correspondance entre les exigences HDS et la plateforme.

Annexe G -Liens

Ressource	Adresse
Dépôt GitHub (privé)	https://github.com/wSimbaa/chu-lakehouse
Application en ligne	https://chu.allanbouhamed.fr
Airflow en ligne	https://airflow.allanbouhamed.fr
Console MinIO en ligne	https://minio.allanbouhamed.fr
Trino en ligne	https://trino.allanbouhamed.fr/ui/

Toutes ces adresses sont servies en HTTPS et protégées par authentification : écran de connexion propre à l'outil (application via Keycloak, Airflow, MinIO) ou identifiant demandé par le reverse proxy Caddy (Trino, Spark). Les identifiants ne figurent pas dans ce document.

Annexe H -Organisation du dépôt

Dossier	Contenu
`infra/`	Configuration des briques : Hive Metastore, Trino, Keycloak, Airflow, Spark, bases PostgreSQL
`pipelines/bronze`	Extraction brute des 4 sources (JDBC, CSV, FTP)
`pipelines/silver`	Typage, normalisation, dédoublonnage, rejets, pseudonymisation
`pipelines/gold`	Dimensions, faits, optimisation, reprise sur version valide
`pipelines/quality`	Contrôles Great Expectations et rapports
`dags/`	Un DAG par source, `dag_gold`, `dag_benchmark`, `dag_demo_alerte`
`benchmark/`	Requêtes métier et protocole de mesure
`app/api`, `app/web`	API FastAPI et application React
`docs/`	Livrables et guide
`reports/`	Sorties générées : qualité, benchmark, journaux, alertes

Annexe I -Document de cadrage

Le document de cadrage " CHU -Cadrage projet et architecture cible " (" Projet Cloud Healthcare Unit : présentation, fonctionnement et stack technique ", 14 pages) est joint au dépôt (`docs/CHU - Cadrage projet et architecture cible.pdf`). Il contient le contexte, les indicateurs, l'architecture cible, la stack et sa justification, le modèle décisionnel, les pipelines, la stratégie d'optimisation, l'application et la gouvernance. Le présent livrable en est la version détaillée et vérifiée sur les données réelles. Les écarts au cadrage sont signalés là où ils interviennent : fréquence mensuelle retenue, exécutée chaque nuit pendant le projet pour multiplier les chargements de test (§ 8.2), absence de capacités et de certifications dans S2 (§ 5.2), localisation du patient au département (§ 7.3) et assistant IA ajouté à l'application (annexes E et F.3).