

CHU
Big Data

CESI
ÉCOLE D'INGÉNIEURS

Projet
Big Data

Livrable 3 – Présentation des résultats et storytelling

Réalisé par
Allan BOUHAMED
Philippe LUU
Mathéo CARVAL
Maeva CHALLIES

Projet encadré par
Djamel AOUAM / Ali SKAF / Lea BEYRIS

Année universitaire 2026/2027

Informations générales

Historique des versions

Version	Date	Auteurs	Objet
1.0	10/11/2026	Allan Bouhamed ; Philippe Luu ; Mathéo Carval ; Maeva Challies	Rapport de restitution : méthodologie, modèle et implémentation, tableau de bord, analyse des résultats pour les praticiens et la direction, recommandations, correspondance avec la grille

Tableau 1 – Historique des versions du document.

Liste de diffusion

Destinataire	Rôle
Djamel Aouam, Ali Skaf, Lea Beyris	Encadrants, évaluation
Groupe 3	Auteurs

Tableau 2 – Liste de diffusion.

Choix technologique et grille d'évaluation

La grille du livrable 3 est écrite pour une restitution dans **Power BI connecté à Cloudera** (connexion au datalake, modèle en étoile repris dans le moteur de modélisation, signets pour le récit). Comme pour les livrables 1 et 2, le projet a été réalisé, **avec l'accord de l'encadrant**, sur une pile open source : Spark, Delta Lake, Hive Metastore et Trino, restitués dans une **application web développée par l'équipe** (FastAPI et React) et publiée en ligne.

Ce choix n'enlève aucune fonction attendue d'un outil de BI. Il ajoute ce qu'un outil branché directement sur les tables ne garantit pas : le masquage des effectifs de moins de 10 patients, des droits vérifiés côté serveur pour chaque profil, et un journal des accès. Le tableau ci-dessous résume les équivalences ; l'annexe A reprend la grille critère par critère.

Attendu de la grille (Power BI / Cloudera)	Réalisation dans le projet
Connexion à Cloudera, répertoires du datalake visibles	L'API interroge la couche Gold par Trino (catalogue `delta`, schéma `gold`), tables déclarées dans le Hive Metastore ; les répertoires du datalake sont visibles dans la console MinIO (buckets `bronze`, `silver`, `gold`)
Modèle en étoile repris dans le moteur de modélisation	La constellation Gold (4 faits, 6 dimensions) est le schéma direct des requêtes : chaque écran agrège un fait, filtré par ses dimensions
Graphiques pertinents, tableau de bord, visible sur mobile	14 écrans, un type de graphique choisi par question (cartes, barres, pyramide, courbes, tableaux), affichage adapté au téléphone
Signets pour le data storytelling	Chaque état d'écran (année, enquête, région, tri) tient dans l'adresse de la page : une suite d'adresses enregistrées joue le rôle d'une suite de signets

Tableau 3 – Équivalences entre la grille et la réalisation.

Synthèse managériale

Le groupe hospitalier CHU voulait répondre aux questions de ses praticiens et de sa direction à partir de quatre sources qui, seules, ne le permettent pas. Les livrables 1 et 2 ont posé l'architecture, le modèle décisionnel et l'implémentation optimisée. Ce troisième livrable présente la **restitution des résultats** : le tableau de bord, l'analyse des indicateurs pour chaque public, et les recommandations qui en découlent.

- **Une plateforme en service.** Chaque nuit, les quatre sources sont rechargées et la couche Gold est republiée (26 millions de lignes de faits) après 44 contrôles qualité, dont 30 bloquants. Le tableau de bord est en ligne sur https://chu.allanbouhamed.fr.
- **Un tableau de bord pour deux publics.** 14 écrans, filtrés selon le profil : les praticiens voient l'activité de soins et leur hôpital, la direction voit la satisfaction, la mortalité et l'entraide. Les effectifs de moins de 10 patients sont masqués partout.
- **Résultat pour la direction.** La satisfaction moyenne est de 74,0 / 100 sur 837 établissements en 2020. L'écart entre régions atteint 9 points (Bretagne 76,0, Guyane 66,7). L'Île-de-France n'est que 12e (71,9) alors qu'elle réunit 135 établissements et le plus grand nombre de répondants : c'est le premier levier d'amélioration. 118 établissements sont en classe D.
- **Résultat pour les praticiens.** Sur 1,03 million de consultations, deux familles de diagnostics dominent (ostéo-articulaire 16,8 %, lésions traumatiques 15,2 %) ; on les retrouve en tête des séjours, avec 15 jours de séjour moyen. Le taux global d'hospitalisation est de 2,47 %.
- **Performance.** Toutes les requêtes de l'application répondent en moins de 2 secondes ; Trino lit jusqu'à 41 fois moins de données grâce au partitionnement et au Z-ORDER.
- **Recommandations.** Ajouter les populations INSEE et des données réelles de lits et d'effectifs, introduire des modèles de prévision de tension hospitalière, et passer à une conformité RGPD continue (analyse d'impact, hébergeur certifié HDS, revue périodique des droits).

Les données fournies ont leurs limites (consultations générées colonne par colonne, fichier des décès arrêté en mars 2020). L'analyse les signale au lieu de les cacher : c'est aussi un résultat, qui montre que les contrôles de vraisemblance fonctionnent.

Sommaire

Informations générales ... 3
Historique des versions ... 3
Liste de diffusion ... 3
Choix technologique et grille d'évaluation ... 3
Synthèse managériale ... 4
Sommaire ... 5
1. Méthodologie ... 6
1.1 Démarche ... 6
1.2 Une architecture lakehouse ... 6
1.3 Une modélisation selon Kimball ... 7
1.4 Les outils ETL ... 7
1.5 Les outils de restitution (BI) ... 8
2. Modélisation et implémentation ... 10
2.1 Le schéma décisionnel ... 10
2.2 Les règles de transformation ETL ... 10
2.3 Les stratégies d'optimisation ... 11
3. Restitution analytique et storytelling ... 13
3.1 Le tableau de bord ... 13
3.2 La protection des données dans la restitution ... 15
3.3 Les choix de visualisation ... 16
3.4 La construction du récit ... 16
3.5 Parcours d'analyse pour la direction : la satisfaction des patients ... 17
3.6 Parcours d'analyse pour les praticiens : l'activité de soins ... 19
3.7 Des alertes à l'action ... 23
3.8 Les insights actionnables ... 24
3.9 Les limites de lecture ... 25
4. Améliorations futures ... 26
4.1 Nouvelles sources de données ... 26
4.2 Intégration de modèles prédictifs ... 26
4.3 Mise en conformité continue ... 27
5. Conclusion ... 28
6. Glossaire ... 29
7. Table des figures et des tableaux ... 30
Annexes ... 32
Annexe A – Correspondance avec la grille d'évaluation ... 32
Annexe B – Chiffres clés ... 32
Annexe C – Liens ... 32

1. Méthodologie

1.1 Démarche

Le projet part des questions métier et non des outils. Les questions du sujet ont été traduites en **huit indicateurs définis sans ambiguïté** (numérateur et dénominateur, livrable 1 § 2.1). Le modèle, les traitements et les écrans en découlent :

1. **Questions** des praticiens et de la direction, reformulées en huit indicateurs ;
2. **Modèle décisionnel** : les faits et dimensions nécessaires pour les calculer ;
3. **Chaîne de traitement** : collecte, nettoyage, pseudonymisation, construction du modèle, contrôles ;
4. **Service** : une API qui applique les droits et le seuil de diffusion ;
5. **Restitution** : un écran par grande question, et un parcours d'analyse par public.

La livraison a suivi la logique du « quick win » : une vue d'ensemble en ligne dès les premières semaines, puis le détail (filtres, drill-down, comparaisons) au fil des itérations.

1.2 Une architecture lakehouse

Les sources mêlent une base relationnelle, des fichiers CSV, des enquêtes déposées sur un serveur FTP et un fichier de 25 millions de décès. Un entrepôt classique aurait imposé un schéma rigide dès l'entrée ; un lac de données seul n'aurait offert ni transactions ni schéma contrôlé. Le **lakehouse** combine les deux.

Critère	Entrepôt classique	Lac de données	Lakehouse (retenu)
Stockage	Base relationnelle, coûteuse à faire grandir	Fichiers bon marché (S3)	Fichiers bon marché (MinIO, S3)
Formats	Données structurées seulement	Tous formats	Tous formats en entrée, Parquet en sortie
Fiabilité	Transactions, schéma imposé	Pas de transaction, schéma libre	Transactions ACID, schéma contrôlé, historique (Delta Lake)
Rejeu et audit	Difficile	Possible, sans garantie	Chaque couche se reconstruit à partir de la précédente
Données sensibles	Contrôle par table	Peu de contrôle	Identifiants confinés en Bronze, pseudonymisés dès Silver

Tableau 4 – Pourquoi un lakehouse.

Les données traversent quatre couches. Chacune a un rôle, une règle de qualité et un public.

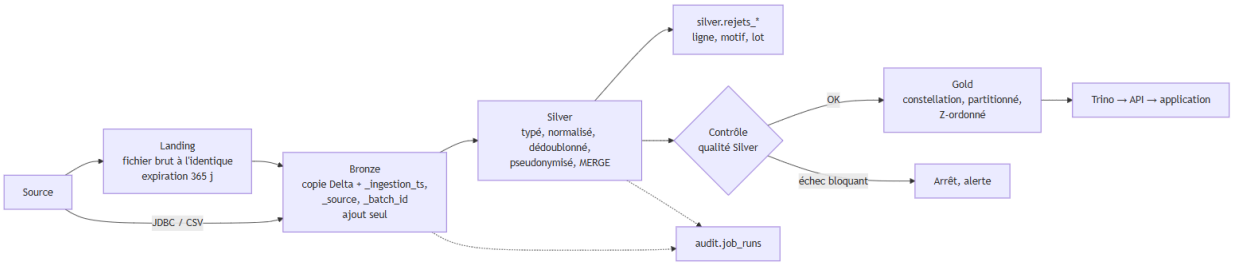


Figure 1 – Parcours des données à travers les couches du lakehouse (livrable 1, figure 3).

Couche	Rôle	Contenu sensible	Public
Landing	Fichiers déposés tels quels	Oui	Plateforme seulement
Bronze	Copie brute de chaque source, horodatée par lot, rejouable	Oui (identifiants)	Data engineers
Silver	Données typées, dédoublonnées, pseudonymisées, rejets isolés	Non (pseudonymes)	Data engineers
Gold	Modèle décisionnel prêt à l'analyse	Non	Application, analystes

Tableau 5 – Les couches du lakehouse.

1.3 Une modélisation selon Kimball

La couche Gold suit l'approche de **Ralph Kimball** : on modélise chaque processus métier (consultation, hospitalisation, décès, satisfaction) par une table de faits, et ces faits partagent des **dimensions conformes** (temps, établissement, localisation, patient, diagnostic, professionnel). L'ensemble forme une **constellation**.

L'approche d'Inmon, qui construit d'abord un entrepôt normalisé de toute l'entreprise, aurait retardé les premiers indicateurs sans bénéfice pour quatre processus bien délimités. Kimball donne un modèle **orienté requête** : un indicateur se calcule par une agrégation sur un fait, filtrée par ses dimensions, ce qui est exactement ce que fait un tableau de bord.

- **Clés de substitution** déterministes (`xxhash64` de la clé métier) : une reconstruction redonne les mêmes clés.
- **Membre « Non renseigné »** de clé -1 dans chaque dimension : un fait sans correspondance est compté, pas perdu.
- **Dénormalisation assumée** : département, région, spécialité sont recopiés dans les dimensions pour limiter les jointures.

1.4 Les outils ETL

Le manuel proposait Talend. L'outil a été retiré par son éditeur en 2024 ; trois alternatives ont été comparées au besoin (extraction JDBC et FTP, jointures sur 25 millions de lignes, pseudonymisation salée, code versionné).

Option	Décision	Raison
Talend Open Studio	Écartée	Retiré en janvier 2024, plus maintenu ni distribué gratuitement
Apache NiFi	Écartée	Excellent pour router des fichiers, peu adapté aux jointures et agrégations massives ; flux difficiles à versionner

Option	Décision	Raison
dbt	Écartée	Ne couvre que la transformation en SQL ; il faut un autre outil pour l'extraction et la pseudonymisation
Apache Spark (PySpark) + Airflow + Great Expectations	**Retenue**	Extraction, transformation et chargement dans un seul outil distribué, en Python versionné ; Airflow orchestre et relance ; Great Expectations bloque la publication si un contrôle échoue

Tableau 6 – Choix des outils ETL.

1.5 Les outils de restitution (BI)

Pour la restitution, trois familles ont été étudiées. Le critère décisif est la **sécurité des données de santé** : un outil de BI connecté directement à Trino verrait toutes les lignes de Gold, sans seuil de diffusion, sans droits par profil et sans journal d'accès.

Option	Décision	Raison
Power BI	Écartée	Licence nécessaire pour publier et partager ; une connexion directe contourne le seuil de 10 et les rôles
Metabase, Apache Superset	Écartées	Open source, mais le seuil de diffusion, les droits par écran et le journal d'accès auraient demandé une forte personnalisation
Trino + application FastAPI / React	**Retenue**	Requêtes paramétrées (pas d'injection SQL), seuil et matrice des droits appliqués dans l'API, cartes, exports, suivi des performances intégré

Tableau 7 – Choix des outils de restitution.

L'application reprend toutes les notions d'un outil de BI. Si le CHU souhaite Power BI demain, il peut le connecter à Trino ou à une vue masquée, sans rien changer à la plateforme.

Notion Power BI	Équivalent dans l'application
Connexion à la source	L'API interroge Trino (catalogue `delta`, schéma `gold`)
Modèle de données	Constellation Gold, relations portées par les jointures SQL
Mesures DAX	Agrégations SQL de l'API (mêmes définitions que le benchmark)
Segments (slicers)	Filtres de période, d'année, d'enquête, de sexe, de périmètre
Filtrage croisé, drill-down	Clic sur une région qui filtre les tableaux ; région → classement → fiche établissement
Signets	Adresse de l'écran, qui mémorise filtres et réglages
Sécurité au niveau des lignes (RLS)	Rôles Keycloak vérifiés par l'API ; périmètre « mon établissement »
Publication, application mobile	Site en HTTPS, affichage adapté au téléphone
Export	PNG, CSV, Excel, rapport PDF composé

Tableau 8 – Correspondance avec les notions de Power BI.

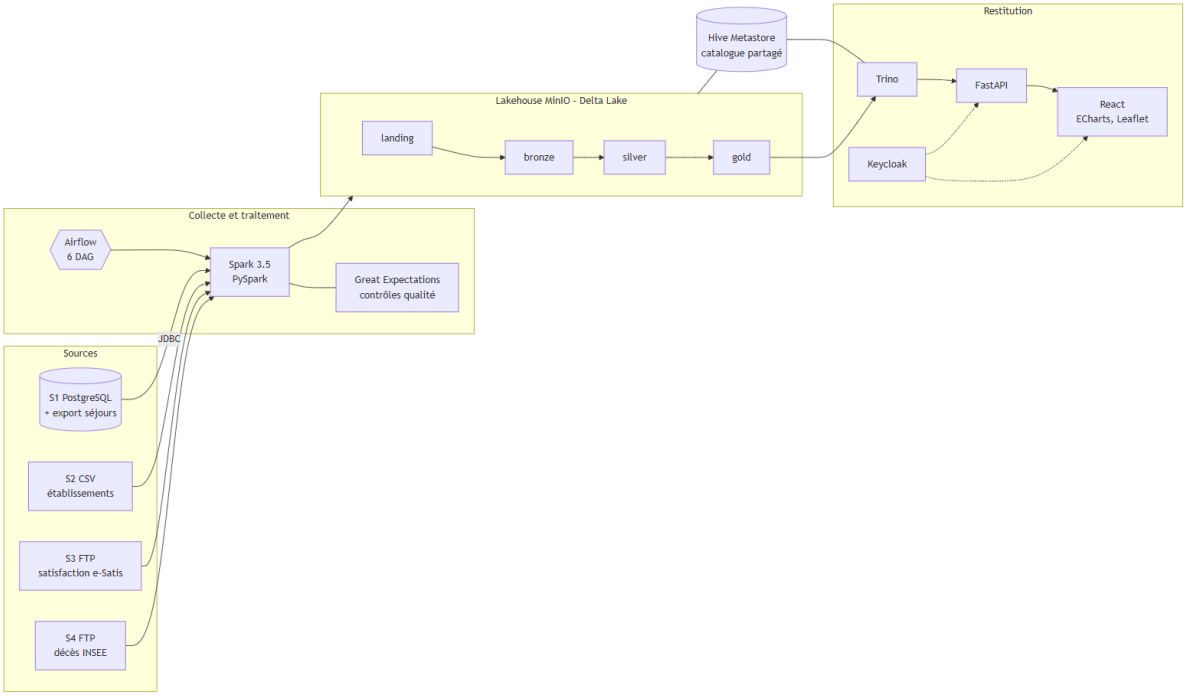


Figure 2 – Architecture d'ensemble de la plateforme (livrable 1, figure 1).

2. Modélisation et implémentation

2.1 Le schéma décisionnel

La couche Gold compte **quatre tables de faits et six dimensions conformes**. Le grain de chaque fait est fixé (une ligne = un événement), ce qui garantit que les mesures s'additionnent sans double comptage.

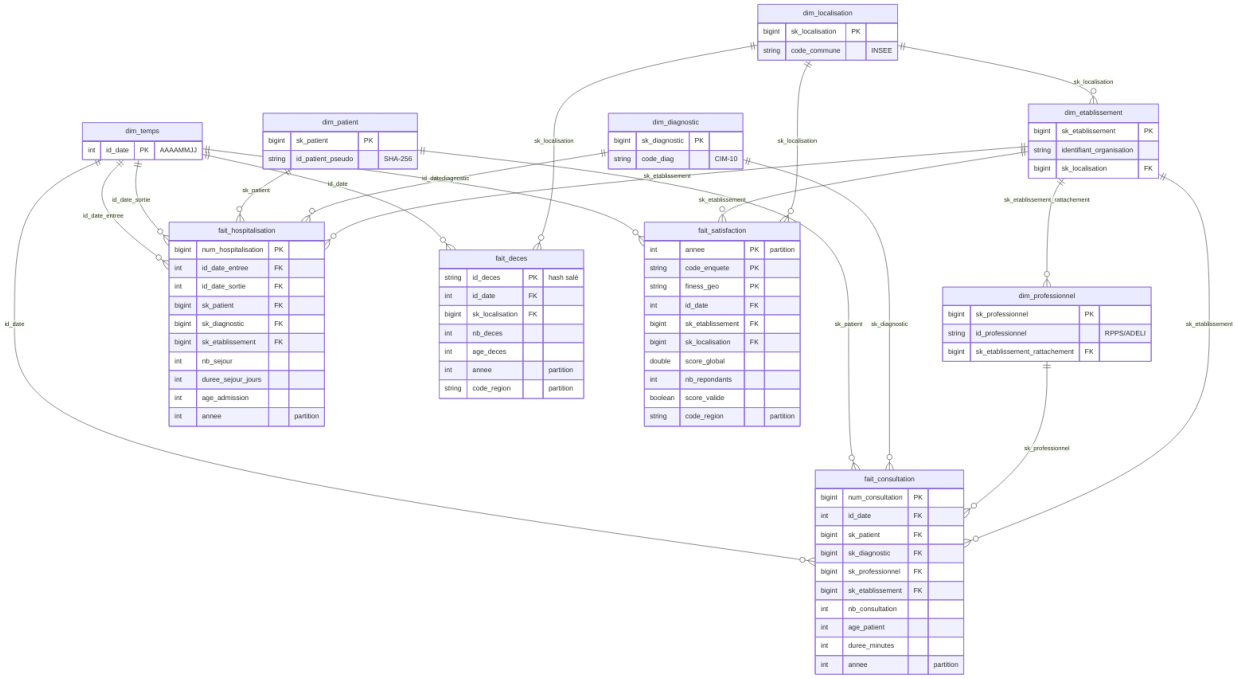


Figure 3 – Modèle en constellation de la couche Gold (livrable 1).

Fait	Grain	Mesures	Lignes	Dimensions
fait_consultation	une consultation	nb_consultation, âge, durée	1 027 157	temps, établissement, patient, diagnostic, professionnel
fait_hospitalisation	un séjour	nb_sejour, durée de séjour, âge à l'admission	2 479	temps (entrée, sortie), établissement, patient, diagnostic
fait_deces	un décès INSEE	nb_deces, âge au décès	24 917 229	temps, localisation
fait_satisfaction	établissement × enquête × année	score global, répondants, recommandation	5 335	temps, établissement

Tableau 9 – Tables de faits de la couche Gold.

2.2 Les règles de transformation ETL

Les traitements sont des jobs PySpark, un par source et par couche, orchestrés par Airflow. Les principales règles sont résumées ci-dessous ; le détail figure à l'annexe C du livrable 1.

Couche	Règle	Exemple
Bronze	Copie brute, sans modification, avec un identifiant de lot	Extraction JDBC parallélisée (8 partitions) des 13 tables PostgreSQL

Couche	Règle	Exemple
Bronze	Encodage explicite des fichiers	Annuaire des professionnels en ISO-8859-1
Silver	Typage et normalisation	FINESS sur 9 caractères, code commune INSEE, dates `M/d/yyyy` et `dd/MM/yyyy`
Silver	Dédoublonnage et rejets isolés	Lignes invalides écrites dans une table de rejets, avec leur motif
Silver	Pseudonymisation et minimisation	Identifiant patient → SHA-256 salé ; nom, adresse, n° de sécurité sociale abandonnés
Silver	Chargement incrémental	MERGE Delta sur les décès : seul un nouveau fichier INSEE est intégré
Gold	Clés de substitution et membre -1	Fait sans établissement connu → `sk_etablissement = -1`
Gold	Rattachement d'une consultation	Établissement déduit de l'exercice principal du professionnel (salarié, puis libéral)
Gold	Mesures calculées à l'acte	Âge à la date de consultation ; vide si la naissance suit l'acte ; tranche décennale
Gold	Durées robustes	Consultation qui passe minuit (20:00 → 02:00) : 360 minutes, et non -1 080

Tableau 10 – Principales règles de transformation.

Le chargement complet tourne chaque nuit : sources entre 00:00 et 01:00 UTC, couche Gold à 03:00 UTC. Il dure environ **25 minutes** sur le serveur, optimisation comprise. Avant toute publication, **44 contrôles** Great Expectations vérifient Silver et Gold, dont les 17 clés étrangères (0 orphelin au dernier chargement). Si un contrôle bloquant échoue, Gold n'est pas publié, la version précédente est restaurée et une alerte part par mail et sur Discord : le tableau de bord n'affiche jamais de chiffres non vérifiés.

2.3 Les stratégies d'optimisation

L'optimisation vise d'abord à **lire moins de données**. Le livrable 2 a mesuré chaque technique sur huit requêtes, deux moteurs et trois versions des données.

Technique	Application	Effet mesuré
Format colonnaire	Parquet compressé sous Delta	Seules les colonnes utiles sont lues
Partitionnement	Année (4 faits) ; année et région (décès, satisfaction)	Décès 2019 : 110,8 Mio lus → 13,8 Mio
Z-ORDER	Établissement et diagnostic (consultations, séjours), localisation (décès)	Consultations par diagnostic : 36,9 Mio → 0,9 Mio (× 41)
Compactage	`OPTIMIZE` sur toutes les tables	Version éclatée en petits fichiers 1,2 à 3,2 fois plus lente
Statistiques	`ANALYZE` pour Trino	Meilleur ordre des jointures
Diffusion des petites dimensions	Broadcast dans Spark	Jointures en mémoire, sans redistribution
Élagage systématique	L'API ajoute `annee BETWEEN ? AND ?` aux filtres de dates	Trino ne lit que les années demandées

Tableau 11 – Techniques d'optimisation et effet mesuré.

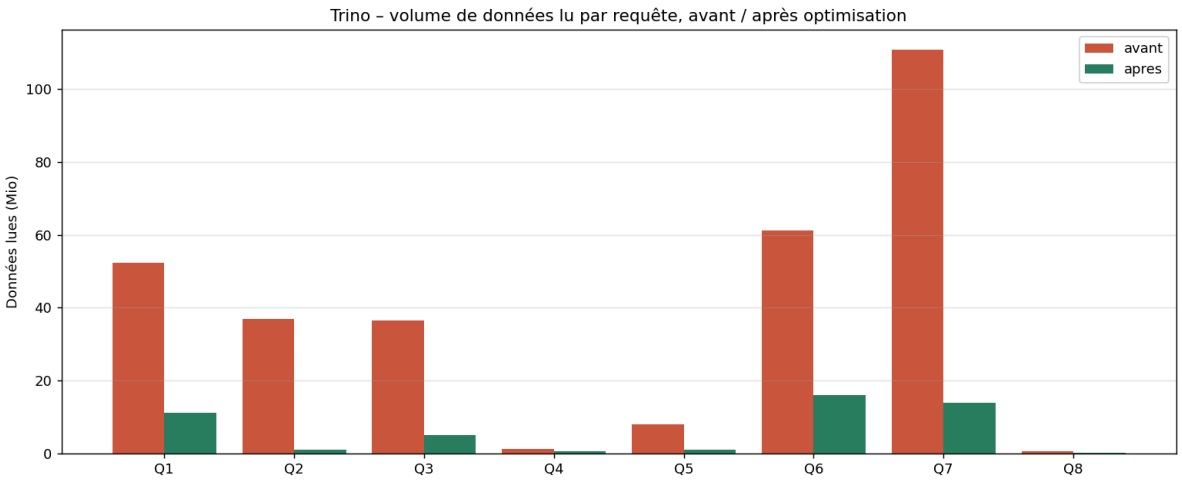


Figure 4 – Volume de données lues par Trino avant et après optimisation (livrable 2, figure 2).

Le partitionnement par sexe et tranche d'âge proposé par la grille a été testé mais non retenu en production : 2 479 séjours répartis en 150 partitions donneraient des fichiers de quelques lignes, plus lents à ouvrir qu'à lire. Le Z-ORDER joue ce rôle sans créer de petits fichiers (livrable 2 § 5.2).

À retenir :
Requête la plus lente de l'application : 1,8 s sur le serveur, très loin de la limite de 2 minutes du cadrage.
Décès par région (25 millions de lignes) dans Spark : 15,5 s en CSV → 2,5 s une fois optimisé (× 6).
Trino lit de 2 à 41 fois moins de données après optimisation ; c'est la mesure la plus fiable, car elle ne dépend pas de la charge du serveur.
L'application intègre un écran **Performance**, réservé à l'équipe data, qui affiche ces mesures et peut réexécuter chaque requête sur Trino, sans cache, dans sa version non optimisée et dans sa version de production, avec le temps, le volume lu et le texte SQL.

3. Restitution analytique et storytelling

3.1 Le tableau de bord

Le tableau de bord est une application web publiée en HTTPS. L'utilisateur se connecte avec son compte ; le menu ne présente que les écrans de son profil. Chaque écran répond à une question.

Écran	Question à laquelle il répond	Praticien	Direction	Data
Mon hôpital	Comment va mon hôpital, comparé à sa région et au groupe ?	✓*		
Vue d'ensemble	Tout va-t-il bien ? Sinon, où regarder ?	✓	✓	✓
Consultations	Qui consulte où, pour quels motifs (indicateurs 1, 2, 6) ?	✓	✓	✓
Hospitalisations	Qui est hospitalisé, pour quoi, combien de temps (3, 4, 5) ?	✓		✓
Établissements	Où les patients sont-ils satisfaits, qui accompagner (8) ?		✓	✓
Profil clinique	Qui consulte pour quoi, quels motifs progressent ?	✓	✓	✓
Mortalité	Où et à quel âge meurt-on (7) ?		✓	✓
Alertes et solutions	Quel problème traiter maintenant, et comment ?	✓	✓	✓
Entraide	Quelles demandes d'aide circulent entre établissements ?		✓	✓
Fiche établissement	Tout sur un établissement précis		✓	✓
Comparaison	Qu'est-ce qui a changé entre deux périodes ?	✓	✓	✓
Assistant IA	Une question en français, sans chercher l'écran	✓	✓	✓
Exports	Les chiffres en fichier, ou un rapport prêt à diffuser	✓	✓	✓
Performance	L'optimisation a-t-elle servi ?			✓

Tableau 12 – Les écrans du tableau de bord et leurs profils (* praticien rattaché à un établissement).

Plusieurs fonctions sont communes à tous les écrans : filtre de période, bascule « Graphique / Tableau » au-dessus de chaque visuel, lecture à voix haute, recherche rapide (Ctrl+K), mode sombre et palettes adaptées au daltonisme. Le badge « Pseudonymisé · seuil < 10 » rappelle en permanence la règle de diffusion.

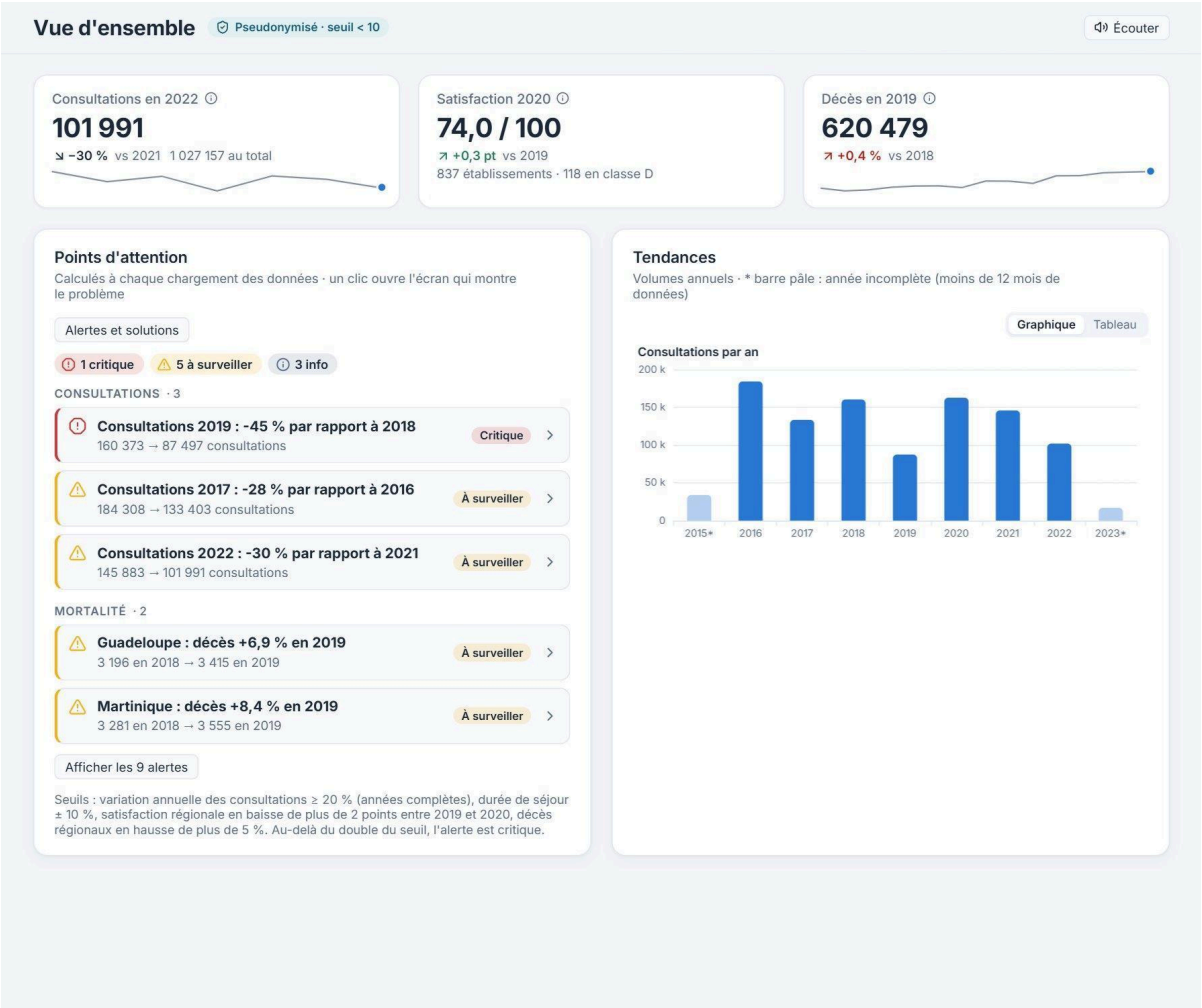


Figure 5 – Vue d'ensemble : indicateurs clés, points d'attention classés par gravité, tendances annuelles (profil direction).

Le même écran s'affiche sur téléphone : le menu passe dans un tiroir et les cartes se placent les unes sous les autres.

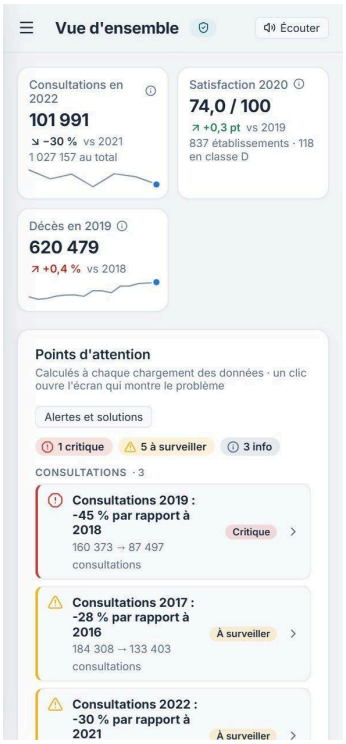


Figure 6 – Vue d'ensemble sur téléphone (profil direction).

3.2 La protection des données dans la restitution

Les données de santé imposent que la restitution elle-même soit protégée, et pas seulement le stockage. Les règles sont appliquées dans l'API, avant que la moindre donnée n'atteigne le navigateur.

Mesure	Mise en œuvre
Authentification	Keycloak (OpenID Connect), jetons de 15 minutes ; aucun écran accessible sans connexion
Droits par profil	Matrice rôle × domaine vérifiée par l'API à chaque appel ; une route hors du profil répond 403, même appelée directement
Seuil de diffusion	Effectifs de 1 à 9 remplacés par « < 10 », avec un secret secondaire qui empêche de les retrouver par différence
Périmètre	Un praticien rattaché voit par défaut son établissement ; la vue nationale reste agrégée
Requêtes paramétrées	Requêtes SQL prédéfinies, paramètres typés : pas d'injection possible depuis l'interface
Traçabilité	Journal des accès par utilisateur et par écran
Séparation des tâches	L'administrateur sécurité gère les comptes mais n'a accès à aucune donnée
Données en amont	Identifiants pseudonymisés (SHA-256 salé) dès Silver ; Gold ne contient aucune donnée directement identifiante

Tableau 13 – Mesures de protection appliquées à la restitution.

3.3 Les choix de visualisation

Chaque graphique est choisi pour la comparaison qu'il doit faciliter. Le camembert, cité par la grille, n'est pas utilisé pour les indicateurs : au-delà de cinq parts, l'œil compare mal des angles. Les exports et l'assistant savent toutefois en produire.

Indicateur	Visuel	Pourquoi
1. Consultation par établissement	Barres horizontales	Comparer des catégories aux noms longs
2. Consultation par diagnostic	Barres horizontales, code ou chapitre	Classement lisible, deux niveaux de détail
3. Taux global d'hospitalisation	Indicateur chiffré	Une seule valeur à retenir
4. Hospitalisation par diagnostic	Tableau trié avec barres	22 chapitres, avec taux et durée
5. Sexe et âge	Pyramide	Lecture naturelle par sexe et tranche
6. Par professionnel	Tableau trié, recherche	Plus de 200 000 professionnels
7. Décès par région	Carte choroplèthe, échelle séquentielle	Une quantité, répartie dans l'espace
8. Satisfaction par région	Carte divergente autour de la moyenne, puis classement	Localiser un écart, puis comparer
Évolutions	Courbes, points reliés 2019 → 2020	Montrer une tendance ou un écart

Tableau 14 – Choix des visuels par indicateur.

D'autres règles soutiennent la lecture : une seule couleur d'accent, les années incomplètes en barres pâles, une bande grise sur le premier confinement, une phrase de lecture sous les graphiques du profil clinique, et des alertes qui ne reposent jamais sur la couleur seule (icône et libellé).

3.4 La construction du récit

Chaque parcours d'analyse suit la même structure : **contexte, tension, résolution, ouverture**. Un graphique porte un message. Les titres des écrans restent descriptifs, pour rester justes quel que soit le filtre ; la conclusion est portée par le texte d'analyse, les phrases de lecture et les encadrés de ce document.

Les **signets** de Power BI sont remplacés par les adresses des écrans, qui mémorisent tous les réglages. Un parcours d'analyse s'enregistre et se partage donc comme une suite d'adresses. Le parcours direction de la partie 3.5 correspond à la suite suivante :

Étape	Adresse (préfixe https://chu.allanbouhamed.fr)	État affiché
1	`/accueil`	Vue d'ensemble et points d'attention
2	`/etablissements?annee=2020`	Carte de la satisfaction 2020, enquête hospitalisation +48 h
3	`/etablissements?region=11&ordre=moins_bons`	Île-de-France sélectionnée, établissements à accompagner
4	`/fiche?etablissement=…`	Fiche de l'établissement choisi
5	`/mortalite?annee=2019`	Décès par région en 2019

Tableau 15 – Parcours direction enregistré sous forme d'adresses (équivalent des signets).

3.5 Parcours d'analyse pour la direction : la satisfaction des patients

Étape	Constat	Écran
Contexte	En 2020, la satisfaction moyenne des établissements évalués est de 74,0 sur 100, sur 837 établissements.	Établissements, carte
Tension	La Bretagne est à 76,0 ; l'Île-de-France n'est que 12e, à 71,9, alors qu'elle réunit 135 établissements et près de 74 000 répondants.	Carte, sélection de la région
Résolution	Les établissements franciliens les moins bien notés sont identifiés nommément, avec leur fiche.	Classement « À accompagner », fiche
Ouverture	La tendance est positive : +0,3 point pour l'Île-de-France depuis 2019, et aucune région ne baisse de plus de 2 points.	Évolution 2019 → 2020

Tableau 16 – Parcours direction en quatre temps.

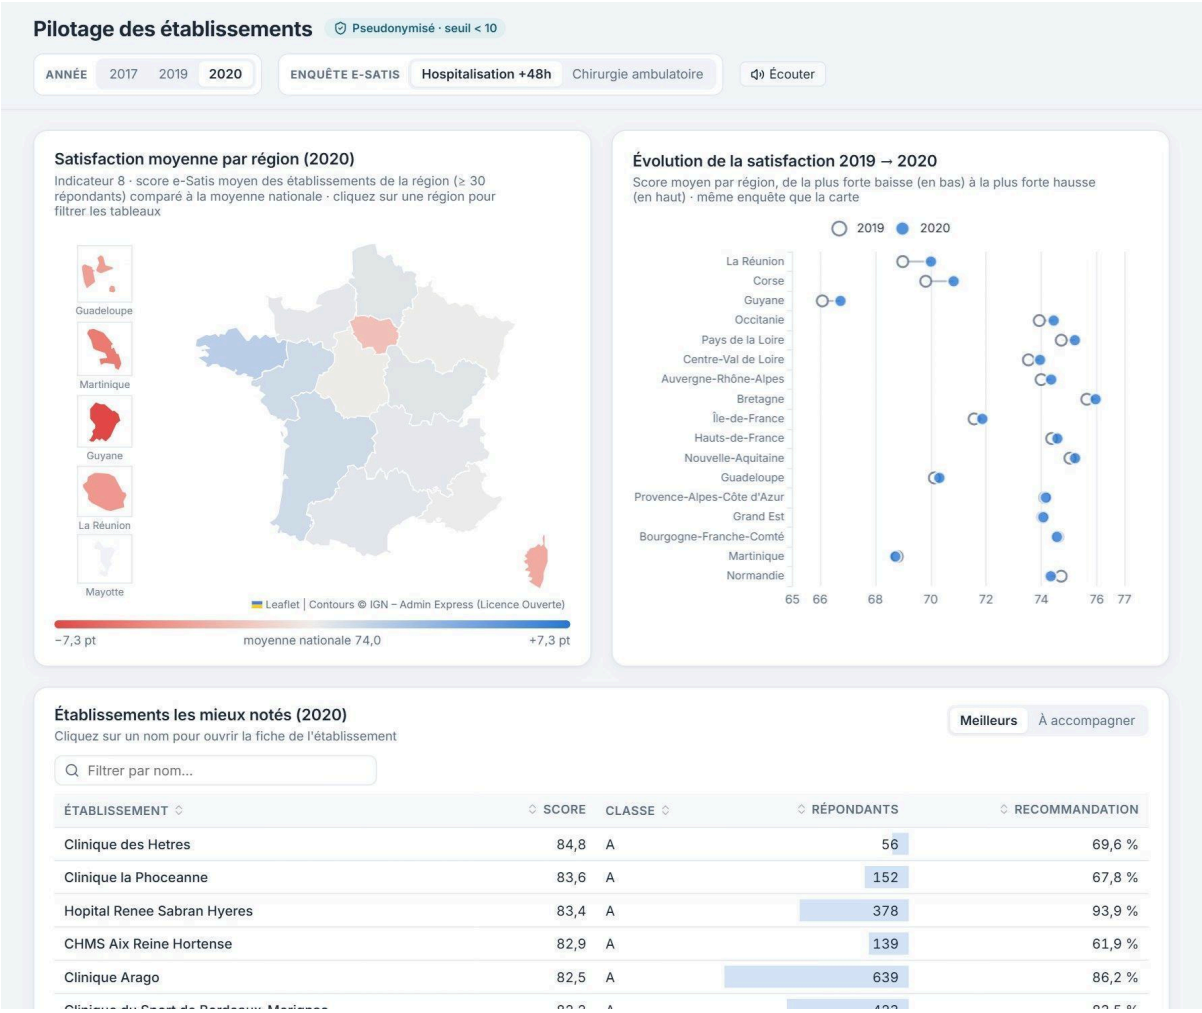


Figure 7 – Satisfaction moyenne par région en 2020 (écart à la moyenne nationale) et évolution depuis 2019.

La carte est en **échelle divergente** : bleu au-dessus de la moyenne nationale, rouge en dessous. Elle fait apparaître deux groupes à accompagner : l'Île-de-France, qui pèse lourd par son nombre d'établissements, et les régions d'outre-mer (Guyane 66,7, Martinique 68,7), où

peu d'établissements sont évalués. Le graphique d'évolution montre que la seule baisse notable concerne la Normandie (-0,4 point), sous le seuil d'alerte de 2 points.

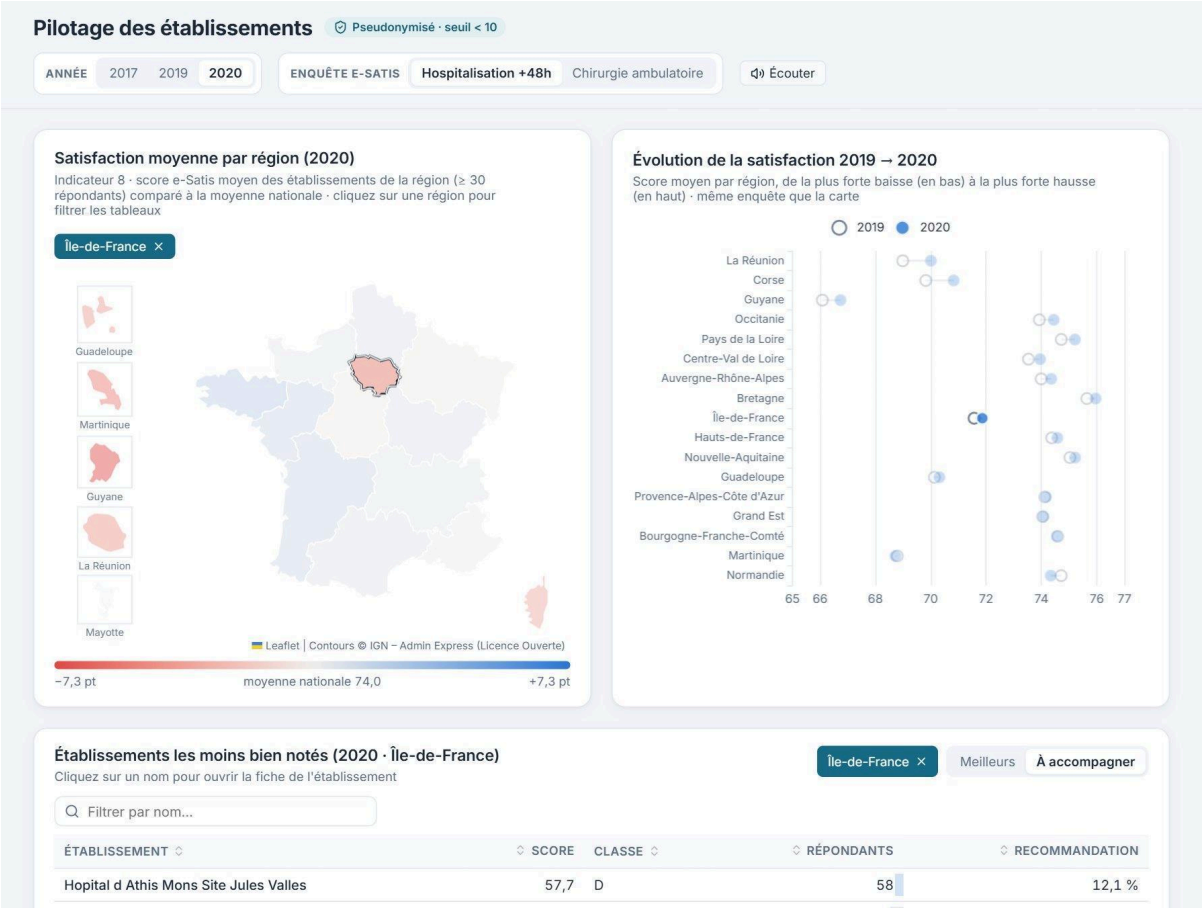


Figure 8 – Après sélection de l'Île-de-France : région mise en avant et établissements à accompagner.

La sélection de la région filtre le classement. En tête des établissements à accompagner apparaît un site noté 57,7 / 100 (classe D), recommandé par seulement 12 % de ses répondants. La fiche de l'établissement donne ensuite son activité, son historique de satisfaction et son rang dans la région : la direction passe d'un constat régional à un interlocuteur précis en trois clics.

La mortalité : un comptage à lire avec prudence

En 2019, le fichier INSEE recense **620 479 décès**, dont 619 733 localisés. L'Île-de-France (76 983) et Auvergne-Rhône-Alpes (70 400) arrivent en tête, et l'âge moyen au décès est de 78,8 ans. Il s'agit d'**un comptage, pas d'un taux** : les régions les plus peuplées ont mécaniquement le plus de décès. Pour les comparer, il faudrait rapporter ces chiffres à la population (recommandation du § 4.1). La Guyane l'illustre : peu de décès (1 012), mais un âge moyen au décès de 57,8 ans, reflet d'une population beaucoup plus jeune.

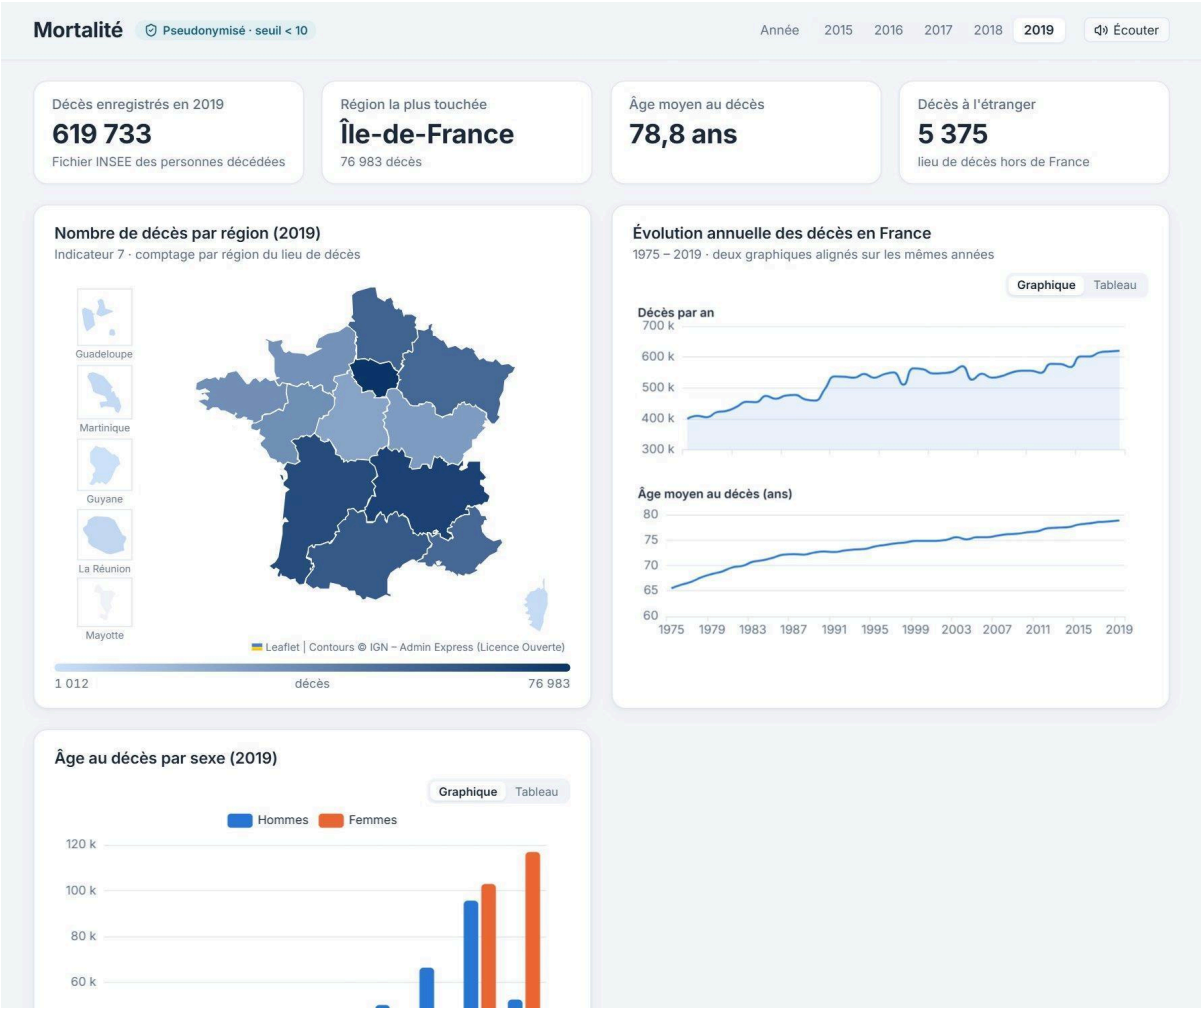


Figure 9 – Mortalité 2019 : décès par région, poids des régions dans les décès et les séjours du groupe, évolution depuis 1975.

Pistes d'action pour la direction
Engager un plan d'accompagnement des établissements en classe D (118 en 2020), en commençant par l'Île-de-France.
Suivre l'évolution annuelle région par région ; l'alerte se déclenche automatiquement au-delà de 2 points de baisse.
Obtenir les populations régionales pour transformer le comptage des décès en taux comparables.

3.6 Parcours d'analyse pour les praticiens : l'activité de soins

Étape	Constat	Écran
Contexte	Sur la période, plus d'un million de consultations pour 100 000 patients.	Consultations
Tension	Deux familles de diagnostics dominent : ostéo-articulaire (16,8 %) et lésions traumatiques (15,2 %).	Barres par chapitre
Résolution	Ces deux familles sont aussi en tête des séjours (15,4 % et 13,8 %), avec environ 15 jours de séjour moyen.	Hospitalisations

Étape	Constat	Écran
Ouverture	Chaque praticien retrouve ces chiffres pour son propre hôpital, comparé à sa région et au groupe.	Mon hôpital

Tableau 17 – Parcours praticien en quatre temps.

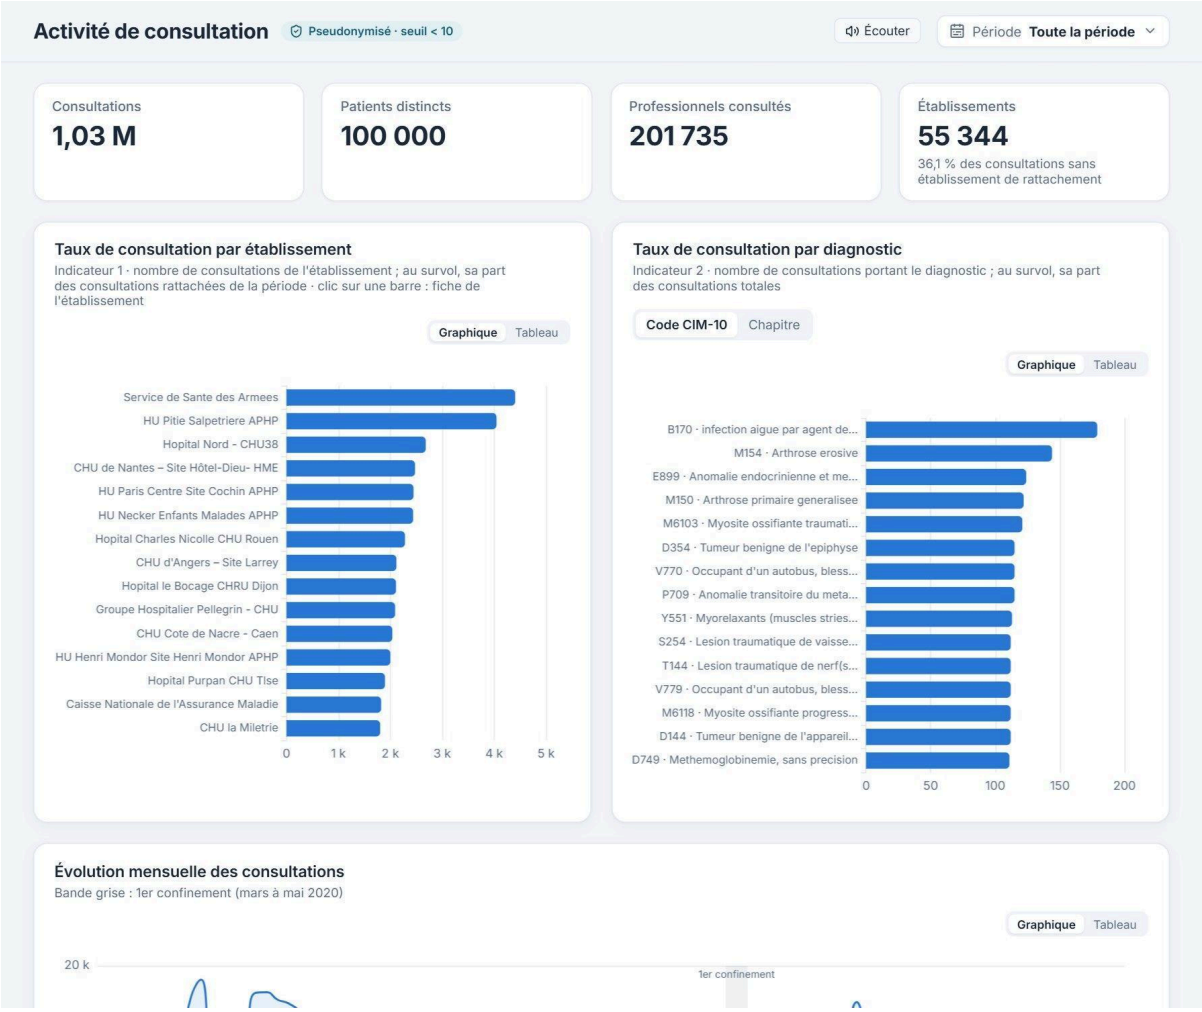


Figure 10 – Activité de consultation : chiffres clés, taux par établissement (indicateur 1) et par diagnostic (indicateur 2).

Sur toute la période, **2 465 patients ont été hospitalisés sur 100 000 suivis**, soit un taux global de 2,47 % (indicateur 3), pour 2 479 séjours d'une durée moyenne de 15,4 jours. La pyramide (indicateur 5) montre plus de femmes que d'hommes dans chaque tranche d'âge, et le tableau des diagnostics (indicateur 4) donne, pour chaque chapitre, sa part des séjours et sa durée moyenne.

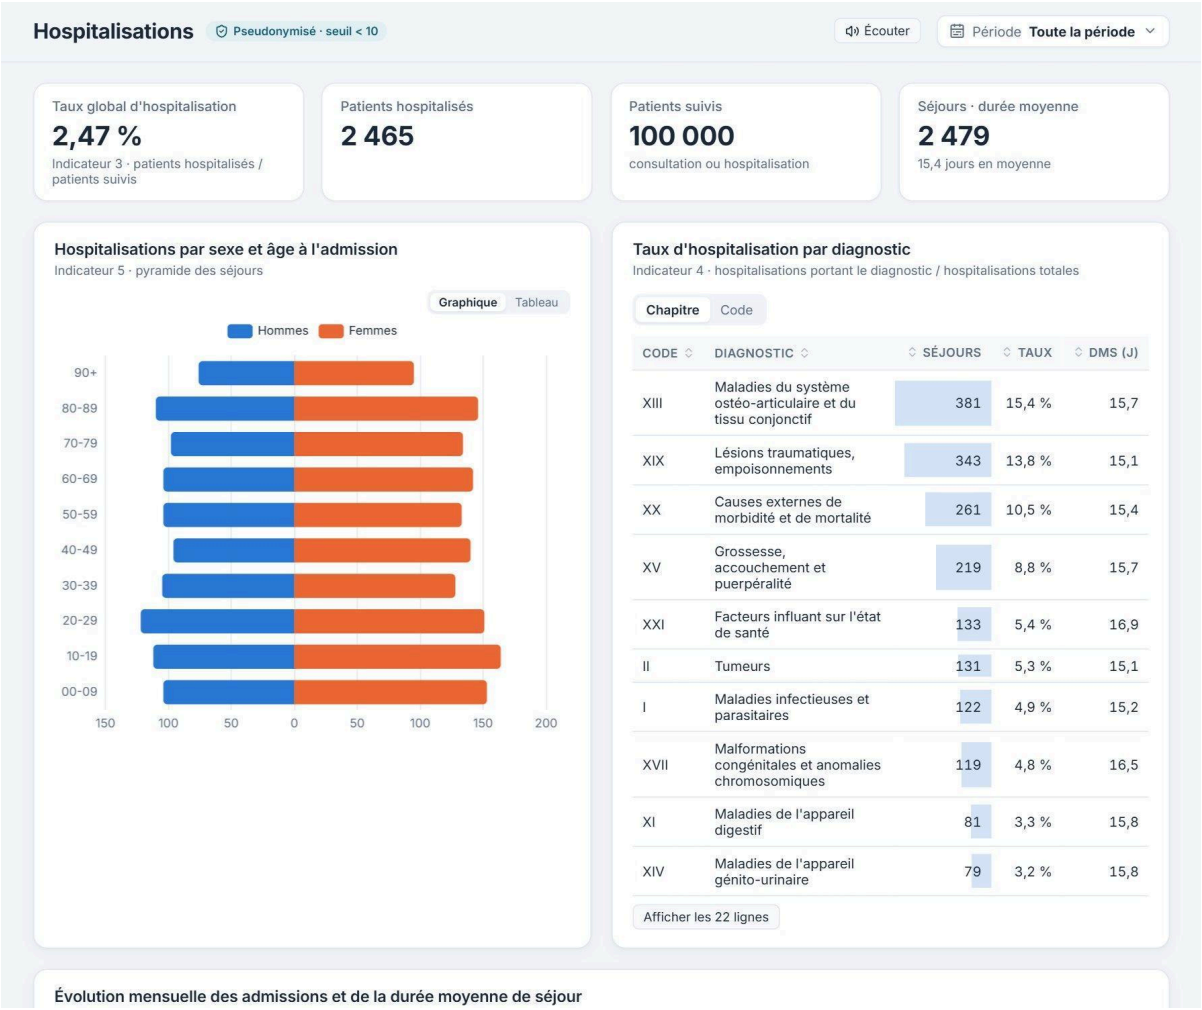


Figure 11 – Hospitalisations : taux global (indicateur 3), pyramide par sexe et âge (indicateur 5), séjours par diagnostic (indicateur 4).

Un praticien rattaché à un établissement arrive directement sur **Mon hôpital**. Pour la Pitié-Salpêtrière, par exemple : 4 047 consultations visibles, 2 899 professionnels rattachés, 1er sur 881 centres hospitaliers en volume de consultations en 2022, et 3,0 % de l'activité francilienne. Les années de moins de 10 consultations sont masquées, et le menu se limite aux écrans du profil praticien.

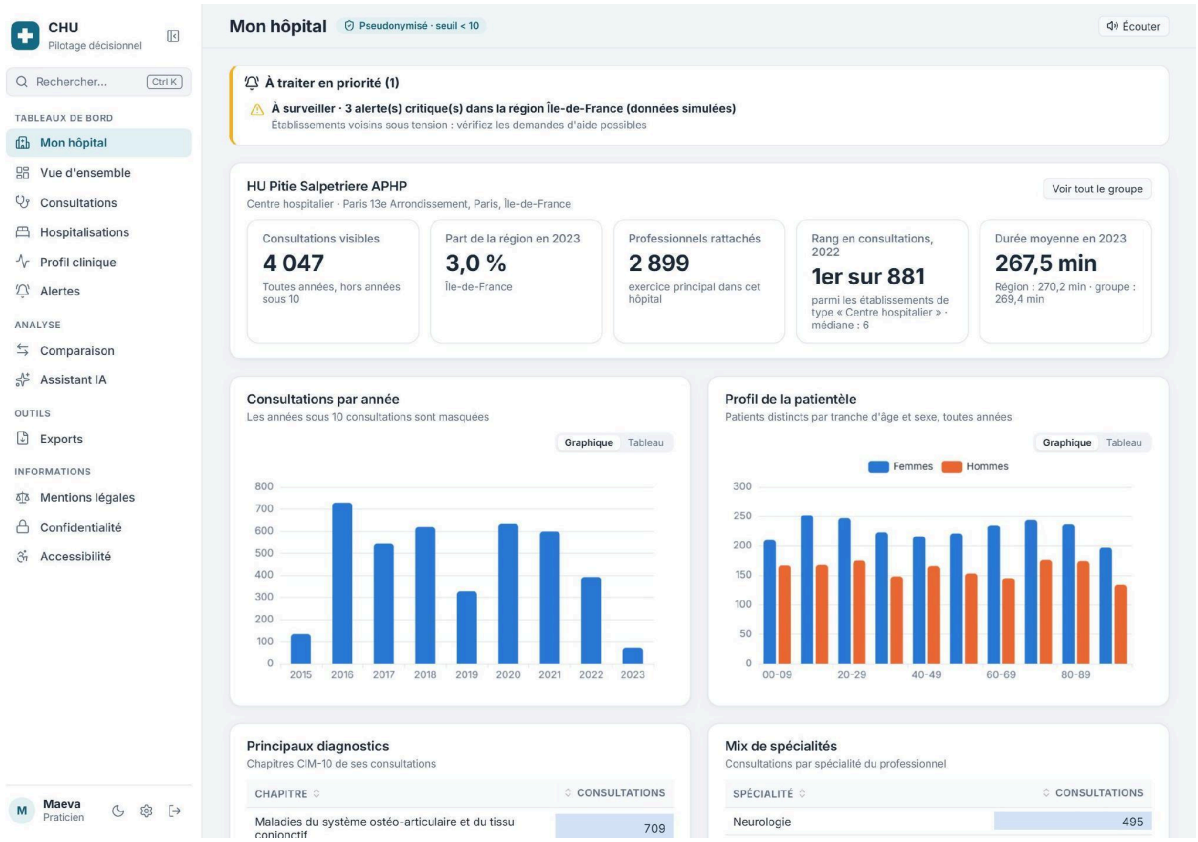


Figure 12 – Mon hôpital, vu par un praticien rattaché : priorités, chiffres clés, activité par année, profil de la patientèle.

Un contrôle de vraisemblance plutôt qu'une fausse découverte

L'écran **Profil clinique** croise l'âge et le diagnostic. Sur ces données, tous les indices de sur-représentation sont compris entre 0,96 et 1,04 : les consultations de grossesse sont aussi fréquentes chez les 10-19 ans que chez les 40-49 ans, et 41 % d'entre elles concernent des hommes. La vérification jusqu'aux tables sources montre que ce n'est pas une erreur de traitement : le jeu de données fourni a été **généré colonne par colonne**, sans lien entre âge, sexe et diagnostic.

L'écran le signale lui-même, par un bandeau et une phrase de lecture (« aucun écart marqué »). C'est une qualité attendue d'un outil de décision : il indique qu'il n'y a rien à conclure, au lieu de laisser croire à une tendance. Sur des données réelles, le même écran ferait ressortir les profils de patients par pathologie.

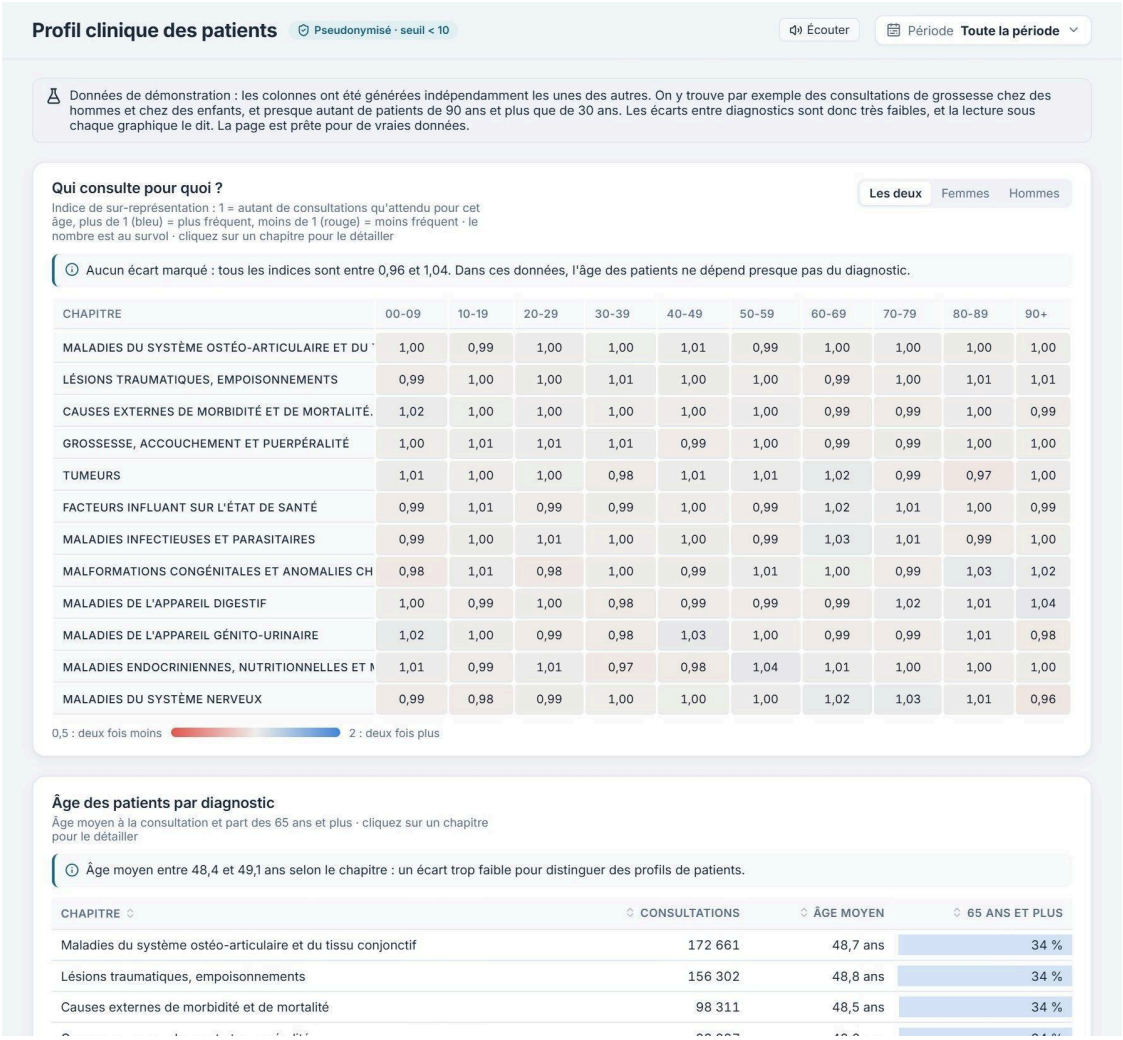


Figure 13 – Profil clinique : carte de chaleur âge × diagnostic et phrase de lecture qui signale l'absence d'écart.

3.7 Des alertes à l'action

La **Vue d'ensemble** calcule des points d'attention à chaque chargement, selon des seuils explicites (consultations ± 20 %, durée de séjour ± 10 %, satisfaction -2 points, décès +5 %). Au-delà du double du seuil, l'alerte devient critique. Un clic ouvre l'écran qui montre le problème, déjà réglé sur la bonne période ou la bonne région.

L'écran **Alertes et solutions** va plus loin : pour chaque alerte, il propose des actions (reporter les admissions non urgentes, accélérer les sorties, rappeler du personnel) et, en cas de saturation, liste les établissements voisins qui ont de la place, avec un message d'aide prêt à envoyer. La direction valide la demande, qui est suivie dans l'écran **Entraide**. Les lits, les patients présents et les effectifs de ces deux écrans sont **simulés**, car les sources n'en contiennent pas ; le mécanisme, lui, est réel et prêt à recevoir des données de production.

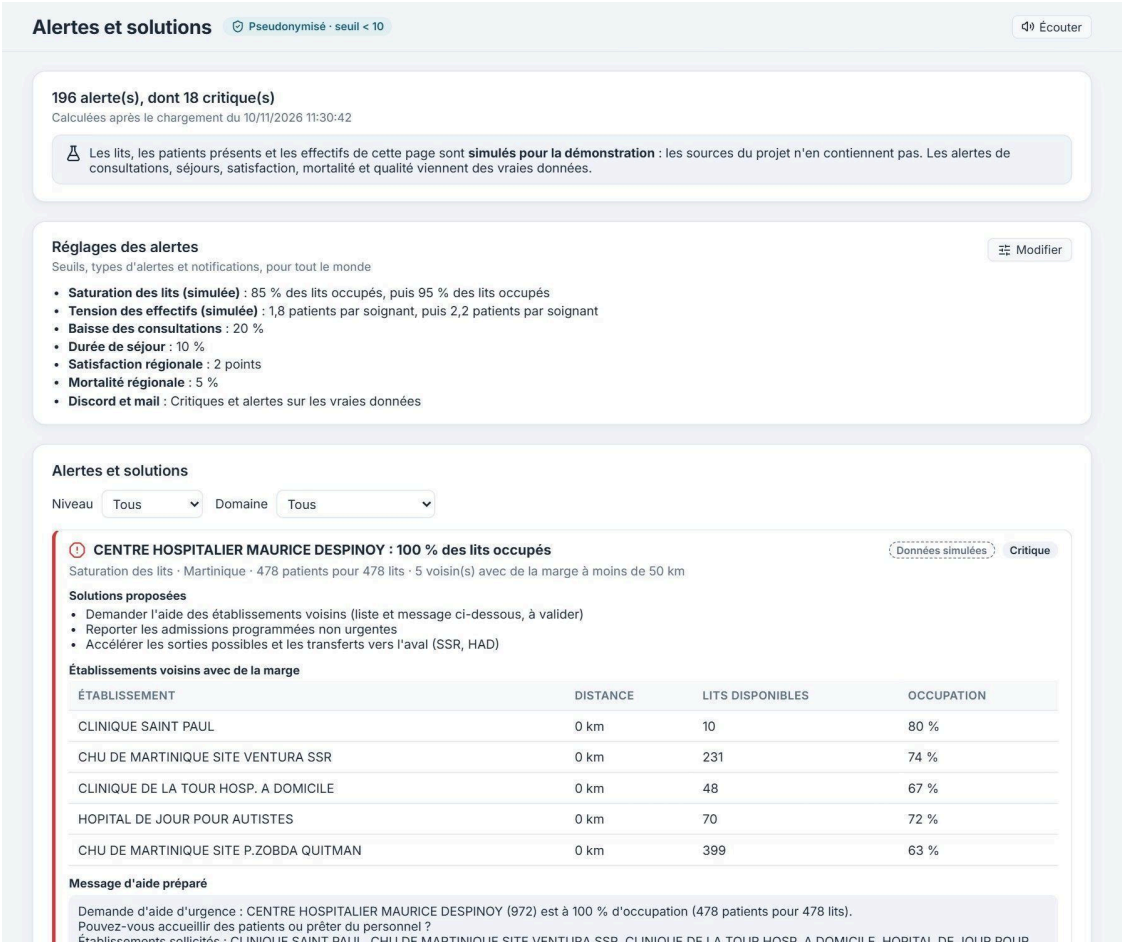


Figure 14 – Alertes et solutions : réglages des seuils, actions proposées, voisins disponibles et message d'aide préparé.

3.8 Les insights actionnables

Constat	Preuve dans le tableau de bord	Action proposée	Pour qui
L'Île-de-France est 12e en satisfaction malgré son poids	Carte et classement, 71,9 / 100, 135 établissements	Plan d'accompagnement des établissements en classe D	Direction
L'outre-mer est le plus en retrait	Guyane 66,7, Martinique 68,7 ; peu d'établissements évalués	Étendre l'évaluation e-Satis, accompagnement ciblé	Direction
36 % des consultations n'ont pas d'établissement	Consultations : part « sans établissement de rattachement »	Compléter le rattachement des professionnels dans le référentiel	Direction, DSI
Deux familles de diagnostics concentrent un tiers de l'activité	Consultations et Hospitalisations, par chapitre	Dimensionner les filières ostéo-articulaire et traumatologie	Praticiens, direction
Le comptage des décès reflète la population	Mortalité : carte et âge moyen par région	Ajouter les populations INSEE pour des taux	Direction, data
Les données sources ont des défauts	Profil clinique, contrôles qualité (2,35 % de consultations avant la naissance)	Corriger la source S1 ; obtenir l'annuaire complet	DSI

Tableau 18 – Insights actionnables issus du tableau de bord.

3.9 Les limites de lecture

Certaines conclusions ne sont pas permises par les données. Elles sont listées ici pour éviter les contresens.

Lecture erronée	Raison	Lecture correcte
Le Covid a fait exploser les consultations	Hausse de 2020 issue du jeu de données fourni	L'outil permet de comparer deux périodes ; la hausse n'est pas interprétable
La mortalité a chuté en 2020	Le fichier INSEE s'arrête en mars 2020	L'année 2020 est incomplète
L'Île-de-France a la plus forte mortalité	C'est un comptage	Le plus grand nombre de décès, dans la région la plus peuplée
Les grossesses concernent tous les âges	Colonnes générées indépendamment	Aucun écart n'est interprétable sur ces données
Toutes les requêtes durent moins de 0,7 s	Mesure d'un poste local dédié	Toutes passent sous 2 s sur le serveur mutualisé

Tableau 19 – Limites de lecture des résultats.

4. Améliorations futures

La plateforme répond aux huit indicateurs du sujet. Les recommandations ci-dessous portent sur ce qui en ferait un outil de pilotage de production : de meilleures données, des analyses qui anticipent, et une conformité entretenue dans la durée.

4.1 Nouvelles sources de données

Source	Apport	Nouvel indicateur ou usage
Populations INSEE par région et par âge	Dénominateurs démographiques	Taux de mortalité standardisés, comparables entre régions
Lits et effectifs réels (systèmes de gestion des lits, planning RH)	Remplace les données simulées	Taux d'occupation, tension des effectifs, alertes réelles
PMSI (résumés de séjour)	Actes, diagnostics associés, modes de sortie	Parcours de soins, réhospitalisations
Heures réelles des consultations	La source n'a que des créneaux	Durée de consultation fiable, charge horaire
Annuaire complet des professionnels	Fichier tronqué à 1 048 575 lignes	Rattachement des 36 % de consultations orphelines
Enquêtes e-Satis de toutes les années	Seules 2017, 2019 et 2020 sont disponibles	Tendances de satisfaction continues

Tableau 20 – Nouvelles sources recommandées.

L'architecture absorbe ces sources sans refonte : un DAG et deux jobs (Bronze, Silver) par source, une dimension ou un fait de plus en Gold, et un écran ou une alerte dans l'application.

4.2 Intégration de modèles prédictifs

Le tableau de bord décrit le passé ; la direction a aussi besoin d'anticiper. Une fois des données réelles disponibles, trois cas d'usage sont prioritaires, complétés par un usage interne à la plateforme.

Cas d'usage	Données	Méthode envisagée	Restitution
Prévoir la tension hospitalière à 7 jours	Admissions, sorties, lits, calendrier, épidémies saisonnières	Séries temporelles (modèles saisonniers, gradient boosting)	Alerte anticipée dans Alertes et solutions, avec demande d'entraide préparée
Anticiper le volume de consultations	Historique par spécialité et par établissement	Séries temporelles par filière	Courbe prévisionnelle dans Consultations
Repérer les établissements à risque en satisfaction	Scores, répondants, activité, durée de séjour	Classification ou régression interprétable	Liste priorisée dans Établissements
Détecter des anomalies dans les données	Volumes et distributions à chaque chargement	Détection statistique d'écarts	Avertissement dans le rapport qualité

Tableau 21 – Modèles prédictifs envisagés.

Ces modèles s'entraîneraient dans Spark (MLlib) sur la couche Gold, seraient suivis avec un outil comme MLflow (versions, métriques, données d'entraînement) et écriraient leurs scores dans une table Gold dédiée, servie par l'API avec les mêmes droits et le même seuil de diffusion. Trois conditions : des données réelles, une validation par les praticiens, et des

modèles explicables ; leur usage dans la décision médicale devra aussi être évalué au regard du règlement européen sur l'intelligence artificielle.

4.3 Mise en conformité continue

La protection est intégrée à chaque couche (pseudonymisation, minimisation, seuil de diffusion, rôles, journal d'accès). Pour un passage en production, la conformité doit devenir un processus suivi, et non un état atteint une fois.

Action	Fréquence	Responsable
Analyse d'impact (AIPD) et fiche du registre des traitements	Avant la mise en production, puis à chaque nouvelle source	CHU, avec le DPO
Hébergement chez un prestataire certifié HDS, chiffrement au repos, authentification multifacteur	Au passage en production	DSI
Revue des comptes et des droits par profil	Trimestrielle	Administrateur sécurité
Analyse du journal d'accès (écrans consultés, refus 403)	Mensuelle	Administrateur sécurité, DPO
Purge automatique selon les durées de conservation (landing 365 jours, Bronze : 3 derniers lots)	À chaque chargement	Plateforme (Airflow)
Test du seuil de diffusion et du secret secondaire sur chaque nouvel écran	À chaque évolution	Équipe data
Sauvegarde sur un second site et test de restauration	Mensuelle	DSI
Assistant IA : modèle à poids ouverts hébergé chez l'hébergeur HDS	Au passage en production	Équipe data
Lignage des données (OpenLineage, Marquez)	En continu	Équipe data

Tableau 22 – Plan de conformité continue.

5. Conclusion

Le projet relie quatre sources hétérogènes à des décisions concrètes. Le lakehouse garantit des données fiables, rejouables et protégées ; le modèle de Kimball rend chaque indicateur calculable par une simple agrégation ; l'optimisation ramène toutes les requêtes sous 2 secondes ; et le tableau de bord met ces résultats à la portée de chaque profil, sans jamais exposer un patient.

L'analyse en tire deux messages. Pour la direction : la satisfaction est bonne en moyenne, mais l'Île-de-France et l'outre-mer sont en retrait, et les établissements à accompagner sont identifiés nommément. Pour les praticiens : l'activité se concentre sur deux familles de diagnostics, et chacun peut suivre son hôpital face à sa région. Enfin, la plateforme montre les limites de ses données au lieu de les masquer. C'est la condition pour que des données réelles, demain, y soient lues avec confiance.

6. Glossaire

Terme	Définition
Lakehouse	Architecture qui stocke les données en fichiers bon marché tout en offrant les garanties d'un entrepôt (transactions, schéma, historique)
Bronze, Silver, Gold	Couches successives du lakehouse : copie brute, données nettoyées et pseudonymisées, modèle décisionnel
Delta Lake	Format de table au-dessus de Parquet qui ajoute un journal de transactions (ACID, MERGE, retour à une version antérieure)
Trino	Moteur de requêtes SQL distribué, utilisé par l'application pour interroger Gold avec des temps de réponse courts
Constellation	Modèle décisionnel où plusieurs tables de faits partagent des dimensions conformes
Grain	Ce que représente une ligne d'une table de faits (une consultation, un séjour…)
Clé de substitution	Identifiant technique d'une dimension, indépendant de la clé de la source
Partitionnement	Répartition des fichiers d'une table par valeur d'une colonne (année, région), pour ne lire que les partitions utiles
Z-ORDER	Réorganisation des données qui regroupe les valeurs voisines, pour sauter des fichiers grâce aux statistiques min / max
Pseudonymisation	Remplacement d'un identifiant par un code (ici SHA-256 salé) ; la donnée reste personnelle au sens du RGPD
Seuil de diffusion	Règle qui masque les effectifs de moins de 10 personnes pour empêcher la ré-identification
Choroplèthe	Carte où chaque zone est colorée selon une valeur
e-Satis	Dispositif national de mesure de la satisfaction des patients hospitalisés (Haute Autorité de santé)
CIM-10	Classification internationale des maladies, 10e révision, organisée en chapitres
DMS	Durée moyenne de séjour
FINESS	Fichier national des établissements sanitaires et sociaux, qui identifie chaque établissement
HDS	Hébergement de données de santé : certification obligatoire en France pour héberger ces données
AIPD	Analyse d'impact relative à la protection des données, exigée par le RGPD pour les traitements à risque

Tableau 23 – Glossaire.

7. Table des figures et des tableaux

Tableau 1 – Historique des versions du document..... 3
Tableau 2 – Liste de diffusion.....3
Tableau 3 – Équivalences entre la grille et la réalisation..... 3
Tableau 4 – Pourquoi un lakehouse.....6
Tableau 5 – Les couches du lakehouse..... 7
Tableau 6 – Choix des outils ETL.....8
Tableau 7 – Choix des outils de restitution.....8
Tableau 8 – Correspondance avec les notions de Power BI.....8
Figure 2 – Architecture d'ensemble de la plateforme (livrable 1, figure 1).....9
Figure 3 – Modèle en constellation de la couche Gold (livrable 1)..... 10
Tableau 9 – Tables de faits de la couche Gold.....10
Tableau 10 – Principales règles de transformation.....11
Tableau 11 – Techniques d'optimisation et effet mesuré..... 11
Figure 4 – Volume de données lues par Trino avant et après optimisation (livrable 2, figure 2)..... 12
Tableau 12 – Les écrans du tableau de bord et leurs profils (* praticien rattaché à un établissement).....13
Figure 5 – Vue d'ensemble : indicateurs clés, points d'attention classés par gravité, tendances annuelles (profil direction).....14
Figure 6 – Vue d'ensemble sur téléphone (profil direction).....15
Tableau 13 – Mesures de protection appliquées à la restitution..... 15
Tableau 14 – Choix des visuels par indicateur..... 16
Tableau 15 – Parcours direction enregistré sous forme d'adresses (équivalent des signets).....16
Tableau 16 – Parcours direction en quatre temps.....17
Figure 7 – Satisfaction moyenne par région en 2020 (écart à la moyenne nationale) et évolution depuis 2019..... 17
Figure 8 – Après sélection de l'Île-de-France : région mise en avant et établissements à accompagner.....18
Figure 9 – Mortalité 2019 : décès par région, poids des régions dans les décès et les séjours du groupe, évolution depuis 1975..... 19
Tableau 17 – Parcours praticien en quatre temps.....20
Figure 10 – Activité de consultation : chiffres clés, taux par établissement (indicateur 1) et par diagnostic (indicateur 2).....20
Figure 11 – Hospitalisations : taux global (indicateur 3), pyramide par sexe et âge (indicateur 5), séjours par diagnostic (indicateur 4)..... 21
Figure 12 – Mon hôpital, vu par un praticien rattaché : priorités, chiffres clés, activité par année, profil de la patientèle.....22
Figure 13 – Profil clinique : carte de chaleur âge × diagnostic et phrase de lecture qui signale l'absence d'écart..... 23
Figure 14 – Alertes et solutions : réglages des seuils, actions proposées, voisins disponibles et message d'aide préparé.....24

Tableau 18 – Insights actionnables issus du tableau de bord.....24
Tableau 19 – Limites de lecture des résultats.....25
Tableau 20 – Nouvelles sources recommandées.....26
Tableau 21 – Modèles prédictifs envisagés.....26
Tableau 22 – Plan de conformité continue.....27
Tableau 23 – Glossaire.....29
Tableau 24 – Correspondance avec la grille du livrable 3.....32
Tableau 25 – Chiffres clés.....32
Tableau 26 – Liens utiles.....33

Annexes

Annexe A – Correspondance avec la grille d'évaluation

Critère (coef.)	Attendu (niveau A)	Réalisation	Où le vérifier
Connexion à Cloudera (1)	Connexions faites, répertoires du datalake visibles dans l'outil de BI	Application connectée à Gold par Trino et le Hive Metastore ; répertoires `bronze`, `silver`, `gold` visibles dans MinIO	§ 1.5
Schéma cible (1)	Modèle en étoile repris dans le moteur de modélisation ; analyses fondées sur ce schéma	Constellation Gold utilisée telle quelle par les requêtes de l'API et les vues d'analyse	§ 2.1 ; livrable 2 § 6
DataViz (2)	Graphiques pertinents (cartes, etc.), cohérents avec les demandes, tableau de bord généré, visible sur mobile	14 écrans, visuel choisi par question, deux cartes régionales, affichage mobile, exports PDF et Excel	§ 3.1, § 3.3 ; figures 5 et 6
Storytelling (2)	Signets ; histoire cohérente avec le contexte et les résultats	Parcours direction et praticien en quatre temps ; adresses d'écran utilisées comme signets	§ 3.4 à § 3.6

Tableau 24 – Correspondance avec la grille du livrable 3.

Annexe B – Chiffres clés

Indicateur	Résultat	Période
Consultations	1 027 157 pour 100 000 patients ; 36,1 % sans établissement de rattachement	2015 – 2023
1. Consultation par établissement	Service de santé des armées (371), HU Pitié-Salpêtrière (327) en tête	2019
2. Consultation par diagnostic	Ostéo-articulaire 16,8 %, lésions traumatiques 15,2 %	2015 – 2023
3. Taux global d'hospitalisation	2,47 % (2 465 patients hospitalisés sur 100 000 suivis)	2015 – 2021
4. Hospitalisation par diagnostic	Ostéo-articulaire 15,4 % des séjours, 15,7 jours en moyenne	2015 – 2021
5. Hospitalisation par sexe et âge	Tranches 10-19 et 20-29 en tête ; plus de femmes dans chaque tranche	2015 – 2021
6. Consultation par professionnel	Médecine générale : environ 50 % des consultations	2019
7. Décès par région	620 479 décès ; Île-de-France 76 983, Auvergne-Rhône-Alpes 70 400 ; âge moyen 78,8 ans	2019
8. Satisfaction par région	Moyenne 74,0 / 100 (837 établissements) ; Bretagne 76,0 ; Île-de-France 71,9 (12e)	2020
Performance	Requête la plus lente 1,8 s ; jusqu'à 41 fois moins de données lues ; Q7 Spark × 6	Serveur, 30/10/2026
Qualité	44 contrôles, dont 30 bloquants ; 17 clés étrangères, 0 orphelin	Chargement nocturne

Tableau 25 – Chiffres clés.

Annexe C – Liens

Service	Adresse
Tableau de bord	https://chu.allanbouhamed.fr
Orchestration (Airflow)	https://airflow.allanbouhamed.fr

Service	Adresse
Requêtes (Trino)	https://trino.allanbouhamed.fr/ui/
Dépôt Git	https://github.com/wSimbaa/chu-lakehouse (branche `main`)
Description des écrans	`docs/comprendre/20_les_ecrans_du_dashboard.md` dans le dépôt

Tableau 26 – Liens utiles.