PROSIT 1

Groupe :

CARVAL Mathéo - Secrétaire

LUU Philippe - Gestionnaire du temps

BOUHAMED Allan - Animateur

CHALIES Maeva - Scribe

Sommaire :

Sommaire :.....2
1. Contexte.....3
2. Mots inconnus / Notions à maîtriser.....3
3. Problématique.....3
4. Plan d'action (Estimé à 12h pour la phase d'étude).....4
5. Réalisation.....5

1. Contexte

À trois semaines de l'échéance, un collaborateur se retrouve subitement responsable de la réussite du projet CHU (Cloud Healthcare Unit), un projet d'analyse de données hospitalières. Une maquette complète est attendue pour démontrer l'exploitation de ces données. Le travail préparatoire a été réalisé par un ancien stagiaire, Archie, qui a mis en place un environnement virtualisé et schématisé une architecture Big Data complexe (intégrant HDFS, Hadoop, MapReduce, Hive et PowerBI). Face à la complexité de cette architecture, aux problèmes de performances pressentis et à la sensibilité des données personnelles traitées, l'équipe doit rapidement valider l'architecture, concevoir un modèle de données multidimensionnel adapté et assurer l'intégration des données tout en respectant les contraintes de confidentialité.

2. Mots inconnus / Notions à maîtriser

- **Les 5V du Big Data** : Volume, Vélocité, Variété, Véracité, Valeur.
- **RGPD (Règlement Général sur la Protection des Données)** : Cadre légal imposant des contraintes strictes sur la manipulation et le stockage des données personnelles et de santé.
- **HDFS (Hadoop Distributed File System)** : Système de fichiers distribué, conçu pour stocker de très grands volumes de données sur des clusters de serveurs.
- **MapReduce** : Modèle de programmation permettant le traitement de données de manière distribuée sur un cluster.
- **ETL (Extract, Transform, Load)** : Processus d'extraction, de transformation et de chargement des données vers un entrepôt.
- **Datawarehouse / Data Mart** : Entrepôt de données global et son sous-ensemble spécialisé (Data Mart) destiné à un métier spécifique.
- **Base de données multidimensionnelle / Cube** : Modélisation des données optimisée pour l'analyse et le requêtage décisionnel (contrairement aux bases relationnelles classiques).
- **NAS vs SAN** : Architectures de stockage en réseau (Network Attached Storage vs Storage Area Network).
- **Hive / Cloudera / PowerBI** : Outils de l'écosystème Big Data (distribution logicielle, infrastructure d'entrepôt de données et outil de visualisation).

3. Problématique

La solution proposée par Archie suffit-elle à transformer des données hospitalières hétérogènes et dispersées en informations fiables et exploitables pour la prise de décision au sein du CHU, et comment la compléter le cas échéant ?

4. Plan d'action (Estimé à 12h pour la phase d'étude)

1. Analyse de l'architecture Big Data existante d'Archie et identification des flux de données (2.5h).
2. Étude des contraintes réglementaires (RGPD) appliquées aux données de santé et des concepts de stockage/traitement distribués (HDFS, MapReduce) (2.5h).
3. Conception du modèle multidimensionnel (Datawarehouse/Data Mart) adapté aux besoins d'analyse du CHU (3h).
4. Définition du pipeline d'intégration (ETL) et de la solution de visualisation (PowerBI) (2h).
5. Validation de la feuille de route technique pour le déploiement de la maquette (2h).

5. Réalisation

- **5.1 Analyse de l'architecture existante (2.5h)** : Une architecture Big Data se lit comme une chaîne en couches : des sources hétérogènes, une ingestion, un stockage distribué, un moteur de traitement parallèle, un entrepôt interrogeable en SQL et une couche de restitution. Le schéma d'Archie suit ce modèle avec la stack Cloudera. Notre projet garde exactement les mêmes couches mais avec des outils maintenus :

Couche	Rôle	Archie (Cloudera)	Notre projet CHU
Sources	Données brutes hétérogènes	PostgreSQL, CSV, fichiers FTP	PostgreSQL DATA2023 (13 tables), CSV établissements, e-Satis (FTP), décès INSEE
Ingestion / ETL	Extraire, transformer, charger	Talend	PySpark, orchestré par Airflow (1 DAG par source)
Stockage distribué	Conserver de gros volumes	HDFS	MinIO (stockage objet S3) + format Delta Lake
Traitement	Calcul parallèle	MapReduce	Spark (successeur de MapReduce, calcul en mémoire)
Entrepôt / SQL	Requêtes analytiques	Hive	Hive Metastore (catalogue) + Trino
Restitution	Tableaux de bord	Power BI	Application web + API FastAPI (Power BI branchable sur Trino)

Limites de la solution d'Archie. Le découpage en couches est pertinent, mais la solution ne suffit pas en l'état :

- Obsolescence : la VM Cloudera date de 2017 et Talend Open Studio a été abandonné en 2024. Ces outils ne reçoivent plus de correctifs de sécurité.
- Performances : MapReduce écrit sur disque entre chaque étape. Hive met donc plusieurs minutes à répondre, ce qui est trop lent pour des tableaux de bord interactifs.
- RGPD : le schéma ne prévoit ni pseudonymisation ni gestion des accès.
- Qualité : aucun contrôle n'est prévu sur les encodages, les lignes tronquées ou les dates incohérentes.

Nous conservons donc l'architecture en couches, mais avec des outils maintenus (Spark, Delta Lake, Trino), complétés par une pseudonymisation et des contrôles qualité.

Les données trouvées dans « Mes documents » ne sont qu'une copie brute des sources : sans modèle dimensionnel, chaque analyse obligerait à relire et joindre plusieurs millions de lignes. C'est un « data swamp », d'où la nécessité de modéliser en parallèle. Les **5V** justifient le choix Big Data :

V	Définition	Dans le projet CHU
Volume	Quantité de données	≈ 32 M de lignes : 25 M décès (1,9 Go), 1 M consultations, 1 M professionnels
Vélocité	Rythme d'arrivée	PostgreSQL quotidien, décès mensuel, dépôt FTP e-Satis surveillé toutes les 30 min
Variété	Diversité des formats	SQL, CSV `;`, XLSX ; encodages UTF-8, ISO-8859-1, Windows-1252
Véracité	Fiabilité	Annuaire tronqué à 1 048 575 lignes (limite Excel), dates de décès partielles, consultations datées avant la naissance
Valeur	Ce que ça rapporte	8 indicateurs pour praticiens et direction (consultations, hospitalisations, décès, satisfaction)

- **5.2 Étude des contraintes réglementaires et du stockage distribué (2.5h)** : Les données de santé sont une **catégorie particulière** au sens de l'article 9 du RGPD : leur traitement est interdit sauf exception (soins, recherche, intérêt public) et doit respecter les principes de finalité, minimisation, limitation de conservation et sécurité. En France, leur hébergement impose en plus un hébergeur certifié **HDS**. Attention : une donnée pseudonymisée reste une donnée personnelle, seule l'anonymisation irréversible sort du RGPD.

Contrainte RGPD	Application dans le projet
Minimisation	Nom, prénom, adresse, e-mail, téléphone, n° de sécurité sociale, groupe sanguin ne dépassent pas la couche Bronze
Pseudonymisation	`Id_patient` remplacé par un SHA-256 salé (sel secret hors dépôt)
Généralisation	Date de naissance → année → tranche d'âge ; code postal → département
Seuil de diffusion	Tout effectif inférieur à 10 est masqué (« < 10 »)
Conservation	Zone landing purgée à 365 jours, historique Delta limité à 7 jours
Accès	Rôles Keycloak : praticien, direction, data engineer, administrateur sécurité
Hébergement	Démo hors HDS (cadre pédagogique) ; production chez un hébergeur HDS (OVHcloud, Scaleway…)

Stockage distribué. Un **cluster** regroupe plusieurs serveurs (nœuds) qui se partagent données et calculs : on ajoute des machines pour monter en charge (scalabilité horizontale). La **virtualisation** permet de simuler ce cluster sur une seule machine : Archie a utilisé une VM Cloudera, nous utilisons des conteneurs Docker, plus légers. Côté stockage réseau :

Critère	NAS	SAN
Accès	Niveau fichier (NFS, SMB) sur le réseau Ethernet	Niveau bloc (iSCSI, Fibre Channel) sur un réseau dédié
Vu par le serveur	Un dossier partagé	Un disque local
Performance	Moyenne	Élevée, faible latence
Coût	Faible	Élevé
Usage type	Partage de fichiers, sauvegardes	Bases de données, virtualisation

HDFS découpe chaque fichier en blocs de 128 Mo répliqués 3 fois sur des DataNodes différents ; le NameNode ne garde que les métadonnées (quel bloc est où). Exemple : `deces.csv` (1,9 Go) = 16 blocs × 3 copies = 48 blocs. Si un nœud tombe, les copies prennent le relais. Le principe est « écrire une fois, lire souvent », idéal pour l'analytique.

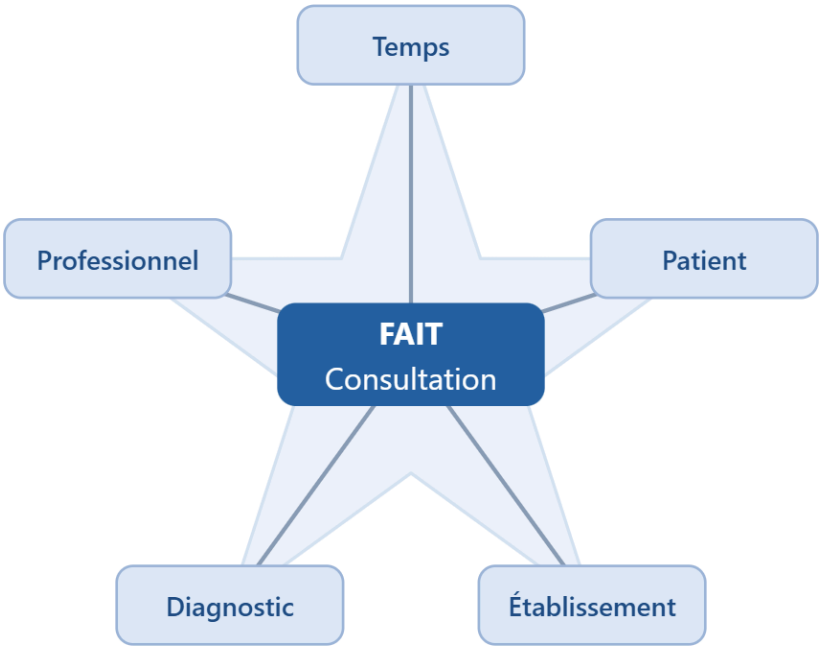
Cloud. Il fournit stockage et calcul à la demande (IaaS, PaaS, SaaS), élastiques et payés à l'usage. Le stockage objet de type S3 y remplace HDFS. Notre MinIO étant compatible S3, la plateforme peut passer chez un cloud HDS sans réécriture. Pour la démo, elle tourne sur un VPS.

- **5.3 Conception du modèle multidimensionnel (3h)** : Un entrepôt de données est intégré, orienté sujet, historisé et non volatil (Inmon) ; un Data Mart en est un sous-ensemble pour un métier. Contrairement à une base relationnelle (OLTP) normalisée pour les écritures, le modèle décisionnel (OLAP) est dénormalisé pour lire vite. Nous avons retenu une **constellation** (approche Kimball) : 4 tables de faits qui partagent 6 dimensions conformes.

Table de faits	Grain (1 ligne =)	Mesures	Dimensions
fait_consultation	une consultation	nb_consultation, durée, âge	temps, patient, diagnostic, professionnel, établissement
fait_hospitalisation	un séjour	nb_sejour, durée de séjour, âge à l'admission	temps (entrée, sortie), patient, diagnostic, établissement
fait_deces	un décès INSEE	nb_deces, âge au décès	temps, localisation
fait_satisfaction	établissement × enquête × année	score global, nb répondants, taux de recommandation	temps, établissement, localisation

  - **dim_temps** : jour, mois, trimestre, année (clé AAAAMMJJ).
  - **dim_localisation** : commune, département, région.
  - **dim_etablissement** : FINESS, raison sociale, type (CHU, CH, clinique…), région.
  - **dim_patient** : identifiant pseudonymisé, sexe, année de naissance, département.
  - **dim_diagnostic** : code et libellé CIM-10, chapitre.
  - **dim_professionnel** : profession, spécialité, établissement de rattachement.

Schéma en étoile privilégié (une seule jointure par dimension) ; seul l'établissement pointe vers la localisation (léger flocon). Chaque dimension a une clé de substitution et un membre « Non renseigné » (clé -1) pour ne perdre aucun fait. Ce modèle couvre les 8 indicateurs : taux de consultation par établissement, diagnostic et professionnel ; taux d'hospitalisation global, par diagnostic, par sexe et âge ; décès par région ; satisfaction par région.



- **5.4 Définition du pipeline d'intégration et visualisation (2h)** : Le traitement distribué repose sur **MapReduce** : la phase Map transforme chaque ligne en paires (clé, valeur) en parallèle sur tous les nœuds, la phase Shuffle regroupe les paires par clé, puis la phase Reduce agrège chaque groupe. Exemple pour compter les décès par région :

```
Map     : ligne de deces.csv     -> (code_region, 1)
Shuffle : regroupe par région    -> ("11", [1,1,1,...]), ("84", [1,1,...])
Reduce  : somme par clé          -> ("11", total IdF), ("84", total ARA)
```

Spark garde ce principe mais conserve les résultats intermédiaires en mémoire au lieu de les écrire sur disque entre chaque étape, d'où son choix. Le pipeline suit l'architecture **médaillon** : Landing (fichiers bruts) → Bronze (copie brute) → Silver (nettoyé, pseudonymisé) → Gold (modèle en étoile), orchestré par Airflow. Trino interroge Gold et alimente l'API puis les tableaux de bord.

Difficultés des traitements distribués identifiées :

  - **Shuffle** : l'échange de données entre nœuds sur le réseau est l'étape la plus coûteuse.
  - **Déséquilibre (data skew)** : 36 % des consultations tombent sur le membre « Non rattaché », une seule tâche porte alors une grosse part du travail.
  - **Petits fichiers** : des milliers de fichiers de quelques Ko ralentissent la lecture (d'où le compactage).
  - **Pannes et cohérence** : un nœud peut tomber en plein calcul ; il faut des jobs rejouables sans doublon.
  - **Mémoire** : Spark a planté avec 7,7 Go alloués à Docker, résolu en passant à 12 Go.

    - **Débogage** : une erreur peut venir de n'importe quel nœud, les journaux sont dispersés.
- **5.5 Validation de la feuille de route (2h)** : Le planning est tenu car l'architecture a été simplifiée : Talend Open Studio a été retiré en 2024 et la VM Cloudera QuickStart date de 2017, ils sont remplacés par Spark, Delta Lake et Trino qui couvrent les mêmes notions.

Phase	Durée	Livrable	Contenu
Architecture et modèle logique	2 j	L1	Sources, architecture médaillon, modèle en constellation, RGPD
Intégration des données	4 j	Pipelines Bronze / Silver	4 DAG Airflow, nettoyage, pseudonymisation, contrôles qualité
Implémentation physique	4 j	L2	Tables Gold partitionnées, optimisation, benchmark
Exploitation et visualisation	4 j	Application	Tableaux de bord par rôle, démonstration